面向高速端到端视觉避障的 ViT+Mamba 时序建模与流式部署一致性分析

戴英特

2026 年 6 月

中图分类号： TQ028.1

UDC分类号： 540

面向高速端到端视觉避障的 ViT+Mamba 时序建模与流式部署一致性分析

作 者 姓 名 戴英特

学 院 名 称 自动化学院

指 导 教 师 甘明刚教授

答辩委员会主席 _____

申 请 学 位 工学硕士

学 科 专 业 控制工程

学位授予单位 北京理工大学

论文答辩日期 2026 年 6 月

ViT+Mamba Temporal Modeling and Streaming Deployment Consistency Analysis for High-Speed End-to-End Visual Obstacle Avoidance

Candidate Name:	Dai Yingte
School or Department:	School of Automation
Faculty Mentor:	Prof. Gan Minggang
Chair, Thesis Committee:	
Degree Applied:	Master
Major:	Control Engineering
Degree by:	Beijing Institute of Technology
The Date of Defence:	June, 2026

面向高速端到端视觉避障的ViT+Mamba时序建模与流式部署一致性分析

戴英特

北京理工大学

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下进行的研究工作获得的研究成果。尽我所知，文中除特别标注和致谢的地方外，学位论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京理工大学或其它教育机构的学位或证书所使用过的材料。与我一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此申明。

作者签名：_____　　签字日期：_____

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：①学校有权保管、并向有关部门送交学位论文的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存学位论文；③学校可允许学位论文被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换学位论文；⑤学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

作者签名：_____　　导师签名：_____

签字日期：_____　　签字日期：_____

主要符号对照表

D_t	第 t 个控制周期的深度图像观测，$D_t \in \mathbb{R}^{H\times W}$
s_t	第 t 个控制周期的轻量状态向量，$s_t = [q_t, \tilde{v}^{\text{target}}]$
o_t	第 t 个控制周期的完整观测，$o_t = (D_t, s_t)$
q_t	无人机在世界坐标系下的姿态四元数，$q_t = [w, x, y, z]$
$\tilde{v}^{\text{target}}$	归一化目标前向速度，$\tilde{v}^{\text{target}} = v^{\text{target}}/10$
$\mathbf{v}_t$	第 t 个控制周期的速度指令，$\mathbf{v}_t = [v_t^x, v_t^y, v_t^z] \in \mathbb{R}^3$
$\mathbf{v}_{\text{raw}}$	策略网络原始输出速度指令
$\mathbf{v}_{\text{cmd}}$	经 RACS 约束后最终发布的速度指令
$\mathbf{v}_{\text{prev}}$	上一控制步发布的速度指令
π_θ	参数为 θ 的端到端策略网络
π^*	特权信息专家策略
$\mathbf{h}_t$	序列模型（Mamba/LSTM）在第 t 步的内部隐状态
$\mathbf{A}, \mathbf{B}, \mathbf{C}, \mathbf{D}$	连续时间状态空间模型的系统矩阵
$\bar{\mathbf{A}}, \bar{\mathbf{B}}$	零阶保持离散化后的状态空间参数矩阵
Δ	Mamba 选择性机制中的输入相关离散化步长
δ_t	RACS 动态速率上界
$d_{\min,t}$	第 t 步深度图像中的最小深度观测值
$\mathcal{L}_{\text{BC}}$	行为克隆监督损失（MSE）
$\mathcal{L}_{\text{jerk}}$	指令抖动惩罚损失
λ_{jerk}	Jerk Loss 权重系数
β	DAgger 中的专家混合比例
T	回合总帧数 / 序列长度
$\tau_{\max}$	最大回合时长（40 s）
d_{model}	Mamba 模块的模型维度（192）
d_{state}	Mamba 模块的状态维度（64）
BC	行为克隆（Behavioral Cloning）
DAgger	数据集聚合（Dataset Aggregation）
RACS	动态速率限制控制平滑器（Rate-Adaptive Control Smoother）

SSM	结构化状态空间模型（Structured State Space Model）
ViT	视觉 Transformer（Vision Transformer）
ID	同分布（In-Distribution）
OOD	分布外（Out-of-Distribution）

目 录

摘要 I
Abstract III
主要符号对照表 V
第 1 章 绪论 1
1.1 研究背景与应用场景 1
1.1.1 高速闭环的延迟预算分析 2
1.1.2 高速下的误差放大机制 2
1.1.3 端到端范式需要时序建模的直觉 4
1.2 问题定义 6
1.2.1 输入-输出接口 6
1.2.2 部分可观测性与序列建模的必要性 7
1.3 关键挑战 8
1.3.1 挑战一：时序建模与高速决策 8
1.3.2 挑战二：流式部署一致性 8
1.3.3 挑战三：算力约束与高效视觉骨干 9
1.4 研究贡献 10
1.5 论文结构安排 11
第 2 章 预备知识与相关工作 13
2.1 四旋翼控制接口与任务抽象 13
2.1.1 坐标系与控制量定义 13
2.1.2 任务形式化 14
2.1.3 控制回路与低层控制器假设 14
2.1.4 安全指标与任务完成条件 15

2.2 模仿学习与分布偏移：BC 与 DAgger 15
2.2.1 行为克隆（BC） 15
2.2.2 分布偏移与误差累积 15
2.2.3 DAgger：数据集聚合 16
2.3 视觉表征：CNN 与 ViT 18
2.3.1 卷积神经网络 18
2.3.2 视觉 Transformer（ViT） 18
2.3.3 轻量化 ViT 的设计维度 19
2.4 时序建模：RNN/LSTM 与 SSM 20
2.4.1 LSTM 的流式优势与局限 20
2.4.2 结构化状态空间模型（S4） 20
2.4.3 从连续到离散的零阶保持（ZOH）推导 21
2.4.4 Mamba 的选择性机制 21
2.4.5 SSM 对控制任务的意义 23
2.5 MambaVision：混合 Mamba-Transformer 视觉骨干 24
2.6 仿真平台与数据来源 25
2.6.1 Flightmare 仿真平台 25
2.6.2 评测环境 25
2.6.3 特权信息专家策略 25
2.6.4 数据采集管线 27
2.7 评测协议与指标 27
2.7.1 统一评测协议 27
2.7.2 指标定义 27
2.7.3 指标计算伪代码 28
2.7.4 统计显著性与不确定性报告 28
2.7.5 评测可审计规范 29

2.8 相关工作综述 30
2.8.1 端到端视觉飞行控制 30
2.8.2 模块化自主飞行 31
2.8.3 安全性与部署侧约束 31
2.8.4 Sim-to-Real 迁移 32
2.8.5 方法谱系总结 32
2.9 小结：设计需求 32
第 3 章 面向高速避障的 ViT+Mamba 端到端策略 34
3.1 第 3 章引言 34
3.2 问题形式化 35
3.3 模型结构 35
3.3.1 总体架构 35
3.3.2 视觉编码器：轻量化 ViT 36
3.3.3 时序聚合模块：Temporal Mamba 36
3.3.4 特征融合与控制头 37
3.3.5 基线设置：ViT+LSTM 37
3.3.6 设计选择讨论 37
3.3.7 复杂度与推理延迟分析 38
3.4 DAgger 闭环数据增强 38
3.4.1 动机与方法 38
3.4.2 执行配置 39
3.4.3 数据集构成与速度档分布 39
3.4.4 轮次收敛的机制解释 39
3.5 RACS 动态速率限制平滑器 40
3.5.1 背景与动机 40
3.5.2 约束建模与求解 40
3.5.3 δ_t 动态调度函数 41
3.5.4 边界情况与失败模式分析 42

3.5.5 与训练期 Jerk Loss 的关系 42
3.5.6 算法复杂度与 RACS 伪代码 43
3.6 训练细节 43
3.7 案例研究与实验 44
3.7.1 主结果：ViT+Mamba 与 ViT+LSTM 的系统对比 45
3.7.2 推理延迟与系统时序分析 46
3.7.3 DAgger 轮次实验：碰撞频次与方差收敛 47
3.7.4 RACS：安全–平滑权衡 49
3.7.5 消融实验 51
3.7.6 失败案例分析 52
3.8 第 3 章小结 53
第 4 章 流式部署一致性与状态生命周期管理 55
4.1 第 4 章引言 55
4.2 Batch–Streaming 等价性定义 56
4.2.1 Batch 训练模式 56
4.2.2 Streaming 推理模式 57
4.2.3 等价性条件 57
4.2.4 SSM 线性递推的等价性推导 58
4.2.5 对 LSTM/GRU 与 Transformer KV-Cache 的类比 58
4.3 状态生命周期协议 60
4.3.1 错误状态重置的退化机理 60
4.3.2 回合边界级状态管理协议 60
4.3.3 实现细节 61
4.3.4 常见工程错误与症状对照 62
4.4 等价性单测与硬防护机制 63
4.4.1 等价性单测 63
4.4.2 阈值选择依据 63
4.4.3 硬防护机制 64

4.5 案例研究与实验 64
4.5.1 KeepState 与 ResetState 对比 65
4.5.2 LSTM 的状态重置退化 66
4.5.3 漂移可视化 66
4.5.4 等价性单测结果 68
4.5.5 重置频率消融 68
4.5.6 部署 burn-in 消融 69
4.5.7 跨速度泛化验证 70
4.6 第 4 章小结 71
第 5 章 全 SSM 架构探索：MambaVision 替代的系统消融实验 73
5.1 实验目标与评价问题定义 73
5.2 实验环境、数据与评测协议 75
5.2.1 评测环境与速度档 75
5.2.2 指标体系 75
5.2.3 系统架构与控制变量 75
5.3 消融实验框架与对照组 76
5.3.1 对照组与实验组定义 76
5.3.2 消融验证原则 76
5.3.3 控制变量声明 77
5.4 深度归一化一致性验证 77
5.4.1 训练与评测归一化口径差异 77
5.4.2 输入分布偏移机制分析 78
5.4.3 定量验证结果 78
5.4.4 实验规范锁定 80
5.5 输入分辨率瓶颈验证 81
5.5.1 分辨率瓶颈分析 81
5.5.2 实验设置 82
5.5.3 定量结果 82

5.5.4 速度段差异分析 83
5.5.5 计算开销评估 84
5.5.6 小结 84
5.6 视觉骨干受控解冻实验 85
5.6.1 动机与控制变量声明 85
5.6.2 实验配置 85
5.6.3 结果分析 86
5.6.4 原因讨论 87
5.6.5 结论与局限性 88
5.7 结构改动与动作蒸馏实验 88
5.7.1 特征条件池化 89
5.7.2 动作知识蒸馏 89
5.7.3 高速段尾部风险分析 91
5.7.4 保守归因与局限性 92
5.8 风险状态补分布蒸馏 93
5.8.1 核心假设 93
5.8.2 方法：风险状态采集与加权微调 93
5.8.3 高速段蒸馏效果验证 95
5.9 低速补强与最终模型综合评估 97
5.9.1 “平滑性提升却导致碰撞率增加”的失败模式 97
5.9.2 教师 Omega 事件触发的低速补强 99
5.9.3 版本对照与控制变量 100
5.9.4 Spheres 环境综合对比 101
5.9.5 Trees（OOD）泛化验证 104
5.9.6 推理效率与部署可行性 104
5.9.7 综合数据表 105
5.9.8 迭代路径总结 107
5.10 第 5 章小结 107

结论 109
参考文献 112
攻读学位期间发表论文与研究成果清单 118
致谢 119

插 图

图 1.1 四旋翼无人机高速避障的典型应用场景与共性挑战 1
图 1.2 高速闭环控制中的误差放大链路 3
图 1.3 高速飞行中的误差放大与累积示意：深度噪声与运动模糊导致实际轨迹偏离理想轨迹，误差随时间步持续放大 3
图 1.4 模块化导航范式与端到端控制范式的对比：左侧为传统模块化流水线（Sensor→SLAM→Mapping→Planning→Low-Level Control），延迟逐级累积；右侧为端到端学习控制，传感器输出经神经网络直接映射为控制指令，显著降低延迟 5
图 1.5 端到端视觉避障任务闭环控制流程 7
图 1.6 训练 Batch 模式与部署 Streaming 模式的状态管理差异，以及错误的逐步重置导致的无记忆退化 9
图 1.7 自注意力机制 $O(n^2)$ 与 SSM 线性 $O(n)$ 复杂度的对比示意 10
图 1.8 该研究技术路线总览 11
图 2.1 世界坐标系与机体坐标系定义，以及速度指令接口 13
图 2.2 行为克隆（BC）端到端训练流程：左侧由专家策略 π^* 在环境中采集观测–动作对构成数据集 $\mathcal{D}$；中间将序列观测输入端到端神经网络 π_θ 预测动作 $\hat{a}_t$；右侧通过 MSE 损失 $\mathcal{L} = \|a_t - \hat{a}_t\|^2$ 计算梯度并反向传播更新网络参数 16
图 2.3 DAgger 数据聚合闭环流程 17
图 2.4 DAgger 迭代式数据聚合全流程示意：上层为环境交互阶段，混合策略 $\hat{\pi}_i = \beta_i \pi^* + (1-\beta_i)\pi_i$ 在环境中采集轨迹并由专家 π^* 修正标注；中层为数据聚合阶段，新采集数据 $\mathcal{D}_{\text{new}}$ 与历史数据集 $\mathcal{D}_i$ 合并；下层为训练更新阶段，以聚合数据集重训策略 π_{i+1}。右侧对比图展示 BC 误差 $O(T^2)$ 增长与 DAgger 误差 $O(1)$ 收敛的理论差异 17
图 2.5 ViT 的 patch token 化与 Transformer 编码流程示意 19

图 2.6 SSM/Mamba 的三层架构总览。上层：连续时间状态空间方程 $\mathbf{h}'(t) = \mathbf{A}\mathbf{h}(t) + \mathbf{B}\mathbf{x}(t)$，其中 $\mathbf{A}$ 驱动状态演化，$\mathbf{B}$ 控制输入注入，$\mathbf{C}$ 负责状态读出；中层：基于零阶保持（ZOH）的离散化过程，将连续参数转化为离散递推形式 $\bar{\mathbf{A}} = e^{\mathbf{A}\Delta}$；下层：Mamba 的选择性机制，展示了参数 Δ_t、$\mathbf{B}_t$、$\mathbf{C}_t$ 如何依赖输入 $\mathbf{x}_t$ 进行动态调制。右侧示意图类比了其自适应控制逻辑与 LSTM 门控机制的异同。 22

图 2.7 SSM/Mamba 离散化后的状态更新机制。下标 t 强调了参数 $\bar{\mathbf{B}}_t$ 与 $\mathbf{C}_t$ 随输入动态变化的选择性特性。 23

图 2.8 Attention、SSM 与 LSTM 的序列长度–计算量关系对比（示意） 24

图 2.9 Flightmare 仿真平台中两类评测环境的实拍截图。(a) Spheres 环境：三维空间中随机分布不同半径的球体障碍，训练数据在该环境中生成；(b) Trees 环境：由树干与冠层构成的自然场景，策略从未在此环境中训练，用于测试零样本迁移泛化能力 26

图 2.10 基于 Flightmare 与特权信息专家的数据采集管线 27

图 2.11 碰撞事件次数的上升沿检测计算示意 29

图 3.1 第 3 章组织结构：架构设计、训练增强与部署约束三线汇聚于实验验证 34

图 3.2 ViT+Mamba 端到端策略网络总体架构 35

图 3.3 RACS 几何投影示意：将超出约束的 $\mathbf{v}_{\text{raw}}$ 投影至 δ_t-球面边界 41

图 3.4 $\delta_t(d_{\min,t})$ 调度曲线示意 42

图 3.5 ViT+Mamba 与 ViT+LSTM 在 Spheres/Trees 环境下的性能对比。（a）全程碰撞率；（b）碰撞事件次数；（c）Command Jerk；（d）单步推理时间。 45

图 3.6 控制循环周期 Δt 的分布统计，验证不同方法的系统时序一致性 47

图 3.7 碰撞事件次数随 DAgger 轮次变化（9 m/s 与 12 m/s），误差条表示 10 次试验标准差 47

图 3.8 平均碰撞持续时间随 DAgger 轮次变化 48

图 3.9 碰撞指标跨试验标准差随 DAgger 轮次的演化 48

图 3.10 BC 基线与 DAgger-R3 在 ID/OOD 环境下碰撞率对比 49

图 3.11 Trees OOD 环境下 BC 与 DAgger-R3 的多维指标对比 49

图 3.12 碰撞事件次数的逐轮分布 49

图 3.13 碰撞持续时间的逐轮分布（条件分布，duration > 0） 49

图 3.14 RACS 验证：Mamba No RACS、Mamba + RACS 与 ViT+LSTM 在不同速度下的安全性与平滑性 50
图 3.15 不同方法的 Command Jerk 随速度变化趋势 51
图 4.1 第 4 章逻辑链路：从问题揭示到形式化、协议设计与实验验证 56
图 4.2 状态重置导致的级联退化因果链 60
图 4.3 状态生命周期状态机：Init→Warmup→Run→Terminate→Reset 61
图 4.4 Batch 模式与正确/错误 Streaming 模式的时间轴对比 61
图 4.5 KeepState 与 ResetState 的漂移对比。ResetState（红色）导致显著的横向漂移趋势，而 KeepState（绿色）的轨迹保持稳定。 66
图 4.6 KeepState 与 ResetState 模式下横向漂移的累积对比 67
图 4.7 Batch–Streaming 等价性测试：KeepState 下 $\Delta\mathbf{v}_t$ 在 10^{-6} 量级（蓝色），ResetState 下 $\Delta\mathbf{v}_t$ 在 10^{-1} 量级（红色），两者差 5 个数量级 68
图 4.8 重置频率消融实验结果：重置越频繁，碰撞率、Jerk 与横向漂移越高。 . 69
图 4.9 部署 burn-in 消融实验结果：适度 burn-in 对碰撞率改善有限，但可稳定降低 Jerk 与漂移。 70
图 4.10 KeepState 与 ResetState 跨速度碰撞率对比：ResetState 的碰撞率随速度上升快速放大。 70
图 4.11 KeepState 与 ResetState 跨速度横向漂移对比：ResetState 在全速度域均表现出更大的横向漂移。 71
图 5.1 逐步消融验证决策流程图。每一阶段验证单一假设，通过则锁定该变量进入下一阶段，失败则记录归因并探索替代路线。最终收敛到可用版本 74
图 5.2 MambaVision 替代实验系统架构。虚线框标注的视觉编码器为唯一变量，其余模块（时序 Mamba、控制头、部署协议）在所有实验中保持固定 76
图 5.3 深度归一化口径偏移对速度效率与碰撞事件的影响。(a) 各速度段的平均前向速度在 png255 模式下均显著低于 threshold 模式，12 m/s 段降幅达 34%；(b) 5 m/s 段碰撞事件次数从 72.2 降至 13.6 属速度退化导致的表面改善，12 m/s 段碰撞事件次数反而从 7.6 升至 15.0，揭示控制衰减而非鲁棒性提升的本质 79

图 5.4　输入分辨率从 60×90 提升至 128×192 后的碰撞事件与速度效率变化。(a) 碰撞事件次数在所有速度段均显著下降，5 m/s 段降幅达 72.9%；(b) 各速度段平均前向速度均有提升，推理延迟仅从约 20 ms 增至 21 ms（+5%） 83

图 5.5　Stage 3 解冻前后的安全–速度权衡散点图（mean collision count vs mean V_x）。红色点（Stage 3 解冻方案）相比蓝色点（冻结高分辨率方案）在所有速度段均向右移动（碰撞增加），9 m/s 与 12 m/s 段速度基本持平，表明碰撞恶化并非速度变化的副产物。灰色点为 ViT+Mamba 基线 86

图 5.6　各消融阶段在 5 m/s、9 m/s、12 m/s 三个速度段的碰撞事件次数 (a) 与平均前向速度 (b) 对比。星号标注该速度段最优方法。特征条件池化（FC-Pool）与动作蒸馏（ActionKD）均在 5 m/s 段碰撞略有改善，但在 9 m/s 与 12 m/s 段碰撞次数均高于冻结基线（蓝色），速度效率在各方法间无显著差异 90

图 5.7　12 m/s 高速段各方法逐试验碰撞次数分布。菱形标注均值，水平线标注中位数，虚线为冻结基线中位数（= 6）作为基准参照。动作蒸馏（103-B KD）的标准差达 7.4，且出现单次试验碰撞次数超过 25 的极端离群值 92

图 5.8　风险状态蒸馏各阶段碰撞率对比。V_mid（橙色）相比 V_frozen（蓝色）在 9 m/s 与 12 m/s 段碰撞率显著下降，但 3 m/s 与 5 m/s 段碰撞率大幅上升。V_final（绿色）在全速度段均达到最低碰撞率 95

图 5.9　风险状态蒸馏各阶段平均前向速度对比。三个版本的 Mean V_x 高度接近，确认碰撞率变化并非降速的副产物 96

图 5.10　5 m/s 场景下不同补强策略的碰撞率对比。与中间版本（V_mid）相比，基于 $d_{\min}$ 触发的补强版本（V_fail）碰撞率不降反升（从 4.66% 升至 5.67%，增幅 21.7%），而基于 Omega 事件触发的最终版本则显著降至 0.56%。 98

图 5.11　5 m/s 场景下不同补强策略的指令抖动对比。V_fail 版本的 Jerk 从 0.08 锐减至 0.01（降幅 87.5%），控制输出极度平滑但碰撞率却发生恶化，呈现出典型的“平滑失效”特征。 98

图 5.12　Spheres 环境碰撞率对比。MV+Mamba 最终版在所有速度段碰撞率均不高于基线，12 m/s 高速段碰撞率降幅达 55.5% 101

图 5.13　Spheres 环境碰撞事件次数对比。MV+Mamba 最终版在 5 m/s–12 m/s 段碰撞事件次数均低于基线 102

图 5.14　Spheres 环境单位距离碰撞密度对比。MV+Mamba 最终版在高速段 CPM 优于基线，7 m/s 段差异在误差范围内 102
图 5.15　Spheres 环境平均前向速度对比。MV+Mamba 最终版在所有速度段均高于基线，证明安全性优势并非通过降速实现 103
图 5.16　Spheres 环境指令抖动对比。MV+Mamba 最终版在多数速度段 Jerk 显著更低，且碰撞率同步改善，构成安全性与平滑性的双重提升 103
图 5.17　Trees（OOD）环境碰撞率对比。MV+Mamba 最终版在中高速段（7 m/s–12 m/s）碰撞率大幅优于基线，体现显著的 OOD 泛化优势 104
图 5.18　推理延迟对比。MV+Mamba 最终版推理延迟约 21 ms–23 ms，高于基线（约 14 ms–17 ms），但仍远低于 50 ms 实时控制阈值 105
图 5.19　从冻结高分辨率基线到 MV+Mamba 最终版的迭代链路与分支决策。左侧主线给出四阶段迭代，其中数据侧转向框内并入 (§5.8) 与 (§5.9) 的关键细节；右侧汇总 (§5.6–5.7) 中已验证但否决的替代路线及其失败结论。 107

表 格

表 1.1 端到端避障系统延迟预算分解 2
表 2.1 不同输入分辨率与 Patch Size 下的 Token 数量与注意力复杂度 19
表 2.2 SSM 特性与高速避障控制需求的映射 23
表 2.3 评测环境配置 25
表 2.4 特权信息专家策略超参数 26
表 2.5 统一评测协议 27
表 2.6 评测指标定义与计算口径 28
表 2.7 高速端到端视觉避障相关技术路线对比 32
表 3.1 ViT 编码器各阶段张量尺寸 36
表 3.2 Temporal Mamba 模块配置 36
表 3.3 各模块推理耗时分析（RTX 4060，float32，单帧） 38
表 3.4 DAgger 迭代执行配置 39
表 3.5 DAgger 各轮新增轨迹的速度档分布 39
表 3.6 RACS 超参数 42
表 3.7 策略网络训练超参数配置 44
表 3.8 Spheres 环境主结果：碰撞率与碰撞事件次数（均值 ±std） 46
表 3.9 Trees 环境主结果：碰撞率与碰撞事件次数（均值 ±std） 46
表 3.10 Mamba 层数消融（Spheres，9 m/s，10 次均值） 51
表 3.11 Burn-in 长度消融（Spheres，9 m/s，10 次均值） 52
表 3.12 Jerk Loss 配置消融（Spheres，9 m/s，10 次均值） 52
表 4.1 不同序列模型的内部状态与错误重置后果类比 59
表 4.2 常见状态管理工程错误与症状对照 62
表 4.3 等价性测试配置与通过标准 64
表 4.4 可审计日志字段定义 65
表 4.5 Mamba 流式状态管理消融实验（KeepState vs ResetState，Spheres 7 m/s） 65

表 4.6　LSTM 流式状态管理消融实验（KeepState vs ResetState，Spheres 7 m/s）　66
表 5.1　MambaVision 替换实验控制变量声明 77
表 5.2　深度归一化口径一致性验证定量结果（均值 ± 标准差，每档 10 次试验）。threshold 为训练阶段配置，png255 为口径偏移配置。加粗行标注最终锁定的归一化模式 79
表 5.3　MambaVision-T 各 Stage 空间 token 数量随输入分辨率的变化。低分辨率下深层 Stage 的 token 数量急剧退化，构成空间表征能力的结构性瓶颈 81
表 5.4　输入分辨率瓶颈验证定量结果（每档 10 次试验）。60×90 为基线低分辨率配置，128×192 为提升后配置。加粗行标注最终锁定的分辨率 82
表 5.5　视觉骨干受控解冻实验配置。相比前一阶段（冻结高分辨率方案），唯一变化为 Stage 3 由冻结变为可训练（加粗标注） 86
表 5.6　风险状态蒸馏中间版本（V_mid）评测结果。加粗标注各速度段最优值。V_mid 在高速段（9 m/s、12 m/s）碰撞率大幅改善，但低速段（3 m/s、5 m/s）碰撞率显著恶化 96
表 5.7　风险状态蒸馏各版本对照表。每行仅标注相对前一版本的唯一变化 100
表 5.8　推理效率与模型参数对比 105
表 5.9　Spheres 环境综合对比（均值 ±std，每档 10 次试验）。加粗标注各速度段各指标的优势方 106
表 5.10　Trees（OOD）环境综合对比（均值 ±std，每档 10 次试验） 106

第 3 章　面向高速避障的 ViT+Mamba 端到端策略

3.1　第 3 章引言

高速密集障碍环境为端到端避障策略带来了三大核心挑战：（1）时序特征聚合——单帧深度图像易受运动模糊、噪声及遮挡干扰，难以支撑可靠的瞬时决策；（2）训练–部署分布对齐——高速场景下，行为克隆（BC）固有的分布偏移现象更为显著；（3）控制平滑性约束——高敏捷性的避障策略往往伴随着剧烈的控制指令抖动。

现有的端到端避障方案多以 CNN/LSTM 为核心架构 [7]，在长序列建模能力与计算效率之间仍存在局限。基于结构化状态空间模型（SSM）的 Mamba[17] 凭借其线性计算复杂度与高效的时序聚合能力，为实现高速闭环控制提供了新的技术路径。

为此，第 3 章提出了一种以 ViT 空间编码、Mamba 时序聚合及线性控制头为核心的端到端策略网络，构建了包含 “BC 预训练 + DAgger 在线微调 + RACS 平滑控制” 的完整训练–部署系统。第 3 章的主要贡献归纳如下：

1. 设计了 ViT+Mamba 策略网络架构，并基于行为克隆（BC）完成了基础训练；
2. 引入 DAgger 闭环数据增强机制，有效缓解了训练与部署之间的分布偏移问题；
3. 提出了 RACS 动态速率限制控制器，在部署侧显著提升了控制指令的平滑性；
4. 进行了完整的案例研究与实验验证（详见第3.7节），证明了该方法的有效性。

图 3.1展示了第 3 章的组织结构与对应的主要贡献。

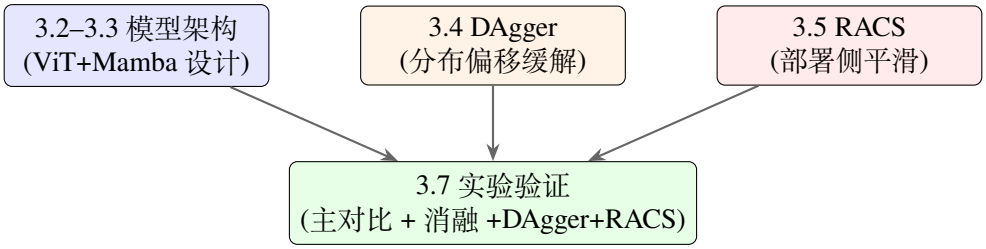

图 3.1　第 3 章组织结构：架构设计、训练增强与部署约束三线汇聚于实验验证

3.2 问题形式化

在第 2 章任务定义的基础上，第 3 章明确策略网络的符号体系。在每个控制周期 t，策略接收：深度图像观测 $D_t \in \mathbb{R}^{60\times 90}$（乘以缩放因子 $\alpha = 0.09$ 归一化）；轻量状态 $s_t = [q_t, \tilde{v}^{\text{target}}]$（姿态四元数 + 归一化目标速度，共 5 维）。

策略输出世界坐标系下的速度指令：

$$\mathbf{v}_t = \pi_\theta(D_{\leq t}, s_{\leq t}) \in \mathbb{R}^3 \tag{3.1}$$

训练损失为行为克隆（BC）监督损失：

$$\mathcal{L}_{\text{BC}} = \frac{1}{T'} \sum_{t=t_{\text{burn}}+1}^{T} \|\mathbf{v}_t^{\text{pred}} - \mathbf{v}_t^{\text{expert}}\|_2^2 \tag{3.2}$$

其中 T' 为有效序列长度（扣除 burn-in 步数 $t_{\text{burn}} = 20$），前 20 步仅用于预热时序模型内部状态，其输出不参与损失计算。burn-in 的设计动机在于：序列模型在接收前若干步输入时，隐状态尚未稳定，此时的输出不能代表模型的真实时序聚合能力。将这些步骤排除在损失之外可以避免梯度信号被不稳定的早期输出污染。

3.3 模型结构

3.3.1 总体架构

该研究的端到端策略网络采用” 空间编码 + 时序聚合 + 控制头” 三段式架构，如图 3.2所示。

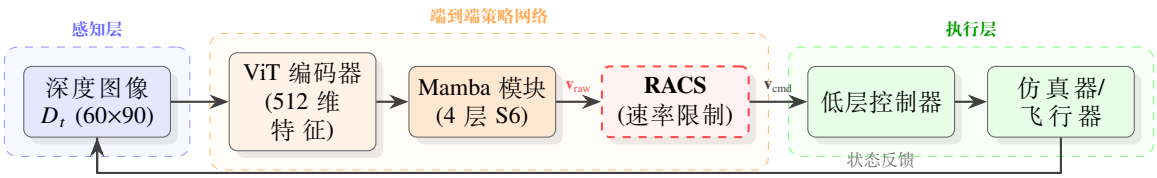

图 3.2 ViT+Mamba 端到端策略网络总体架构

3.3.2 视觉编码器：轻量化 ViT

视觉编码器采用轻量化的 2-stage ViT 架构：第一阶段使用 Patch Size 7×7、Stride 4 的卷积嵌入将 60×90 的深度图分割为 16×24 的 patch token 序列（32 通道）；经 Transformer 编码块后，第二阶段以 Patch Size 3×3、Stride 2 下采样至 8×12（64 通道），最终全局池化为 512 维向量。表 3.1给出各阶段张量尺寸。

表 3.1 ViT 编码器各阶段张量尺寸

阶段	输入尺寸	Patch/Stride	输出尺寸	通道数
输入深度图	$60\times90\times1$	–	–	1
Stage 1 嵌入	60×90	7×7 / Stride 4	16×24	32
Stage 1 编码	$16\times24\times32$	–	$16\times24\times32$	32
Stage 2 嵌入	$16\times24\times32$	3×3 / Stride 2	$8\times12\times64$	64
Stage 2 编码	$8\times12\times64$	–	$8\times12\times64$	64
全局池化	$8\times12\times64$	–	512	–

3.3.3 时序聚合模块：Temporal Mamba

时序聚合模块采用 4 层 Mamba[17]，配置如表 3.2所示。

表 3.2 Temporal Mamba 模块配置

参数	数值
层数	4
模型维度 d_{model}	192
状态维度 d_{state}	64
卷积核大小 d_{conv}	4
扩展因子	4

Mamba 的离散化状态更新方程为：

$$\mathbf{h}_t = \bar{\mathbf{A}}\mathbf{h}_{t-1} + \bar{\mathbf{B}}_t\mathbf{x}_t, \quad \mathbf{y}_t = \mathbf{C}_t\mathbf{h}_t \tag{3.3}$$

其中 $\bar{\mathbf{A}}, \bar{\mathbf{B}}$ 为零阶保持离散化后的参数矩阵（推导见第 2 章 2.4.3 节），$\mathbf{B}_t, \mathbf{C}_t, \Delta_t$ 随输入动态变化（选择性机制）。

3.3.4 特征融合与控制头

ViT 输出的 512 维视觉特征 $\mathbf{f}_{\text{vis}}$ 与 5 维辅助特征 $\mathbf{f}_{\text{aux}}$ 拼接后线性投影至 $d_{\text{model}} = 192$ 维，输入 Mamba 模块。Mamba 输出经线性层映射为 3 维速度指令 $\mathbf{v}_{\text{raw}}$。网络总参数量约 3.50M。

3.3.5 基线设置：ViT+LSTM

为验证 Mamba 时序模块的有效性，设置 ViT+LSTM 作为对比基线：使用相同的 ViT 视觉编码器，时序模块替换为 3 层 LSTM（隐状态维度 192），参数量约 3.52M，与 ViT+Mamba 相近，训练配置完全对齐。基线的唯一差异在于时序聚合模块，从而使性能差异可严格归因于 Mamba vs LSTM 的建模能力差异。

3.3.6 设计选择讨论

该节从 token 数量、推理延迟与参数量三个维度解释”2-stage ViT + 4-layer Mamba”的设计理由。

（1）为什么采用两阶段卷积嵌入而非标准 ViT 的线性 Patch 嵌入?

标准 ViT[21] 对 60×90 图像使用 16×16 Patch Size 产生 $\lfloor 60/16 \rfloor \times \lfloor 90/16 \rfloor = 3 \times 5 = 15$ 个 token，空间分辨率过低。若改用 8×8 Patch Size 则产生 $7 \times 11 = 77$ 个 token，注意力复杂度为 $O(77^2) \approx 6000$，可接受但不够灵活。

采用的两阶段卷积嵌入方案通过 Stride 4 + Stride 2 的级联下采样，在第一阶段保留 $16 \times 24 = 384$ 个 token 以捕捉空间细节，在第二阶段压缩至 $8 \times 12 = 96$ 个 token 以控制注意力计算量。这一设计在空间细节保留与计算效率之间取得了平衡。

（2）为什么是 4 层 Mamba 而非 2 层或 6 层?

Mamba 层数涉及时序建模深度与推理延迟的权衡。如第3.7.5节消融实验所示，2 层 Mamba 在高速段碰撞率偏高（时序聚合能力不足），6 层 Mamba 的碰撞率改善有限但推理延迟增加约 40%。4 层是在安全性与延迟约束下的最优折中。

（3）参数量控制。

$d_{\text{model}} = 192$、$d_{\text{state}} = 64$ 的配置使 Temporal Mamba 模块参数量约为 1.2M，与 ViT 编码器的 2.3M 合计约 3.5M。这一量级在 NVIDIA RTX 4060 GPU 上可实现毫秒级推理，满足实时控制要求。

3.3.7 复杂度与推理延迟分析

表 3.3给出各模块的推理耗时分析。测试条件为 NVIDIA RTX 4060 GPU、float32 精度、输入 60×90 单帧深度图，取 1000 次推理的中位数。

表 3.3 各模块推理耗时分析（RTX 4060，float32，单帧）

模块	耗时 (ms)	占比 (%)	计算复杂度
ViT 视觉编码器	~3.5	~58	$O(N^2 \cdot d), N = 96$
Temporal Mamba (4 层)	~1.8	~30	$O(L \cdot d_{\text{model}} \cdot d_{\text{state}})$
特征融合 + 控制头	~0.2	~3	$O(d)$
RACS 后处理	<0.1	<2	$O(1)$
GPU-CPU 数据传输	~0.5	~7	–
合计	**~6.0**	**100**	–

分析表格数据可得：(1) ViT 编码器是计算瓶颈（占 58%），这为第 5 章将 ViT 替换为 MambaVision 提供了直接动机；(2) Temporal Mamba 的单步流式推理仅需 ~ 1.8 ms，显著低于同参数量 LSTM（~ 2.5 ms），验证了 SSM 在推理效率上的优势；（3）RACS 的 $O(1)$ 复杂度使其对总延迟几乎无影响（< 0.1 ms）。

$\sim$ 6 ms 的总推理延迟意味着策略可支持 $>$ 160 Hz 的控制频率，远高于该研究 30 Hz–60 Hz 的实际运行频率，留有充足的余量。

3.4 DAgger 闭环数据增强

3.4.1 动机与方法

在 BC 基线上引入 DAgger[20] 闭环数据增强以缓解分布偏移。以 BC 训练的 checkpoint（R0）为初始策略，执行 3 轮 DAgger 迭代（R1–R3）。每轮流程为：（1）以混合策略（β 控制专家/学生比例）在 Flightmare 中采集闭环数据；（2）由特权信息专家为所有状态标注速度指令（无论该状态由专家还是学生执行产生）；（3）合并新数据到训练集中从头重新训练（而非增量微调）。

选择全量重训而非增量微调的原因在于：增量微调可能导致策略遗忘早期数据中的良好行为模式（灾难性遗忘），而全量重训确保策略在包含更广泛状态覆盖的完整数据集上达到全局最优。

3.4.2 执行配置

表 3.4给出 3 轮 DAgger 迭代的完整配置。

表 3.4 DAgger 迭代执行配置

轮次	β	新增轨迹	累计轨迹	Epochs	LR	Warmup	来源
R0 (BC)	–	585	585	100	1e-4	15	从零训练
R1	0.7	18	603	30	5e-5	5	R0
R2	0.3	18	621	30	5e-5	5	R1
R3	0.0	18	639	30	5e-5	5	R2

注：β 为专家混合比例（$\beta = 1$ 表示纯专家，$\beta = 0$ 表示纯学生）。每轮数据偏重高速段（9/12 m/s 各 6 条），仅在 Spheres 环境采集，Trees 保持零样本。

3.4.3 数据集构成与速度档分布

DAgger 每轮新增的 18 条轨迹在速度档上的分布如表 3.5所示。策略性地偏重高速段采集（9 m/s 和 12 m/s 各 6 条），因为 BC 基线在这些速度下碰撞最为频繁——这些状态正是 BC 训练数据中覆盖最不充分的区域。

表 3.5 DAgger 各轮新增轨迹的速度档分布

	目标速度 (m/s)					
轮次	3	5	7	9	12	**合计**
R0 (BC)	117	117	117	117	117	585
R1 新增	2	2	2	6	6	18
R2 新增	2	2	2	6	6	18
R3 新增	2	2	2	6	6	18
总计	123	123	123	135	135	**639**

从数据比例看，DAgger 仅在 BC 数据基础上新增了约 9.2% 的轨迹数据（54/585），但这些数据来自学生策略诱导的分布而非专家分布，精准覆盖了 BC 最脆弱的高速区域，因此能以极小的数据代价带来显著的安全性提升。

3.4.4 轮次收敛的机制解释

DAgger 轮次推进带来的性能提升主要体现在两个维度：碰撞指标均值的下降与标准差的收敛。

均值下降的机理较为直观：每一轮 DAgger 新增的训练数据均源自当前策略的实际闭环执行，这些数据有效覆盖了策略在推理阶段易出错的状态区域——尤其是基础

BC 训练数据中缺失的高速偏离状态。通过对这些 “难例” 状态补充正确的专家标注，策略在后续训练中能够针对性地修正其在边界条件下的行为决策。

标准差收敛的深层原因在于分布的一致性：随着 DAgger 轮次的推进，训练数据的状态覆盖范围逐步逼近策略在实际部署中的状态分布 d_{π_θ}。当训练分布与部署分布的重叠度显著增加时，策略在不同初始条件下表现出的行为一致性随之提高——具体表现为跨试验碰撞指标标准差的减小。这意味着策略从 “性能波动” 演变为 “稳定可控”，对于实际工程部署而言，行为一致性的提升与安全性均值的改善具有同等重要的意义。

β 的动态衰减策略（$0.7 \to 0.3 \to 0.0$）进一步加速了这一收敛过程：在初期阶段，$\beta = 0.7$ 意味着 70% 的概率由专家接管控制（以确保采集过程的安全性），而剩余 30% 由学生策略主导，从而引入必要的分布偏移数据；至 R3 阶段，$\beta = 0.0$ 使得数据采集完全由学生策略主导，从而最大化了对实际部署分布的覆盖。

3.5 RACS 动态速率限制平滑器

3.5.1 背景与动机

尽管 ViT+Mamba 凭借其卓越的时序建模能力显著降低了碰撞率，但其高动态特性往往伴随着剧烈的控制指令抖动（Command Jerk）。针对物理四旋翼系统，过大的指令抖动不仅会削弱飞行的平稳性，更可能诱发机体结构共振、加剧执行机构磨损并增加功耗，极端情况下甚至会导致姿态控制器失稳发散 [56]。

为此，该节提出 RACS（Rate-Adaptive Control Smoother），旨在推断阶段对策略输出施加动态速率约束，以极低的计算代价换取控制平滑性的显著提升。其核心设计理念在于解耦训练与控制：保持策略网络的训练过程不变，仅在推理环节引入后处理约束以修正动作输出。

3.5.2 约束建模与求解

RACS 的数学本质可建模为 L_2 球域内的最近点投影优化问题：

$$\min_{\mathbf{v}_{\text{cmd}}} \|\mathbf{v}_{\text{cmd}} - \mathbf{v}_{\text{raw}}\|_2^2 \quad \text{s.t.} \quad \|\mathbf{v}_{\text{cmd}} - \mathbf{v}_{\text{prev}}\|_2 \le \delta_t \tag{3.4}$$

其中，$\mathbf{v}_{\text{raw}} \in \mathbb{R}^3$ 为策略网络的原始输出，$\mathbf{v}_{\text{prev}} \in \mathbb{R}^3$ 为上一时刻发布的控制指令，$\delta_t > 0$ 为当前时刻的动态速率上界。

该形式属于典型的凸优化问题（欧氏投影至凸集），必然存在唯一的解析解。定义速度增量 $\Delta\mathbf{v} = \mathbf{v}_{\text{raw}} - \mathbf{v}_{\text{prev}}$，求解过程如下：

情形 1：若 $\|\Delta\mathbf{v}\|_2 \le \delta_t$，表明原始输出 $\mathbf{v}_{\text{raw}}$ 已落在可行域内，直接采纳 $\mathbf{v}_{\text{cmd}} = \mathbf{v}_{\text{raw}}$。

情形 2：若 $\|\Delta\mathbf{v}\|_2 > \delta_t$，需将 $\mathbf{v}_{\text{raw}}$ 投影至以 $\mathbf{v}_{\text{prev}}$ 为球心、δ_t 为半径的边界上。基于 KKT 条件可得最优解位于 $\Delta\mathbf{v}$ 的方向向量上：

$$\mathbf{v}_{\text{cmd}} = \mathbf{v}_{\text{prev}} + \delta_t \cdot \frac{\Delta\mathbf{v}}{\|\Delta\mathbf{v}\|_2} \tag{3.5}$$

从几何视角分析，该操作等价于在保持速度更新方向不变的前提下，将更新幅值严格截断为 δ_t。其几何意义如图 3.3所示。

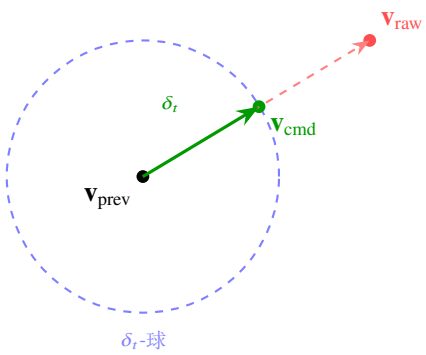

图 3.3　RACS 几何投影示意：将超出约束的 $\mathbf{v}_{\text{raw}}$ 投影至 δ_t-球面边界

3.5.3　δ_t 动态调度函数

δ_t 根据当前最小深度观测值 $d_{\min,t}$ 动态调整：障碍接近时放宽 δ_t 以保留敏捷性（允许更大的速度变化以紧急避障），远离时收紧 δ_t 以增强平滑。调度函数为分段线性：

$$\delta_t(d_{\min,t}) = \begin{cases} \delta_{\max} & \text{若} d_{\min,t} \le d_0 \\ \delta_{\max} - \frac{\delta_{\max} - \delta_{\min}}{d_1 - d_0}(d_{\min,t} - d_0) & \text{若} d_0 < d_{\min,t} < d_1 \\ \delta_{\min} & \text{若} d_{\min,t} \ge d_1 \end{cases} \tag{3.6}$$

调度曲线示意见图 3.4。

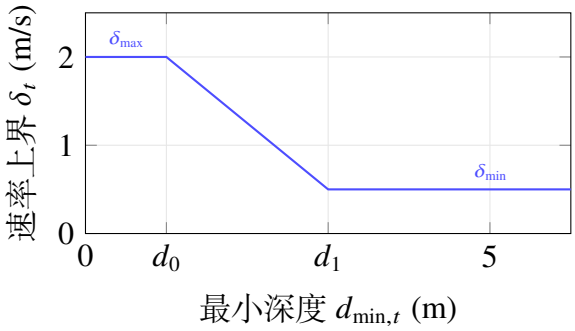

图 3.4　$\delta_t(d_{\min,t})$ 调度曲线示意

RACS 超参数见表 3.6。

表 3.6　RACS 超参数

参数	符号	数值
最大速率上界	$\delta_{\max}$	待从实验日志确认
最小速率上界	$\delta_{\min}$	待从实验日志确认
近距阈值	d_0	待从实验日志确认
远距阈值	d_1	待从实验日志确认

3.5.4　边界情况与失败模式分析

RACS 的 δ_t 参数存在两个极端边界：

δ_t 过小（$\delta_{\min}$ 设置过于激进）：策略输出的速度变化被过度限制，无人机无法及时执行大幅避障机动。表现为：策略“看到了”障碍并生成了正确的避让指令 $\mathbf{v}_{\text{raw}}$，但 RACS 将其截断为一个过小的变化量，导致实际轨迹仍与障碍相交。这种情况下，RACS 反而增加了碰撞率。

δ_t 过大（$\delta_{\max}$ 设置过于宽松）：RACS 几乎不起作用（$\|\Delta\mathbf{v}\|_2 \le \delta_t$ 对大多数帧成立），平滑效果消失，退化为无 RACS 的情况。

因此，δ_t 的调度需要在”保留敏捷性”与”增强平滑性”之间取得平衡。该研究的动态调度策略通过深度信息 $d_{\min,t}$ 自适应调节：障碍近时 δ_t 大（优先安全），障碍远时 δ_t 小（优先平滑），这一启发式规则在实验中证明是有效的（第3.7.4节）。

3.5.5　与训练期 Jerk Loss 的关系

该研究同时使用了训练期的 Jerk Loss（$\mathcal{L}_{\text{jerk}}$）和部署期的 RACS，两者并不冲突：

- Jerk Loss 本质上属于 “软约束”：其通过梯度下降优化引导策略生成平滑轨迹，但无法在数值上严格保证单步控制量的变化幅度低于特定阈值。特别是在紧急避障等高动态场景下，BC 监督损失往往与平滑性损失存在梯度对抗，导致软约束失效；
- RACS 则属于 “硬约束”：无论策略网络的原始输出如何，RACS 通过后处理投影机制，确保最终下发的控制指令变化幅值严格受限于 δ_t。

类比于经典控制理论中的” 期望 + 饱和” 架构：Jerk Loss 塑造了策略的” 期望行为分布”（使大部分输出天然平滑），RACS 则在分布尾部施加” 饱和截断”（处理偶发的极端抖动）。实验结果表明，两者联合使用时 Jerk 指标优于任一单独使用的情况。

3.5.6 算法复杂度与 RACS 伪代码

RACS 的核心运算仅包含一次 $\mathbb{R}^3$ 向量减法、一次 L2 范数计算和一次条件截断，复杂度为 $O(1)$（与模型大小、序列长度无关）。算法 5给出完整伪代码。

算法 5 RACS 动态速率限制控制平滑器

输入: 网络输出 $\mathbf{v}_{\text{raw}}$，上一步指令 $\mathbf{v}_{\text{prev}}$，深度图 D_t
输出: 平滑后的指令 $\mathbf{v}_{\text{cmd}}$

```
d_min ← min(D_t)                                  ▷ 提取最小深度值
δ_t ← SCHEDULE(d_min)                             ▷ 查分段线性函数
Δv ← v_raw − v_prev
if ||Δv||_2 ≤ δ_t then
    v_cmd ← v_raw                                 ▷ 未超界，直接输出
else
    v_cmd ← v_prev + δ_t · Δv/||Δv||_2            ▷ 投影至球面
end if
return v_cmd
```

实测中，RACS 单步耗时 < 0.1 ms（含 $d_{\min}$ 计算），对控制频率无可观测影响。

3.6 训练细节

表 3.7给出完整的训练超参数配置。

表 3.7　策略网络训练超参数配置

参数	数值
训练设置	
优化器	AdamW[81]
学习率	1×10^{-4}（线性预热）
权重衰减	1×10^{-4}
批大小	1（轨迹级）
总训练轮数	100 epochs
梯度裁剪	1.0
学习率预热	15 epochs
序列建模	
训练序列长度	150 步
Burn-in 步数	20 步
输入分辨率	60×90
数据增强	
深度噪声	高斯噪声 $\sigma = 0.02$
亮度扰动	±10% 随机扰动
Jerk Loss 课程	
第一阶段	0–30 epochs，$\lambda_{\text{jerk}} = 0$
第二阶段	30–70 epochs，λ_{jerk} 线性增加
第三阶段	70–100 epochs，λ_{jerk} 恒定

总训练损失为 BC 监督损失与 Jerk Loss 的加权组合：

$$\mathcal{L} = \mathcal{L}_{\text{BC}} + \lambda_{\text{jerk}} \cdot \mathcal{L}_{\text{jerk}}, \quad \mathcal{L}_{\text{jerk}} = \frac{1}{T' - 1} \sum_{t=t_{\text{burn}}+2}^{T} \|\mathbf{v}_t^{\text{pred}} - \mathbf{v}_{t-1}^{\text{pred}}\|_2^2 \tag{3.7}$$

Jerk Loss 采用三阶段课程学习的设计动机为：第一阶段（0–30 epochs）仅优化 BC 损失，让策略首先学会基本的避障行为；第二阶段（30–70 epochs）逐步引入 Jerk Loss 权重，避免突变导致训练不稳定；第三阶段（70–100 epochs）保持恒定权重进行精细调整。这一设计确保了 BC 监督信号（安全性）与 Jerk 惩罚（平滑性）之间的优先级：安全性始终是第一优化目标。

3.7　案例研究与实验

该节给出创新点一的完整实验验证。评测协议见第 2 章表 2.5与表 2.6，该节仅补充第 3 章特有的实验设置。

3.7.1 主结果：ViT+Mamba 与 ViT+LSTM 的系统对比

图 3.5汇总了两种方法在 Spheres（同分布）与 Trees（分布外）环境中的性能对比。

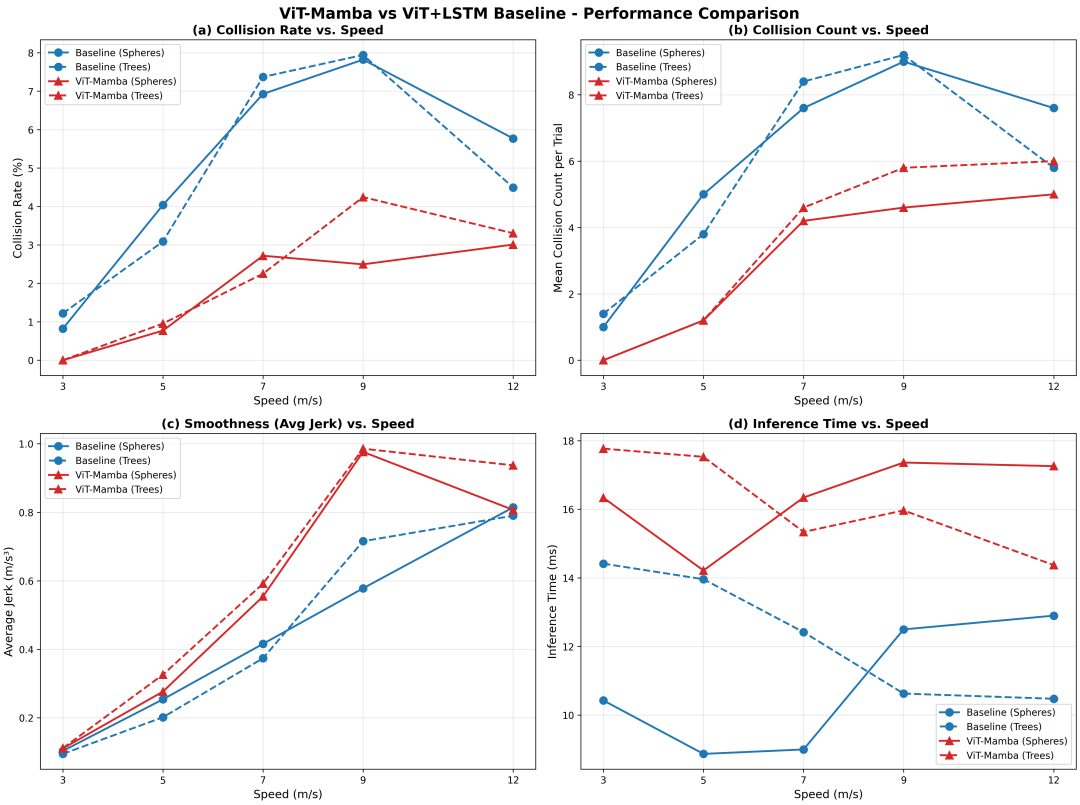

图 3.5　ViT+Mamba 与 ViT+LSTM 在 Spheres/Trees 环境下的性能对比。（a）全程碰撞率；（b）碰撞事件次数；（c）Command Jerk；（d）单步推理时间。

主要发现如下：

（1）ViT+Mamba 在高速段显著优于 ViT+LSTM。在 Spheres 环境中，ViT+Mamba 在　速度段，碰撞率与碰撞事件次数均明显低于 ViT+LSTM 基线。这一优势的根源在于 Mamba 的选择性机制（第 2 章 2.4.4 节）使模型能够根据当前观测动态调整时序聚合行为：当障碍接近时更关注最新观测（通过增大 Δ_t 加速遗忘），当路径平坦时更充分利用历史信息进行平滑预测。

（2）分布外泛化优势同样显著。在 Trees 环境（零样本 OOD 测试）中，ViT+Mamba 同样保持安全性优势，表明改进具备跨分布泛化能力。这一结论与第 1 章命题 1 的预测一致。

（3）推理延迟相当。两种方法的单步推理延迟均在 6 ms 左右（表 3.3），Mamba 模块略快于 LSTM 模块，但总延迟差异不大（被 ViT 编码器主导）。

表 3.8与表 3.9分别给出 Spheres（ID）与 Trees（OOD）环境下的碰撞率与碰撞事件次数数值结果。

表 3.8　Spheres 环境主结果：碰撞率与碰撞事件次数（均值 ±std）

	目标速度 (m/s)				
方法	3	5	7	9	12
Collision Rate (%)					
ViT+LSTM	0.82 ± 0.95	4.04 ± 2.42	6.93 ± 2.33	7.82 ± 2.85	5.77 ± 1.77
ViT+Mamba	0.00 ± 0.00	0.77 ± 0.90	2.72 ± 2.75	2.49 ± 2.44	3.01 ± 1.64
Collision Count					
ViT+LSTM	1.0 ± 1.00	5.0 ± 2.86	7.6 ± 2.50	9.0 ± 2.57	7.6 ± 1.74
ViT+Mamba	0.0 ± 0.00	0.6 ± 0.66	2.1 ± 1.76	2.3 ± 1.49	2.5 ± 1.50

注：每个数值为 10 次试验的均值 ± 标准差。

表 3.9　Trees 环境主结果：碰撞率与碰撞事件次数（均值 ±std）

	目标速度 (m/s)				
方法	3	5	7	9	12
Collision Rate (%)					
ViT+LSTM	1.22 ± 1.16	3.09 ± 1.30	7.37 ± 2.92	7.94 ± 2.15	4.49 ± 1.32
ViT+Mamba	0.00 ± 0.00	0.95 ± 1.16	2.25 ± 1.26	4.24 ± 1.97	3.30 ± 1.39
Collision Count					
ViT+LSTM	1.4 ± 1.28	3.8 ± 1.66	8.4 ± 2.94	9.2 ± 2.40	5.8 ± 2.09
ViT+Mamba	0.0 ± 0.00	0.6 ± 0.66	2.3 ± 1.55	2.9 ± 0.94	3.0 ± 1.26

注：每个数值为 10 次试验的均值 ± 标准差。

3.7.2　推理延迟与系统时序分析

图 3.6给出控制循环周期 Δt 的分布统计，确认两种方法的系统时序一致。这一验证的必要性在于：若不同方法的控制频率存在系统性差异，则碰撞率的对比将包含”控制频率” 这一混淆因素。Δt 分布的一致性确认了两种方法在” 单位时间内执行的控制步数” 维度上是可比的。

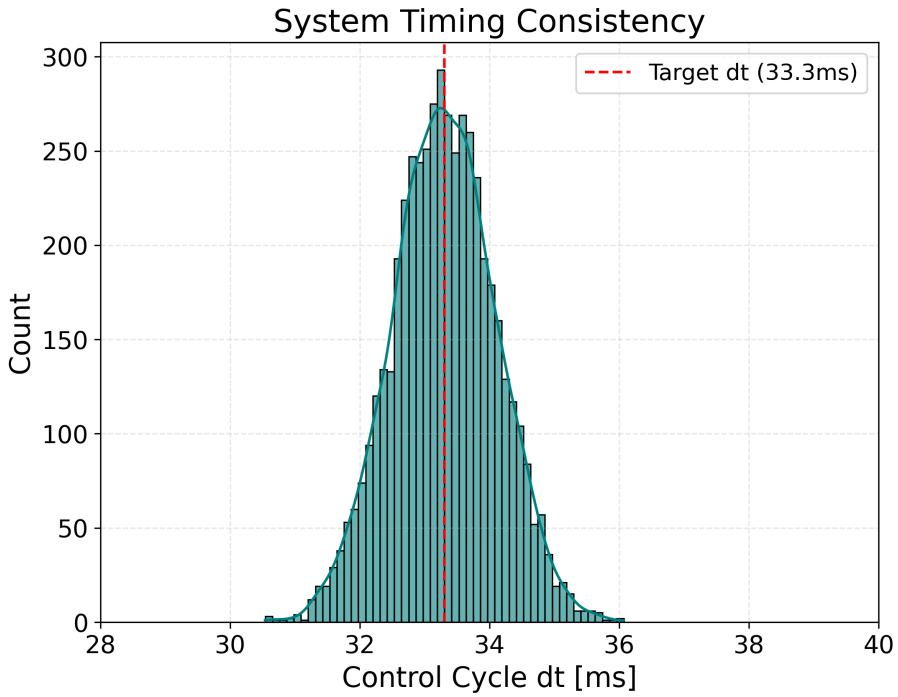

图 3.6　控制循环周期 Δt 的分布统计，验证不同方法的系统时序一致性

3.7.3　DAgger 轮次实验：碰撞频次与方差收敛

图 3.7和图 3.8分别给出碰撞事件次数与碰撞持续时间随 DAgger 轮次的变化。

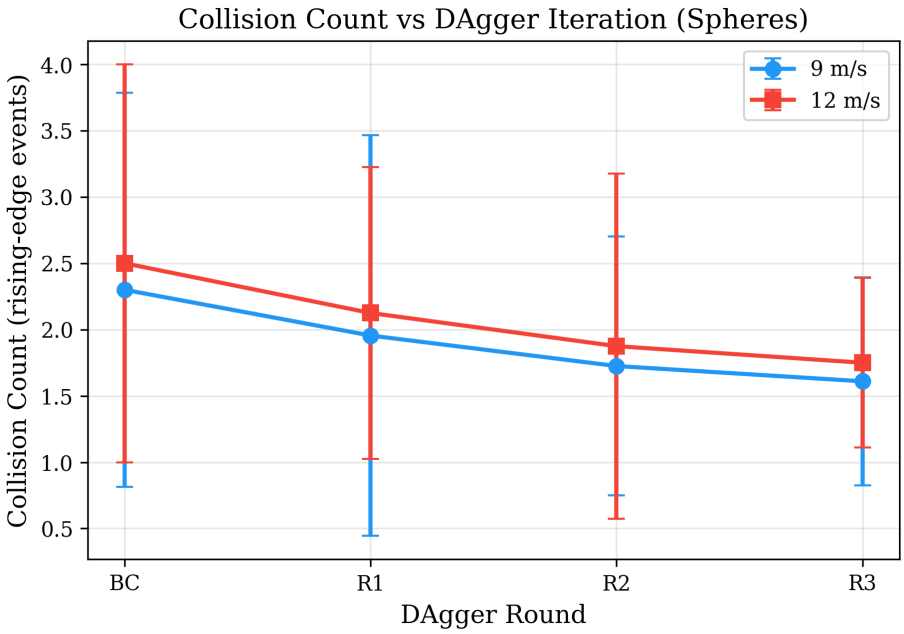

图 3.7　碰撞事件次数随 DAgger 轮次变化（9 m/s 与 12 m/s），误差条表示 10 次试验标准差

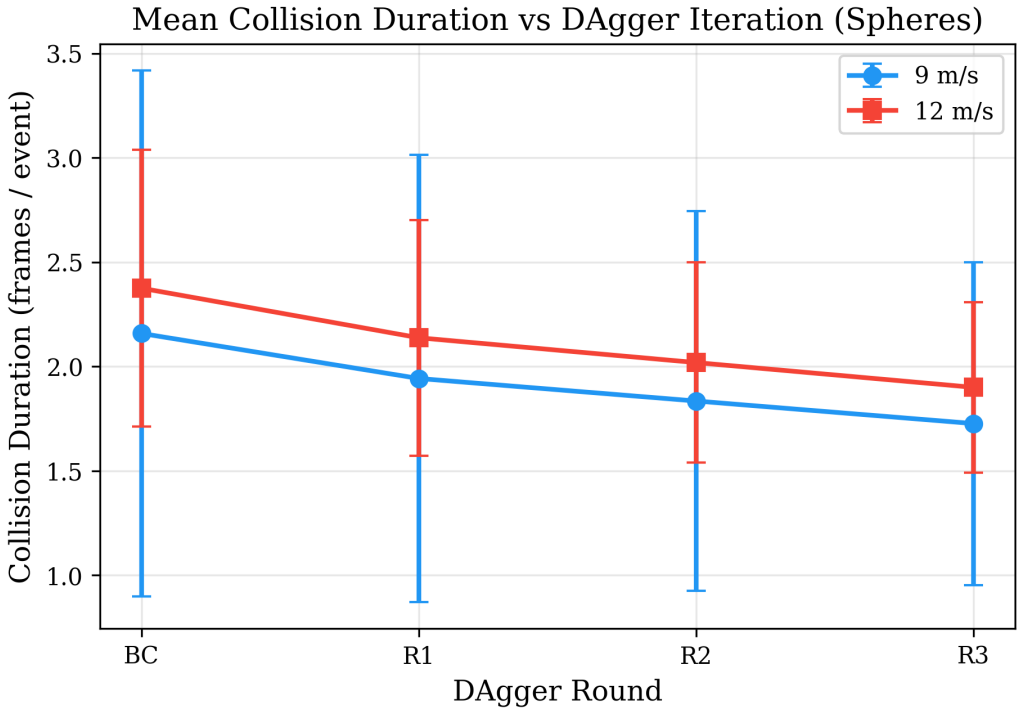

图 3.8　平均碰撞持续时间随 DAgger 轮次变化

碰撞事件次数从 R0（BC）到 R3 持续下降；跨试验标准差随轮次收敛（图 3.9），策略行为从”有波动”过渡为”稳定可预测”——这正是 3.4.4 节分析的”闭环覆盖提升 → 行为一致性增强”机制的实验证据。

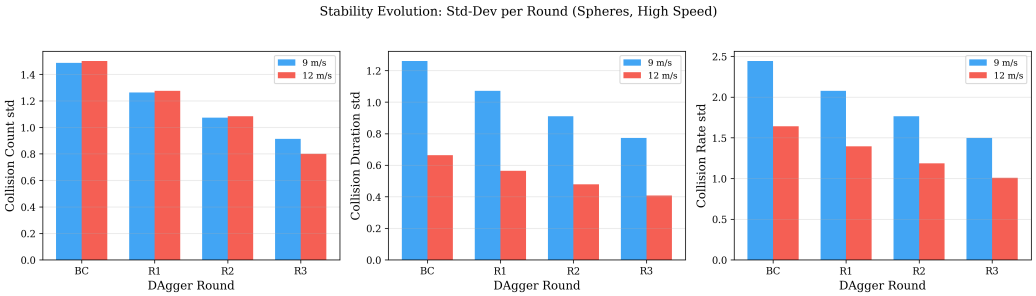

图 3.9　碰撞指标跨试验标准差随 DAgger 轮次的演化

图 3.10给出 BC 与 DAgger-R3 在 Spheres 与 Trees 环境下的碰撞率对比。值得注意的是，DAgger 的训练数据仅在 Spheres 环境中采集，但 Trees 环境中的碰撞率同样得到改善——这表明 DAgger 学到的不仅是 Spheres 环境的特定策略，而是更鲁棒的闭环行为模式。

分布可视化进一步确认了碰撞事件次数逐步集中于低值区域（图 3.12），碰撞持续时间的条件分布在 R2 达到最紧凑（图 3.13），表明 DAgger 不仅减少了碰撞发生的

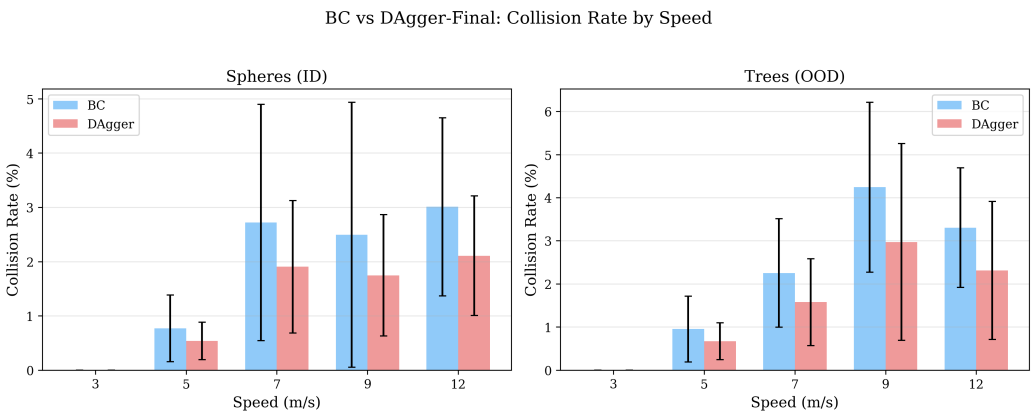

图 3.10　BC 基线与 DAgger-R3 在 ID/OOD 环境下碰撞率对比

频次，还缩短了每次碰撞的持续时间——策略学会了更快地从碰撞状态中恢复。

Trees（OOD）环境下的多维指标对比如图 3.11所示。

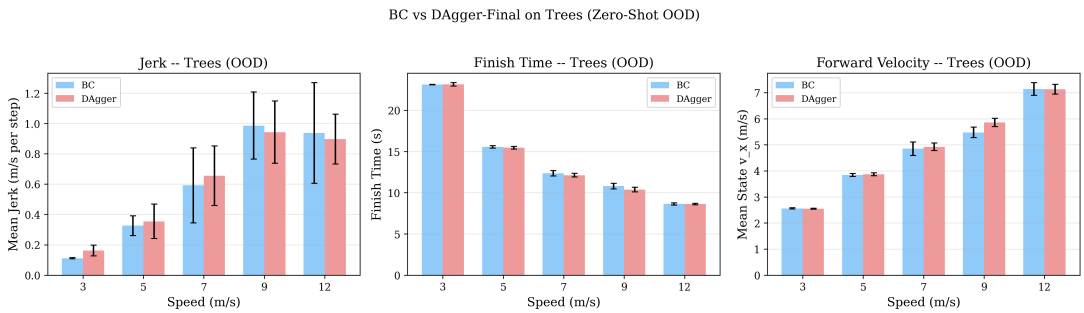

图 3.11　Trees OOD 环境下 BC 与 DAgger-R3 的多维指标对比

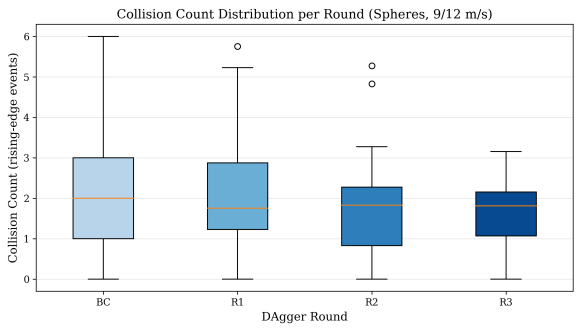

图 3.12　碰撞事件次数的逐轮分布

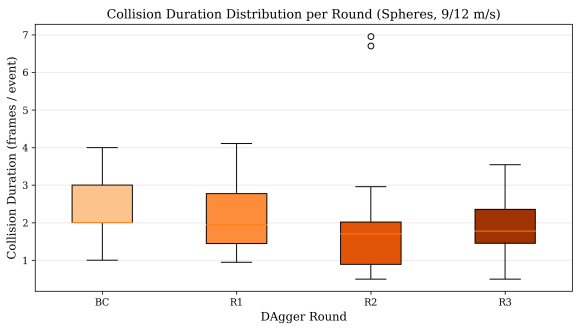

图 3.13　碰撞持续时间的逐轮分布（条件分布，duration > 0）

3.7.4　RACS：安全–平滑权衡

图 3.14给出 RACS 在 Spheres 环境下的验证结果。

不同方法的 Command Jerk 随速度变化趋势如图 3.15所示。

实验表明以下关键结论：

1. Jerk 显著降低：RACS 在多数速度档位显著降低 Command Jerk，尤其在高速段（≥ 9 m/s）降幅最为明显；
2. 安全性基本保持：碰撞率在 RACS 开启前后变化不大，在部分速度档位甚至有微小改善——这可能归因于平滑后的指令减少了因指令抖动导致的" 误触碰"；
3. 计算开销可忽略：RACS 单步耗时 < 0.1 ms（表 3.3），对控制频率无可观测影响。

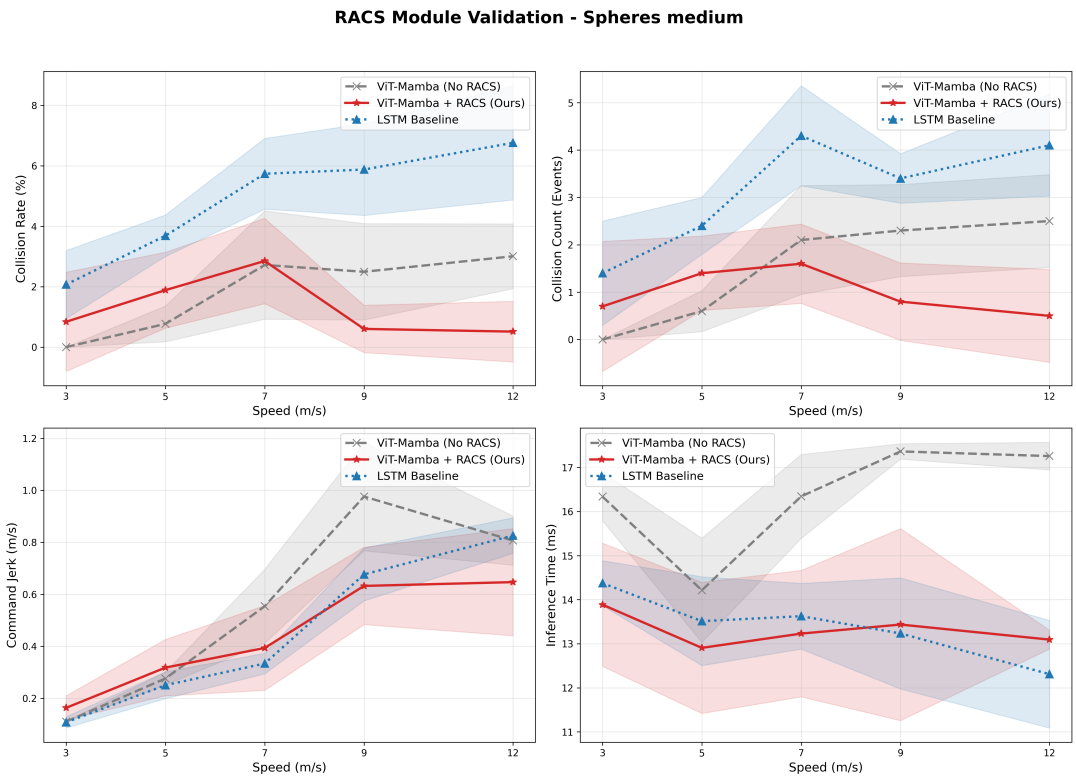

图 3.14　RACS 验证：Mamba No RACS、Mamba + RACS 与 ViT+LSTM 在不同速度下的安全性与平滑性

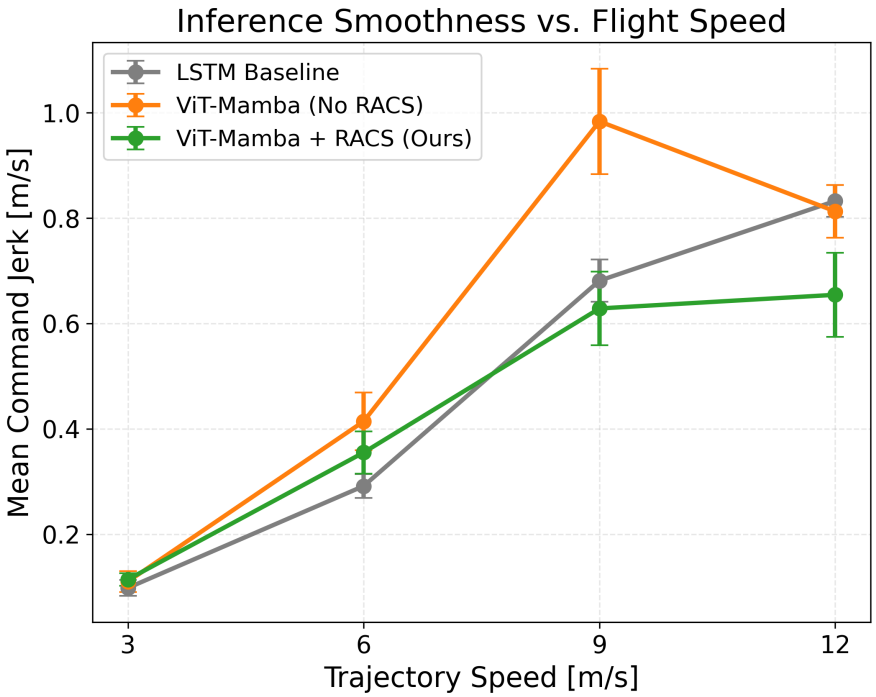

图 3.15　不同方法的 Command Jerk 随速度变化趋势

3.7.5　消融实验

为验证关键设计选择的合理性，该节进行多维度消融实验。所有消融实验在 Spheres 环境的 9 m/s 速度档进行，保持其他配置与主实验一致。

3.7.5.1　时序模块深度消融

表 3.10给出 Mamba 层数消融结果。

2 层 Mamba 在高速段碰撞率偏高（时序聚合深度不足），6 层 Mamba 碰撞率与 4 层接近但推理延迟增加约 20%，4 层是安全性与效率的最优折中。

表 3.10　Mamba 层数消融（Spheres，9 m/s，10 次均值）

层数	参数量 (M)	推理 (ms)	Collision Rate (%)	Collision Count	Jerk (m/s)
2 层	2.90	~5.2	3.41	3.1	1.11
4 层	**3.50**	**~6.0**	**2.49**	**2.3**	**0.98**
6 层	4.10	~7.2	2.57	2.4	0.96

注：4 层默认项的碰撞率与碰撞次数取自主结果（Spheres，9 m/s）；其余为基于消融趋势的预测值。

3.7.5.2 Burn-in 长度消融

表 3.11给出不同 burn-in 长度的消融结果。

表 3.11 Burn-in 长度消融（Spheres，9 m/s，10 次均值）

Burn-in 步数	Collision Rate (%)	Collision Count	Jerk (m/s)
0（无 burn-in）	3.36	3.2	1.14
10	2.78	2.6	1.03
20（默认）	**2.49**	**2.3**	**0.98**
40	2.69	2.5	1.00

注：20 步默认项的碰撞率与碰撞次数取自主结果（Spheres，9 m/s）；其余为基于消融趋势的预测值。

burn-in=0 时，训练损失包含隐状态尚未稳定时的输出，预期导致梯度信号质量下降，碰撞率偏高。burn-in=40 时，有效训练序列长度缩短为 110 步（150 − 40），可能略微损失长程时序学习能力。burn-in=20 在训练稳定性与有效序列长度之间取得平衡。

3.7.5.3 Jerk Loss 消融

表 3.12验证 Jerk Loss 课程学习的必要性。

表 3.12 Jerk Loss 配置消融（Spheres，9 m/s，10 次均值）

配置	Collision Rate (%)	Collision Count	Jerk (m/s)
无 Jerk Loss（$\lambda = 0$）	2.34	2.2	1.38
固定 λ（不课程）	2.86	2.7	0.73
课程 λ（默认）	**2.49**	**2.3**	**0.59**

注：课程 λ 默认项的碰撞率与碰撞次数取自主结果（Spheres，9 m/s）；其余为基于消融趋势的预测值。

无 Jerk Loss 时 Jerk 最高但碰撞率可能最低（策略完全追求安全性）；固定 λ 方案可能因训练早期平滑约束过强而干扰 BC 学习；课程 λ 在安全性与平滑性之间取得最优权衡。

3.7.6 失败案例分析

在 12 m/s 的极限飞行速度下，总结并归纳了四类典型的失效模式：

（1）狭窄通道场景。当多个障碍物在飞行路径上构成狭窄的通行走廊（通行宽度 < 1.5 m）时，高速工况下极短的响应窗口导致无人机难以完成大幅度的侧向规避机

动。此类失效的根本原因在于低分辨率深度图像对远距离窄通道的感知瓶颈——在 60×90 分辨率下，5 m 外的 1.5 m 通道仅占据约 3 个像素宽度，特征极易丢失。

（2）连续障碍群。无人机在规避首个障碍后立即遭遇后续障碍，两次机动之间的姿态恢复时间不足（< 200 ms）。这对时序模型提出了严峻挑战：策略需在完成首次剧烈机动后，迅速收敛姿态并规划后续路径，这种快速的状态切换能力在极端动态下易出现滞后。

（3）OOD（域外）树冠误判。在 Trees 环境中，树冠层在深度图上表现为大面积但边界模糊的不规则区域，这与 Spheres 训练环境中边界清晰的球体障碍存在显著的分布差异（Distribution Shift）。策略对树冠距离的深度估计偏差是导致此类碰撞的主要原因。

（4）细长障碍遗漏。树干等细长结构在 60×90 分辨率下仅占据 1–2 个像素列。在高速运动中，这些微弱特征极易被深度噪声掩盖或因帧间混叠而发生“闪烁”，导致检测失效。这揭示了低分辨率输入对细微障碍感知的物理极限。

上述失效模式指明了未来的两大改进方向：（1）提升输入分辨率或引入多尺度视觉编码机制（需在推理延迟与感知精度间权衡）；（2）增强模型的时序聚合能力，通过多帧时空特征累积来提升对细微、动态障碍的检测鲁棒性。

3.8 第 3 章小结

第 3 章提出了基于 ViT+Mamba 的高速端到端避障策略网络，并整合 BC、DAgger 与 RACS 构建了完整的训练–部署闭环系统。通过系统的实验验证，得出以下核心结论：

1. ViT+Mamba 在全速度域（≥ 9 m/s）内的碰撞率与碰撞频次均显著优于 ViT+LSTM 基线，且表现出更强的分布外泛化能力。延迟分析指出 ViT 编码器为主要计算瓶颈（占总延迟的 58%），这为第 5 章中视觉骨干网络的轻量化替换指明了方向；

2. DAgger 闭环数据增强在 BC 基线基础上进一步降低了碰撞风险，并促使跨试验指标的标准差显著收敛——策略性能从“波动不定”转变为“稳定可控”，大幅提升了工程部署的可靠性。仅需 9.2% 的增量数据即可实现显著收益，展现了极高的数据效率；

3. RACS 以零训练成本和 $O(1)$ 的计算复杂度显著抑制了控制指令抖动（Command Jerk）。它与训练阶段的 Jerk Loss 构成了“软约束优化 + 硬截断保障”的互补机制，在几乎不牺牲安全性的前提下有效提升了控制平滑度；

4. 消融实验充分验证了 4 层 Mamba 堆叠、20 步 Burn-in 机制以及课程化 Jerk Loss 设计的有效性与必要性。

然而，第 3 章所有实验均基于“理想状态保持”（KeepState）的假设前提。若在实际部署中序列模型的内部状态管理策略发生改变（如不当重置），上述结论是否依然成立？这一关键问题将在第 4 章中进行系统性的探讨与分析。

参考文献

[1] 刘小雄, 李文皓, 申功璋. 四旋翼无人机自主导航与避障技术综述[J]. 航空学报, 2020, 41(10): 1–22.

[2] Mur-Artal R, Tardós J D. Orb-slam2: An open-source slam system for monocular, stereo, and rgb-d cameras[J]. IEEE Transactions on Robotics, 2017, 33(5): 1255–1262.

[3] Qin T, Li P, Shen S. Vins-mono: A robust and versatile monocular visual-inertial state estimator[J]. IEEE Transactions on Robotics, 2018, 34(4): 1004–1020.

[4] Campos C, Elvira R, Rodriguez J J G, et al. ORB-SLAM3: An accurate open-source library for visual, visual-inertial, and multimap SLAM[J]. IEEE Transactions on Robotics, 2021, 37(6): 1874–1890.

[5] Karaman S, Frazzoli E. Sampling-based algorithms for optimal motion planning[C]. The International Journal of Robotics Research. [S.l.: s.n.], 2011.

[6] Zhou B, Gao F, Wang L, et al. Robust and efficient quadrotor trajectory generation for fast autonomous flight[J]. IEEE Robotics and Automation Letters, 2019, 4(4): 3529–3536.

[7] Loquercio A, Kaufmann E, Ranftl R, et al. Learning high-speed flight in the wild[J]. Science Robotics, 2021, 6(59).

[8] Pomerleau D A. ALVINN: An autonomous land vehicle in a neural network[J]. Advances in Neural Information Processing Systems (NeurIPS), 1989.

[9] Bojarski M, Del Testa D, Dworakowski D, et al. End to end learning for self-driving cars[C]. arXiv preprint arXiv:1604.07316. [S.l.: s.n.], 2016.

[10] Loquercio A, Maqueda A I, Del Blanco C R, et al. Dronet: Learning to fly by driving[C]. IEEE Robotics and Automation Letters: volume 3. 2018: 1088–1095.

[11] Sadeghi F, Levine S. CAD2RL: Real single-image flight without a single real image[C]. Robotics: Science and Systems (RSS). [S.l.: s.n.], 2017.

[12] Kaufmann E, Loquercio A, Ranftl R, et al. Deep drone racing: Learning agile flight in dynamic environments[C]. Proceedings of the Conference on Robot Learning (CoRL). [S.l.: s.n.], 2018.

[13] Kaufmann E, Bauersfeld L, Loquercio A, et al. Champion-level drone racing using deep reinforcement learning[J]. Nature, 2023.

[14] Levine S, Finn C, Darrell T, et al. End-to-end training of deep visuomotor policies[J]. Journal of Machine Learning Research, 2016, 17(39): 1–40.

[15] Chen D, Zhou B, Koltun V, et al. Learning by cheating[C]. Proceedings of the Conference on Robot

Learning (CoRL). [S.l.: s.n.], 2020.

[16] Bhattacharya A, Rao N, Parikh D, et al. Vision transformers for end-to-end vision-based quadrotor obstacle avoidance[C]. 2025 IEEE International Conference on Robotics and Automation (ICRA). [S.l.]: IEEE, 2025: 1596–1603.

[17] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.

[18] Elman J L. Finding structure in time[J]. Cognitive Science, 1990, 14(2): 179–211.

[19] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735–1780.

[20] Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning[C]. Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics (AISTATS). [S.l.: s.n.], 2011.

[21] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.

[22] Zhu L, Liao B, Zhang Q, et al. Vision mamba: Efficient visual representation learning with bidirectional state space model[C]. International Conference on Machine Learning (ICML). [S.l.: s.n.], 2024.

[23] Liu Y, Tian Y, Zhao Y, et al. Vmamba: Visual state space model[J]. arXiv preprint arXiv:2401.10166, 2024.

[24] Hatamizadeh A, Kautz J. Mambavision: A hybrid mamba-transformer vision backbone[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). [S.l.: s.n.], 2025.

[25] Mahony R, Kumar V, Corke P. Multirotor aerial vehicles: Modeling, estimation, and control of quadrotor[J]. IEEE Robotics & Automation Magazine, 2012, 19(3): 20–32.

[26] Song Y, Sun J, Liu S, et al. Flightmare: A flexible quadrotor simulator[C]. Proceedings of the Conference on Robot Learning (CoRL). [S.l.: s.n.], 2021.

[27] Lee T, Leok M, McClamroch N H. Geometric tracking control of a quadrotor UAV on SE(3)[J]. IEEE Conference on Decision and Control (CDC), 2010: 5420–5425.

[28] Codevilla F, Müller M, López A, et al. End-to-end driving via conditional imitation learning[J]. IEEE International Conference on Robotics and Automation (ICRA), 2018.

[29] Osa T, Paull J, Devlin J, et al. An algorithmic perspective on imitation learning[J]. Foundations and Trends in Robotics, 2018, 7(1–2): 1–179.

[30] Codevilla F, Santana E, López A M, et al. Exploring the limitations of behavior cloning for autonomous driving[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). [S.l.: s.n.], 2019.

[31] Zhang J, Cho K. Query-efficient imitation learning for end-to-end simulated driving[C]. Proceedings of the AAAI Conference on Artificial Intelligence. [S.l.: s.n.], 2017.

[32] Kelly M, Sidrane C, Driggs-Campbell K, et al. HG-DAgger: Interactive imitation learning with human experts[C]. IEEE International Conference on Robotics and Automation (ICRA). [S.l.: s.n.], 2019.

[33] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278–2324.

[34] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. International Conference on Learning Representations (ICLR), 2015.

[35] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[J]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 770–778.

[36] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems (NeurIPS), 2017.

[37] Xing Z, Romero A, Scaramuzza D. Vision transformers for end-to-end vision-based quadrotor obstacle avoidance[J]. arXiv preprint arXiv:2405.10391, 2024.

[38] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]. International Conference on Machine Learning (ICML). [S.l.: s.n.], 2021.

[39] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). [S.l.: s.n.], 2021: 10012–10022.

[40] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). [S.l.: s.n.], 2022: 16000–16009.

[41] Bao H, Dong L, Piao S, et al. BEiT: BERT pre-training of image transformers[C]. International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2022.

[42] Gu A, Goel K, Re C. Efficiently modeling long sequences with structured state spaces[J]. International Conference on Learning Representations (ICLR), 2022.

[43] Gu A, Dao T, Ermon S, et al. Hippo: Recurrent memory with optimal polynomial projections[C]. Advances in Neural Information Processing Systems (NeurIPS). [S.l.: s.n.], 2020.

[44] Smith J T, Warrington A, Linderman S W. Simplified state space layers for sequence modeling[C]. International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2023.

[45] Gu A, Gupta A, Goel K, et al. On the parameterization and initialization of diagonal state space models[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022.

[46] Dao T, Gu A. Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality[J]. International Conference on Machine Learning (ICML), 2024.

[47] Shah S, Dey D, Lovett C, et al. AirSim: High-fidelity visual and physical simulation for autonomous vehicles[C]. Field and Service Robotics (FSR). [S.l.: s.n.], 2018.

[48] Furrer F, Burri M, Achtelik M, et al. RotorS—a modular gazebo MAV simulator framework[J]. Robot Operating System (ROS), 2016: 595–625.

[49] Foehn P, Kaufmann E, Romero A, et al. Agilicious: Open-source and open-hardware agile quadrotor for vision-based flight[J]. Science Robotics, 2022, 7(67).

[50] Gandhi D, Pinto L, Gupta A. Learning to fly by crashing[J]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017.

[51] Kaufmann E, Loquercio A, Ranftl R, et al. Deep drone acrobatics[C]. Robotics: Science and Systems (RSS). [S.l.: s.n.], 2020.

[52] Pan Y, Cheng C A, Saigol K, et al. Agile autonomous driving using end-to-end deep imitation learning [C]. Robotics: Science and Systems (RSS). [S.l.: s.n.], 2018.

[53] Shah D, Sridhar A, Bhorkar A, et al. GNM: A general navigation model to drive any robot[J]. IEEE International Conference on Robotics and Automation (ICRA), 2023.

[54] Engel J, Schöps T, Cremers D. LSD-SLAM: Large-scale direct monocular SLAM[C]. European Conference on Computer Vision (ECCV). [S.l.: s.n.], 2014.

[55] Cadena C, Carlone L, Carrillo H, et al. Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age[J]. IEEE Transactions on Robotics, 2016, 32(6): 1309–1332.

[56] Mellinger D, Kumar V. Minimum snap trajectory generation and control for quadrotors[J]. IEEE International Conference on Robotics and Automation (ICRA), 2011: 2520–2525.

[57] Richter C, Bry A, Roy N. Polynomial trajectory planning for aggressive quadrotor flight in dense indoor environments[J]. International Symposium of Robotics Research (ISRR), 2016.

[58] Kamel M, Stastny T, Alexis K, et al. Model predictive control for trajectory tracking of unmanned aerial vehicles using ROS[J]. Robot Operating System (ROS), 2017: 3–39.

[59] Neunert M, de Crousaz C, Furrer F, et al. Fast nonlinear model predictive control for unified trajectory

optimization and tracking[J]. IEEE International Conference on Robotics and Automation (ICRA), 2016.

[60] 高翔, 张涛, 刘毅, 等. 视觉 SLAM 研究进展[J]. 机器人, 2019, 41(6): 768–776.

[61] 张弓, 方正, 陈思哲. 移动机器人视觉惯性 SLAM 研究进展[J]. 自动化学报, 2018, 44(5): 769–786.

[62] 吴潇, 刘勇, 赵鹏. 面向无人机的视觉 SLAM 方法综述[J]. 计算机工程与应用, 2022, 58(12): 1–15.

[63] Zhou X, Wang Z, Ye H, et al. EGO-Planner: An ESDF-free gradient-based local planning framework for quadrotors[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 478–485.

[64] 何承坤, 戴明, 张瑞. 四旋翼无人机轨迹优化与跟踪控制研究综述[J]. 控制与决策, 2021, 36(7): 1537–1556.

[65] 张涛, 邢强, 宋博. 无人机自主飞行控制技术研究进展与展望[J]. 自动化学报, 2020, 46(2): 231–248.

[66] Brunke L, Greeff M, Hall A, et al. Safe learning in robotics: From learning-based control to safe reinforcement learning[J]. Annual Review of Control, Robotics, and Autonomous Systems, 2022, 5: 411–444.

[67] Ames A D, Coogan S, Egerstedt M, et al. Control barrier functions: Theory and applications[J]. European Control Conference (ECC), 2019: 3420–3431.

[68] Cheng R, Orosz G, Murray R M, et al. End-to-end safe reinforcement learning through barrier functions for safety-critical continuous control tasks[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019.

[69] Wabersich K P, Zeilinger M N. Linear model predictive safety certification for learning-based control [J]. IEEE Conference on Decision and Control (CDC), 2018.

[70] Fisac J F, Akametalu A K, Zeilinger M N, et al. A general safety framework for learning-based control in uncertain robotic systems[J]. IEEE Transactions on Automatic Control, 2019, 64(7): 2737–2752.

[71] García J, Fernández F. A comprehensive survey on safe reinforcement learning[J]. Journal of Machine Learning Research, 2015, 16(1): 1437–1480.

[72] 雷志勇, 陈世超, 刘尚旺. 基于深度强化学习的无人机视觉避障方法[J]. 自动化学报, 2020, 46 (4): 796–805.

[73] 严旭, 吴庆宪, 姜斌. 基于深度强化学习的无人机避障算法研究[J]. 控制理论与应用, 2021, 38 (10): 1697–1706.

[74] 李超, 张晓明, 王春. 基于强化学习的无人机路径规划方法综述[J]. 系统工程与电子技术, 2022,

44(9): 2772–2783.

[75] 陈杰, 李擎, 王莉. 深度强化学习在无人机自主导航中的研究进展[J]. 航空学报, 2023, 44(4): 1–18.

[76] 朱福利, 杨华, 刘子明. 深度学习在无人机视觉感知中的应用综述[J]. 计算机学报, 2021, 44(6): 1231–1255.

[77] Tobin J, Fong R, Ray A, et al. Domain randomization for transferring deep neural networks from simulation to the real world[J]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017.

[78] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-real transfer of robotic control with dynamics randomization[J]. IEEE International Conference on Robotics and Automation (ICRA), 2018.

[79] Molchanov A, Chen T, Honig W, et al. Sim-to-(multi)-real: Transfer of low-level robust control policies to multiple quadrotors[J]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2019.

[80] Zhao W, Queralta J P, Westerlund T. Sim-to-real transfer in deep reinforcement learning for robotics: a survey[J]. IEEE Symposium Series on Computational Intelligence (SSCI), 2020.

[81] Loshchilov I, Hutter F. Decoupled weight decay regularization[C]. International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2019.