面向高速端到端视觉避障的 ViT+Mamba 时序建模与流式部署一致性分析

戴英特

2026 年 6 月

中图分类号： TQ028.1

UDC分类号： 540

面向高速端到端视觉避障的 ViT+Mamba 时序建模与流式部署一致性分析

作 者 姓 名 戴英特

学 院 名 称 自动化学院

指 导 教 师 甘明刚教授

答辩委员会主席 _____

申 请 学 位 工学硕士

学 科 专 业 控制工程

学位授予单位 北京理工大学

论文答辩日期 2026 年 6 月

ViT+Mamba Temporal Modeling and Streaming Deployment Consistency Analysis for High-Speed End-to-End Visual Obstacle Avoidance

Candidate Name:	Dai Yingte
School or Department:	School of Automation
Faculty Mentor:	Prof. Gan Minggang
Chair, Thesis Committee:	
Degree Applied:	Master
Major:	Control Engineering
Degree by:	Beijing Institute of Technology
The Date of Defence:	June, 2026

面向高速端到端视觉避障的ViT+Mamba时序建模与流式部署一致性分析

戴英特

北京理工大学

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下进行的研究工作获得的研究成果。尽我所知，文中除特别标注和致谢的地方外，学位论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京理工大学或其它教育机构的学位或证书所使用过的材料。与我一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此申明。

作者签名：_____　　签字日期：_____

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：①学校有权保管、并向有关部门送交学位论文的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存学位论文；③学校可允许学位论文被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换学位论文；⑤学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

作者签名：_____　　导师签名：_____

签字日期：_____　　签字日期：_____

主要符号对照表

D_t	第 t 个控制周期的深度图像观测，$D_t \in \mathbb{R}^{H\times W}$
s_t	第 t 个控制周期的轻量状态向量，$s_t = [q_t, \tilde{v}^{\text{target}}]$
o_t	第 t 个控制周期的完整观测，$o_t = (D_t, s_t)$
q_t	无人机在世界坐标系下的姿态四元数，$q_t = [w, x, y, z]$
$\tilde{v}^{\text{target}}$	归一化目标前向速度，$\tilde{v}^{\text{target}} = v^{\text{target}}/10$
$\mathbf{v}_t$	第 t 个控制周期的速度指令，$\mathbf{v}_t = [v_t^x, v_t^y, v_t^z] \in \mathbb{R}^3$
$\mathbf{v}_{\text{raw}}$	策略网络原始输出速度指令
$\mathbf{v}_{\text{cmd}}$	经 RACS 约束后最终发布的速度指令
$\mathbf{v}_{\text{prev}}$	上一控制步发布的速度指令
π_θ	参数为 θ 的端到端策略网络
π^*	特权信息专家策略
$\mathbf{h}_t$	序列模型（Mamba/LSTM）在第 t 步的内部隐状态
$\mathbf{A}, \mathbf{B}, \mathbf{C}, \mathbf{D}$	连续时间状态空间模型的系统矩阵
$\bar{\mathbf{A}}, \bar{\mathbf{B}}$	零阶保持离散化后的状态空间参数矩阵
Δ	Mamba 选择性机制中的输入相关离散化步长
δ_t	RACS 动态速率上界
$d_{\min,t}$	第 t 步深度图像中的最小深度观测值
$\mathcal{L}_{\text{BC}}$	行为克隆监督损失（MSE）
$\mathcal{L}_{\text{jerk}}$	指令抖动惩罚损失
λ_{jerk}	Jerk Loss 权重系数
β	DAgger 中的专家混合比例
T	回合总帧数 / 序列长度
$\tau_{\max}$	最大回合时长（40 s）
d_{model}	Mamba 模块的模型维度（192）
d_{state}	Mamba 模块的状态维度（64）
BC	行为克隆（Behavioral Cloning）
DAgger	数据集聚合（Dataset Aggregation）
RACS	动态速率限制控制平滑器（Rate-Adaptive Control Smoother）

SSM	结构化状态空间模型（Structured State Space Model）
ViT	视觉 Transformer（Vision Transformer）
ID	同分布（In-Distribution）
OOD	分布外（Out-of-Distribution）

目 录

摘要 I
Abstract III
主要符号对照表 V
第 1 章 绪论 1
1.1 研究背景与应用场景 1
1.1.1 高速闭环的延迟预算分析 2
1.1.2 高速下的误差放大机制 2
1.1.3 端到端范式需要时序建模的直觉 4
1.2 问题定义 6
1.2.1 输入-输出接口 6
1.2.2 部分可观测性与序列建模的必要性 7
1.3 关键挑战 8
1.3.1 挑战一：时序建模与高速决策 8
1.3.2 挑战二：流式部署一致性 8
1.3.3 挑战三：算力约束与高效视觉骨干 9
1.4 研究贡献 10
1.5 论文结构安排 11
第 2 章 预备知识与相关工作 13
2.1 四旋翼控制接口与任务抽象 13
2.1.1 坐标系与控制量定义 13
2.1.2 任务形式化 14
2.1.3 控制回路与低层控制器假设 14
2.1.4 安全指标与任务完成条件 15

2.2 模仿学习与分布偏移：BC 与 DAgger 15
2.2.1 行为克隆（BC） 15
2.2.2 分布偏移与误差累积 15
2.2.3 DAgger：数据集聚合 16
2.3 视觉表征：CNN 与 ViT 18
2.3.1 卷积神经网络 18
2.3.2 视觉 Transformer（ViT） 18
2.3.3 轻量化 ViT 的设计维度 19
2.4 时序建模：RNN/LSTM 与 SSM 20
2.4.1 LSTM 的流式优势与局限 20
2.4.2 结构化状态空间模型（S4） 20
2.4.3 从连续到离散的零阶保持（ZOH）推导 21
2.4.4 Mamba 的选择性机制 21
2.4.5 SSM 对控制任务的意义 23
2.5 MambaVision：混合 Mamba-Transformer 视觉骨干 24
2.6 仿真平台与数据来源 25
2.6.1 Flightmare 仿真平台 25
2.6.2 评测环境 25
2.6.3 特权信息专家策略 25
2.6.4 数据采集管线 27
2.7 评测协议与指标 27
2.7.1 统一评测协议 27
2.7.2 指标定义 27
2.7.3 指标计算伪代码 28
2.7.4 统计显著性与不确定性报告 28
2.7.5 评测可审计规范 29

2.8 相关工作综述 30
2.8.1 端到端视觉飞行控制 30
2.8.2 模块化自主飞行 31
2.8.3 安全性与部署侧约束 31
2.8.4 Sim-to-Real 迁移 32
2.8.5 方法谱系总结 32
2.9 小结：设计需求 32
第 3 章 面向高速避障的 ViT+Mamba 端到端策略 34
3.1 第 3 章引言 34
3.2 问题形式化 35
3.3 模型结构 35
3.3.1 总体架构 35
3.3.2 视觉编码器：轻量化 ViT 36
3.3.3 时序聚合模块：Temporal Mamba 36
3.3.4 特征融合与控制头 37
3.3.5 基线设置：ViT+LSTM 37
3.3.6 设计选择讨论 37
3.3.7 复杂度与推理延迟分析 38
3.4 DAgger 闭环数据增强 38
3.4.1 动机与方法 38
3.4.2 执行配置 39
3.4.3 数据集构成与速度档分布 39
3.4.4 轮次收敛的机制解释 39
3.5 RACS 动态速率限制平滑器 40
3.5.1 背景与动机 40
3.5.2 约束建模与求解 40
3.5.3 δ_t 动态调度函数 41
3.5.4 边界情况与失败模式分析 42

3.5.5 与训练期 Jerk Loss 的关系 42
3.5.6 算法复杂度与 RACS 伪代码 43
3.6 训练细节 43
3.7 案例研究与实验 44
3.7.1 主结果：ViT+Mamba 与 ViT+LSTM 的系统对比 45
3.7.2 推理延迟与系统时序分析 46
3.7.3 DAgger 轮次实验：碰撞频次与方差收敛 47
3.7.4 RACS：安全–平滑权衡 49
3.7.5 消融实验 51
3.7.6 失败案例分析 52
3.8 第 3 章小结 53
第 4 章 流式部署一致性与状态生命周期管理 55
4.1 第 4 章引言 55
4.2 Batch–Streaming 等价性定义 56
4.2.1 Batch 训练模式 56
4.2.2 Streaming 推理模式 57
4.2.3 等价性条件 57
4.2.4 SSM 线性递推的等价性推导 58
4.2.5 对 LSTM/GRU 与 Transformer KV-Cache 的类比 58
4.3 状态生命周期协议 60
4.3.1 错误状态重置的退化机理 60
4.3.2 回合边界级状态管理协议 60
4.3.3 实现细节 61
4.3.4 常见工程错误与症状对照 62
4.4 等价性单测与硬防护机制 63
4.4.1 等价性单测 63
4.4.2 阈值选择依据 63
4.4.3 硬防护机制 64

4.5 案例研究与实验 64
4.5.1 KeepState 与 ResetState 对比 65
4.5.2 LSTM 的状态重置退化 66
4.5.3 漂移可视化 66
4.5.4 等价性单测结果 68
4.5.5 重置频率消融 68
4.5.6 部署 burn-in 消融 69
4.5.7 跨速度泛化验证 70
4.6 第 4 章小结 71
第 5 章 全 SSM 架构探索：MambaVision 替代的系统消融实验 73
5.1 实验目标与评价问题定义 73
5.2 实验环境、数据与评测协议 75
5.2.1 评测环境与速度档 75
5.2.2 指标体系 75
5.2.3 系统架构与控制变量 75
5.3 消融实验框架与对照组 76
5.3.1 对照组与实验组定义 76
5.3.2 消融验证原则 76
5.3.3 控制变量声明 77
5.4 深度归一化一致性验证 77
5.4.1 训练与评测归一化口径差异 77
5.4.2 输入分布偏移机制分析 78
5.4.3 定量验证结果 78
5.4.4 实验规范锁定 80
5.5 输入分辨率瓶颈验证 81
5.5.1 分辨率瓶颈分析 81
5.5.2 实验设置 82
5.5.3 定量结果 82

5.5.4 速度段差异分析 83
5.5.5 计算开销评估 84
5.5.6 小结 84
5.6 视觉骨干受控解冻实验 85
5.6.1 动机与控制变量声明 85
5.6.2 实验配置 85
5.6.3 结果分析 86
5.6.4 原因讨论 87
5.6.5 结论与局限性 88
5.7 结构改动与动作蒸馏实验 88
5.7.1 特征条件池化 89
5.7.2 动作知识蒸馏 89
5.7.3 高速段尾部风险分析 91
5.7.4 保守归因与局限性 92
5.8 风险状态补分布蒸馏 93
5.8.1 核心假设 93
5.8.2 方法：风险状态采集与加权微调 93
5.8.3 高速段蒸馏效果验证 95
5.9 低速补强与最终模型综合评估 97
5.9.1 “平滑性提升却导致碰撞率增加”的失败模式 97
5.9.2 教师 Omega 事件触发的低速补强 99
5.9.3 版本对照与控制变量 100
5.9.4 Spheres 环境综合对比 101
5.9.5 Trees（OOD）泛化验证 104
5.9.6 推理效率与部署可行性 104
5.9.7 综合数据表 105
5.9.8 迭代路径总结 107
5.10 第 5 章小结 107

结论 109
参考文献 112
攻读学位期间发表论文与研究成果清单 118
致谢 119

插 图

图 1.1 四旋翼无人机高速避障的典型应用场景与共性挑战 1
图 1.2 高速闭环控制中的误差放大链路 3
图 1.3 高速飞行中的误差放大与累积示意：深度噪声与运动模糊导致实际轨迹偏离理想轨迹，误差随时间步持续放大 3
图 1.4 模块化导航范式与端到端控制范式的对比：左侧为传统模块化流水线（Sensor→SLAM→Mapping→Planning→Low-Level Control），延迟逐级累积；右侧为端到端学习控制，传感器输出经神经网络直接映射为控制指令，显著降低延迟 5
图 1.5 端到端视觉避障任务闭环控制流程 7
图 1.6 训练 Batch 模式与部署 Streaming 模式的状态管理差异，以及错误的逐步重置导致的无记忆退化 9
图 1.7 自注意力机制 $O(n^2)$ 与 SSM 线性 $O(n)$ 复杂度的对比示意 10
图 1.8 该研究技术路线总览 11
图 2.1 世界坐标系与机体坐标系定义，以及速度指令接口 13
图 2.2 行为克隆（BC）端到端训练流程：左侧由专家策略 π^* 在环境中采集观测–动作对构成数据集 $\mathcal{D}$；中间将序列观测输入端到端神经网络 π_θ 预测动作 $\hat{a}_t$；右侧通过 MSE 损失 $\mathcal{L} = \|a_t - \hat{a}_t\|^2$ 计算梯度并反向传播更新网络参数 16
图 2.3 DAgger 数据聚合闭环流程 17
图 2.4 DAgger 迭代式数据聚合全流程示意：上层为环境交互阶段，混合策略 $\hat{\pi}_i = \beta_i \pi^* + (1-\beta_i)\pi_i$ 在环境中采集轨迹并由专家 π^* 修正标注；中层为数据聚合阶段，新采集数据 $\mathcal{D}_{\text{new}}$ 与历史数据集 $\mathcal{D}_i$ 合并；下层为训练更新阶段，以聚合数据集重训策略 π_{i+1}。右侧对比图展示 BC 误差 $O(T^2)$ 增长与 DAgger 误差 $O(1)$ 收敛的理论差异 17
图 2.5 ViT 的 patch token 化与 Transformer 编码流程示意 19

图 2.6 SSM/Mamba 的三层架构总览。上层：连续时间状态空间方程 $\mathbf{h}'(t) = \mathbf{A}\mathbf{h}(t) + \mathbf{B}\mathbf{x}(t)$，其中 $\mathbf{A}$ 驱动状态演化，$\mathbf{B}$ 控制输入注入，$\mathbf{C}$ 负责状态读出；中层：基于零阶保持（ZOH）的离散化过程，将连续参数转化为离散递推形式 $\bar{\mathbf{A}} = e^{\mathbf{A}\Delta}$；下层：Mamba 的选择性机制，展示了参数 Δ_t、$\mathbf{B}_t$、$\mathbf{C}_t$ 如何依赖输入 $\mathbf{x}_t$ 进行动态调制。右侧示意图类比了其自适应控制逻辑与 LSTM 门控机制的异同。 22

图 2.7 SSM/Mamba 离散化后的状态更新机制。下标 t 强调了参数 $\bar{\mathbf{B}}_t$ 与 $\mathbf{C}_t$ 随输入动态变化的选择性特性。 23

图 2.8 Attention、SSM 与 LSTM 的序列长度–计算量关系对比（示意） 24

图 2.9 Flightmare 仿真平台中两类评测环境的实拍截图。(a) Spheres 环境：三维空间中随机分布不同半径的球体障碍，训练数据在该环境中生成；(b) Trees 环境：由树干与冠层构成的自然场景，策略从未在此环境中训练，用于测试零样本迁移泛化能力 26

图 2.10 基于 Flightmare 与特权信息专家的数据采集管线 27

图 2.11 碰撞事件次数的上升沿检测计算示意 29

图 3.1 第 3 章组织结构：架构设计、训练增强与部署约束三线汇聚于实验验证 34

图 3.2 ViT+Mamba 端到端策略网络总体架构 35

图 3.3 RACS 几何投影示意：将超出约束的 $\mathbf{v}_{\text{raw}}$ 投影至 δ_t-球面边界 41

图 3.4 $\delta_t(d_{\min,t})$ 调度曲线示意 42

图 3.5 ViT+Mamba 与 ViT+LSTM 在 Spheres/Trees 环境下的性能对比。（a）全程碰撞率；（b）碰撞事件次数；（c）Command Jerk；（d）单步推理时间。 45

图 3.6 控制循环周期 Δt 的分布统计，验证不同方法的系统时序一致性 47

图 3.7 碰撞事件次数随 DAgger 轮次变化（9 m/s 与 12 m/s），误差条表示 10 次试验标准差 47

图 3.8 平均碰撞持续时间随 DAgger 轮次变化 48

图 3.9 碰撞指标跨试验标准差随 DAgger 轮次的演化 48

图 3.10 BC 基线与 DAgger-R3 在 ID/OOD 环境下碰撞率对比 49

图 3.11 Trees OOD 环境下 BC 与 DAgger-R3 的多维指标对比 49

图 3.12 碰撞事件次数的逐轮分布 49

图 3.13 碰撞持续时间的逐轮分布（条件分布，duration > 0） 49

图 3.14 RACS 验证：Mamba No RACS、Mamba + RACS 与 ViT+LSTM 在不同速度下的安全性与平滑性 50
图 3.15 不同方法的 Command Jerk 随速度变化趋势 51
图 4.1 第 4 章逻辑链路：从问题揭示到形式化、协议设计与实验验证 56
图 4.2 状态重置导致的级联退化因果链 60
图 4.3 状态生命周期状态机：Init→Warmup→Run→Terminate→Reset 61
图 4.4 Batch 模式与正确/错误 Streaming 模式的时间轴对比 61
图 4.5 KeepState 与 ResetState 的漂移对比。ResetState（红色）导致显著的横向漂移趋势，而 KeepState（绿色）的轨迹保持稳定。 66
图 4.6 KeepState 与 ResetState 模式下横向漂移的累积对比 67
图 4.7 Batch–Streaming 等价性测试：KeepState 下 $\Delta\mathbf{v}_t$ 在 10^{-6} 量级（蓝色），ResetState 下 $\Delta\mathbf{v}_t$ 在 10^{-1} 量级（红色），两者差 5 个数量级 68
图 4.8 重置频率消融实验结果：重置越频繁，碰撞率、Jerk 与横向漂移越高。 . 69
图 4.9 部署 burn-in 消融实验结果：适度 burn-in 对碰撞率改善有限，但可稳定降低 Jerk 与漂移。 70
图 4.10 KeepState 与 ResetState 跨速度碰撞率对比：ResetState 的碰撞率随速度上升快速放大。 70
图 4.11 KeepState 与 ResetState 跨速度横向漂移对比：ResetState 在全速度域均表现出更大的横向漂移。 71
图 5.1 逐步消融验证决策流程图。每一阶段验证单一假设，通过则锁定该变量进入下一阶段，失败则记录归因并探索替代路线。最终收敛到可用版本 74
图 5.2 MambaVision 替代实验系统架构。虚线框标注的视觉编码器为唯一变量，其余模块（时序 Mamba、控制头、部署协议）在所有实验中保持固定 76
图 5.3 深度归一化口径偏移对速度效率与碰撞事件的影响。(a) 各速度段的平均前向速度在 png255 模式下均显著低于 threshold 模式，12 m/s 段降幅达 34%；(b) 5 m/s 段碰撞事件次数从 72.2 降至 13.6 属速度退化导致的表面改善，12 m/s 段碰撞事件次数反而从 7.6 升至 15.0，揭示控制衰减而非鲁棒性提升的本质 79

图 5.4　输入分辨率从 60×90 提升至 128×192 后的碰撞事件与速度效率变化。(a) 碰撞事件次数在所有速度段均显著下降，5 m/s 段降幅达 72.9%；(b) 各速度段平均前向速度均有提升，推理延迟仅从约 20 ms 增至 21 ms（+5%） 83

图 5.5　Stage 3 解冻前后的安全–速度权衡散点图（mean collision count vs mean V_x）。红色点（Stage 3 解冻方案）相比蓝色点（冻结高分辨率方案）在所有速度段均向右移动（碰撞增加），9 m/s 与 12 m/s 段速度基本持平，表明碰撞恶化并非速度变化的副产物。灰色点为 ViT+Mamba 基线 86

图 5.6　各消融阶段在 5 m/s、9 m/s、12 m/s 三个速度段的碰撞事件次数 (a) 与平均前向速度 (b) 对比。星号标注该速度段最优方法。特征条件池化（FC-Pool）与动作蒸馏（ActionKD）均在 5 m/s 段碰撞略有改善，但在 9 m/s 与 12 m/s 段碰撞次数均高于冻结基线（蓝色），速度效率在各方法间无显著差异 90

图 5.7　12 m/s 高速段各方法逐试验碰撞次数分布。菱形标注均值，水平线标注中位数，虚线为冻结基线中位数（= 6）作为基准参照。动作蒸馏（103-B KD）的标准差达 7.4，且出现单次试验碰撞次数超过 25 的极端离群值 92

图 5.8　风险状态蒸馏各阶段碰撞率对比。V_mid（橙色）相比 V_frozen（蓝色）在 9 m/s 与 12 m/s 段碰撞率显著下降，但 3 m/s 与 5 m/s 段碰撞率大幅上升。V_final（绿色）在全速度段均达到最低碰撞率 95

图 5.9　风险状态蒸馏各阶段平均前向速度对比。三个版本的 Mean V_x 高度接近，确认碰撞率变化并非降速的副产物 96

图 5.10　5 m/s 场景下不同补强策略的碰撞率对比。与中间版本（V_mid）相比，基于 $d_{\min}$ 触发的补强版本（V_fail）碰撞率不降反升（从 4.66% 升至 5.67%，增幅 21.7%），而基于 Omega 事件触发的最终版本则显著降至 0.56%。 98

图 5.11　5 m/s 场景下不同补强策略的指令抖动对比。V_fail 版本的 Jerk 从 0.08 锐减至 0.01（降幅 87.5%），控制输出极度平滑但碰撞率却发生恶化，呈现出典型的“平滑失效”特征。 98

图 5.12　Spheres 环境碰撞率对比。MV+Mamba 最终版在所有速度段碰撞率均不高于基线，12 m/s 高速段碰撞率降幅达 55.5% 101

图 5.13　Spheres 环境碰撞事件次数对比。MV+Mamba 最终版在 5 m/s–12 m/s 段碰撞事件次数均低于基线 102

图 5.14　Spheres 环境单位距离碰撞密度对比。MV+Mamba 最终版在高速段 CPM 优于基线，7 m/s 段差异在误差范围内 102
图 5.15　Spheres 环境平均前向速度对比。MV+Mamba 最终版在所有速度段均高于基线，证明安全性优势并非通过降速实现 103
图 5.16　Spheres 环境指令抖动对比。MV+Mamba 最终版在多数速度段 Jerk 显著更低，且碰撞率同步改善，构成安全性与平滑性的双重提升 103
图 5.17　Trees（OOD）环境碰撞率对比。MV+Mamba 最终版在中高速段（7 m/s–12 m/s）碰撞率大幅优于基线，体现显著的 OOD 泛化优势 104
图 5.18　推理延迟对比。MV+Mamba 最终版推理延迟约 21 ms–23 ms，高于基线（约 14 ms–17 ms），但仍远低于 50 ms 实时控制阈值 105
图 5.19　从冻结高分辨率基线到 MV+Mamba 最终版的迭代链路与分支决策。左侧主线给出四阶段迭代，其中数据侧转向框内并入 (§5.8) 与 (§5.9) 的关键细节；右侧汇总 (§5.6–5.7) 中已验证但否决的替代路线及其失败结论。 107

表 格

表 1.1 端到端避障系统延迟预算分解 2
表 2.1 不同输入分辨率与 Patch Size 下的 Token 数量与注意力复杂度 19
表 2.2 SSM 特性与高速避障控制需求的映射 23
表 2.3 评测环境配置 25
表 2.4 特权信息专家策略超参数 26
表 2.5 统一评测协议 27
表 2.6 评测指标定义与计算口径 28
表 2.7 高速端到端视觉避障相关技术路线对比 32
表 3.1 ViT 编码器各阶段张量尺寸 36
表 3.2 Temporal Mamba 模块配置 36
表 3.3 各模块推理耗时分析（RTX 4060，float32，单帧） 38
表 3.4 DAgger 迭代执行配置 39
表 3.5 DAgger 各轮新增轨迹的速度档分布 39
表 3.6 RACS 超参数 42
表 3.7 策略网络训练超参数配置 44
表 3.8 Spheres 环境主结果：碰撞率与碰撞事件次数（均值 ±std） 46
表 3.9 Trees 环境主结果：碰撞率与碰撞事件次数（均值 ±std） 46
表 3.10 Mamba 层数消融（Spheres，9 m/s，10 次均值） 51
表 3.11 Burn-in 长度消融（Spheres，9 m/s，10 次均值） 52
表 3.12 Jerk Loss 配置消融（Spheres，9 m/s，10 次均值） 52
表 4.1 不同序列模型的内部状态与错误重置后果类比 59
表 4.2 常见状态管理工程错误与症状对照 62
表 4.3 等价性测试配置与通过标准 64
表 4.4 可审计日志字段定义 65
表 4.5 Mamba 流式状态管理消融实验（KeepState vs ResetState，Spheres 7 m/s） 65

表 4.6　LSTM 流式状态管理消融实验（KeepState vs ResetState，Spheres 7 m/s）　66
表 5.1　MambaVision 替换实验控制变量声明 77
表 5.2　深度归一化口径一致性验证定量结果（均值 ± 标准差，每档 10 次试验）。threshold 为训练阶段配置，png255 为口径偏移配置。加粗行标注最终锁定的归一化模式 79
表 5.3　MambaVision-T 各 Stage 空间 token 数量随输入分辨率的变化。低分辨率下深层 Stage 的 token 数量急剧退化，构成空间表征能力的结构性瓶颈 81
表 5.4　输入分辨率瓶颈验证定量结果（每档 10 次试验）。60×90 为基线低分辨率配置，128×192 为提升后配置。加粗行标注最终锁定的分辨率 82
表 5.5　视觉骨干受控解冻实验配置。相比前一阶段（冻结高分辨率方案），唯一变化为 Stage 3 由冻结变为可训练（加粗标注） 86
表 5.6　风险状态蒸馏中间版本（V_mid）评测结果。加粗标注各速度段最优值。V_mid 在高速段（9 m/s、12 m/s）碰撞率大幅改善，但低速段（3 m/s、5 m/s）碰撞率显著恶化 96
表 5.7　风险状态蒸馏各版本对照表。每行仅标注相对前一版本的唯一变化 100
表 5.8　推理效率与模型参数对比 105
表 5.9　Spheres 环境综合对比（均值 ±std，每档 10 次试验）。加粗标注各速度段各指标的优势方 106
表 5.10　Trees（OOD）环境综合对比（均值 ±std，每档 10 次试验） 106

结论

该研究面向高速端到端视觉避障控制任务，围绕”时序建模升级与训练方法、流式部署一致性、全 SSM 架构探索”三个核心维度，构建了完整的端到端闭环控制系统，并进行了系统化的实验评测与分析。以下总结该研究的主要工作、核心发现与不足之处，并展望未来研究方向。

主要工作与核心发现

（1）提出 ViT+Mamba 高速端到端避障策略并构建完整的训练与部署系统（第 3 章）。该研究构建了以 ViT 空间编码、Mamba 选择性状态空间模型时序聚合与线性控制头为核心的端到端策略网络，采用行为克隆（BC）范式在 Flightmare 仿真平台中训练。在 Spheres（同分布）与 Trees（分布外）两类环境、3–12 m/s 五档速度下的系统评测表明，ViT+Mamba 相比 ViT+LSTM 基线在高速段显著降低碰撞率与碰撞事件次数，且在零样本 OOD 场景中仍保持优势。在 BC 基线的基础上，进一步引入 3 轮 DAgger 迭代式闭环数据增强，在高速段碰撞事件次数与碰撞持续时间进一步降低，跨试验标准差显著收敛。部署侧 RACS 动态速率限制模块以低于 0.1 ms 的开销有效降低 Command Jerk。

（2）揭示流式部署中的无记忆退化现象并提出状态生命周期管理协议（第 4 章）。该研究系统分析了序列模型在训练（Batch 前向）与部署（Streaming 逐步递推）之间的语义差异，揭示了错误的逐步状态重置会使序列模型退化为无记忆策略，导致碰撞率从 0% 跃升至 90%、横向漂移达 0.770 m 的严重后果。为此提出回合边界级状态生命周期管理协议，并实现运行时断言、配置锁定与可审计日志等硬防护机制，确保评测结论不受实现细节污染。

（3）通过逐步消融验证方法学系统探索 MambaVision 替代 ViT 视觉编码器的可行性（第 5 章）。在保持时序 Mamba 模块、训练流程与部署协议完全不变的条件下，该研究将视觉编码器替换为 MambaVision，依次完成归一化口径一致性锁定、输入分辨率提升验证（$60\times90 \rightarrow 128\times192$）、骨干解冻与结构/蒸馏路线的失败归因分析，最终通过风险状态补分布蒸馏实现突破。最终模型在 Trees（OOD）环境中高速段碰撞率降幅达 56%–84%，平均前向速度提升 40% 以上；在 Spheres（ID）环境中安全性与基线可比且飞行效率更高；推理延迟约 21 ms，仍满足实时闭环控制要求。消融实验同时揭示了”更平滑但更撞”的失败模式，证明平滑性不能单独作为安全性的代理指标。

不足与局限性

1. 该研究仍存在以下局限：

2. 仿真环境局限：所有实验在 Flightmare 仿真平台中完成，尚未进行真实环境（Sim-to-Real）验证。仿真与真实之间的传感噪声、气动效应与延迟特性差异可能影响策略在真实部署中的表现。

3. 静态障碍假设：当前评测环境中的障碍物均为静态，未涉及动态障碍（如运动物体、其他飞行器）的避障场景。

4. 单一传感模态：策略仅使用单目深度图像作为视觉输入，未融合 RGB 图像、激光雷达或事件相机等多模态信息。

5. DAgger 规模有限：该研究实施的 DAgger 仅执行了 3 轮迭代，每轮新增 18 条轨迹，数据增量较小。DAgger 的安全性提升上界有待在更大采集规模、更多迭代轮次与更高难度环境配置下进一步验证。

6. RACS 的启发式特性：RACS 的动态速率上界 δ_t 基于最小深度的启发式规则，缺乏形式化安全保证。

7. MambaVision 骨干冻结限制：第 5 章实验中 MambaVision 骨干完全冻结，未充分发掘任务自适应微调的潜力；风险状态触发条件依赖启发式规则，缺乏形式化保证。

未来工作展望

1. 基于该研究基础，后续工作将在以下方向展开：

2. DAgger 更大规模扩展：在当前 3 轮 DAgger 的基础上，增加迭代轮次（5 轮以上）、引入更困难的环境配置（更高密度障碍、更极端速度）、扩大每轮采集规模，系统探索 DAgger 在高速避障任务中的收益上界。

3. 风险状态补分布方法深化：将第 5 章的启发式风险状态触发条件升级为数据驱动的风险估计，探索更高分辨率的教师策略以消除 teacher-student 分辨率差异对蒸馏效果的限制。

4. 仿真到真实迁移：结合域随机化、系统辨识与真实飞行数据校正，将策略部署到真实四旋翼平台上进行验证。

5. 动态障碍应对：扩展评测环境以包含动态障碍物，探索策略在时变环境中的避障能力。

6. 多模态融合：探索将 RGB 图像、事件相机等多模态信息融合到视觉编码器中，提升感知鲁棒性。

7. RACS 向风险自适应升级：将 RACS 的启发式规则升级为基于 TTC 或碰撞概率的数据驱动风险估计，或与 CBF/MPSC 等安全证书方法进行融合，提供更严格的安全保证。

参考文献

[1] 刘小雄, 李文皓, 申功璋. 四旋翼无人机自主导航与避障技术综述[J]. 航空学报, 2020, 41(10): 1–22.

[2] Mur-Artal R, Tardós J D. Orb-slam2: An open-source slam system for monocular, stereo, and rgb-d cameras[J]. IEEE Transactions on Robotics, 2017, 33(5): 1255–1262.

[3] Qin T, Li P, Shen S. Vins-mono: A robust and versatile monocular visual-inertial state estimator[J]. IEEE Transactions on Robotics, 2018, 34(4): 1004–1020.

[4] Campos C, Elvira R, Rodriguez J J G, et al. ORB-SLAM3: An accurate open-source library for visual, visual-inertial, and multimap SLAM[J]. IEEE Transactions on Robotics, 2021, 37(6): 1874–1890.

[5] Karaman S, Frazzoli E. Sampling-based algorithms for optimal motion planning[C]. The International Journal of Robotics Research. [S.l.: s.n.], 2011.

[6] Zhou B, Gao F, Wang L, et al. Robust and efficient quadrotor trajectory generation for fast autonomous flight[J]. IEEE Robotics and Automation Letters, 2019, 4(4): 3529–3536.

[7] Loquercio A, Kaufmann E, Ranftl R, et al. Learning high-speed flight in the wild[J]. Science Robotics, 2021, 6(59).

[8] Pomerleau D A. ALVINN: An autonomous land vehicle in a neural network[J]. Advances in Neural Information Processing Systems (NeurIPS), 1989.

[9] Bojarski M, Del Testa D, Dworakowski D, et al. End to end learning for self-driving cars[C]. arXiv preprint arXiv:1604.07316. [S.l.: s.n.], 2016.

[10] Loquercio A, Maqueda A I, Del Blanco C R, et al. Dronet: Learning to fly by driving[C]. IEEE Robotics and Automation Letters: volume 3. 2018: 1088–1095.

[11] Sadeghi F, Levine S. CAD2RL: Real single-image flight without a single real image[C]. Robotics: Science and Systems (RSS). [S.l.: s.n.], 2017.

[12] Kaufmann E, Loquercio A, Ranftl R, et al. Deep drone racing: Learning agile flight in dynamic environments[C]. Proceedings of the Conference on Robot Learning (CoRL). [S.l.: s.n.], 2018.

[13] Kaufmann E, Bauersfeld L, Loquercio A, et al. Champion-level drone racing using deep reinforcement learning[J]. Nature, 2023.

[14] Levine S, Finn C, Darrell T, et al. End-to-end training of deep visuomotor policies[J]. Journal of Machine Learning Research, 2016, 17(39): 1–40.

[15] Chen D, Zhou B, Koltun V, et al. Learning by cheating[C]. Proceedings of the Conference on Robot

Learning (CoRL). [S.l.: s.n.], 2020.

[16] Bhattacharya A, Rao N, Parikh D, et al. Vision transformers for end-to-end vision-based quadrotor obstacle avoidance[C]. 2025 IEEE International Conference on Robotics and Automation (ICRA). [S.l.]: IEEE, 2025: 1596–1603.

[17] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.

[18] Elman J L. Finding structure in time[J]. Cognitive Science, 1990, 14(2): 179–211.

[19] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735–1780.

[20] Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning[C]. Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics (AISTATS). [S.l.: s.n.], 2011.

[21] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.

[22] Zhu L, Liao B, Zhang Q, et al. Vision mamba: Efficient visual representation learning with bidirectional state space model[C]. International Conference on Machine Learning (ICML). [S.l.: s.n.], 2024.

[23] Liu Y, Tian Y, Zhao Y, et al. Vmamba: Visual state space model[J]. arXiv preprint arXiv:2401.10166, 2024.

[24] Hatamizadeh A, Kautz J. Mambavision: A hybrid mamba-transformer vision backbone[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). [S.l.: s.n.], 2025.

[25] Mahony R, Kumar V, Corke P. Multirotor aerial vehicles: Modeling, estimation, and control of quadrotor[J]. IEEE Robotics & Automation Magazine, 2012, 19(3): 20–32.

[26] Song Y, Sun J, Liu S, et al. Flightmare: A flexible quadrotor simulator[C]. Proceedings of the Conference on Robot Learning (CoRL). [S.l.: s.n.], 2021.

[27] Lee T, Leok M, McClamroch N H. Geometric tracking control of a quadrotor UAV on SE(3)[J]. IEEE Conference on Decision and Control (CDC), 2010: 5420–5425.

[28] Codevilla F, Müller M, López A, et al. End-to-end driving via conditional imitation learning[J]. IEEE International Conference on Robotics and Automation (ICRA), 2018.

[29] Osa T, Paull J, Devlin J, et al. An algorithmic perspective on imitation learning[J]. Foundations and Trends in Robotics, 2018, 7(1–2): 1–179.

[30] Codevilla F, Santana E, López A M, et al. Exploring the limitations of behavior cloning for autonomous driving[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). [S.l.: s.n.], 2019.

[31] Zhang J, Cho K. Query-efficient imitation learning for end-to-end simulated driving[C]. Proceedings of the AAAI Conference on Artificial Intelligence. [S.l.: s.n.], 2017.

[32] Kelly M, Sidrane C, Driggs-Campbell K, et al. HG-DAgger: Interactive imitation learning with human experts[C]. IEEE International Conference on Robotics and Automation (ICRA). [S.l.: s.n.], 2019.

[33] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278–2324.

[34] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. International Conference on Learning Representations (ICLR), 2015.

[35] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[J]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 770–778.

[36] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems (NeurIPS), 2017.

[37] Xing Z, Romero A, Scaramuzza D. Vision transformers for end-to-end vision-based quadrotor obstacle avoidance[J]. arXiv preprint arXiv:2405.10391, 2024.

[38] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]. International Conference on Machine Learning (ICML). [S.l.: s.n.], 2021.

[39] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). [S.l.: s.n.], 2021: 10012–10022.

[40] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). [S.l.: s.n.], 2022: 16000–16009.

[41] Bao H, Dong L, Piao S, et al. BEiT: BERT pre-training of image transformers[C]. International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2022.

[42] Gu A, Goel K, Re C. Efficiently modeling long sequences with structured state spaces[J]. International Conference on Learning Representations (ICLR), 2022.

[43] Gu A, Dao T, Ermon S, et al. Hippo: Recurrent memory with optimal polynomial projections[C]. Advances in Neural Information Processing Systems (NeurIPS). [S.l.: s.n.], 2020.

[44] Smith J T, Warrington A, Linderman S W. Simplified state space layers for sequence modeling[C]. International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2023.

[45] Gu A, Gupta A, Goel K, et al. On the parameterization and initialization of diagonal state space models[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022.

[46] Dao T, Gu A. Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality[J]. International Conference on Machine Learning (ICML), 2024.

[47] Shah S, Dey D, Lovett C, et al. AirSim: High-fidelity visual and physical simulation for autonomous vehicles[C]. Field and Service Robotics (FSR). [S.l.: s.n.], 2018.

[48] Furrer F, Burri M, Achtelik M, et al. RotorS—a modular gazebo MAV simulator framework[J]. Robot Operating System (ROS), 2016: 595–625.

[49] Foehn P, Kaufmann E, Romero A, et al. Agilicious: Open-source and open-hardware agile quadrotor for vision-based flight[J]. Science Robotics, 2022, 7(67).

[50] Gandhi D, Pinto L, Gupta A. Learning to fly by crashing[J]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017.

[51] Kaufmann E, Loquercio A, Ranftl R, et al. Deep drone acrobatics[C]. Robotics: Science and Systems (RSS). [S.l.: s.n.], 2020.

[52] Pan Y, Cheng C A, Saigol K, et al. Agile autonomous driving using end-to-end deep imitation learning [C]. Robotics: Science and Systems (RSS). [S.l.: s.n.], 2018.

[53] Shah D, Sridhar A, Bhorkar A, et al. GNM: A general navigation model to drive any robot[J]. IEEE International Conference on Robotics and Automation (ICRA), 2023.

[54] Engel J, Schöps T, Cremers D. LSD-SLAM: Large-scale direct monocular SLAM[C]. European Conference on Computer Vision (ECCV). [S.l.: s.n.], 2014.

[55] Cadena C, Carlone L, Carrillo H, et al. Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age[J]. IEEE Transactions on Robotics, 2016, 32(6): 1309–1332.

[56] Mellinger D, Kumar V. Minimum snap trajectory generation and control for quadrotors[J]. IEEE International Conference on Robotics and Automation (ICRA), 2011: 2520–2525.

[57] Richter C, Bry A, Roy N. Polynomial trajectory planning for aggressive quadrotor flight in dense indoor environments[J]. International Symposium of Robotics Research (ISRR), 2016.

[58] Kamel M, Stastny T, Alexis K, et al. Model predictive control for trajectory tracking of unmanned aerial vehicles using ROS[J]. Robot Operating System (ROS), 2017: 3–39.

[59] Neunert M, de Crousaz C, Furrer F, et al. Fast nonlinear model predictive control for unified trajectory

optimization and tracking[J]. IEEE International Conference on Robotics and Automation (ICRA), 2016.

[60] 高翔, 张涛, 刘毅, 等. 视觉 SLAM 研究进展[J]. 机器人, 2019, 41(6): 768–776.

[61] 张弓, 方正, 陈思哲. 移动机器人视觉惯性 SLAM 研究进展[J]. 自动化学报, 2018, 44(5): 769–786.

[62] 吴潇, 刘勇, 赵鹏. 面向无人机的视觉 SLAM 方法综述[J]. 计算机工程与应用, 2022, 58(12): 1–15.

[63] Zhou X, Wang Z, Ye H, et al. EGO-Planner: An ESDF-free gradient-based local planning framework for quadrotors[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 478–485.

[64] 何承坤, 戴明, 张瑞. 四旋翼无人机轨迹优化与跟踪控制研究综述[J]. 控制与决策, 2021, 36(7): 1537–1556.

[65] 张涛, 邢强, 宋博. 无人机自主飞行控制技术研究进展与展望[J]. 自动化学报, 2020, 46(2): 231–248.

[66] Brunke L, Greeff M, Hall A, et al. Safe learning in robotics: From learning-based control to safe reinforcement learning[J]. Annual Review of Control, Robotics, and Autonomous Systems, 2022, 5: 411–444.

[67] Ames A D, Coogan S, Egerstedt M, et al. Control barrier functions: Theory and applications[J]. European Control Conference (ECC), 2019: 3420–3431.

[68] Cheng R, Orosz G, Murray R M, et al. End-to-end safe reinforcement learning through barrier functions for safety-critical continuous control tasks[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019.

[69] Wabersich K P, Zeilinger M N. Linear model predictive safety certification for learning-based control [J]. IEEE Conference on Decision and Control (CDC), 2018.

[70] Fisac J F, Akametalu A K, Zeilinger M N, et al. A general safety framework for learning-based control in uncertain robotic systems[J]. IEEE Transactions on Automatic Control, 2019, 64(7): 2737–2752.

[71] García J, Fernández F. A comprehensive survey on safe reinforcement learning[J]. Journal of Machine Learning Research, 2015, 16(1): 1437–1480.

[72] 雷志勇, 陈世超, 刘尚旺. 基于深度强化学习的无人机视觉避障方法[J]. 自动化学报, 2020, 46 (4): 796–805.

[73] 严旭, 吴庆宪, 姜斌. 基于深度强化学习的无人机避障算法研究[J]. 控制理论与应用, 2021, 38 (10): 1697–1706.

[74] 李超, 张晓明, 王春. 基于强化学习的无人机路径规划方法综述[J]. 系统工程与电子技术, 2022,

44(9): 2772–2783.

[75] 陈杰, 李擎, 王莉. 深度强化学习在无人机自主导航中的研究进展[J]. 航空学报, 2023, 44(4): 1–18.

[76] 朱福利, 杨华, 刘子明. 深度学习在无人机视觉感知中的应用综述[J]. 计算机学报, 2021, 44(6): 1231–1255.

[77] Tobin J, Fong R, Ray A, et al. Domain randomization for transferring deep neural networks from simulation to the real world[J]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017.

[78] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-real transfer of robotic control with dynamics randomization[J]. IEEE International Conference on Robotics and Automation (ICRA), 2018.

[79] Molchanov A, Chen T, Honig W, et al. Sim-to-(multi)-real: Transfer of low-level robust control policies to multiple quadrotors[J]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2019.

[80] Zhao W, Queralta J P, Westerlund T. Sim-to-real transfer in deep reinforcement learning for robotics: a survey[J]. IEEE Symposium Series on Computational Intelligence (SSCI), 2020.

[81] Loshchilov I, Hutter F. Decoupled weight decay regularization[C]. International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2019.

[82] Blelloch G E. Prefix sums and their applications[J]. Synthesis of Parallel Algorithms, 1990: 35–60.