城市路网交通流的模型预测控制方法研究

姓名：黄振涛

学号：3220220851

学院：自动化学院

2025 年 6 月

中国知网 https://www.cnki.net

中图分类号：U491.1; TP13
UDC 分类号：656.07:62-83

城市路网交通流的模型预测控制方法研究

作 者 姓 名　黄振涛
学 院 名 称　自动化学院
指 导 教 师　戴荔教授
行业合作导师　李贺
答辩委员会主席　张金会教授
申 请 类 别　电子信息硕士
学 位 领 域　控制工程
学位授予单位　北京理工大学
论文答辩日期　2025 年 6 月 4 日

中国知网　https://www.cnki.net

Model Predictive Control of Traffic Flow for Urban Road Networks

Candidate Name:	Zhentao Huang
School or Department:	School of Automation
Faculty Mentor:	Prof. Li Dai
Industry Collaboration Mentor:	He Li
Chair, Thesis Committee:	Prof. Jinhui Zhang
Degree Applied:	Master of Electronic and Information
Major:	Control Engineering
Degree by:	Beijing Institute of Technology
The Date of Defence:	June, 4th, 2025

中国知网 https://www.cnki.net

摘要

智能交通系统通过交通信号控制实现对路网交通流通行拥堵的优化，而模型预测控制通过构建短时交通流预测模型与滚动优化机制，可实现控制策略随交通状态的自适应调整，因此在城市路网的交通流优化中有着广泛应用。针对城市路网交通流的模型预测控制问题，目前研究面临的问题集中在：特定交通状况下的交通流优化；路网规模提升后应对计算复杂度提高以及网络计算负荷的挑战。基于此，本文提出了三种基于模型预测控制的交通流控制方案，由路口交通信号作为控制输入，实现对路网交通流的优化。本文主要研究内容有：

（1）针对特殊车辆的交通流通行优化问题，提出了一种包含公交车专用道的三路口交通流模型预测控制方案。首先，利用基础的交通流 S 模型进行改进，增加公交车、公交车站与公交专用道元素，并扩展为前后连接的三路口系统，通过公交车行驶特征对基础 S 模型的约束进行重构，并在系统中对上下游交通流进行流量交互设计。其次，进行集中式模型预测控制方案设计，通过不同目标函数的设计，利用交通信号控制平衡普通车辆的拥堵问题与公交车辆的进站排队问题。最后，通过案例研究，验证所设计方案的有效性。

（2）针对大规模路网的交通流优化问题，提出了一种分层分布式模型预测控制方案。首先，构建双层优化框架：上层采用集中式模型预测控制，依据区域宏观基本图特性进行全局流量优化；下层通过分布式控制，结合存储转发模型与交替方向乘子法实现信号协同优化，同时确保上层交换流量的有效执行。其次，通过交通信号控制缓解过饱和条件下的拥堵，并通过分层分布式的策略降低模型维度与计算复杂度。最后，通过案例研究，验证所设计方案的有效性。

（3）针对交通流模型预测控制过程中的计算负荷问题，提出了一种云边协同分布式模型预测控制方案。首先，在云控制系统中构建交通流模型预测控制问题，在云控层求解基于云的分布式模型预测控制问题，实现全网态势预测与策略生成，在边缘层求解基于边的模型预测控制问题执行区域实时感知与动态优化。其次，设计事件触发机制根据需求调整云控制器执行频率。然后，利用 Docker 容器化技术，确保了分布式模型预测控制的高效部署。最后，通过案例研究，验证所设计方案的有效性。

中国知网 https://www.cnki.net

关键词：模型预测控制；交通流；城市路网；云控制系统；智能交通系统

中国知网 https://www.cnki.net

Abstract

Intelligent transportation systems (ITS) optimize traffic congestion across road networks by traffic signal control (TSC). Model predictive control (MPC), by constructing short-term traffic flow prediction models and adopting a rolling optimization mechanism, enables adaptive adjustment of control strategies according to traffic states. Therefore, it has been widely applied in urban traffic flow optimization. For the problem of MPC for urban road network traffic flow, current research mainly faces two challenges: optimizing traffic flow under specific traffic conditions, and addressing the increased computational complexity and network load resulting from the expansion of the road network scale. In response, this thesis proposes three traffic flow control schemes based on MPC, which use TSC as the input to achieve optimization of traffic flow across the network. The main content of this work are as follows:

(1) To address the optimization of traffic flow involving special vehicles, an MPC scheme for three-intersection traffic control including bus-only lanes is proposed. First, the basic traffic flow S model is improved by introducing elements such as buses, bus stations, and bus-only lanes. It is then extended into a connected three-intersection system. The constraints of the basic S model are reconstructed based on bus operation characteristics, and flow interaction is designed between upstream and downstream intersections. Next, a centralized MPC scheme is developed. Through the design of different objective functions, TSC is employed to balance general vehicle congestion with bus queueing at stations. Finally, the effectiveness of the proposed scheme is verified through case study.

(2) To address the optimization of traffic flow in large scale road networks, a hierarchical distributed MPC (HDMPC) scheme is proposed. First, a two-layer optimization framework is constructed: the upper layer adopts centralized MPC for global flow optimization based on macroscopic fundamental diagram (MFD) characteristics of traffic regions; the lower layer uses distributed control, where signal coordination is achieved through a store-and-forward model and the alternating direction method of multipliers (ADMM), while ensuring the effective execution of flow exchanges from the upper layer. Then, TSC is used to alleviate congestion under over-saturated conditions. The hierarchical distributed strategies help re-

中国知网 https://www.cnki.net

duce model dimensionality and computational complexity. Finally, the effectiveness of the proposed scheme is verified through case study.

(3) To address computational load issues in traffic flow MPC processes, a cloud-edge cooperative distributed MPC (CEC-DMPC) scheme is proposed. First, the traffic flow MPC problem is formulated in the cloud control system (CCS) In the cloud layer, the cloud-based distributed MPC (C-DMPC) problem is solved to perform global state prediction and strategy generation. In the edge layer, the edge-based distributed MPC (E-DMPC) problem is solved to perform real-time regional perception and dynamic optimization. Next, an event-triggered mechanism is designed to adjust the execution frequency of the cloud controller based on demand. Then, Docker containerization technology is adopted to ensure efficient deployment of the distributed MPC. Finally, the effectiveness of the proposed scheme is verified through case study.

Key Words: model predictive control; traffic flow; urban road networks; cloud control system; intelligent transportation system

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状及发展趋势.....3
1.2.1 城市路网交通流研究概况.....3
1.2.2 模型预测控制方法概况.....5
1.2.3 基于云控制系统的模型预测控制方法概况.....7
1.3 本文主要研究工作.....9
第 2 章 预备知识.....12
2.1 交通流宏观模型建立.....12
2.1.1 交通流模型的变量描述.....12
2.1.2 S 模型.....14
2.1.3 存储转发模型.....16
2.1.4 宏观基本图.....18
2.2 模型预测控制相关理论.....20
2.3 本章小结.....23
第 3 章 包含公交专用道的三路口交通流模型预测控制.....24
3.1 引言.....24
3.2 问题构建.....25
3.2.1 三路口交通系统的 S 模型.....25
3.2.2 公交专用道的 S 模型.....29
3.2.3 优化问题构建.....31
3.3 集中式模型预测控制方案设计.....34
3.4 案例研究.....36
3.4.1 仿真设置.....36
3.4.2 仿真结果.....39
3.5 本章小结.....42
第 4 章 大规模城市路网交通流的分层分布式模型预测控制.....43
4.1 引言.....43
4.2 问题构建.....44
4.3 交通流分层分布式模型预测控制方案设计.....47
4.3.1 上层交通需求平衡控制器设计.....47
4.3.2 下层交通信号优化控制器设计.....50
4.4 案例研究.....56
4.4.1 仿真设置.....56

中国知网 https://www.cnki.net

4.4.2 仿真结果.....60
4.5 本章小结.....63
第 5 章 城市路网交通流的云边协同分布式模型预测控制.....64
5.1 引言.....64
5.2 问题构建.....65
5.3 交通流云边协同分布式模型预测控制方案设计.....67
5.3.1 具有触发通信的云边协同分布式模型预测控制架构.....67
5.3.2 基于云的分布式模型预测控制器设计.....69
5.3.3 基于边的分布式模型预测控制器设计.....71
5.3.4 云边协同分布式模型预测控制器设计.....75
5.4 案例研究.....76
5.4.1 仿真设置.....76
5.4.2 仿真结果.....78
5.5 本章小结.....81
结论.....82
参考文献.....84

中国知网 https://www.cnki.net

插图

图 1.1 中国民用汽车拥有量和公路里程数变化示意图 1
图 1.2 城市智能交通系统示意图 3
图 1.3 城市路网交通流控制架构示意图 4
图 1.4 云控制系统经典结构示意图 9
图 1.5 本文组织结构示意图 10
图 2.1 信号灯相位示意图 13
图 2.2 S 模型所示路段示意图 14
图 2.3 存储转发模型所示路网图 16
图 2.4 定义良好的宏观基本图曲线图 19
图 2.5 模型预测控制基本原理示意图 21
图 3.1 改进后 S 模型所建模路段示意图 25
图 3.2 v 路口普通车辆通行相位示意图 27
图 3.3 公交专用道与车站路段示意图 29
图 3.4 包含公交专用道的三路口交通流集中式模型预测控制方案示意图 34
图 3.5 优化后 v 路口通行相位示意图 35
图 3.6 本章仿真流程示意图 37
图 3.7 SUMO 平台交通仿真环境 37
图 3.8 本章仿真中不同控制方案下路网交通流指标变化趋势图 40
图 4.1 一个由 4 个路口组成的城市网络实例 45
图 4.2 大规模城市路网交通流分层分布式模型预测控制方案示意图 47
图 4.3 区域交通流交换示意图 48
图 4.4 在 VISSIM 中建立道路网络以及区域划分 56
图 4.5 本章仿真流程示意图 56
图 4.6 三个子区域的宏观基本图拟合曲线 57
图 4.7 本章仿真中不同控制方案下各区域的车辆数变化趋势 60
图 4.8 本章仿真中不同控制方案下各区域的车辆 TTS 变化趋势 61
图 4.9 本章仿真中不同控制方案下各区域的加权交通流变化趋势 61

中国知网 https://www.cnki.net

图 4.10　本章仿真中不同控制方案下各区域的车辆平均等待时间变化趋势 62
图 4.11　本章仿真中不同控制方案下各区域的车辆平均排队长度变化趋势 62
图 5.1　本章所构建路段集合示意图 65
图 5.2　交通流云边协同分布式模型预测控制方案示意图 68
图 5.3　本章所构建路网示意图 76
图 5.4　本章仿真中不同控制方案下路段 TTS 变化趋势 78
图 5.5　本章仿真中不同控制方案下路段排队长度变化趋势 79
图 5.6　本章仿真中不同控制方案下车辆通行速度变化趋势 80

中国知网　https://www.cnki.net

表格

表 3.1 改进后 S 模型中各普通路段符号的定义 28
表 3.2 改进后 S 模型中公交专用路段符号的定义 31
表 3.3 本章仿真中对系统定值变量的数值设定 38
表 4.1 示例路网结构对应信号灯相位设置. 45
表 4.2 各信号灯相位下可通行的路段 45
表 4.3 本章仿真中对系统定值变量的数值设定 59
表 4.4 本章仿真中不同方案下平均车辆占用率 60
表 4.5 本章仿真中不同方案下 CPU 计算时间 62
表 5.1 本章仿真中对系统定值变量的数值设定 77
表 5.2 本章仿真中不同方案下 CPU 计算时间 80
表 5.3 本章仿真中不同方案下边缘层内存占用量 81

中国知网 https://www.cnki.net

主要符号对照表

$\mathbb{R}$	实数集
$\mathbb{R}^n$	n 维实数列向量组成的集合
$\mathbb{R}^{n\times m}$	$n\times m$ 维实数矩阵组成的集合
$x(k+t\|k)$	k 时刻下对 $k+t$ 时刻状态量 x 的预测值
floor{}	向下取整函数
rem{}	取余函数
round{}	四舍五入函数
I_n	n 维单位矩阵
$A^\top$	矩阵 A 的转置
$\|x\|$	向量 x 的欧几里得范数，$x\in\mathbb{R}^n$，$\|x\|=\sqrt{x^\top x}$
$\|x\|_P$	向量 x 的加权范数，$x\in\mathbb{R}^n$，$P\in\mathbb{R}^{n\times n}$，$\|x\|_P=\sqrt{x^\top Px}$
$\|x\|^2$	向量 x 的欧几里得范数平方，$x\in\mathbb{R}^n$，$\|x\|^2=x^\top x$

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景及意义

随着我国社会经济水平不断提高与城市化进程的加快，城市规模持续扩张，对基础设施的依赖日益增强，城市交通系统在居民日常生活中的重要性愈发凸显。经济总量的增长和城市空间的拓展，推动了居民私家车拥有量的显著上升。据公安部统计，截至 2024 年底，全国机动车保有量已达 4.53 亿辆，其中汽车数量为 3.53 亿辆；2024 年全年新增注册机动车 3583 万辆，较 2023 年增加 104 万辆，同比增长 2.98%；其中新增注册汽车达 2690 万辆，年增长率高达 9.53%。自 2015 年起，我国已连续十年实现年新增机动车注册量超过 3000 万辆的记录[1-2]。

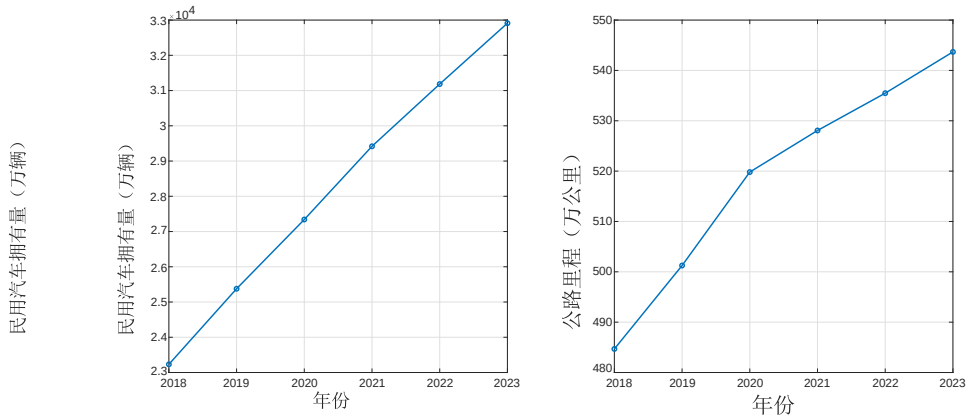

(a) 中国民用汽车拥有量变化趋势　　(b) 中国公路里程数变化趋势

图 1.1　中国民用汽车拥有量和公路里程数变化示意图

与民用汽车保有量迅猛增长相对应的，却是我国公路基础设施建设的相对滞后。如图1.1所示，尽管近年来我国公路总里程持续增长，但增速已逐渐放缓。交通运输部 2023 年底发布数据显示[3]，全国公路总里程为 543.68 万公里，公路密度为 56.63 公里/百平方公里，相较 2022 年增长率仅为 1.5%，且自 2020 年以来始终维持在这一低速增长水平。中美两国的数据均表明，汽车拥有量与公路资源供给之间存在显著的增长失衡。例如，美国联邦公路管理局发布的《2023 年公路统计》指出，截至 2022 年，美国汽车保有量已达 2.8 亿辆，五年增长 2.6%，而同期公路总里程增长不足 1%[4]。

这种交通供需矛盾在大城市中表现尤为突出。百度地图发布的《2024 年度中国城市交通报告》显示[5]，全国通勤高峰期拥堵指数排名前十的城市中，重庆、广州等八个城市的拥堵程度较上一年进一步上升。周末拥堵指数最高的城市如广州、杭州与

中国知网 https://www.cnki.net

重庆，在主要交叉口普遍存在信号灯等待时间超过 40 秒的现象。类似地，美国交通部报告指出，在特大城市中，通勤者每年需承受平均 84 小时的交通延误，拥堵带来的年均经济损失高达 6784 美元[6]。道路拥堵问题在经济、社会与生态层面均产生了广泛而深远的负面影响。一方面，长期拥堵降低了城市居民的出行效率，影响了生产力和生活质量；另一方面，交通拥堵加剧了能源消耗，并导致大量有害气体排放，进一步恶化了城市环境[7-8]。因此，城市交通拥堵已成为现代社会亟需解决的重要难题，直接关系到城市运行效率与可持续发展。

交通拥堵的本质是当前社会发展阶段城市交通的供求关系不平衡[9]。通过扩建基础设施，如拓宽道路、修建高架桥等，可以显著增加交通供给能力，然而，考虑到重建主要城市道路的高成本和复杂性，很难在短时间内通过大量基础设施的建设实现对拥堵现象的缓解。因此，通过提高现有道路的路口通行能力，利用交通信号控制（Traffic Signal Control, TSC）来优化交通流（Traffic Flow）通行，以达到提高交通运输效率的目的是当前可以缓解拥堵的有效方案，通过适应路网交通状态的交通流控制策略，可以实现可持续的拥堵减少[10]。

道路交叉口作为城市交通网络的关键枢纽节点，既是交通拥堵的易发区域，更是优化城市路网交通流的核心控制对象。交叉口的运行效率直接影响交通网络的宏观运行状态，其交通流组织优化是提升有限道路资源利用效率、缓解城市交通压力的关键突破口。从控制机理而言，交叉口信号系统通过动态通行权分配实现人车交通流的时空分离[11]。理想状态下，科学的信号控制应达成多目标协同优化：通过相位协同与配时优化提升通行能力，借助冲突消解机制降低事故风险，最大限度提升安全性，同时在通行权分配中确保道路使用者的公平路权诉求[12]。有效的交通信号控制有利于交通网络内部的流动，可以缓解拥堵，优化交通流，同时可以改善社会经济的生产力，对城市交通的管理至关重要[13]。

传统交通信号控制受限于固定配时参数与孤立控制单元，难以精准刻画交通流的时变随机特性，更缺乏对多交叉口协同控制的空间维度拓展能力。随着随着第五代移动通信（5G）技术的高速发展以及信息化时代下对信息处理、存储以及优化的技术进步，研究人员依托多源异构数据融合构建的智能交通系统（Intelligent Transportation System, ITS），正推动交叉口信号控制策略发生根本性变革[14]。如图1.2所示为城市智能交通系统的示意图，基于模型预测控制（Model Predictive Control, MPC）的动态优化框架为智能交通系统应对交通流状态提供了新路径：通过构建短时交通流预测模型

中国知网 https://www.cnki.net

图 1.2　城市智能交通系统示意图

与滚动优化机制，可实现控制策略随交通状态的自适应调整[15]。而云控制系统（Cloud Control System, CCS）的引入进一步突破了物理边界的约束，依托云端算力资源对区域交通流进行宏观态势推演，同时通过边缘计算节点执行分布式实时控制指令[16]。这种“云-边-端”协同架构不仅增强了控制系统的时空关联性，更通过数字孪生技术实现了控制策略的虚拟验证与在线迭代。结合模型预测控制与云控制系统的城市交通流优化与信号控制策略，已成为推动智能交通系统发展的重要研究方向。

1.2 国内外研究现状及发展趋势

1.2.1 城市路网交通流研究概况

由于交叉口之间的交通状态存在复杂的时空耦合关系，如何从单一交叉口控制扩展至城市级路网的整体交通流优化，已成为当前交通系统控制研究的热点问题。一般认为城市路网主要由十字路口与道路组成，各个交叉口间由双向道路连接，路段交通流则定义为规定时间内通过该路段的车辆集合。从基础设施的角度看，车辆行驶中会根据所需要行驶的方向和交通规则选择其通行的路段。对交通流的控制优化，其目的是对道路内车辆在交叉路口通行以及路网全局通行时的拥堵延误进行优化，包括车辆停车等待时间，路口排队车辆数量以及车辆通过城市路网的总耗时等均可作为评价指标。对交通流的控制方式则是由交叉口处的信号灯信号实现，通过信号灯在周期内对不同行驶方向调节通行的绿灯时间与禁行的红灯时间，使得不同方向路段内的交通流

中国知网　https://www.cnki.net

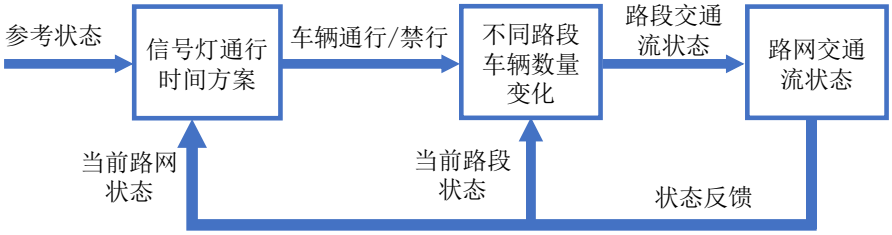

图 1.3　城市路网交通流控制架构示意图

在路网交通流控制领域，为实现交通信号设置方案的最优配置，研究者通常依托道路传感器所获取的在线交通数据进行分析与建模。基于对实时交通状态的动态感知，国内外众多学者相继提出并开发了多种具备协调特性的交通响应方法。例如，文献 [17] 中提出的动态规划（Dynamic Programming, PRODYN）方案和文献 [18] 中通过离线和在线模块解决一个基于线性二次型调节器（Linear Quadratic Regulator, LQR）的优化问题，均是通过处理集中式优化问题的约束提高交通信号处理质量，使得排队长度和信号分配达到最优。然而，集中式求解的方法并不适用于多路口组成的城市路网，因为它们在穷举搜索或动态规划优化时复杂度会指数性上升。而文献 [19] 中提出的悉尼协调自适应交通系统（Sydney Coordinated Adaptive Traffic System, SCATS）方案和文献 [20] 中提出的自适应控制优化策略（Optimization Policies for Adaptive Control, OPAC）方案均采用的是分层架构方案，即将集中式的控制问题转化为若干相关或者独立的子问题，然后实施协调控制。与此同时，近年来也有研究者将人工智能（Artificial Intelligence, AI）相关方法运用到交通流控制领域，如文献 [21] 将深度强化学习算法（Deep Reinforcement Learning Algorithm, DRLA）应用于路口信号灯优化；文献 [22] 通过深度学习（Deep Learning, DL）对交通流进行预测，并将预测结果用于实时交通信号优化，以缓解交通拥堵；文献 [23] 利用优化后的遗传算法（Genetic Algorithm, GA）对交通流进行优化，提高交通系统的整体效率。

在这些优化方法中，基于车辆守恒定律的交通模型，如 S 模型[24]、存储转发模型（Store-and-Forward Model, SFM）[25] 和细胞传输模型（Cell Transmission Model, CTM）[26] 等宏观交通流模型，由于其简单而准确地描述了交通随时间和空间的演变，被广泛用于预测未来交通行为。事实上，在交通控制策略的演进历程中，初始阶段主要依赖无模型控制方法[27]。为了提升控制效果，一些可表征和预测路网交通流状态变化，同时可及时反馈控制策略对交通流动态影响的预测模型被研究人员构建，并成为实现交通

中国知网　https://www.cnki.net

态势预测的重要技术途径。从理论上来说，完备的交通模型应具备基于实时路网状态与未来交通需求输入的动态推演能力，从而保障路网运行效率[28]。现代交通流理论框架下，模型体系通常解构为微观与宏观两个维度[29]：微观模型聚焦于车辆个体运动特征的精细化描述，通过车辆跟驰模型[30]、元胞自动机[31] 等建模方法，从单车运动规律推导群体动力学特性；宏观模型则基于流体动力学理论，将交通流视为研究对象进行整体分析，建立流量-密度-速度的宏观方程，其主要包括前文所提的各种交通流连续模型[24-26]。从方法论层面审视，两类模型具有本质差异：微观模型通过高分辨率车辆轨迹数据构建精确仿真环境，但面临大规模路网实时计算的高复杂性与计算量约束；宏观模型具有简约的公式形式，但忽略了个体车辆的通行状况，在减少计算量的同时，与现实交通状况存在一定差距[32]。在应用层面，城市交通控制通常以路网通行效率、区域拥堵指数等宏观指标为优化目标，而非特定车辆的行进状态。这种系统级优化需求与在线计算时效性要求，使得宏观模型在控制策略研究中具有显著优势。

由此可见，尽管存在建模差异，宏观模型仍能有效捕捉交通流的核心动力学特征，因此目前城市交通控制的研究一般都采用宏观交通流模型[33]。故本文主要研究基于宏观交通流模型进行控制优化，对微观模型下的优化方法不再赘述；同时本文主要基于交通流模型进行交通信号控制以优化交通流，对无信号交通系统等方面的优化不再赘述。

1.2.2 模型预测控制方法概况

基于模型进行交通流预测与优化时，会受到交通容量、输入输出等方面的约束限制。前述方法通常只能通过参数调整以实现对约束的满足，或者在某些情形下出现违反约束的情况。模型预测控制方法能够依据状态方程对未来行为进行预测，并将约束表现在一个在线求解的优化过程中，处理各种约束限制，应用于城市路网的交通流控制后，可以为交通流的预测控制与决策规划增加新的解决方案。

模型预测控制是一种基于滚动优化策略的先进控制方法，其核心原理在于周期性地应用最优控制理论进行动态系统调控。该理论体系最初由 Richalet 等人于 1978 年正式提出[34]，现已成为现代控制工程领域的重要研究方向。在工程实践中，多数控制模型需应对由外部环境干扰引发的状态约束、输入约束等多重限制条件。相较于传统比例-积分-微分（Proportional-Integral-Derivative, PID）控制方案仅能通过参数调整间接满足系统约束，甚至在某些情况下无法保证约束条件的特性，模型预测控制因其处

中国知网 https://www.cnki.net

理约束的能力及在多变量耦合系统中的鲁棒性优势，现已成为复杂控制问题优化求解的主流方法。通过建立预测模型并构建有限时域的最优控制序列，该方法能够实现约束条件下的动态性能优化，这一特性使其在工业过程控制、智能交通系统等领域的应用价值日益凸显。

基于上述理论框架，模型预测控制的理论演进可划分为三个典型发展阶段。初始阶段聚焦传统预测控制理论架构，涌现出系列经典算法：以文献 [35] 为代表的先驱性研究，引入控制时域概念并构建了动态矩阵控制（Dynamic Matrix Control, DMC）体系；文献 [36] 则结合最小方差控制与自适应控制理论，提出了广义预测控制（Generalized Predictive Control, GPC）方法。尽管上述理论在工业过程控制中得到初步应用，但由于缺乏系统的稳定性分析框架，其向复杂对象如非线性系统的推广受到限制[37]。至 20 世纪 90 年代，随着 Lyapunov 稳定性理论、不变集理论及最优控制理论的发展，模型预测控制的迭代可行性与稳定性分析体系逐步完善，确立了以终端代价函数、终端约束域及终端控制器设计为核心的稳定性“三元结构”[38]。进入 21 世纪，相关理论创新加速，鲁棒模型预测控制[39]、分布式模型预测控制[40]、经济预测控制[41] 及随机预测控制[42] 等新兴方法陆续提出并发展，有效拓展了在不确定性系统、多智能体协同优化及经济性能优化等复杂场景的应用边界。

在理论不断发展的推动下，模型预测控制在解决复杂系统优化问题中的工程应用价值得以逐步凸显。以大规模交通网络优化为例，交通流的控制优化面临双重挑战：一方面源于路网拓扑结构的高度复杂性与交通流的动态不确定性，另一方面源自各交叉口相邻信号控制单元的相位协同耦合特性。这种多尺度动态关联特征使得孤立优化单一交叉口绿灯时间难以实现全局最优，如何构建考虑上下游交通流传递效应的协同控制架构成为路网效能提升的核心瓶颈问题[43]。而模型预测控制在复杂工业过程控制领域展现出的多变量约束处理能力与滚动优化特性，为突破上述交通控制难题提供了实践依据。

基于这一背景，研究人员针对城市交通网络进行了系统建模，探讨了利用模型预测控制优化交通流的多种方案。文献 [44] 开创性地将交叉口信号配时优化问题建模为二次规划问题，通过滚动优化机制实现控制效率的动态提升，为实时交通控制奠定了算法基础。在此基础上，文献 [45] 通过引入多参数二次规划理论构建显式模型预测控制框架，成功将在线计算复杂度降低以增强了算法适用性。文献 [46] 和 [47] 则是基于深度学习算法对交通流进行建模的预测控制。这些控制方式本身属于集中式

中国知网 https://www.cnki.net

控制策略，在应对复杂约束时在线优化的计算效率有明显不足，而分布式控制架构的研究则为复杂路网协同优化开辟新途径。文献 [48] 和 [49] 分别将分布式模型预测控制（Distributed Model Predictive Control, DMPC）与交替优化和场景树等算法进行集成，此外文献 [50] 和 [51] 中提出了将分布式模型预测控制与交通流模型相结合的分层控制策略，这些研究表明分布式模型预测控制已成功应用于多个路口的交通信号协调，有效降低了对交通流进行模型预测控制的计算复杂度。与此同时，预测模型的结构优化作为影响控制精度与计算效能的关键要素，也成为当前研究重点突破方向：文献 [52] 创新性地采用宏观基本图构建交通流预测模型，通过两区域边界模型预测控制控制策略使区域通行能力提升，实现路网旅行次数最大化目标。文献 [53] 提出的基于宏观基本图拥堵度评估的串行分布式预测控制方案，成功将子区域通行延误降低。这些研究标志着模型预测控制正从单点优化向多层级协同方向演进，其与分层递阶控制、分布式计算框架的深度集成，正在重构智能交通系统的理论与实践路径。此外面对不同场景下的交通流模型预测控制也有着相关研究：文献 [54] 在交通模型中加入自行车相关量，并对交通网络进行合并，以协调十字路口的车辆交通与自行车交通；文献 [55] 将模型预测控制与应急车辆场景相结合，在缓解路网拥堵的同时为应急车辆提供高效通行路径。这些工作将控制策略的应用场景扩展到更加真实的场合。

综上所述不难看出，模型预测控制在交通流控制优化问题上具有广泛应用。然而当前的研究却也面临如下问题：（1）很少考虑一些特定交通状况下的控制；（2）关注的路网规模多数较低，而提升路网规模的同时应用模型预测控制策略又须考虑其在线计算复杂度和计算负荷带来的挑战。因此对城市路网交通流的模型预测控制仍有很多问题需要解决，本文主要研究基于模型预测控制的交通流优化问题，对于其他方法的研究不再赘述。

1.2.3 基于云控制系统的模型预测控制方法概况

在基于模型预测控制的交通流优化研究中，随着系统数据采集与存储规模的扩大，如何有效缓解控制系统的通信与计算负荷已成为关键性技术挑战。特别对于城市路网交通流预测控制场景，当研究范畴扩展至大规模拓扑结构时，交叉口数量的线性增加将导致路段状态变量、信号控制单元及车辆轨迹信息呈现超线性增长态势。传统控制架构因受限于本地计算资源与通信带宽约束，难以满足高维状态空间下的实时控制要求。为此，文献 [56] 和 [57] 所提出的云控制系统通过集成云计算平台、大数据

中国知网 https://www.cnki.net

处理框架及深度强化学习算法，构建了新型控制架构：依托云端对多源异构感知数据的融合存储能力，实现交通流动态特性的在线参数辨识与预测模型更新[58]；借助云端高性能计算资源，完成大规模路网状态预测、滚动时域优化及控制策略生成等计算密集型任务，进而形成“云端决策-边缘执行”的控制架构，显著提升了模型预测控制在复杂交通场景下的可扩展性[59]。

在概念体系化之前，早期探索已显现云端赋能的雏形：卡耐基 · 梅隆大学率先实现机器人系统的云端数据协同，开创“云机器人”在移动医疗等领域的工程应用[60]；美国国家航空航天局通过云端部署无人机空管系统，突破传统导航系统的时空约束，实现实时通信、导航并协同路径规划与避障[61]。2012 年文献 [56] 中正式构建云控制系统理论框架，系统阐释其体系架构与核心算法，该领域进入快速发展期。学术前沿聚焦的方向与成果包括：文献 [57]、[62] 和 [63] 在数据驱动云控制、基于云计算的模型预测控制及系统安全防护方面取得成果；文献 [64] 和 [65] 攻克云边通信时延下的多智能体预测控制稳定性难题；文献 [66] 基于云控制系统创新异步通信监控架构，实现远程控制闭环。在工程应用层面，文献 [67] 构建的智能网联汽车云控平台，通过五维技术体系重构车辆控制范式，其中云控制模块已成为智能交通系统的核心支撑。

基于上述理论演进与实践，总结得到云控制系统的典型架构如图1.4所示。其核心特征体现为控制单元的云端化部署，即被控对象、执行器及感知单元部署于本地边缘网络域内，而控制决策模块则迁移至具备弹性计算资源的云端平台，形成“边缘感知-云端决策”的跨网域协同架构[68]。依托云计算环境的高效算法引擎，系统通过公共网络实现状态感知、优化求解与控制指令传输的全链路闭环，最终达成复杂动态系统的自主智能控制目标。

在云控制算法层面，主要包括数据驱动云控制和基于云计算的模型预测控制。前者通过深度挖掘云端历史数据建立非机理控制模型，后者则强调基于动态模型的滚动优化机制。二者的融合创新为应对云控场景下的时变通信约束、计算-通信资源竞争等挑战提供了方法基础，其基于云计算的模型预测控制因其显式处理时延与约束的能力，在多智能体协同等强耦合场景中展现出独特优势，成为近年来的研究焦点。

当前基于云计算的模型预测控制的研究呈现多维度突破：文献 [69] 针对网络时变时延与数据丢包问题，构建切换型预测控制框架，实现被控系统的有限时间镇定；文献 [64] 和 [65] 首创多智能体云预测控制方案，通过状态预测器与协调优化机制设计，在保证系统一致性的同时补偿通信时延；文献 [70] 利用交替方向乘子法（Alternating

中国知网 https://www.cnki.net

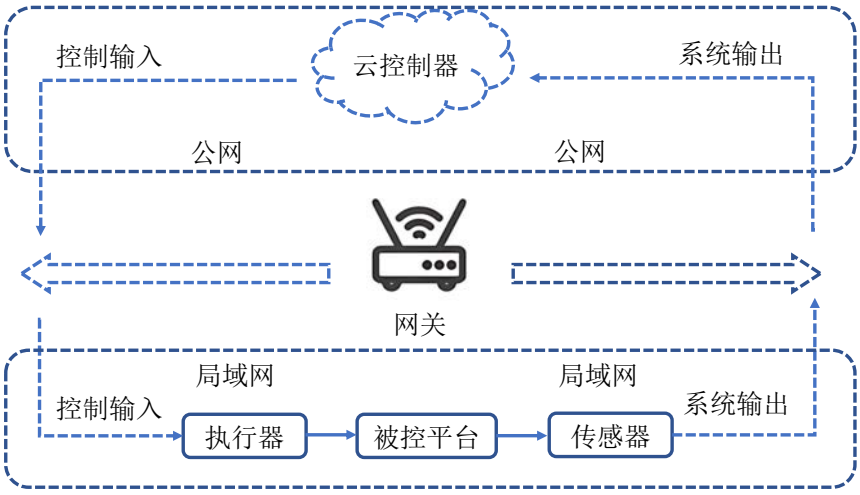

图 1.4　云控制系统经典结构示意图

direction method of multipliers, ADMM）算法构建模型预测控制云工作流，建立非线性模型预测控制非凸优化问题求解的收敛性条件，使用容器技术，降低云端计算时延。文献 [71] 提出的双通道感知调度机制，将分组预测控制与通信调度深度耦合，有效提升多子系统控制稳定性。

尽管现有研究在多智能体协同、非线性补偿等维度取得显著进展，但在城市交通流优化这一典型复杂系统场景中，基于云计算的模型预测控制仍面临独特挑战：路网规模扩展引发的维数灾难、多交叉口耦合导致的约束复杂性、以及交通流强时变特性对实时性的严苛要求。这些特性使得传统多智能体控制方案难以直接迁移，亟需构建适配交通流时空演化规律的专用云控制框架。本文研究内容包含基于云计算的模型预测控制下城市路网交通流的优化问题，对其他云控制系统的算法与应用不做赘述。

1.3 本文主要研究工作

综上所述，有关模型预测控制在城市路网交通流的控制优化领域虽取得了一定的进展，但一些具有研究意义的重难点问题依旧存在。首先，在使用宏观交通流模型进行集中式模型预测控制时，现有文献很少考虑一些特定交通状况下的控制；其次，现有文献所考虑的路网规模多数较低，而提升路网规模的同时应用模型预测控制策略又须考虑其在线计算复杂度和计算时间；最后，现有文献在解决交通流应对复杂网络的计算负荷方面缺乏研究，例如与云控制系统的融合以借助云端求解。因此，本文将针对城市路网交通流的模型预测控制方法进行研究，提出三种基于模型预测控制的交通

中国知网　https://www.cnki.net

流控制框架，并进行实例研究以验证有效性。本文的组织结构如图1.5所示，具体研究内容为：

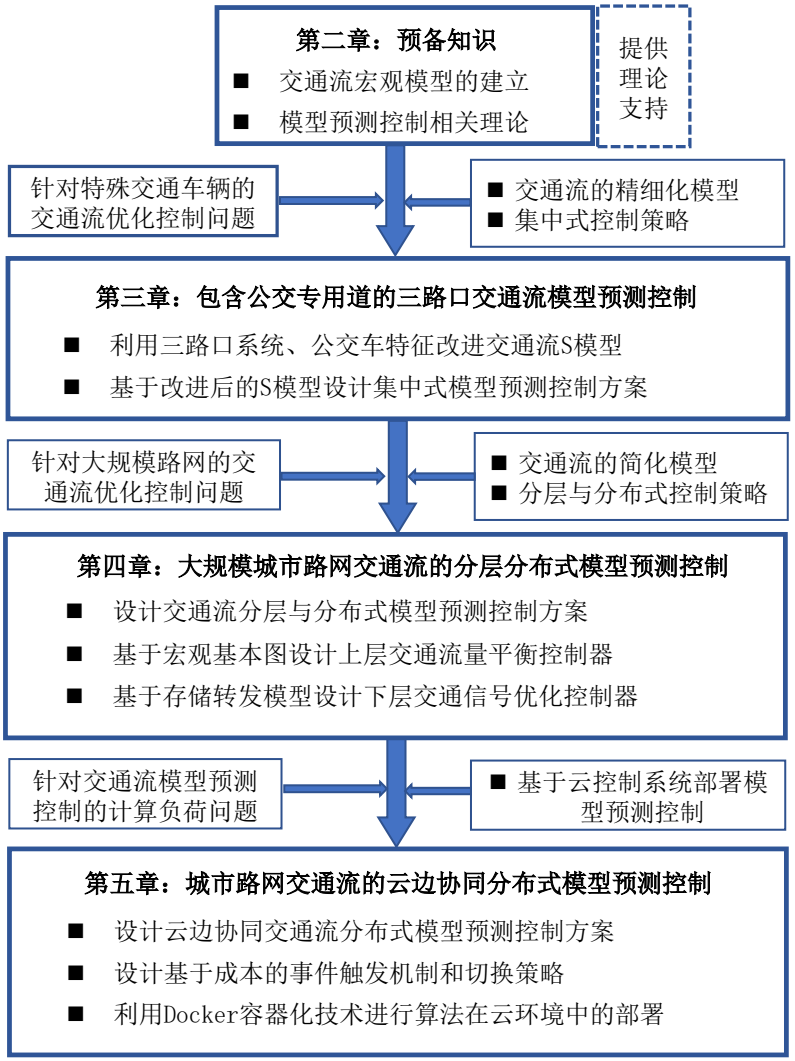

图 1.5　本文组织结构示意图

第 1 章为绪论。本章首先阐明了城市路网交通流优化控制的研究背景与意义，随后基于国内外相关成果，总结了交通流控制理论的发展现状，并引出模型预测控制，介绍其研究进展及在交通流控制中的应用，之后引出云控制系统的相关介绍与基于云计算的模型预测控制研究，最后给出本文的研究工作以及组织结构。

第 2 章为预备知识。因本文主要采用 S 模型与存储转发模型对具体道路交通流进行建模，并使用宏观基本图从路网角度进行交通流性质分析，故本章将对这些内容进行介绍，以通过宏观交通流模型的构建为后续研究奠定基础。最后，给出模型预测控

中国知网 https://www.cnki.net

制的相关理论知识。

第 3 章提出基于改进后的 S 模型的交通流模型预测控制方法。目的是提高路口通行效率，缓解拥堵。主要对模型进行两个方面的改进：（1）将城市道路上的普通车辆和公交车分开建模，考虑了公交车专用车道和停靠站；（2）在交通网络中加入三个交叉口，以考虑两个路段的交互影响。在此基础上，设计了一个集中式模型预测控制方案来调节十字路口的交通灯状态，从而有效地控制交通流。通过仿真平台在交通网络中实现该控制方案并与其他方案的比较，验证了该模型和控制策略的有效性。

第 4 章提出一种城市路网交通流的分层分布式模型预测控制方案。该方法构建双层优化框架：上层采用集中式模型预测控制，依据区域宏观基本图特性进行全局流量优化；下层通过分布式模型预测控制，结合存储转发模型与交替方向乘子法实现路段级信号协同优化，同时确保上层交换流量的有效执行。本章所提出分层分布式模型预测控制方案将模型预测控制与路网特征相结合，有利于通过交通信号控制缓解过饱和条件下的拥堵，并通过分层分布式的策略降低模型维度与计算复杂度，交替方向乘子法的应用则解决路网区域间信号时间耦合的问题。通过仿真与其他方案进行比较，验证了所提方案的有效性。

第 5 章在前文的基础上提出一种城市路网交通流的云边协同分布式模型预测控制方案。研究将路网交通流的分布式模型预测控制算法部署在云端进行求解的相关工作。利用 docker 容器化技术，在具有卓越分布式计算能力的云服务器上设计并部署了一种分布式模型预测控制算法。为确保网络异常情况下的交通流通行安全，引入边缘计算，在路段边缘设计并部署一种复杂度较低的分布式模型预测控制算法。并引入事件触发机制，在保持控制性能的同时优化云计算利用率并降低运营成本。最后，通过仿真与其他方案进行比较，验证了所提方案的有效性。。

最后为结论，总结本文完成的工作以及存在的不足，并对未来工作进行展望。

中国知网 https://www.cnki.net

第 2 章 预备知识

本章主要介绍开展本文研究所依赖的基础理论与关键技术，为后续章节的算法设计提供理论支撑。主要内容包括：交通流宏观模型的建立以及模型预测控制方法。其中，交通流宏观模型作为交通状态预测的重要工具，为交通流优化提供建模基础；模型预测控制则是本文提出控制策略的核心方法支撑。

2.1 交通流宏观模型建立

2.1.1 交通流模型的变量描述

城市交通路网作为一个高度复杂的系统，其复杂性不仅源于庞大的变量数量，还体现在变量间复杂的相互关系上。若将其作为控制对象，可以明确系统中包含输入变量、状态变量与输出变量。为此，本节对交通流相关的主要变量名词进行说明[72]。

车流量：规定时间内由通过规定路段的车辆集合称之为该路段的车流量，为便于系统状态量计算，各路段的车流量在计算取车辆数与时间的比例，单位为 veh/s。车流量根据驶入和驶出路段的车辆数计算，并且与上下游路段相关。

转向率：路段内的车辆根据即将驶入方向的不同可进行划分，每一部分的车辆数与总数的比值，称为该方向的转向率，其数据以比值形式呈现。转向率是计算上下游交通流的重要参数，其数值可根据历史数据得出固定参数。

车辆密度：指单位路段内实际车辆数与该路段容量之间的比值。容量表示该路段所能承载的最大车辆数。车辆密度反映路段的拥堵程度，是衡量路网交通状态的重要指标，其数值越高，表示路段越拥堵。

等待车辆数：指某一路段内所有处于等待通行状态的车辆数量总和。等待现象可能由信号灯红灯或路段拥堵导致。单一时刻的等待车辆数难以准确反映交通状况，但其在一定时间内的累计值能够有效评估交通流优化效果。

加权车流量：指在路网由多条路段组成的情况下，各路段车流量按一定权重计算后的总值。加权车流量反映路网整体的流通性能，数值越大表明路网交通流通行状态越佳。

总通行时间：指路网内所有车辆通过整个路网所消耗时间的总和。车辆在行驶过程中因延误等因素导致通行时间增加，因此总通行时间可作为衡量交通流控制效果的

中国知网 https://www.cnki.net

重要指标。

饱和交通流：即路段车辆通行达到拥堵前的临界状态，此时对应的车流量称为饱和车流量，路段处于饱和状态。此状态下当拥堵加剧时路段为过饱和（拥堵）状态，当拥堵缓解时路段为欠饱和（自由流）状态。

本文通过路口交通信号控制实现对路网交通流的控制优化，交通信号控制中有四种控制变量可以调节[73]。

相位：在路网的交叉路口中，车流量在不同方向路段的通行情况由一组信号控制，在某一时间段内只允许特定方向的车辆同时通过。这样的一组信号被定义为信号灯的一个相位。通过合理的相位设置，可以保证交叉口的交通流不发生冲突。例如，单一路口如图2.1(a)所示，其信号相位由图2.1(b)所示，确定最优的相位数量及其组成是影

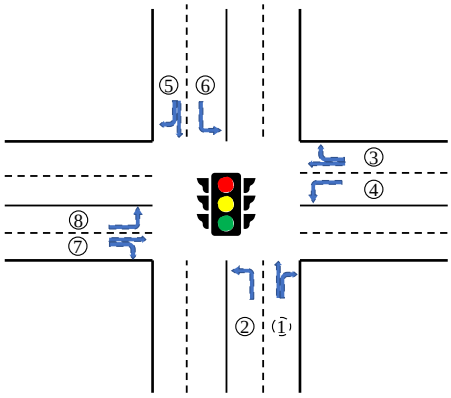

(a) 某路口各路段通行方向示意图

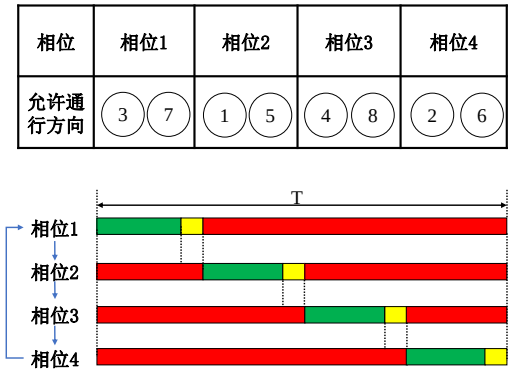

(b) 该路口信号灯相位设置示意图

图 2.1　信号灯相位示意图

周期：路口所有相位进行一次循环的时间长度即为周期。在较长周期下，由于损失时间在整个周期中所占比例降低，可提升路口的通行能力；然而，周期延长也可能导致红灯方向车辆的等待时间增加，从而加剧交通拥堵。

绿灯时间：指一个路段在单个信号周期内各相位获得通行权的时间总和，其总和不超过该周期长度。绿灯时间应根据各路段及整体路网的车流情况进行优化分配，以提升通行效率。

相位差：指相邻两个路口在连续信号周期中，相同相位开始执行的时间差值，用于协调路口间的信号配时。相位差的设定不仅需考虑相邻路口之间的距离，还应综合评估可能出现的车辆排队长度对协调效果的影响。

中国知网 https://www.cnki.net

通常，相位、绿灯时间与周期为路口控制中的基本控制变量，而相位差则主要出现在多路口协调控制的场景中。在本文的后续的案例研究中，为简化步骤设定相位差为 0，即各路口信号灯周期同步开始执行。

2.1.2 S 模型

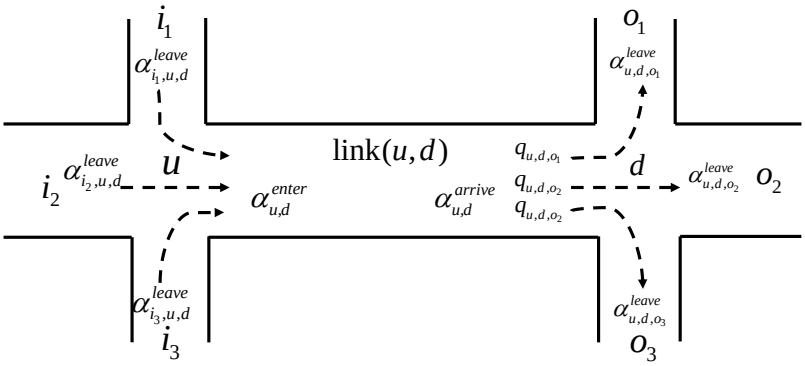

图 2.2　S 模型所示路段示意图

如图2.2 所示是路网内某条路段的示意图，定义其上游与下游路口分别为 u 和 d，则可将该路段命名为 link(u,d)。定义 i_a 和 o_a （$a=1,2,3$）分别为路口 u 车辆来源的上游节点和路口 d 车辆通行的下游节点。图中所示各变量中，$\alpha^{\text{leave}}i_a,u,d$ 表示从 i_a 离开并汇入 link(u,d) 的车流量，$\alpha^{\text{enter}}u,d$ 为进入 link(u,d) 的车流量，$\alpha^{\text{arrive}}u,d$ 表示即将到达 link(u,d) 排队队尾的车流量，$\alpha^{\text{leave}}o_a,d$ 为从 link(u,d) 离开驶向 o_a 的车流量，q_{u,d,o_a} 则表示在 link(u,d) 上转向 o_a 的车流排队长度。

在 S 模型中，路网各节点的信号灯周期设定为其对应仿真时间间隔。设交叉口 u 与 d 的信号周期为 c_d，则在时刻 k，link(u,d) 上的车辆数可按如下公式进行计算：

$$n_{u,d}(k+1)=n_{u,d}(k)+\left(\alpha^{\text{enter}}_{u,d}(k)-\alpha^{\text{leave}}_{u,d}(k)\right)\cdot c_d \tag{2.1}$$

其中汇入 link(u,d) 的车流量可计算为上游各方向进入车流量之和，即

$$\alpha^{\text{enter}}_{u,d}(k)=\sum\alpha^{\text{enter}}_{i,u,d}(k) \tag{2.2}$$

在一个周期 c_d 时间内，从 link(u,d) 离开并驶向各个下游路段的车流量 $\alpha^{\text{leave}}_{u,d,o}(k_d)$，由该路段的通行容量、当前排队与到达车辆的总量、以及下游路段的剩余可用空间共同

中国知网 https://www.cnki.net

决定。该关系可由以下公式描述：

$$\alpha_{u,d,o}^{\text{leave}}(k) = \min\left(\frac{\beta_{u,d,o}(k)\mu_{u,d}g_{u,d,o}(k)}{c_d}, \frac{q_{u,d,o}(k)}{c_d} + \alpha_{u,d,o}^{\text{arrive}}(k), \beta_{u,d,o}(k)\cdot\frac{C_{d,o}-n_{d,o}(k)}{c_d}\right) \tag{2.3}$$

其中，$\beta_{u,d,o}$ 表示车辆从 link(u,d) 转向下游路口 o 的转弯率，$\mu_{u,d}$ 表示 link(u,d) 的饱和车流量，$g_{u,d,o}$ 表示一个周期内由 link(u,d) 转向 o 的绿灯时长，$C_{d,o}$ 表示 link(d,o) 的容量，$n_{d,o}$ 表示该下游路段上的车辆数。

路口处等待通行的排队车辆数量可由以下公式进行计算：

$$q_{u,d,o}(k+1) = q_{u,d,o}(k) + \left(\alpha_{u,d,o}^{\text{arrive}}(k) - \alpha_{u,d,o}^{\text{leave}}(k)\right)\cdot c_d \tag{2.4}$$

规定车辆从进入 link(u,d) 到达到该路段排队队尾所经历的时间为 $\tau(k)\cdot C_d+\gamma(k)$，据此可得如下关系式：

$$\alpha_{u,d}^{\text{arrive}}(k) = (1-\gamma(k))\cdot\alpha_{u,d}^{\text{enter}}(k-\tau(k)) + \gamma(k)\cdot\alpha_{u,d}^{\text{enter}}(k-\tau(k)-1) \tag{2.5}$$

$$\tau(k) = \text{floor}\left\{\frac{(C_{u,d}-q_{u,d}(k))\cdot l_{\text{veh}}}{N_{u,d}^{\text{lane}}\cdot v_{u,d}^{\text{free}}\cdot C_d}\right\} \tag{2.6}$$

$$\gamma(k) = \text{rem}\left\{\frac{(C_{u,d}-q_{u,d}(k))\cdot l_{\text{veh}}}{N_{u,d}^{\text{lane}}\cdot v_{u,d}^{\text{free}}\cdot C_d}\right\} \tag{2.7}$$

其中 l_{veh} 表示车辆的平均长度，$N_{u,d}^{\text{lane}}$ 为该行驶方向所含路段数量，$v_{u,d}^{\text{free}}$ 为车辆平均速度。借助 S 模型，可将任一时刻路网内的车辆数表示为系统状态的函数形式：

$$n(k+1) = f(n(k), g(k), d(k)) \tag{2.8}$$

其中 $n(k)$ 表示 k 时刻的系统状态，即路网内的车辆数；$g(k)$ 为信号灯配时方案对应绿灯长度；$d(k)$ 为可预测扰动，代表外部输入至路段的交通流量。设仿真时间间隔为 T_s，控制时间间隔为 T_c，预测时域长度为 N_p，则需满足 $T_c = M\cdot T_s$ 的约束关系。

中国知网 https://www.cnki.net

定义对未来第 k 步交通需求的预测为:

$$d(k) = [d^\top(k|k) \quad d^\top(k+1|k) \cdots d^\top(k+MN_p-1|k)]^\top \tag{2.9}$$

同时定义将来的控制信号为:

$$g(k) = [g^\top(k|k) \quad g^\top(k+1|k) \cdots g^\top(k+N_p-1|k)]^\top \tag{2.10}$$

则可以预测第 k 步的交通状况（车辆数）为:

$$n(k) = [n^\top(k|k) \quad n^\top(k+1|k) \cdots n^\top(k+MN_p|k)]^\top \tag{2.11}$$

由此，S 模型通过引入多维度交通参数分析实现了对路段内未来交通流的预测。并因为其考量了车辆微观特征如速度、长度等因素，并可以根据通行特点改进部分变量计算方式，故根据不同车辆类型的特征可对模型进行改进，在对规模较小的路网进行集中式控制时，可以构建存在多种车辆的路网的 S 模型，以达到拟合实际交通通行状况的要求。

2.1.3 存储转发模型

上节所述 S 模型在对路段数量较小的路网进行建模时，可以充分考虑行驶车辆特征元素，但是当路网规模进一步提高，尤其是对城市规模的交通流进行模型建立时，S 模型因其模型表达式的复杂性难以保证模型的简便与约束条件的设计要求。故本节将介绍交通流建模中另一种较为简化的存储转发模型，以便于本文对大规模城市路网的研

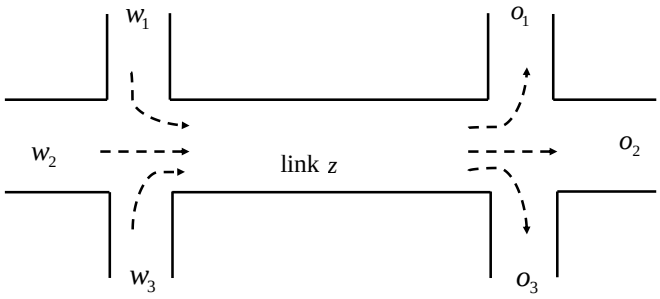

图 2.3　存储转发模型所示路网图

该模型以简化的方式表述了路网中交通流量的动态变化过程。如图 2.3 所示，设

中国知网 https://www.cnki.net

路段 z 位于两个信号控制路口之间，其交通流预测方程可由下式描述：

$$n_z(k+p+1|k) = n_z(k) + \sum_{t=0}^{p} \sum_{w \in \mathcal{N}_z^+} [r_{wz}(k+t|k) \cdot q_w(k+t|k) - q_z(k+t|k)] \quad (2.12)$$

具体来说，首先定义路段 z 存在上游路段向其输送车辆，同时存在下游路段接收其驶出车辆，上游路段集合为 $\mathcal{N}_z^+$，下游路段集合为 $\mathcal{N}_z^-$。w 表示路网除 z 外的一条路段并假设其与 z 相邻。$n_z(k)$ 表示路段 z 在时间步长 k 内的车辆数量；$r_{wz}(k)$ 表示路段 w 向其下游相邻 $z \in \mathcal{N}_w^-$ 的输送的交通流量百分比，及对应行驶方向的转弯率。$q_w(k)$ 和 $q_z(k)$ 分别表示时间步长 k 时离开路段 w 和 z 的车辆数量。对于的每条路段 z，在 $k_d \geq 0$ 时，均有 $r_{wz}(k) > 0$ 以及 $\sum_{w \in \mathcal{N}_z^+} r_{wz}(k) = 1$。根据定义，可以通过路口的交通信号来控制下游的交通流量，即通过信号灯时间控制离开路段 z 的车辆数 $q_z(k)$。在存储转发模型中，下游交通流的状态由以下方程确定：

$$q_z(k) = S_z \cdot g_z(k) \quad (2.13)$$

$$g_z(k) = \sum_{\widetilde{p} \in \mathcal{P}_z} g_p(k) \quad (2.14)$$

其中 S_z 为路段 z 内的饱和车流量，$g_z(k)$ 为路段 z 在步长 k 内的绿灯时间总长度，其由该步长内全部相位对应绿灯时间求和得出。同时定义 $\widetilde{p}$ 为相位，g_p 为该相位下路段 z 的绿灯时间，$\mathcal{P}_z$ 为全部信号灯相位的集合。为满足为了满足式 (2.13)，必须充分利用路口的绿灯时间，以保证有足够的车辆通过路段 z。故存储转发模型必须遵守以下约束：

$$q_z(k) \leq n_z(k) \quad (2.15)$$

定义一个控制步长 k 对应信号灯时间为 T_u，该约束保证在区间 $[(k+p)T_u, (k+p+1)T_u]$ 期间，从路段 z 中驶出的车辆数小于等于时刻 $(k+p)T_u$ 内路段 z 上的车辆数与上游进入该路段的车辆数之和，即确保有足够的车辆在路段内行驶。另外，从相邻的上游链路 w 进入链路 z 的上游离开车辆数必须满足：

$$\sum_{w \in \mathcal{N}_z^+} r_{wz}(k) q_w(k) \leq \bar{n}_z - n_z(k) \quad (2.16)$$

在这里，$\bar{n}_z$ 表示道路路段 z 中的饱和车辆数。这一约束确保了路段内的车辆畅通无

中国知网 https://www.cnki.net

阻。有关这些约束的更多细节可参考文献 [75]。

此外路段 z 在相位 p 时间段内控制车辆离开的绿灯时间 $g_p(k)$ 必须遵守以下约束：

$$0 \leq g_p(k) \leq \bar{g}_p \leq T_u \tag{2.17}$$

其中 $\bar{g}_p$ 表示相位 p 在路口允许设定的最大绿灯时间。

进一步地，存储转发模型可被表述为描述区域交通流在离散时间下的状态空间形式：

$$\mathbf{x}(k+1) = \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{u}(k) + \mathbf{e}(k) \tag{2.18}$$

其中，$\mathbf{x}(k)$ 表示路网中所有路段车辆数构成的状态向量；$\mathbf{u}(k)$ 为控制输入向量，由各路段的绿灯时间 $g_z(k)$ 构成；$\mathbf{e}(k)$ 为非受控车流的扰动项，体现系统的不确定性与外部输入。状态矩阵 $\mathbf{A}$ 为单位阵，控制矩阵 $\mathbf{B}$ 由转向率 r_{wz} 与饱和流量 S_z 的组合构成。

由此得到了关于路网中一条路段的存储转发模型，相比于 S 模型对于变量的定义与约束，存储转发模型简化了这一部分的建模方式，在应用于大规模路网的交通流预测控制过程中可以有效降低计算复杂度。该模型下虽对于特殊车辆类型的建模无法细化，但是在应对大量交通流通行时可以有效利用控制算法在宏观层面进行流量控制规划，针对特殊车辆类型的建模在大规模路网的交通流通行中未必是必须的[75]。

2.1.4 宏观基本图

在对路段内的车辆通行进行建模的同时，更宏观层面的交通流模型同样对本文后续研究起到帮助。宏观基本图（Macroscopic Fundamental Diagram, MFD）：用于描述特定区域内交通状态基本特性的图像，作为交通网络的核心属性之一，从宏观层面提供了交通行为与性能的整体视角[76]。通过关联网络内车辆数量（或密度）与空间交通流量，建立对应的可视化图像，并可通过对宏观基本图曲线的数值分析对路网内车辆拥堵情况进行评估。通常认为，宏观基本图的形状特征及其离散程度与路网中车辆密度的空间分布均衡性相关。已有研究表明，当车辆密度的方差较小，即交通在空间上分布较为均匀时，宏观基本图能够表现出良好的函数性质，从而具备明确的定义与描述能力。

如图2.4所示为一个定义良好的宏观基本图图像曲线。其中，蓝色曲线为基于黑色散点数据拟合所得，用以近似表示路网内车辆数量与整体通行流量之间的关系。对

中国知网 https://www.cnki.net

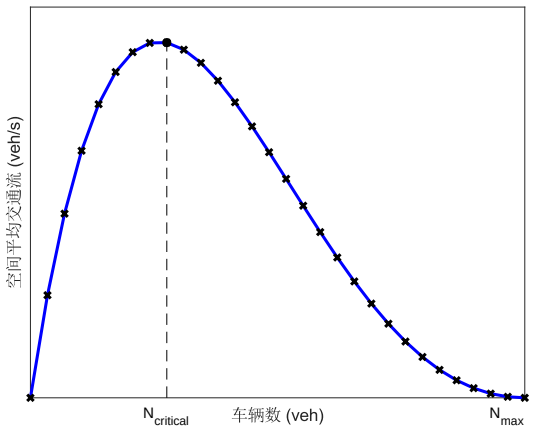

图 2.4　定义良好的宏观基本图曲线图

应区域内路网通行车辆数最大时，对应的 N_{critical} 将宏观基本图曲线分为两部分。左侧对应于路网处于未拥堵状态，即欠饱和状态下，平均交通流量维持在自由流水平；右侧则反映过饱和状态，随着车辆数量增加，网络整体通行能力显著下降，交通拥堵加剧。因而，若将城市交通网络视为一个整体，宏观基本图可有效表述其运行特性，借助该曲线可直观反映区域路网交通动态变化过程[76]。

例如，基于这些特性，可以建立一个数学模型来描述交通系统中不同区域内车辆数量的变化。假设宏观基本图定义了城市路网特定区域 i 内车辆数量与空间平均交通流量之间的函数关系，其数学表达式为：

$$q_i^w(k) = \mathcal{G}_i(N_i(k)) = \sum_{b=0}^{d} a_b N_i^b(k) \tag{2.19}$$

其中 $q_i^w(k)$ 表明该区域内在控制步长 k 内的加权车流量，$N_i(k)$ 表示步长 k 内在 i 区域的车辆数量，$\mathcal{G}_i(N_i(k))$ 表示车辆数与加权交通流之间的函数关系。函数关系具体可表现为一个多项式，其中多次项次数 d 和系数 a_b 是根据路网区域的特征确定的。加权交通流可进一步解释为空间平均交通流，其计算方式为：

$$q_i^w(k) = \frac{\sum_{r\in\mathcal{R}_i} q_r(k) l_r}{\sum_{r\in\mathcal{R}_i} l_r} \tag{2.20}$$

其中 $\mathcal{R}_i$ 是区域 i 中的路段集合，l_r 是路段 r 的长度，$q_r(k)$ 是在时间步长 k 时由传感器检测到的路段 r 上的通行车流量。利用从实地实验中收集到的交通流量数据，可以推导出区域道路网络的宏观基本图。在本文后续所呈现的相关仿真案例研究中，也将使用多项式拟合方法来获取此函数。

中国知网 https://www.cnki.net

此外宏观基本图还可通过路网通行加权车流量与流出车流量之间的数值拟合出二者之间的比例关系。该特征的数学表达式为：

$$D_i(k) = Q_{i,\text{out}}(k) + \sum_{j\in\mathcal{N}_i} Q_{ij}(k) = \kappa_i q_i^w(k) \tag{2.21}$$

其中 $D_i(k)$ 为区域 i 的总流出量，$Q_{i,\text{out}}(k)$ 为向路网外部流出的总流量，$Q_{ij}(k)$ 为向区域 j 流出的总流量，$\mathcal{N}_i$ 为与区域 i 相连的区域集合，κ_i 为由宏观基本图拟合获取的比例系数。最后可以得到一个描述区域内车辆数量变化的预测方程

$$N_i(k+1) = N_i(k) + T_u\left(Q_{i,\text{in}}(k) - Q_{i,\text{out}}(k) + \sum_{j\in\mathcal{N}_i}\left(Q_{ji}(k) - Q_{ij}(k)\right)\right) \tag{2.22}$$

其中 T_u 为样本时间间隔，$Q_{i,\text{in}}(k)$ 为来自路网外部的总流入量，$Q_{ji}(k)$ 为来自区域 j 对区域 i 的流入量。

理论研究如文献 [77-78] 证明宏观基本图曲线拟合过程中，其数据散点的分布、曲线的形状与城市路网区域的结构、路网内车流密度等有密切关系。研究表明，当所研究区域在路网结构与车辆密度分布方面保持均匀时，可获得定义良好的宏观基本图。然而，在实际大规模城市路网中，车辆密度通常呈现非均匀分布。因此，可将整体路网划分为若干相对独立的子网络；若子网络内部车流密度分布较为均匀，其对应的宏观基本图亦能展现出良好的结构特性与拟合效果[76]。因此通过宏观基本图拟合得到的数学关系作为预测模型，建立推进和优化整个网络的交通控制，可以有效在宏观层面通过区域周界控制减少城市拥堵。

2.2 模型预测控制相关理论

模型预测控制的基本原理如图2.5所示。定义一个连续系统的状态空间模型为

$$\dot{x} = f(x, u) \tag{2.23}$$

其中 $x \in \mathbb{R}^n$ 表示系统的状态变量，$u \in \mathbb{R}^m$ 为控制输入，二者需要满足

$$x \in \mathbb{X}, \quad u \in \mathbb{U} \tag{2.24}$$

其中 $\mathbb{X}$ 表示状态约束集合，$\mathbb{U}$ 表示控制输入的可行集合。设采样时间为 δ，$p = N_1\delta$ 为预测时域，N_1 为预测步数，$m = N_2\delta$ 为控制时域，N_2 为控制步数。一般取 $p = m$。

中国知网 https://www.cnki.net

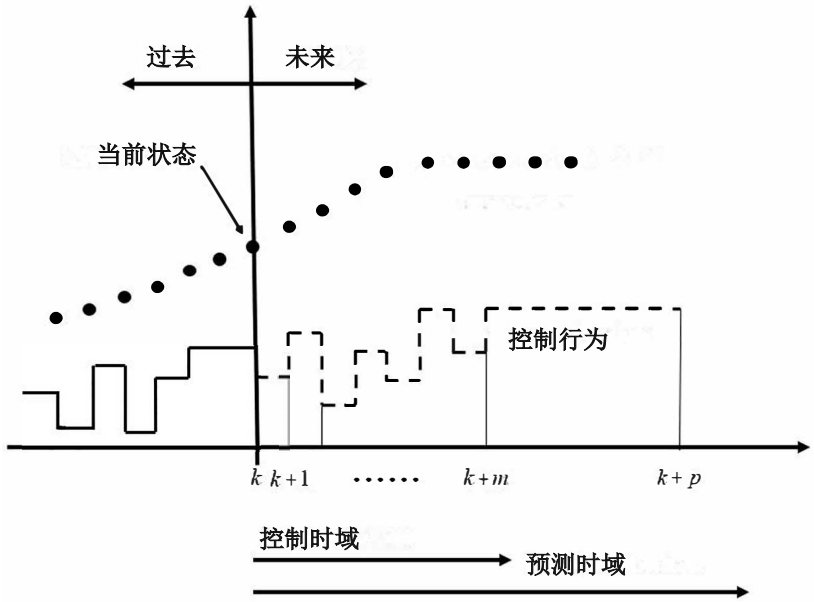

图 2.5　模型预测控制基本原理示意图

在 k 时刻，构造模型预测控制问题的成本函数为

$$J(x(k),u(k))=\int_{k}^{k+p}L(x(k+t|k),u(k+t|k))\mathrm{d}\tau+E(x(k+p|k)) \tag{2.25}$$

其中阶段代价函数表示为 $L(x(k+t|k),u(k+t|k))=|x(k+t|k)|_Q^2+|u(k+t|k)|_R^2$，终端代价函数为 $E(x(k+p|k))=|x(k+p|k)|_P^2$，$Q$、$R$、$P$ 为正定权重矩阵，用以调节系统状态与控制输入在优化过程中的权衡关系，从而影响控制器性能。因此，k 时刻的模型预测控制优化问题可表述为：

问题 2.1.

$$\min_{u(k)} \quad J(x(k),u(k)) \tag{2.26a}$$

$$\text{s.t.} \quad x(k|k)=x(k) \tag{2.26b}$$

$$\dot{x}(k+t|k)=f(x(k+t|k),u(k+t|k)) \tag{2.26c}$$

$$x(k+t|k)\in\mathbb{X} \tag{2.26d}$$

$$u(k+t|k)\in\mathbb{U} \tag{2.26e}$$

$$x(k+p|k)\in\Omega \tag{2.26f}$$

其中 $(k+t)\in[k,k+p]$，Ω 为终端约束域，用以保证模型预测控制问题在迭代过程中的可行性与闭环系统的稳定性。通过求解上述优化问题，可得到在预测区间内的最优

中国知网 https://www.cnki.net

控制序列：

$$\mathbf{u}^*(k) = \{u^*(k|k), u^*(k+\tau|t), \ldots, u^*(k+p|k)\} \tag{2.27}$$

在每个控制时刻，仅将最优控制序列 $\mathbf{u}^*(k)$ 中的首个控制输入 $u^*(k|k)$ 应用于实际系统，并在下一时刻重新测量系统状态，重复上述优化与执行过程。由此，模型预测控制的基本步骤可归纳如下：（1）在时刻 t，采集当前系统状态 $x(t)$；（2）以 $x(t)$ 为初始状态，求解对应的最优化问题，得到最优控制序列 $\mathbf{u}^*(t)$；（3）将控制序列中的首项 $u^*(t|t)$ 应用于系统，并将时间更新至 $t+1$，重复上述过程。

总结得出一个模型预测结构包含以下几个部分[79-80]：

（1）预测模型。模型预测控制是一类基于模型的控制方法，其核心在于利用系统模型对未来的动态行为进行预测。预测模型依据系统历史状态与未来控制输入，对未来输出进行估计。常用的模型形式包括状态空间模型、传递函数模型等传统建模方法，对于线性稳定系统，也可采用阶跃响应或脉冲响应等非参数模型实现预测功能。此外，若非线性系统或分布参数系统的模型具备可预测性，同样可纳入预测控制框架。通过预测模型模拟系统未来的响应行为，可在仿真中评估不同控制策略的性能，为控制器设计提供依据。

（2）滚动优化。预测控制相较于传统最优控制的主要区别在于其引入有限时域的滚动优化机制。传统最优控制通常基于全局时间范围内的统一性能指标进行求解，而预测控制在每个采样时刻仅优化当前时刻起始的一段有限预测时域内的控制输入，并在后续采样时刻将优化区间随时间滚动推进。因此，预测控制强调局部动态调整而非全局一次性求解，具备更强的实时性与适应性。这也意味着优化过程不是一次性离线求解完成，而是持续在线滚动进行，这正是预测控制能够应对不确定性问题，增强系统鲁棒性的根本所在。

（3）反馈校正。预测控制作为一种闭环控制方法，其基本思路是在优化过程中生成最优控制序列，但仅将第一个控制输入量输入系统，以减小模型误差和外部干扰带来的影响。在下一个采样时刻，系统先检测实际输出，再用实时数据修正预测，之后再重新进行优化，进而形成闭环反馈提高系统控制性能。

（4）显式处理约束。与传统控制方法相比，模型预测控制的一大优势在于其能够将系统的各种约束条件显式纳入优化问题的求解过程中。通过在优化过程中直接考虑这些约束，求解既满足约束又最优化性能指标的控制序列，实现对系统的有效调控。

中国知网 https://www.cnki.net

2.3 本章小结

本章作为预备知识，主要介绍了城市交通流宏观模型的建立和模型预测控制相关内容。第一部分通过对交通流相关概念以及 S 模型、存储转发模型和宏观基本图的介绍，为城市交通流在模型预测控制方法运用时的数学模型建立奠定基础。其中 S 模型适合用于规模较小的路段模型并可根据不同的车辆特征类型进行模型的改进；存储转发模型在应对大规模路网的交通流控制时具有显著的简化特点，通过在宏观层面将各类车辆抽象为相同的车流降低了对约束处理的复杂度；宏观基本图则在城市区域的周界控制中提供了一种有效的工具，以交通流数据散点拟合曲线，进而进行数学模型的构建，在此基础上进行通行优化可有效提高大规模区域路网的通行效率。最后，模型预测控制作为本文主要使用的控制方法，本章介绍了其相关理论知识，对基本原理与结构优势等进行了说明。通过以上介绍，为后续章节的研究提供了有力支撑。

中国知网 https://www.cnki.net

第 3 章 包含公交专用道的三路口交通流模型预测控制

3.1 引言

随着城市交通系统的复杂化，宏观城市交通模型逐渐发展为解析路网动态特性的有效工具。这类模型与控制理论的深度融合，为提升交通网络管控效能开辟了新路径。模型预测控制作为处理多约束非线性系统的先进方法，通过在每个采样周期求解带有约束的开环优化问题，实现可行域内代价函数的最小化，现已成为智能交通领域的重要技术方式。典型应用如文献 [54] 在模型预测控制中整合自行车流量参数，构建多模态交通协调机制；文献 [55] 则将模型预测控制与应急车辆优先调度相结合，在缓解路网拥堵的同时实现应急通道的动态保障。但现有模型在异构交通流表征方面仍存在显著局限：一方面，多数研究聚焦于普通机动车的基础通行行为建模，对公交系统等特殊车流的动力学特性缺乏系统刻画；另一方面，交通控制策略与多源交通数据的融合深度不足，制约了模型在真实场景中的预测精度。

另外，前文2.1.2节所介绍的研究人员构建的 S 模型虽在异构交通流建模方面取得进展，但其空间尺度局限性与动态耦合机制缺失仍制约着复杂路网管控效能。该模型的基础形式下所引入的车辆类型特征参数体系实现了私家车、货运车辆等独立主体的差异化描述，却未能充分表征公交系统特有的运行约束，如专用道占用逻辑、站点停靠引发的车流扰动，以及信号优先请求触发的相位突变等关键交通流特性。既有研究如文献 [81-83] 虽尝试将公交要素纳入宏观交通模型，但多采用静态权值分配方式处理车辆交互，忽略了公交停靠站引发的。此外，现有模型预测控制框架在协调多交叉口信号时，往往将公交优先简化为固定相位延长策略，缺乏与周边社会车辆通行需求的动态博弈机制。因此，通过对 S 模型的改进建立具有多尺度耦合特征的扩展型交通流模型，并为此设计模型预测控制方案已成为实现公交优先与路网整体效能协同优化的关键。

针对上述挑战，本章提出一种包含公交专用道的三路口交通流模型预测控制方案，主要研究内容以及创新点为：

1. 在 S 模型框架基础上，改进建立包含公交车辆元素、公交专用道元素、站点停靠行为以及多交叉口协同的扩展模型。通过引入公交车辆与其专用道模型，以及站点停留行为模型，实现对普通社会车辆与公交车辆混合交通流的多尺度耦

中国知网 https://www.cnki.net

合表征，有效刻画上下游交叉口的交通流传递。

2. 基于改进后的 S 模型，本章提出了一种新颖的模型预测控制方案，兼顾社会车辆通行效率与公交站点排队优化的双目标代价函数。该框架通过交通信号控制对交通流状态变量进行通行优化，通过求解滚动时间范围内的在线优化问题，实现多路口信号灯配时方案动态优化与公交优先请求的响应。

3. 通过 Python-城市交通模拟平台（Simulation of urban mobility, SUMO）联合仿真，并与固定信号灯配时方案与 SUMO 平台自带通行机制方案进行对比，验证该模型预测控制框架下的应用显著改善了网络内的交通流通行拥堵压力，为拥堵管理提供了一种有前景的方法。

3.2 问题构建

3.2.1 三路口交通系统的 S 模型

第2.1.2节所示基础 S 模型，其能够更好地呈现真实的交通系统中的多种元素，并可根据不同车辆与通行要求进行模型改写，同时相比于复杂的微观交通流模型其计算负担有显著降低。然而值得注意的是，原模型仅考虑单一路段，因此在实际应用中缺乏对多个路段之间相互耦合以及上下游交通流量对交叉路口接入影响的考量。为了克服这些局限性，本节中对 S 模型进行了扩展。

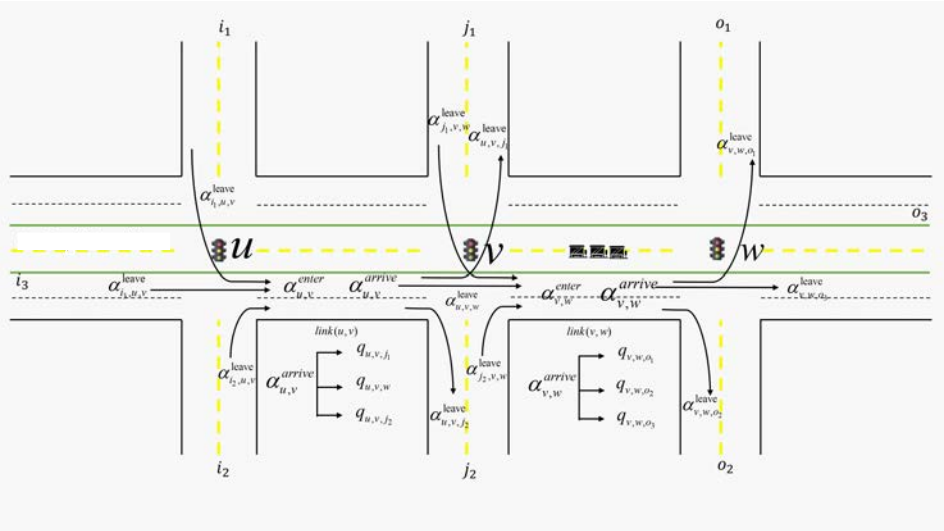

图 3.1　改进后 S 模型所建模路段示意图

如图3.1所示，将图2.2所示的双路口模型进一步扩展为三路口，分别使用 u、v、w

中国知网 https://www.cnki.net

表示三个路口，link(u,v) 表示路口 u 和路口 v 之间的路段，而 link(v,w) 表示路口 v 和路口 w 之间的路段。首先在不考虑图中的公交车专用道及公交车辆通行的情况下，仅对普通车辆通行的路段进行建模。结合 S 模型的数学表达式，构建三路口交通系统中 link(u,v) 和 link(v,w) 的 S 模型如式(3.1) - (3.20)所示，其各符号对应变量见表3.1。

$$n_{u,v}(k+1) = n_{u,v}(k) + \left(\alpha_{u,v}^{\text{enter}}(k) - \alpha_{u,v}^{\text{leave}}(k)\right) \cdot c_d \tag{3.1}$$

$$\alpha_{u,v}^{\text{leave}}(k) = \alpha_{u,v,j_1}^{\text{leave}}(k) + \alpha_{u,v,j_2}^{\text{leave}}(k) + \alpha_{u,v,w}^{\text{leave}}(k) \tag{3.2}$$

$$\alpha_{u,v}^{\text{enter}}(k) = \sum_{i_1,i_2,i_3} \alpha_{(i_1,i_2,i_3),u,v}^{\text{leave}}(k) \tag{3.3}$$

$$\begin{aligned}\alpha_{u,v,(j_1,j_2,w)}^{\text{leave}}(k) = \min\Bigg(&\frac{\beta_{u,v,(j_1,j_2,w)}(k)\mu_{u,v}g_{u,v,(j_1,j_2,w)}(k)}{c_d},\\ &\frac{q_{u,v,(j_1,j_2,w)}(k)}{c_d} + \alpha_{u,v,(j_1,j_2,w)}^{\text{arrive}}(k),\\ &\beta_{u,v,(j_1,j_2,w)}(k) \cdot \frac{C_{v,(j_1,j_2,w)} - n_{v,(j_1,j_2,w)}(k)}{c_d}\Bigg)\end{aligned} \tag{3.4}$$

$$q_{u,v,(j_1,j_2,w)}(k+1) = q_{u,v,(j_1,j_2,w)}(k) + \left(\alpha_{u,v,(j_1,j_2,w)}^{\text{arrive}}(k) - \alpha_{u,v,(j_1,j_2,w)}^{\text{leave}}(k)\right) \cdot c_d \tag{3.5}$$

$$\alpha_{u,v,(j_1,j_2,w)}^{\text{arrive}}(k) = \beta_{u,v,(j_1,j_2,w)}(k) \cdot \alpha_{u,v}^{\text{arrive}}(k) \tag{3.6}$$

$$\begin{aligned}\alpha_{u,v}^{\text{arrive}}(k) = &\frac{c_d - \gamma_{u,v}(k)}{c_d} \cdot \alpha_{u,v}^{\text{enter}}\left(k - \tau_{u,v}(k)\right) +\\ &\frac{\gamma_{u,v}(k)}{c_d} \cdot \alpha_{u,v}^{\text{enter}}\left(k - \tau_{u,v}(k) - 1\right)\end{aligned} \tag{3.7}$$

$$\tau_{u,v}(k) = \text{floor}\left\{\frac{(C_{u,v} - q_{u,v}(k)) \cdot l_{\text{veh}}}{N_{u,v}^{\text{lane}} \cdot v_{u,v}^{\text{free}} \cdot c_d}\right\} \tag{3.8}$$

$$\gamma_{u,v}(k) = \text{rem}\left\{\frac{(C_{u,v} - q_{u,v}(k)) \cdot l_{\text{veh}}}{N_{u,v}^{\text{lane}} \cdot v_{u,v}^{\text{free}} \cdot c_d}\right\} \tag{3.9}$$

$$q_{u,v}(k) = \sum_{j_1,j_2,w} q_{u,v,(j_1,j_2,w)}(k) \tag{3.10}$$

$$n_{v,w}(k+1) = n_{v,w}(k) + \left(\alpha_{v,w}^{\text{enter}}(k) - \alpha_{v,w}^{\text{leave}}(k)\right) \cdot c_d \tag{3.11}$$

$$\alpha_{v,w}^{\text{leave}}(k) = \alpha_{v,w,o_1}^{\text{leave}}(k) + \alpha_{v,w,o_2}^{\text{leave}}(k) + \alpha_{v,w,o_3}^{\text{leave}}(k) \tag{3.12}$$

$$\alpha_{v,w}^{\text{enter}}(k) = \sum_{j_1,j_2,u} \alpha_{(j_1,j_2,u),v,w}^{\text{leave}}(k) \tag{3.13}$$

$$\begin{aligned}\alpha_{v,w,(o_1,o_2,o_3)}^{\text{leave}}(k) = \min\Bigg(&\frac{\beta_{v,w,(o_1,o_2,o_3)}(k)\mu_{v,w}g_{v,w,(o_1,o_2,o_3)}(k)}{c_d},\\ &\frac{q_{v,w,(o_1,o_2,o_3)}(k)}{c_d} + \alpha_{v,w,(o_1,o_2,o_3)}^{\text{arrive}}(k),\\ &\beta_{v,w,(o_1,o_2,o_3)}(k) \cdot \frac{C_{w,(o_1,o_2,o_3)} - n_{w,(o_1,o_2,o_3)}(k)}{c_d}\Bigg)\end{aligned} \tag{3.14}$$

中国知网 https://www.cnki.net

$$q_{v,w,(o_1,o_2,o_3)}(k+1) = q_{v,w,(o_1,o_2,o_3)}(k) + \left(\alpha^{\text{arrive}}_{v,w,(o_1,o_2,o_3)}(k) - \alpha^{\text{leave}}_{v,w,(o_1,o_2,o_3)}(k)\right) \cdot c_d \tag{3.15}$$

$$\alpha^{\text{arrive}}_{v,w,(o_1,o_2,o_3)}(k) = \beta_{v,w,(o_1,o_2,o_3)}(k) \cdot \alpha^{\text{arrive}}_{v,w}(k) \tag{3.16}$$

$$\begin{aligned}\alpha^{\text{arrive}}_{v,w}(k) = {} & \frac{c_d - \gamma_{v,w}(k)}{c_d} \cdot \alpha^{\text{enter}}_{v,w}\left(k - \tau_{v,w}(k)\right) + \\ & \frac{\gamma_{v,w}(k)}{c_d} \cdot \alpha^{\text{enter}}_{v,w}\left(k - \tau_{v,w}(k) - 1\right)\end{aligned} \tag{3.17}$$

$$\tau_{v,w}(k) = \text{floor}\left\{\frac{(C_{v,w} - q_{v,w}(k)) \cdot l_{\text{veh}}}{N^{\text{lane}}_{v,w} \cdot v^{\text{free}}_{v,w} \cdot c_d}\right\} \tag{3.18}$$

$$\gamma_{v,w}(k) = \text{rem}\left\{\frac{(C_{v,w} - q_{v,w}(k)) \cdot l_{\text{veh}}}{N^{\text{lane}}_{v,w} \cdot v^{\text{free}}_{v,w} \cdot c_d}\right\} \tag{3.19}$$

$$q_{v,w}(k) = \sum_{o_1,o_2,o_3} q_{v,w,(o_1,o_2,o_3)}(k) \tag{3.20}$$

两路段在 v 路口处的交通流发生交互，其关系如下所示：

$$\alpha^{\text{leave}}_{u,v,w}(k) = \alpha^{\text{enter}}_{v,w}(k) \tag{3.21}$$

由此建立的 link(u,v) 与 link(v,w) 之间的 S 模型形成了特定的数值关联关系。在分析通过交叉口 v 的交通流情况时，必须综合考虑直接穿越该交叉口的车辆，以及进出该节点的车辆交通行为。为了更合理地刻画通行过程中的便利程度，本研究针对普通车辆在交叉口 v 的通行制定了相应的规则，其基本设计如图 3.2 所示。该通行规则旨在在保障交通流连续性的基础上，尽可能反映现实交通场景中驾驶行为的基本特征和通行优先关系。

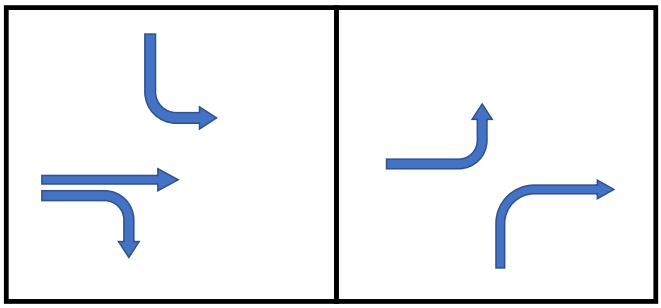

图 3.2　v 路口普通车辆通行相位示意图

在采用改进后的 S 模型对系统未来状态进行预测时，可通过预设的交通检测器或

中国知网 https://www.cnki.net

表 3.1　改进后 S 模型中各普通路段符号的定义

符号	对应变量物理意义
$n_{u,v}$	link(u,v) 内的普通车辆总数
$n_{v,w}$	link(v,w) 内的普通车辆总数
$q_{u,v,(j_1,j_2,w)}$	link(u,v) 各条车道上排队等候的平均车辆数
$q_{v,w,(o_1,o_2,o_3)}$	link(v,w) 各条车道上排队等候的平均车辆数
$\alpha_{u,v}^{\text{enter}}$	进入 link(u,v) 的车流量
$\alpha_{v,w}^{\text{enter}}$	进入 link(v,w) 的车流量
$\alpha_{u,v}^{\text{arrive}}$	到达 link(u,v) 排队队尾的车流量
$\alpha_{v,w}^{\text{arrive}}$	到达 link(v,w) 排队队尾的车流量
$\alpha_{(i_1,i_2,i_3),u,v}^{\text{leave}}$	离开 i_1,i_2,i_3 方向进入 link(u,v) 的车流量
$\alpha_{u,v,(j_1,j_2,w)}^{\text{leave}}$	从 j_1,j_2,w 方向离开 link(u,v) 的车流量
$\alpha_{(u,j_1,j_2),v,w}^{\text{leave}}$	离开 u,j_1,j_2 方向进入 link(v,w) 的车流量
$\alpha_{v,w,(o_1,o_2,o_3)}^{\text{leave}}$	从 o_1,o_2,o_3 方向离开 link(v,w) 的车流量
$q_{u,v,(j_1,j_2,w)}$	在 link(u,v) 排队离开并通向不同方向的车辆数
$q_{v,w,(o_1,o_2,o_3)}$	在 link(v,w) 排队离开并通向不同方向的车辆数
$n_{v,(j_1,j_2,w)}$	在 v 路口从不同方向离开 link(u,v) 的车辆数
$n_{w,(o_1,o_2,o_3)}$	在 w 路口从不同方向离开 link(v,w) 的车辆数
$\mu_{u,v}$	离开 link(u,v) 的饱和车流量
$\mu_{v,w}$	离开 link(v,w) 的饱和车流量
$g_{u,v,(j_1,j_2,w)}$	一个周期内 link(u,v) 中通向不同方向的绿灯时间
$g_{v,w,(o_1,o_2,o_3)}$	一个周期内 link(v,w) 中通向不同方向的绿灯时间
$\beta_{u,v,(j_1,j_2,w)}$	link(u,v) 中车辆通向不同方向的转弯率
$\beta_{v,w,(o_1,o_2,o_3)}$	link(v,w) 中车辆通向不同方向的转弯率
$C_{v,(j_1,j_2,w)}$	link(u,v) 中不同通行方向车道的最大容量
$C_{w,(o_1,o_2,o_3)}$	link(u,v) 中不同通行方向车道的最大容量
c_d	信号灯周期时间长度

历史交通数据，获取部分关键变量在预测步骤 k 内的数值。例如，车辆数 $n(k)$ 与排队车辆数 $q(k)$ 等状态量需要根据系统当前的交通流通行状况进行动态更新，以反映实时交通运行态势；而转弯率 β、通行容量 C、车辆平均通行速度 v^{free}、车辆长度 l_{veh}

中国知网 https://www.cnki.net

以及车道数 N^{lane} 等参数，通常具有相对稳定的统计特性，因此可依据历史数据设定为固定值。通过这种方式，有效降低了由不确定因素引起的模型误差，提升了预测模拟的稳定性与可靠性。仿真结果在缺乏外部扰动和未知变量干扰的条件下，能够较为准确地反映所构建模型的性能与行为特征。

3.2.2 公交专用道的 S 模型

在图3.1所示 S 模型建模交通系统中，除了普通车辆在路段内通行外，还增加了一条公交车专用车道（Bus Rapid Transit Lane，BRTL）与公交车需要进行临时停靠的公交站点（Station），图3.3所示为公交车在交通系统内的通行路段与方向。

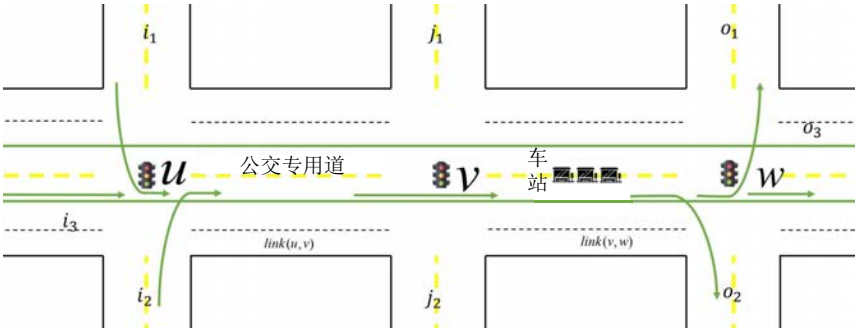

图 3.3　公交专用道与车站路段示意图

快速公交（Bus Rapid Transit, BRT）是当前城市应对城市中心重要道路为疏解公共交通通行效率采用的一种方式，作为现代城市交通治理的重要创新模式，通过构建公交车辆专用路权体系实现交通效率优化[84]。其为公交车辆单独划定通行车道以消解普通车辆与公共交通的在路段内通行的平面冲突，提升公交服务可靠性和运行效率[85]。本研究将其加入三路口交通系统中，并增加车站元素以重点探究公交类型车辆与普通车辆的通行动态平衡。针对公交车元素的 S 模型如式(3.22) - (3.33)所示，其中各符号对应变量见表3.2。

需要说明的是，所设计的公交车行驶路线在 v 路口仅有直线行驶一个前进方向，由此可以便于利用 v 路口的信号灯方案设置优化车站的排队车流，这仅是根据实际可能出现情况在后文案例研究中使用的一种假设。

对于公交车的 S 模型构建，受到车辆行驶方式本身以及专用道、车站的限制，其数学模型本身相比于普通车辆有如下变化：

(1)公交车辆在 link(u,v) 与 link(v,w) 上的行驶状态不同，在 link(u,v) 中正常行驶，

中国知网 https://www.cnki.net

$$n_{u,v}^{\mathrm{B}}(k+1) = n_{u,v}^{\mathrm{B}}(k) + \left(\alpha_{u,v}^{\text{B-enter}}(k) - \alpha_{u,v}^{\text{B-leave}}(k)\right) \cdot c_d \tag{3.22}$$

$$n_{v,w}^{\mathrm{B}}(k+1) = n_{v,w}^{\mathrm{B}}(k) + \left(\alpha_{v,w}^{\text{B-enter}}(k) - \alpha_{v,w}^{\text{B-leave}}(k)\right) \cdot c_d \tag{3.23}$$

$$q_{u,v}^{\mathrm{B}}(k+1) = q_{u,v}^{\mathrm{B}}(k) + \left(\alpha_{u,v}^{\text{B-arrive}}(k) - \alpha_{u,v}^{\text{B-leave}}(k)\right) \cdot c_d \tag{3.24}$$

$$q_{v,w}^{\mathrm{B}}(k+1) = q_{v,w}^{\mathrm{B}}(k) + \left(\alpha_{v,w}^{\text{B-arrive}}(k) - \alpha_{v,w}^{\text{B-leave}}(k)\right) \cdot c_d \tag{3.25}$$

$$\alpha_{u,v}^{\text{B-enter}}(k) = \sum_{i_1,i_2,i_3} \alpha_{(i_1,i_2,i_3),u,v}^{\text{B-leave}}(k) \tag{3.26}$$

$$\alpha_{u,v}^{\text{B-leave}}(k) = \min\left(\frac{\mu_{u,v}^{B} \cdot g_{u,v}^{\mathrm{B}}(k)}{c_d}, \frac{q_{u,v}^{\mathrm{B}}(k)}{c_d}\right) \tag{3.27}$$

$$\alpha_{u,v}^{\text{B-arrive}}(k) = \alpha_{u,v}^{\text{B-enter}}\left(k - \tau_{u,v}^{B}(k)\right) \tag{3.28}$$

$$\tau_{u,v}^{\mathrm{B}}(k) = \text{round}\left\{\frac{\left(C_{u,v}^{B} - q_{u,v}^{B}(k)\right) \cdot l_{\text{veh}}^{\mathrm{B}}}{N_{u,v}^{\text{B-lane}} \cdot v_{u,v}^{\text{B-free}} \cdot c_d}\right\} \tag{3.29}$$

$$\alpha_{v,w}^{\text{B-enter}}(k) = \alpha_{u,v}^{\text{B-leave}}(k) \tag{3.30}$$

$$\alpha_{v,w}^{\text{B-leave}}(k) = \min\left(\frac{\mu_{v,w}^{B} \cdot g_{v,w}^{\mathrm{B}}(k)}{c_d}, \frac{q_{v,w}^{\mathrm{B}}(k)}{c_d}\right) \tag{3.31}$$

$$\alpha_{v,w}^{\text{B-arrive}}(k) = \alpha_{v,w}^{\text{B-enter}}\left(k - \tau_{v,w}^{B}(k)\right) \tag{3.32}$$

$$\tau_{v,w}^{B}(k) = \text{round}\left\{\frac{\left(C_{u,v}^{B} - q_{\text{station}}^{\mathrm{B}}(k) - q_{v,w}^{B}(k)\right) \cdot l^{\mathrm{B}}}{N_{v,w}^{\text{B-lane}} \cdot v_{v,w}^{\text{B-free}} \cdot c_d}\right\} \tag{3.33}$$

接受 i_1, i_2, i_3 方向行驶汇入的车流量，故式(3.26)的表现形式与普通车辆的形式(3.3)相同；但车辆在 link(v,w) 中所接受的只有 link(u,v) 驶出的车流量，故 $\alpha_{v,w}^{\text{B-enter}}(k)$ 表现为式(3.30)；

(2) 公交车辆属于少数比例类型，其输出车流量通常不超过下游可用空间，因此式(3.27)和式(3.31)中省略了下游路段的可用空间的影响；

(3) 公交车辆在专用道内不会单独出现相互间的拥堵情况，故对式(3.28)和(3.32)中 $\alpha^{\text{B-arrive}}(k)$ 公交车流在路段排队的延误进行了简化，并假设舍入延迟充分反映了总车流量的状态变化；

(4) 受公交车在车站的停靠影响，$\alpha_{v,w}^{\text{B-arrive}}(k)$ 需要加入车站部分排队车流，如式(3.33)所示；

(5) 结合公交车的行驶特性，选择使用round{} 函数计算路口排队延误[86]。

中国知网 https://www.cnki.net

表 3.2　改进后 S 模型中公交专用路段符号的定义

符号	对应变量物理意义
$n^{\mathrm{B}}_{u,v}$	link(u,v) 的公交车辆数
$n^{\mathrm{B}}_{v,w}$	link(v,w) 的公交车辆数
$\alpha^{\text{B-enter}}_{u,v}$	进入 link(u,v) 的公交车流量
$\alpha^{\text{B-enter}}_{v,w}$	进入 link(v,w) 的公交车流量
$\alpha^{\text{B-arrive}}_{u,v}$	到达 link(u,v) 排队队尾的公交车流量
$\alpha^{\text{B-arrive}}_{v,w}$	到达 link(v,w) 排队队尾的公交车流量
$\alpha^{\text{B-leave}}_{(i_1,i_2,i_3),u,v}$	从 i_1,i_2,i_3 方向汇入 link(u,v) 的公交车流量
$\alpha^{\text{B-leave}}_{u,v}$	从 v 路口直行离开 link(u,v) 的车流量
$\alpha^{\text{B-leave}}_{v,w}$	从 w 路口离开 link(v,w) 的公交车流量
$q^{\mathrm{B}}_{u,v}$	在 link(u,v) 排队直行离开并进入 link(v,w) 的公交车辆数
$q^{\mathrm{B}}_{v,w}$	在 link(v,w) 排队离开的公交车辆数
$q^{\mathrm{B}}_{\text{station}}$	在车站排队等待离开的公交车辆数
$\mu^{\mathrm{B}}_{u,v}$	离开 link(u,v) 的饱和公交车流量
$\mu^{\mathrm{B}}_{v,w}$	离开 link(v,w) 的饱和公交车流量
$g^{\mathrm{B}}_{u,v}$	一个周期内 v 路口公交车允许通行的绿灯时间
$g^{\mathrm{B}}_{v,w}$	一个周期内 w 路口公交车允许通行的绿灯时间
$C^{\mathrm{B}}_{u,v}$	link(u,v) 中公交车专用道的最大容量
$C^{\mathrm{B}}_{v,w}$	link(v,w) 中公交车专用道的最大容量
$l^{\mathrm{B}}_{\text{veh}}$	公交车辆车长
$v^{\text{B-free}}$	公交车辆平均通行速度
N^{B}	link(u,v) 与 link(v,w) 中公交车专用道车道数
N_{Station}	公交车站中最多可以同时停靠的车辆数
c_d	信号灯周期时间长度

3.2.3 优化问题构建

在对改进后的 S 模型构建数学表达式后，可对交通网络的交通流状态进行预测。在预测控制与优化过程中，每个采样时间步长 k 内通过测量队列、车辆和公交车的数量，以及公交车站和每个交叉路口的当前状态，可获得对应变量在 k 时刻的当前状

中国知网 https://www.cnki.net

态。在此基础上，通过构造合适的成本函数可构造优化问题，通过求解计算满足系统约束条件的交通信号控制最优绿灯时间。由于公交车元素的存在，使得 link(u,v) 和 link(v,w) 中的路段构成并不相同，针对交通流的通行需要兼顾车辆的拥堵与公交车排队进站的问题。故在整个包含公交专用道的三路口交通系统中，可对二者分别构建优化目标函数。

定义图3.1所示三路口交通系统中全部路段的集合 $L = L_1 \cap L_2$。L_1 为全部普通车道与 link(u,v) 中的公交专用道，需要优化拥堵问题；L_2 为 link(v,w) 中公交专用道，因存在公交车站，需要优化进站排队问题。

对于 link(u,v)，普通车辆与公交车辆在该路段通行方式相同，交通流的优化以缓解拥堵为主要优化指标，需要保证全部车辆的尽快通过，故总消耗时间（Total Time Spent, TTS）可作为目标函数。而对于 link(v,w)，普通的车辆的通行仍以快速通过路段为目标。故对系统 TTS 的优化目标函数可构建如式(3.34)所示。

$$J_{\text{TTS}} = \sum_{t=1}^{p} \left(n_{u,v}(k+t|k) \cdot c_d + n^{\text{B}}_{u,v}(k+t|k) \cdot c_d + n_{v,w}(k+t|k) \cdot c_d \right) \tag{3.34}$$

其中 p 为预测时域，预测步长设定为周期时间的整数倍。对应优化问题描述为：

问题 3.1.

$$\min_{U_{k_1}} \quad \sum_{\text{link}\in L_1} J_{TTS} \tag{3.35a}$$

$$\begin{aligned}
\text{s.t.} \quad & \text{for} \quad t = 0,1,2,\ldots,p-1 \quad \text{and} \quad \text{link} \in L_1 \\
& n_{u,v}(k+t+1|k) = f\left(n_{u,v}(k+t|k), q_{u,v}(k+t|k), \right. \\
& \qquad\qquad \left. g_{u,v}(k+t|k)\right) && (3.35b) \\
& 0 \le n_{u,v}(k+t|k) \le C_{u,v} && (3.35c) \\
& q_{u,v}(k+t|k) \ge 0 && (3.35d) \\
& 0 \le g_{u,v}(k+t|k) \le c_d && (3.35e) \\
& n^{B}_{u,v}(k+t+1|k) = f\left(n^{B}_{u,v}(k+t|k), q^{B}_{u,v}(k+t|k), \right. \\
& \qquad\qquad \left. g^{B}_{u,v}(k+t|k)\right) && (3.35f) \\
& 0 \le n^{B}_{u,v}(k+t|k) \le C^{B}_{u,v} && (3.35g) \\
& q^{B}_{u,v}(k+t|k) \ge 0 && (3.35h) \\
& 0 \le g^{B}_{u,v}(k+t|k) \le c_d && (3.35i) \\
& n_{v,w}(k+t+1|k) = f\left(n_{v,w}(k+t|k), q_{v,w}(k+t|k), \right. \\
& \qquad\qquad \left. g_{v,w}(k+t|k)\right) && (3.35j) \\
& 0 \le n_{v,w}(k+t|k) \le C_{v,w} && (3.35k)
\end{aligned}$$

中国知网 https://www.cnki.net

$$q_{v,w}(k+t|k) \geq 0 \tag{3.35l}$$
$$0 \leq g_{v,w}(k+t|k) \leq c_d \tag{3.35m}$$

根据3.2.1和3.2.2节对普通车辆与公交车辆交通流所构建的 S 模型表达式，可认为构建了如式(3.35b)、式(3.35f)和式(3.35j)所示的交通流状态的预测函数。各变量间还需要满足如下不等式约束关系：（1）各路段车辆的数量不能超过路段容量，如式(3.35c)、式(3.35g) 和式(3.35k)所示；（2）在一个步长内各路段排队车辆为正整数，如式(3.35d)、式(3.35h) 和式(3.35l)所示；（3）绿灯时间长度不超过一个周期长度，如式(3.35e)、式(3.35i) 和式(3.35m)所示。

对于 link(v,w) 的公交车专用道，公交车辆需要在车站位置临时停靠，交通流的优化以疏解排队等待为主要优化指标。通过利用上下游信号灯控制 link(v,w) 内公交车的驶入与流出，进而对公交车站同时停靠车辆数进行限制，减少在车站外等待排队进站的车辆数量。故车站队列（Station Queue, SQ）可作为目标函数。系统 SQ 的优化目标函数可构建如式(3.36)所示。

$$J_{\text{SQ}} = \sum_{t=1}^{p} \left(n^{\text{B}}_{v,w}(k+t|k) - q^{\text{B}}_{v,w}(k+t|k) - N_{\text{station}} \right) \tag{3.36}$$

对应构建优化问题可描述为：

问题 3.2.

$$\min_{U_{k_2}} \quad \sum_{\text{link}\in L_2} J_{SQ} \tag{3.37a}$$
$$\text{s.t.} \quad \text{for} \quad t = 0,1,2,\ldots,p-1 \quad \text{and} \quad \text{link} \in L_2$$
$$n^B_{v,w}(k+t+1|k) = f\left(n^B_{v,w}(k+t|k), q^B_{v,w}(k+t|k), g^B_{v,w}(k+t|k)\right) \tag{3.37b}$$
$$0 \leq n^B_{v,w}(k+t|k) \leq C^B_{v,w} \tag{3.37c}$$
$$q^B_{v,w}(k+t|k) \geq 0 \tag{3.37d}$$
$$0 \leq g^B_{v,w}(k+t|k) \leq c_d \tag{3.37e}$$

根据3.2.2节对公交车辆交通流所构建的 S 模型表达式，可认为构建了式(3.37b)所示的 link(v,w) 内公交车专用道内交通流状态的预测函数。与 TTS 对应优化问题相同，各变量间也需要满足如下不等式约束关系：(1) 车辆数不超过路段容量，如式(3.37c)所示；（2）在一个步长内在路口排队车辆为正整数，如式(3.37d)所示；（3）绿灯时间长度不超过一个周期长度，如(3.37e)所示。

中国知网 https://www.cnki.net

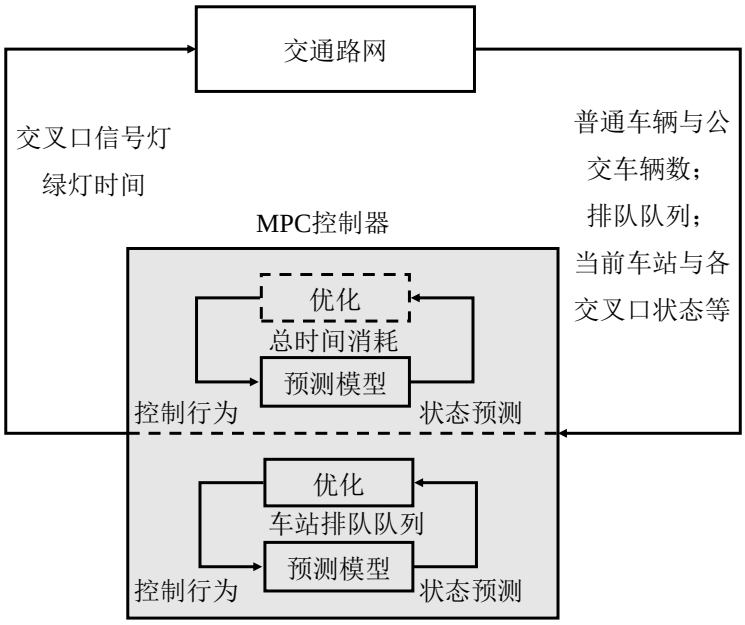

图 3.4　包含公交专用道的三路口交通流集中式模型预测控制方案示意图

通过对优化目标 TTS 和 SQ 优化问题的设立，得到了两个求解控制变量 U_{k_1} 和 U_{k_2} 的问题。

$$U_{k_1} = \begin{bmatrix} g_1^{\mathrm{T}}(k|k) & g_1^{\mathrm{T}}(k+1|k) & \dots & g_1^{\mathrm{T}}(k+p-1|k) \end{bmatrix} \tag{3.38}$$

$$U_{k_2} = \begin{bmatrix} g_2^{\mathrm{T}}(k|k) & g_2^{\mathrm{T}}(k+1|k) & \dots & g_2^{\mathrm{T}}(k+p-1|k) \end{bmatrix} \tag{3.39}$$

U_{k_1} 和 U_{k_2} 是优化问题求解路段对应的信号灯绿灯时间序列矩阵。对于问题 3.1 和问题 3.2，一旦（3.35）和（3.37）给出的非线性优化问题得到对应的数值解（3.38）和（3.39），则模型预测控制可被用于该交通系统的交通流控制中，控制序列中的第一个控制动作将应用于每个交叉口信号灯。

3.3 集中式模型预测控制方案设计

在3.2节，通过对一个包含公交车专用道的三路口交通系统进行了 S 模型的升级构建，得到了两个对不同路段的优化问题，本节将设计一个集中式模型预测控制方案实现对该系统交通流的模型预测控制。

首先对系统的控制方案设计如图3.4所示，在当前时刻采样时间 k 内，通过对 S 模型中所需变量，包括排队车辆数量、道路上行驶车辆总数以及公交车辆的数量等动

中国知网 https://www.cnki.net

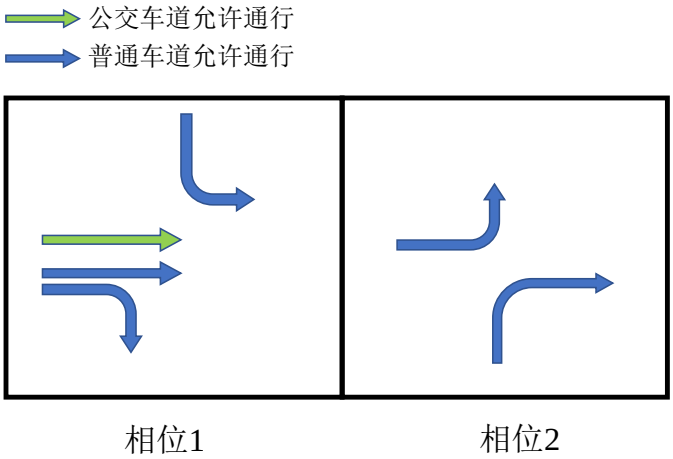

图 3.5　优化后 v 路口通行相位示意图

态交通流参数的测量计算，并结合对公交车站点状态及各信号灯所控制交叉路口的运行状态，获取系统在当前时间步 k 时刻的完整状态信息。将对应参数传入模型预测控制器后，通过两个优化问题的求解获得两组信号灯绿灯时长控制序列。需要指出的是，问题 3.1 与问题 3.2 均为非线性优化问题，可选择序列最小二乘规划法（Sequential Least Squares Quadratic Programming, SLSQP）进行求解。在对式（3.35）给出的问题 3.1 进行求解时，会出现普通车辆行驶车道与公交车专用道信号灯时间差异化问题，同时因公交车专用道划定的行驶方向与普通车辆行驶方向在 v 路口会出现冲突，故在模型预测控制器中设置如图3.5所示相位解决通行冲突问题，并设计算法1对信号灯绿灯时长进行调整，解决 v 路口公交车与普通车辆绿灯时间长度协调的问题。

算法1提出了一种基于加权平均与约束修正的协调方法。问题 3.1 中优化得到的控制序列 U_{k_1}，其中第一项 $g_1^{\mathrm{T}}(k|k)$ 中取公交车绿灯时长 g_{B} 与普通车绿灯时长 g_{O}，建立具有权重可配置特性的线性组合模型 $g_{\mathrm{share}} = \lambda_1 g_{\mathrm{B}} + \lambda_2 g_{\mathrm{O}}$，其中 $\lambda_1, \lambda_2 \in [0, 1]$ 表示优先权分配系数；考虑到实际信号配时对绿灯时长存在最小、最大及当前相位可用时长等约束，算法进一步对 g_{share} 进行逐项判断与修正，实施多约束合规性迭代修正过程，确保协调结果在满足交通安全与信号周期约束的同时，实现对公交优先与普通车辆通行的兼顾。

至此，优化问题求解所得控制序列的第一项均转化为可实际使用的绿灯时间，结合相位设置下一时刻 $k+1$ 所使用的信号灯方案后实现控制量在系统内的输入，并令 $k \to k+1$ 实现滚动优化，得到了在预测时域内全部路段所对应的绿灯通行时间。

中国知网　https://www.cnki.net

算法 1: v 路口公交车与普通车辆直行绿灯时间协调算法

Input: 问题 3.1 优化得到的公交车绿灯时长 g_{B} 与普通车绿灯时长 g_{O}；
权重系数 λ_1, λ_2，满足 $\lambda_1 + \lambda_2 = 1$；
最小绿灯时长 $g_{\min}$，最大绿灯时长 $g_{\max}$；
当前相位 1 可分配的最大绿灯总时长 g_{budget}

Output: 协调后统一的绿灯时间 g_{share}

```
计算加权平均:
    g_share ← λ1 · g_O + λ2 · g_B;
if g_share < g_min then
    g_share ← g_min ;                    // 确保不低于最小绿灯时长
end
if g_share > g_max then
    g_share ← g_max ;                    // 防止绿灯时间过长
end
if g_share > g_budget then
    g_share ← g_budget ;                 // 确保不超过当前相位的时长上限
end
返回协调后的绿灯时间 g_share;
```

3.4 案例研究

3.3节完成了三路口交通系统的模型预测控制方案设计，并针对 v 路口潜在信号冲突问题提出了相应的协调机制与算法，为多类型车辆信号优化提供了具体实施方案。本节将使用 SUMO 软件对该方案进行仿真验证其可行性与可靠性。

3.4.1 仿真设置

仿真使用的是 3.60GHz Intel® Core™ i5 -82500U 的 CPU，运行内存 12GB，64 位 Windows10 操作系统，采用 Python-SUMO 的联合仿真，其中 Python 版本为 3.7，SUMO 版本为 1.16.0。具体联合仿真方式为先使用 SUMO 搭建如图3.1所示交通系统，通过预先的车流通行设定或得到交通流定值变量，并设置检测器获取交通流动态变量的当前状态值，通过 Python 3.7 进行优化问题的构建与求解，将对应的求解结果以信号灯时间设定的形式返回 SUMO 平台进行下一时刻仿真的推进。在 SUMO 中读取与写入数据时使用 Traci 接口接入 Python 程序内，在 Python 中使用 SciPy 库的 minimize 函数求解优化问题与处理约束。

本研究的交通仿真建模基于 SUMO 平台实现，其仿真流程如图3.6所示。首先通过 Netedit.exe 路网编辑器构建如图3.1所示基础路网结构，随后进行多层次参数配置：

中国知网 https://www.cnki.net

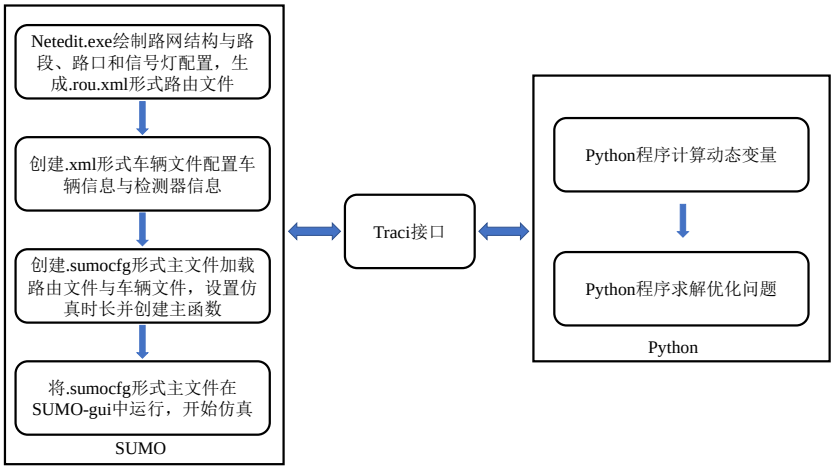

图 3.6　本章仿真流程示意图

包括道路优先权分配、交通流量参数设定以及信号灯相位设定。针对系统改进后 S 模型中的固定值变量，本研究采用表3.3所示的预先设定方案。对于改进 S 模型中涉及的动态变量，先通过 SUMO 内置检测器实现对路段车道实时车辆数据的采集。该检测器可获取路段车辆密度、速度等微观交通参数，并通过 Traci 接口与 Python 算法模块建立数据通道，实现动态变量的迭代计算与参数更新。

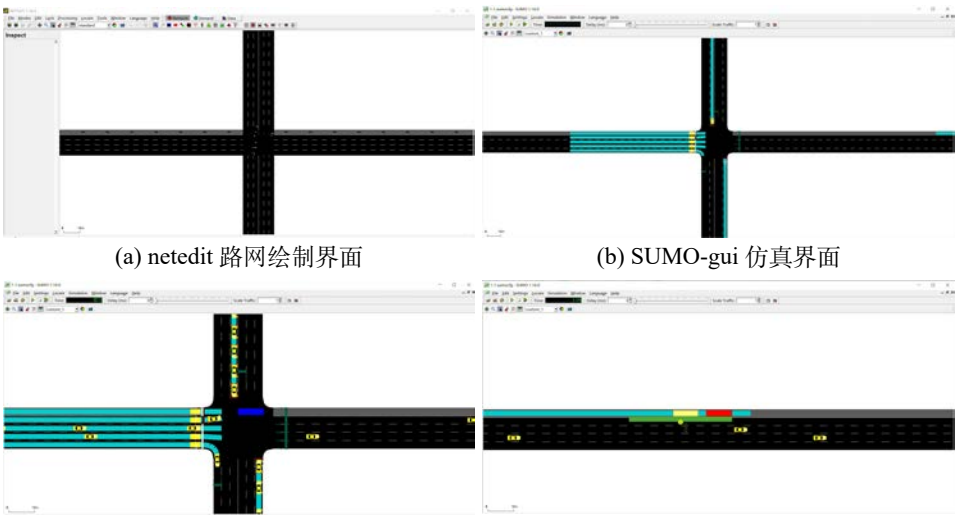

(a) netedit 路网绘制界面　(b) SUMO-gui 仿真界面

(c) 仿真进行阶段 v 路口界面　(d) 仿真进行阶段 link(v, w) 车站界面

图 3.7　SUMO 平台交通仿真环境

SUMO 可视化界面如图3.7所示，其中3.7(a)为 Netedit.exe 路网编辑器界面；图3.7(b)-3.7(d)为仿真过程中 SUMO-gui 界面，蓝色区域为检测器在仿真时的显示效果，灰色区域表征公交专用车道，绿色区块为公交站点区域。在可视化呈现方面，常规车辆采用黄色标识，公交车辆则通过差异化色彩编码实现运行空间分布的可视化追踪。

中国知网　https://www.cnki.net

表 3.3　本章仿真中对系统定值变量的数值设定

符号	物理意义	数值设定	单位
c_d	信号灯周期时间	30	秒
l_{veh}	普通车辆的平均长度	5	米
$l_{\text{veh}}^{\text{B}}$	公交车辆的平均长度	10	米
$N_{u,v}^{\text{lane}}$	link(u,v) 中普通车辆车道数	4	条
$N_{v,w}^{\text{lane}}$	link(v,w) 中普通车辆车道数	4	条
N^{B}	link(u,v) 和 link(v,w) 中公交车专用车道数	1	条
N_{Station}	公交车站最多可同时停靠车辆数	3	辆
v^{free}	普通车辆行驶平均速度	22	米/秒
$v^{\text{B-free}}$	公交车辆行驶平均速度	11.11	米/秒
C	普通路段单条车道容量	70	辆
C^{B}	公交专用道单条车道容量	40	辆
l_{lane}	普通路段单条车道长度	500	米
$l_{\text{lane}}^{\text{B}}$	公交专用道单条车道长度	500	米
μ	离开普通路段的饱和车流量	3.5	辆/秒
μ^{B}	离开公交专用道的饱和车流量	2	辆/秒
β	各通行方向转向率	0.33	–
–	i_1, i_2, i_3, j_1, j_2 路口分别进入系统的普通车流量	1000	辆/小时
–	i_1, i_2, i_3 路口分别进入系统的公交车流量	300	辆/小时

仿真总时长设置为 1800 秒（即 0.5 小时），其中前 300 秒为系统预热时间，便于车流量进入系统并平稳通行。同时确定仿真精度为 1 秒（即仿真 1 秒代表实际时间 1 秒），确保交通状态的连续演化与动态捕捉精度。在模型预测控制器中，步长设定为每 60 秒（即 2 个信号灯时间周期）进行一次滚动预测与控制变量更新。每个控制周期内的优化问题均依据当前系统状态重新构建，以实现实时性响应与动态调整。初始信号配时以传统均匀时长方案进行设定，作为滚动优化的初始控制变量。绿灯时长的优化上下限约束设置为 [10,30] 秒，黄灯固定为 3 秒，以符合交通法规与驾驶行为反应。预测步长 p 设置为 10（即 600 秒），以实现短期内对交通状态的精细预测与控制。

本研究设置如下三组仿真方案进行具体的仿真输入与仿真结构对比分析：

中国知网 https://www.cnki.net

方案 A：固定信号灯相位时间方案。采用在整个仿真过程中交通信号灯配时方案保持不变的设定，即在车辆运行期间，信号灯控制策略不随交通状态动态调整。所采用的信号配时程序基于经验数据设定，反映当前实际交通管理中常见的静态控制模式。该策略不考虑交通流变化对信号灯配时的反馈调节能力，主要用于与动态优化控制方案进行对比分析，评估后者在适应性与通行效率方面的改进效果。

方案 B：模型预测控制方案。采用3.3节所设计模型预测控制方案对交通系统进行动态优化。在每一个仿真时间步内，系统实时测量当前交通状态变量，并基于所获取的状态信息对未来交通演化过程进行预测，从而构建并求解3.2.3节中定义的优化问题。优化求解得到的信号灯控制序列中，仅第一项控制量被转化为实际交叉口的信号灯配时指令，并即时作用于交通系统，以实现对交通流的滚动优化控制。

方案 C：优先权通行方案。采用 SUMO 仿真平台内置的交叉口通行机制进行交通控制。该机制基于车道优先级策略对不同方向的车辆通行顺序进行判定，高优先级车道上的车辆将优先通过交叉口，低优先级车辆需等待空隙或让行，从而形成一种非显式信号灯控制的通行模式。由于该机制缺乏对交通流的全局调节能力，容易在交通流密度较高时出现过度拥堵现象，导致整体通行效率较低。因此，本方案主要作为对照组用于评估系统在无外部优化干预下的最差通行性能，仅用于 TTS 的计算与对比分析，不参与后续优化策略的完整性能评价。

为提高仿真结果的稳定性与鲁棒性，本章在不同的交通控制方案下均进行了多轮独立仿真。具体来说，对于每种控制方案分别运行 10 轮独立仿真。每轮仿真在保持交通流总体强度与路网结构一致的基础上，引入轻度扰动以模拟实际交通的不确定性，如车辆到达时刻与路径选择的细微差异等，从而提升仿真所得结论的泛化能力。

3.4.2 仿真结果

通过对3.4.1节仿真设置的实现，获得所提方案 A、B、C 的交通流仿真数据。为全面评估所提出控制方案的效果，本节设置多项交通性能指标，包括 TTS、平均排队长度、最大排队长度与公交车站排队程度，对3.2.3节优化问题的优化效果进行评估。所有指标均通过 SUMO 仿真平台与 Traci 接口进行数据实时采集，并结合 Python 脚本完成处理与统计。

不同控制方案下路网交通流指标变化如图3.8所示，由图可见，不同控制方案对交通流运行效率存在明显影响，红色线条所示方案 B 即集中式模型预测控制方案的

中国知网 https://www.cnki.net

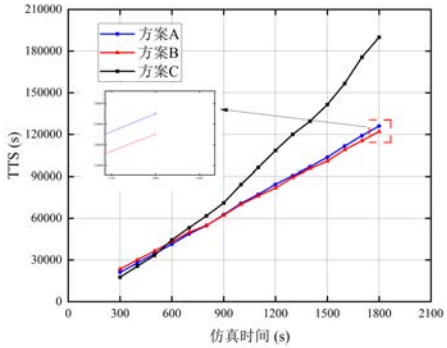

(a) 路网 TTS 变化趋势图

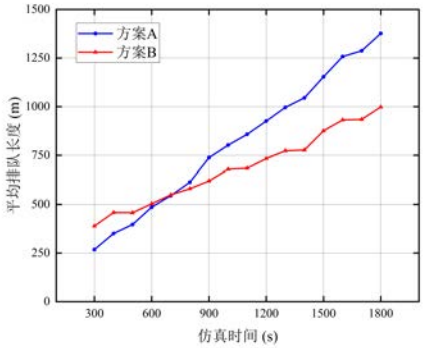

(b) 路网车辆平均排队长度变化趋势图

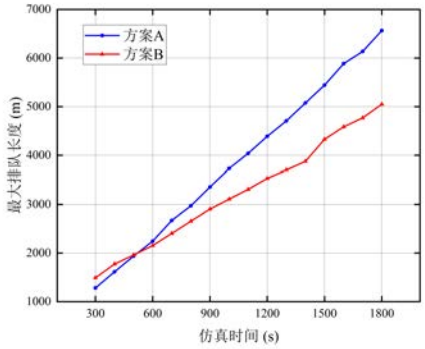

(c) 路网车辆最大排队长度变化趋势

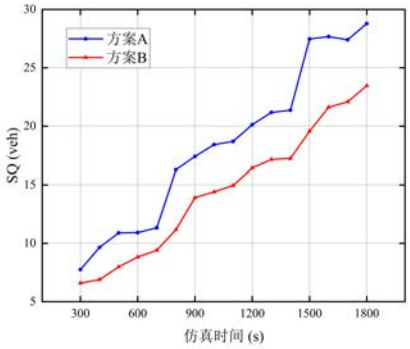

(d) 车站排队车辆变化趋势图

图 3.8　本章仿真中不同控制方案下路网交通流指标变化趋势图

控制效果随时间推移优化效果明显。以下将分别对各个指标的变化情况进行详细分析与讨论。

总通行消耗时间：通过计算路网中所有车辆的总通行时间 TTS 来对三种控制方案的整体性能进行对比分析。TTS 在本文中定义为所有车辆完全穿越交通网络所花费时间的总和。需要指出的是，考虑到在 link(v, w) 设有公交车站，公交车辆在该段存在强制停靠行为，且其停靠时间具有不确定性，因此在 TTS 的统计中不包含公交专用车道上公交车辆的通行时间，以确保各方案在可比前提下的评估公平性。仿真及对比结果如图3.8(a)所示。在仿真时间控制在 700 秒以内时，方案 B 所采用的模型预测控制方案在 TTS 方面尚未体现出显著优势。然而随着仿真时间的增长，其 TTS 相较于方案 A 与方案 C 逐步降低，表明模型预测控制方案在提升整体现通效率方面具有更强的长期控制效果。这一趋势验证了模型预测控制在动态交通环境中对外界扰动和系统不确定性具有较强鲁棒性，能够实现对交通系统状态变化的实时响应与滚动优化。与此相比，方案 A 采用的固定信号灯时间方案，根据历史经验设定静态信号灯相

中国知网 https://www.cnki.net

位时间分配，在短时间内具有一定稳定性，能够较好地维持交叉口基本运行秩序。然而，该方案不具备对系统状态变化的自适应能力，随着运行时间延长，控制效果逐渐弱化，难以实现对交通网络全局通行效率的持续优化。而对于方案 C，其基于车辆优先级实现的通行机制仅适用于交通流量较小、冲突不显著的情形。当系统内车辆数量持续增加时，交通冲突加剧，方案 C 的通行效率急剧下降，控制效果明显劣于方案 B。因此，从 TTS 这一指标来看，模型预测控制方案在中长期交通管理中展现出更优的性能和系统适应性。

平均与最大排队长度：除 TTS 外，交通系统内交叉口排队情况同样是衡量交通系统运行效率的重要指标之一。在本研究中，通过监测交叉口处各车道的排队长度，对比分析方案 A 与方案 B 在不同时间尺度下对车辆排队情况的控制效果。如图3.8(b)中所示，系统每个信号周期内都会记录各交叉口车道的车辆平均排队长度，并进行累加以作为评估参考。同时，为避免因极端时刻的严重拥堵而掩盖平均值背后的控制弱点，进一步引入最大排队长度作为补充性指标，对系统在高负荷状态下的承压能力进行评估，相应结果见图3.8(c)。从仿真结果可以观察到，在仿真初期（600s 内）两种控制方案在排队长度控制方面差异并不明显，系统整体处于较低负载状态。然而随着仿真时间的延长与系统负载的逐步加重，方案 B 采用的模型预测控制方案在平均排队长度与最大排队长度控制方面均优于传统的方案 A。具体而言，模型预测控制方案在动态响应交通状态变化的基础上，能够根据预测的交通负载提前调整信号灯时长分配，避免高峰时段的严重拥堵，从而有效抑制在交叉口出排队车辆长度的持续积累。从控制拐点来看，两种方案在排队指标上的差异同样在仿真约 600 秒左右开始显现，进一步印证了模型预测控制方案在中长期交通优化中的显著优势。因此，平均与最大排队长度作为 TTS 指标的重要补充，不仅反映了系统整体运行效率，也从侧面验证了模型预测控制在提升路网通行稳定性和均衡性方面的优越性能。

公交车站排队长度：在前述内容中，通过对 S 模型的改进，本研究引入了公交专用车道及位于 link(v, w) 的公交车站。为进一步实现对公交车通行效率的优化，在第三章提出的优化模型中，明确将车站处公交车的排队数量作为成本函数中的一项进行建模，因此，本节选取公交车站排队长度 SQ 作为衡量方案有效性的评价指标之一。具体而言，仿真过程中系统在每一时间步对车站处等待进入站点的公交车辆数量进行统计，其结果如图3.8(d)所示。如图中红色曲线所示，在引入模型预测控制方案后，对公交车站前后两个交叉口的信号配时进行了联动优化，使得车站排队长度明显优于未

中国知网 https://www.cnki.net

实施该方案的传统控制方案。特别是在仿真中后期系统负载逐步上升的背景下，模型预测控制方案能够通过预测公交车到站时刻与车流状态，合理分配直行绿灯时间，从而有效减少公交车辆因车道冲突或信号等待所导致的排队积压现象。此外，公交车站排队长度作为控制方案对“公交优先”目标落实程度的重要体现，也间接反映了系统在保障特定交通需求（如定时发车、准点到站）下的协调能力。从整体来看，模型预测控制在保证车站排队长度合理可控的同时，并未造成交叉口其他车道的严重排队冲突，展示出其在系统级联通优化方面的潜力。因此，基于模型预测控制的信号优化方案在提升公交运行效率、缓解站点拥堵方面具有良好的运用效果。

综上所述，通过对比不同控制方案在 TTS、交叉口排队长度（平均与最大值）以及 SQ 等多个维度下的表现，可以看出基于模型预测控制的方案 B 在长时间仿真过程中展现出更优越的交通流调控能力。尤其是在仿真时间超过 600 秒后，方案 B 在系统整体通行效率、拥堵缓解及公交优先保障等方面均优于传统经验控制方案 A 及依赖通行优先机制的方案 C，验证了滚动优化策略在复杂交通网络中的适应性与鲁棒性。

3.5 本章小结

本章设计了一种包含公交专用道的三路口交通流模型预测控制方案，并通过在传统 S 模型中引入公交车辆、公交专用车道及公交车站，进一步提升了交通流模型的现实性。该方案以信号灯绿灯时长为控制变量，构建并求解包含公交元素的优化问题以平衡普通车辆拥堵问题与公交车辆进站排队问题，采用集中式模型预测控制，对小型复杂路网系统中的交通流进行动态调控。通过 Python-SUMO 平台进行联合仿真，与固定信号灯时间的控制方案及基于通行优先级的方案进行对比，结果表明，采用模型预测控制方法在长时间运行过程中，能有效应对交通系统模型与实际运行状态间的偏差与不确定性，具有更强的鲁棒性与全局优化能力。

中国知网 https://www.cnki.net

第 4 章 大规模城市路网交通流的分层分布式模型预测控制

4.1 引言

在上一章中，研究通过改进传统 S 模型并设计模型预测控制方案，成功实现了对小型复杂路网系统的交通流动态调控。但是由于 S 模型本身变量及约束的复杂性，其在大规模路网结构中的应用一直受到模型建立繁琐与计算复杂度的影响。针对这一情况，2.1.3节所介绍的存储转发模型提供了一个合适的可替代选择。而2.1.4节所介绍的宏观基本图，在更加宏观的层面对区域交通流进行周界控制建模，同样是大规模路网交通流预测模型建立的合适工具。

同时需要指出的是，上一章中所使用的模型预测控制为集中式，即整个系统使用一个控制器，实现了高度的协调，但具有很大的计算需求。模型预测控制同时还有分布式以及分层架构：分布式模型预测控制通过允许控制器在共享信息的同时优化其子系统来平衡可扩展性和协调性；分层模型预测控制将控制系统按层次组织，全局层用于协调，局部层用于子系统优化，使其对大规模和相互依赖的系统有效。针对大规模路网交通流的控制优化问题，对模型预测控制方式的选择同样为降低计算复杂度提供了合适的途径。文献 [48-49] 将分布式模型预测控制与场景树与交替优化等算法结合应用于交通流控制中，文献 [87] 将分层架构与宏观基本图结合应用于路网交通流优化中。分布式模型预测控制与分层架构还可组合成为分层分布式模型预测控制（Hierarchical distributed model predictive control, HDMPC），以应用于交通流控制。文献 [88] 对此进行了初步研究，进一步将复杂的路网交通流问题降维求解。其与存储转发模型与以及宏观基本图性质的结合为大规模城市路网交通流优化控制提供了新的方案。

因此，本章提出一种改进后的分层分布式模型预测控制方案，在不同层次分别使用宏观基本图与存储转发模型作为交通流预测模型，研究大规模城市路网交通流的模型预测控制。主要研究内容及创新点为：

1. 在文献 [88] 提出的分层分布式模型预测控制策略基础上，进一步扩展其下层模型及优化算法设计。在保留基于宏观基本图的上层交通需求平衡控制器的前提下，所提出的方法克服了现有模型在应对大规模路网时适用性差的局限性。不仅能更有效地应对过饱和交通状态，同时具备良好的可扩展性。此外，信号相

中国知网 https://www.cnki.net

位设置机制的优化亦使得本方法在实际应用中更加契合交通流的动态特性与运行需求，进一步提升了整体控制效果。

2. 设计了具有双重定制目标函数的下层交通信号优化控制器。其首个目标旨在有效执行上层控制器生成的控制序列，以协调区域间的交通流交换；第二个目标则侧重于路段层级的信号控制优化，通过根据本地交通条件动态调整信号配时，从而提升交通运行效率。

3. 进一步构建了基于存储转发模型的交通流预测模型，并将其与分布式模型预测控制相集成，以提升交通状态预测的准确性。为应对不同子路网间的耦合问题，采用交替方向乘子法实现多子区域的协调优化，有效整合分布式控制结果，提升了相互依赖路网的管理效率与协同性能。

4. 通过 MATLAB-VISSIM 平台联合仿真，并与固定信号灯时间的方案和仅使用分布式模型预测控制的方案进行对比，验证该方案对城市路网交通流的拥堵缓解效果。

4.2 问题构建

与第 3 章的三路口系统相比，城市路网的路口更多，并一般认为至少 4 个路口相连围成的区域，因其涉及各方向转向与上下游及区域的协调，才能基本反应城市规模的交通流通行行为。对于一个城市规模的交通路网，其可被建模为由一组由多个交叉口通过有向道路连接而成的系统。如图4.1所示为一个由 4 个路口组成的城市网络实例，其左图为来自谷歌地图的源图像，右图是将其抽象形成的图形表示。车辆依据其行驶意图，例如直行、右转或左转，以及交通规则选择相应的路段行驶，其最终目的为通行经过整个路网系统。

城市道路网络可形式化地表示为有向图 $\mathcal{T} = (\mathcal{J}, \mathcal{L})$，其中 $\mathcal{J} = \{J_1, J_2, \ldots\}$ 表示交叉口集合，$\mathcal{L} = \{1, 2, \ldots\}$ 表示道路连接集合。对于任意道路连接 $z \in \mathcal{L}$，定义 $\sigma(z)$ 和 $\tau(z)$ 分别为其上游交叉口和下游交叉口。记 $\mathcal{O}$ 为所有外部源点与汇点的集合，这些点虽不属于城市道路网络内部，但与其相连。因而，对于任意 $z \in \mathcal{L}$，有 $\sigma(z), \tau(z) \in \mathcal{J} \cup \mathcal{O}$。

设 $z, w \in \mathcal{L}$ 为任意两条道路连接，若 $\sigma(z) = \tau(w)$，则称 z 为 w 的下游邻接道路，

中国知网 https://www.cnki.net

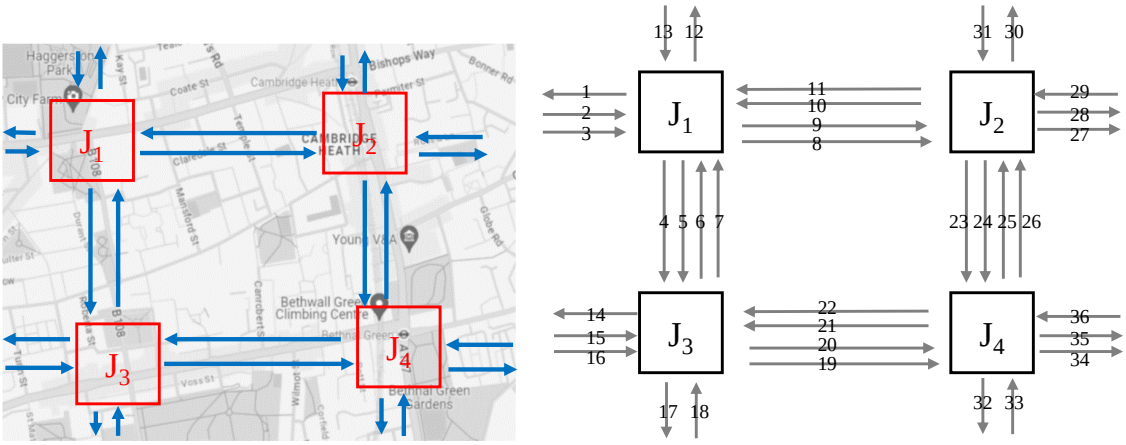

图 4.1　一个由 4 个路口组成的城市网络实例

w 为 z 的上游邻接道路。定义与道路连接 z 相对应的上下游邻接集合如下：

$$\mathcal{N}_z^- = \{w \in \mathcal{L} : \sigma(w) = \tau(z)\}, \quad \mathcal{N}_z^+ = \{w \in \mathcal{L} : \tau(w) = \sigma(z)\}$$

城市路网内交通流的通行同样由信号灯相位处理其在交叉口的通行冲突情况，图 4.1中每个交叉口对应的信号相位如表 4.1 所示；表 4.2 则给出了信号相位与其控制的路段之间的对应关系。结合表格信息可以明确每条道路连接所允许的车辆行驶方向。

表 4.1　示例路网结构对应信号灯相位设置.

相位类型	路口	相位 1	相位 2	相位 3	相位 4
1	J_1, J_3				
2	J_2, J_4				

表 4.2　各信号灯相位下可通行的路段

路口	相位 1	相位 2	相位 3	相位 4
J_1	$3, 11$	13	$6, 7$	$2, 10$
J_2	$8, 9$	29	31	$25, 26$
J_3	$16, 22$	$4, 5$	18	$15, 21$
J_4	$19, 20$	36	$23, 24$	33

基于前文对路网结构的定义，本节所示网络中的交叉口集合为 $\mathcal{J} = \{J_1, J_2, J_3, J_4\}$，

中国知网　https://www.cnki.net

道路连接集合为 $\mathcal{L} = \{1, 2, \ldots, 36\}$。其中，道路连接 $2, 5, 6, 9, 10, 15, 20, 21, 24, 25, 28, 35$ 上的车辆行驶方向仅限左转。以部分道路连接为例，其上游与下游交叉口定义如下：$\sigma(6) = J_3, \tau(6) = J_1$；$\sigma(8) = J_1, \tau(8) = J_2$；$\sigma(20) = J_3, \tau(20) = J_4$；$\sigma(26) = J_4, \tau(26) = J_2$。对应的上游邻接集合与下游邻接集合分别为：$\mathcal{N}_6^+ = \{15, 18, 22\}$，$\mathcal{N}_6^- = \{1\}$；$\mathcal{N}_8^+ = \{3, 7, 13\}$，$\mathcal{N}_8^- = \{23, 24, 27, 28\}$；$\mathcal{N}_{20}^+ = \{5, 16, 18\}$，$\mathcal{N}_{20}^- = \{25, 26\}$；$\mathcal{N}_{26}^+ = \{20, 33, 36\}$，$\mathcal{N}_{26}^- = \{27, 28, 30\}$。

由此建立的一个路网模型将规模进一步扩大，并全面考虑了交通流在不同路段上的动态演化、信号相位在交叉口中的控制机制以及车辆在网络中的迁移关系，从而真实地再现了城市道路网络的运行特征。

进一步地，大规模城市路网通常由多个结构相似的小型子网络通过特定的连接方式构建而成，每个子网络在路段数量、长度以及连通模式等方面具有一致性。根据交通网络建模的一般假设，将图4.1所示路网进一步按比例扩展为更大规模地网络即可代表一个典型的城市路段网络，其对应的通行准则及信号灯相位则可由前文对该路网的设定进行沿用。

为更充分地捕捉大规模路网的结构复杂性与交通动态特征，本章选取了一个由 32 个交叉口组成的城市道路网络作为研究对象。该网络具有大量交叉口、密集的路段连接以及复杂的连接拓扑结构，用以作为说明性示例。本章的研究目标是在上述 32 个交叉口构成的路网中，实现交通流的协调控制与优化调度，缓解交通拥堵，并在此基础上兼顾计算效率与可扩展性，以期推广至更大规模的城市道路网络中应用。需要指出的是，该网络结构并非唯一方案，而是为了验证所提出方法的可行性与通用性。

注 1. *本研究选取由 32 个交叉口构成的路网结构，旨在更真实地模拟并分析大规模城市道路网络中的结构复杂性。通过对图 4.1 所示的基础结构进行拓展，可较为准确地近似实际的城市交通网络。*

注 2. *本研究对真实道路网络进行了简化建模，并将其抽象为有向图结构。通过对结构的重复扩展，在理论上可生成包含多个交叉口的大型交通网络，从而使模型具有良好的可拓展性，并可根据具体研究对象进行灵活调整。*

注 3. *本研究中车辆的行驶方向依据每个交叉口可通行的方向进行预先设定，并遵循一定比例进行分配，从而实现交通流在不同区域间的随机重分布。通过在区域边界处对交通流进行合理控制，可以有效增加特定区域内的车辆数量。*

中国知网 https://www.cnki.net

4.3 交通流分层分布式模型预测控制方案设计

通过4.2节所示例路网的扩展，可得到由多个相似子网络连接构建而成的大规模城市道路网络。由于其结构规模庞大、状态变量众多及计算复杂性高，交通流控制面临显著挑战。为此，本节提出一种将分层控制策略与分布式模型预测控制相结合的分层分布式模型预测控制方案，并对该方案的结构与设计进行详细阐述。

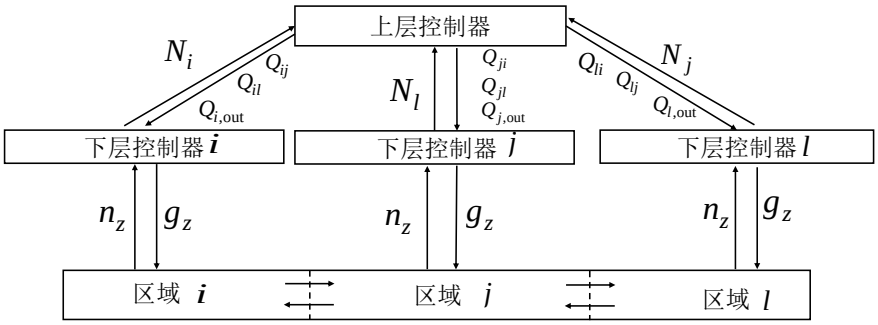

图 4.2　大规模城市路网交通流分层分布式模型预测控制方案示意图

如图 4.2 所示，所提出的交通流控制系统由上下两个层级组成。该分层框架将整体优化任务合理分配至不同层级：上层控制器负责区域间交通流的协调与调控，而下层控制器则根据局部交通状态确定各道路连接的绿灯时间。通过在两个层级分别求解具有不同目标的模型预测控制优化问题，本方案能够在交通过饱和的城市路网中有效提升通行效率。

此外，该分层设计显著降低了道路网络在建模与控制过程中的维度复杂性，使得各层控制器能够独立地处理较低维的优化问题。与此同时，分布式模型预测控制的引入进一步减少了系统计算复杂度，使得大规模交通网络中的控制问题得以分解并并行求解，从而有效提升了整体的计算效率与控制性能。

4.3.1 上层交通需求平衡控制器设计

上层交通需求平衡控制器的设计从宏观角度出发，管理网络各区域内的交通流状态及车辆数量。根据宏观基本图的特性，当某一区域内的车辆数量处于特定范围时，其加权交通流量可达到最大值，从而实现最佳通行效率。

为此，本研究参考已有研究方法[89]，将大规模城市道路网络划分为若干个规模相近、结构均匀的子区域。通过调控各区域之间的车辆交换数量，实现区域间交通需求的动态平衡，从而保证各区域内部的空间平均交通流量维持在最优状态。在此基础

中国知网 https://www.cnki.net

上，本研究首先设计一个基于宏观基本图的集中式模型预测控制器，其中以宏观基本图型作为预测模型，建立了区域内车辆数量、空间平均交通流量与输出交通流之间的函数关系。该控制器基于各区域当前车辆总数等实时数据，求解得到最优的交通流交换策略（即区域间车辆流动的控制序列），并将其作为参考目标传递给下层控制器。

该控制器的核心目标在于确定一组最优的区域间交通流交换策略，并将其作为参考信息传递给下层控制器。通过利用宏观基本图的特性，尤其是最大化区域内空间平均交通流量，以提升车辆在各区域内的通行效率。该控制器的目标函数由两个主要部分构成：（1）最小化各区域内的车辆数量，以缓解局部拥堵并防止整个网络陷入过饱和状态；（2）将各区域车辆数量稳定在宏观基本图所对应的临界值 N_{critical} 附近，从而实现空间平均交通流量的最优化。

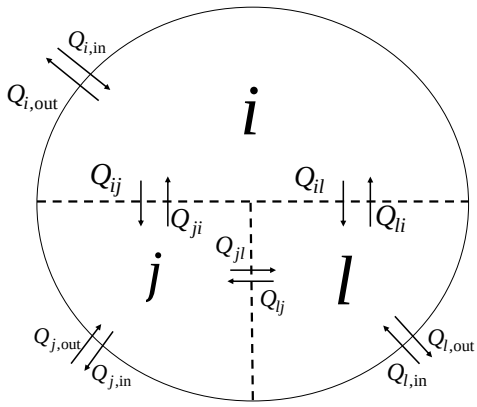

图 4.3　区域交通流交换示意图

如图4.3所示，道路网络被划分为三个相互连接的区域，构成了一个典型的区域间交通交换场景。该框架具有良好的可扩展性，可根据需求进一步拓展至更多区域。基于这种区域划分及其连通关系，可构建了相应的代价函数与约束条件，以形成满足上述优化目标的控制问题。

具体而言，受文献 [88] 研究结果的启发，本研究在上层交通需求平衡控制器中继续将总通行时间 TTS 作为目标函数的组成部分之一，相关设计如下：

$$J_{\text{TTS}} = \sum_{t=0}^{p^{\text{upper}}} \left[N_i(k+t|k) + N_j(k+t|k) + N_l(k+t|k) \right] \cdot T_u \tag{4.1}$$

其中 p^{upper} 为上层预测时域，T_u 为控制步长对应间隔时间. $N_i(k+t|k)$、$N_j(k+t|k)$ 和 $N_l(k+t|k)$ 分别表示对 $k+t$ 步内 i、j、l 区域的预测车辆数。此外，采用另一个惩罚

中国知网 https://www.cnki.net

函数来确保每个区域的车辆数量能够维持在宏观基本图所得临界值：

$$
\begin{aligned}
J_{\text{pen}} = \sum_{t=0}^{p^{\text{upper}}} \Big(& [\max(0, N_i(k+t|k)) - N_{i,\text{critical}}]^2 \\
& + [\max(0, N_j(k+t|k)) - N_{j,\text{critical}}]^2 \\
& + [\max(0, N_l(k+t|k)) - N_{l,\text{critical}}]^2 \Big)
\end{aligned} \tag{4.2}
$$

其中 $N_{i,\text{critical}}$、$N_{j,\text{critical}}$ 和 $N_{l,\text{critical}}$ 分别代表根据宏观基本图所得 i, j 和 l 区域的临界车辆数。

以 i 区域为例，可以将上层优化问题表述为以下形式，j 和 l 区域可以以类似的方式构建。

问题 4.1.

$$
\min_{\mathbf{Q}(\mathbf{k})} \quad J_{\text{upper}} = J_{\text{TTS}} + \alpha J_{\text{Pen}} \tag{4.3a}
$$

$$
\begin{aligned}
\text{s.t.} \quad & \text{for} \quad t = 0, 1, 2, \ldots, p^{\text{upper}} - 1 \\
& N_i(k+t+1|k) = N_i(k+t|k) + T_u \Big([Q_{i,\text{in}}(k+t|k) \\
& \qquad - Q_{i,\text{out}}(k+t|k)] + [Q_{ji}(k+t|k) - Q_{ij}(k+t|k)] \\
& \qquad + [Q_{il}(k+t|k) - Q_{li}(k+t|k)] \Big)
\end{aligned} \tag{4.3b}
$$

$$
q_i^{\omega}(k+t|k) = \sum_{b_i=0}^{d_i} a_{b_i} N_i^{b_i}(k+t|k) \tag{4.3c}
$$

$$
D_i(k+t|k) = \kappa_i \cdot q_i^{\omega}(k+t|k) \tag{4.3d}
$$

$$
\begin{aligned}
D_i(k+t|k) = & Q_{i,\text{out}}(k+t|k) + Q_{ij}(k+t|k) \\
& + Q_{il}(k+t|k)
\end{aligned} \tag{4.3e}
$$

$$
0 \le Q_{i,\text{out}}(k+t|k) \le m_{i,\text{out}} \cdot q_{s,i,\text{out}} \tag{4.3f}
$$

$$
0 \le Q_{ij}(k+t|k) \le m_{ij} \cdot q_{s,ij} \tag{4.3g}
$$

$$
0 \le Q_{il}(k+t|k) \le m_{il} \cdot q_{s,il} \tag{4.3h}
$$

$$
\mathbf{Q}^{\top}(\mathbf{k}) = \begin{bmatrix} \mathbf{Q}^{\top}(\mathbf{k}|\mathbf{k}) & \mathbf{Q}^{\top}(\mathbf{k}+\mathbf{1}|\mathbf{k}) & \cdots & \mathbf{Q}^{\top}(\mathbf{k}+\mathbf{t}|\mathbf{k}) \end{bmatrix} \tag{4.4}
$$

$$
\mathbf{Q}(\mathbf{k}|\mathbf{k}) = [Q_{i\,\text{out}}(k|k)\, Q_{ij}(k|k)\, Q_{il}(k|k)\, \ldots\, Q_{l,\text{out}}(k|k)\, Q_{li}(k|k)\, Q_{lj}(k|k)] \tag{4.5}
$$

其中 $\mathbf{Q}(\mathbf{k})$ 表示控制变量的集合，具体表现为式(4.4)。以第一项 $\mathbf{Q}(\mathbf{k}|\mathbf{k})$ 为例，其为

中国知网 https://www.cnki.net

式(4.5)中包含元素的集合，包含了第 k 步时区域间预测交通流以及各区域通往外部网络的交通流。同时，式(4.3a)中的 $\alpha > 0$ 为权重系数，根据平衡目标函数中不同部分的权重设置。

在约束条件(4.3b)中，Q 表示交通流量变量。例如，$Q_{i,\text{out}}(k)$ 表示区域 i 在第 k 步时刻向外部网络的总出流量，$Q_{ij}(k)$ 则表示从区域 i 出发流向区域 j 的交通流。

结合2.1.4节对宏观基本图对应数学关系的介绍，在约束条件(4.3d)中，a_{b_i} 为宏观基本图曲线对应的多项式系数，d_i 为多项式的指数。此外，$q_i^w(k)$ 表示加权交通流量，$D_i(k)$ 表示区域 i 的总交通出流。约束条件(4.3e)中的系数 κ_i 为通过交通数据测量得到的模型参数。(4.3f) - (4.3h)中，$m_{i,\text{out}}$、m_{ij} 与 m_{il} 分别表示连接区域与外部环境、区域之间或区域内部的车道数；相应地，$q_{s,i,\text{out}}$、$q_{s,ij}$ 及 $q_{s,il}$ 则表示这些车道在饱和状态下的平均通行能力。

具体而言，(4.3b)用于预测区域 i 内车辆的数量变化；(4.3c)与(4.3d)描述的是宏观基本图曲线所体现的交通状态之间的函数关系；(4.3e)体现了区域出流的实际计算方式；而(4.3f) - (4.3h)则为交通流交换必须满足的物理不等式约束条件。

通过求解问题 4.1 所构建的优化问题，得到一组最优交通流控制序列 $\mathbf{Q}^*(\mathbf{k})$。为了实现这个解决方案，通过将 $\mathbf{Q}^*(\mathbf{k}|\mathbf{k})$ 传递给低级控制器来应用这个最优序列的第一个元素。需要指出的是，尽管通过区域划分和控制区域间车辆交换，可有效实现区域内车辆数量的管控，但该层次的控制模型并未考虑道路连接层面的具体交通状况，亦无法直接实现控制指令的执行。因此，还需依赖下层控制器对路段信号配时等局部控制任务进行精细化管理，以保障整体交通控制策略的实施。

4.3.2 下层交通信号优化控制器设计

在分层分布式模型预测控制的下层信号优化控制器中，一个核心目标是将上层控制器获得的最优区域间交通流分配结果，转换为各个路段的对应绿灯时间 g_z。此外，由于各交叉口自身的控制行为无法对其他交叉口及其路段的交通状况产生直接影响，因此必须设计下层控制器以优化整个路网的交通流，从而实现全面缓解交通拥堵的目的。

在该层级中，采用存储转发模型来表征道路的交通状态，并将其作为模型预测控制问题的预测模型，具体建模过程在第2.1.3 节已详细描述。为降低在线计算的复杂度并提升系统对突发扰动的鲁棒性，本研究引入了一种分布式多智能体协同控制方

中国知网 https://www.cnki.net

法。具体而言，将整个路网划分为若干互不重叠的子系统，并为每个子系统配置一个代理。每个智能体通过与其邻近智能体之间的协商决策，实现整个系统的最优性能。针对本层控制目标的双重需求：（1）实现上层控制器下发的控制序列；（2）优化各个路段的交通流状态。本节分别设计了两类目标函数，并将其组合形成每个子系统的整体优化目标。同时为解决相邻子系统之间的耦合问题，引入交替方向乘子法，有效协调各子系统之间的信号控制策略，从而确定路段的绿灯时间，制定对应信号灯配时方案。

基于道路网络的结构特性，可以将每个区域内的路段划分为多个子系统。例如，图 4.1 所示的道路网络结构可视为一个单一的子系统。这种划分方式有助于构建和求解分布式模型预测控制问题，从而有效降低计算复杂度。

在 4.3.1 节中，通过求解问题 4.1 所定义的优化问题，获得了一组控制序列 $\mathbf{Q}(\mathbf{k})$。选取该控制序列的首项 $\mathbf{Q}(\mathbf{k}|\mathbf{k})$ 传递给下层信号优化控制器，下层控制器的主要任务即是对该控制量进行跟踪与实施。

在每个区域内部以及道路网络与外部环境之间的连接处，均通过特定路段实现连通性，这些链路集合记作 $\mathcal{L}_c$。根据需要实现的控制量，这些连接链路可以分为 9 类，例如 $Q_{i,\text{out}}$、Q_{ij}、Q_{il} 等，每一类链路都对应于控制序列 $\mathbf{Q}(\mathbf{k}|\mathbf{k})$ 中的某一具体控制量。以子系统中连接区域 i 与 j 的路段集合 $\mathcal{L}_{ij}$ 为例，该集合中的链路需实现的控制目标为 $Q_{ij}(k|k)$。针对该控制量的优化，其目标函数构造如下所示：

$$\Psi^{(1)}(k) = \sum_{z\in\mathcal{L}_{ij}} \sum_{t=0}^{p^{\text{lower}}} \left(n_z(k+t|k) - \frac{Q_{ij}\cdot T_u}{m_{ij}} \right)^2 \tag{4.6}$$

其中 p^{lower} 表示下层控制器的预测时域，$n_z(k+t|k)$ 表示在时间步 $k+t$ 时刻，路段 z 上的车辆数量，Q_{ij} 为连接区域 i 与 j 之间交通流的控制量，m_{ij} 表示连接区域 i 和 j 的车道数量。

在问题 4.1 中，系统通过调节所有连接区域 i 与 j 的路段上车辆的数量 n_z，以实现设定的控制量 Q_{ij}。通过替换式 (4.6) 中的 Q_{ij} 和 m_{ij} ，还可以构造实现 $\mathbf{Q}(\mathbf{k}|\mathbf{k})$ 中其他控制量的目标函数。例如，对于连接区域 i 与 l 的路段集合 $\mathcal{L}_{il}$，其对应的目标函数可表示为：

$$\Psi^{(2)}(k) = \sum_{z\in\mathcal{L}_{il}} \sum_{t=0}^{p^{\text{lower}}} \left(n_z(k+t|k) - \frac{Q_{il}\cdot T_u}{m_{il}} \right)^2 \tag{4.7}$$

中国知网 https://www.cnki.net

其中目标函数通过调节所有连接区域 i 与 l 的路段上的车辆数量 n_z，实现了对控制量 Q_{il} 的执行。同理，该方法亦可推广应用于其他路段。通过对子系统中所有相关路段的个体目标函数进行求和，便可得到与控制链路集合 $\mathcal{L}_c$ 对应的整体目标函数 $\Psi(k)$。

此外，在每一个下层控制区域中，存在一类路段并不直接执行上层控制指令，但在缓解局部拥堵、提升整个路网运行效率方面依然发挥着关键作用。这些路段主要通过协调下游交叉口的信号配时方案来调节进入区域的交通流，本研究将其称为一般路段，并用 $\mathcal{L}_g$ 表示该类链路在一个子系统中的集合。针对这些一般路段，其目标函数可构建如下：

$$\Phi^{(1)}(k) = \sum_{z\in\mathcal{L}_g}\sum_{t=0}^{p^{\text{lower}}}\frac{1}{\bar{n}_z}(n_z(k+t+1|k))^2 \tag{4.8}$$

$$\Phi^{(2)}(k) = \sum_{z\in\mathcal{L}_g}\sum_{t=0}^{p^{\text{lower}}}T_u\cdot n_z(k+t+1|k) \tag{4.9}$$

$$\Phi^{(3)}(k) = \sum_{z\in\mathcal{L}_g}\sum_{t=0}^{p^{\text{lower}}}(n_z(k+t|k)-q_z(k+t|k)) \tag{4.10}$$

为最大化路段内的车辆通行效率和交通基础设施的利用率，本研究考虑以下三个性能指标作为目标函数设计的依据：

（1）利用率均衡性：目标函数 $\Phi^{(1)}(k)$ 旨在平衡各路段的相对利用率，从而避免部分路段过度拥堵或资源闲置；

（2）小化车辆总滞留时间：目标函数 $\Phi^{(2)}(k)$ 以最小化车辆在城市路网中的总逗留时间为目标，提升整体运行效率；

（3）降低无效停滞车辆数量：在目标函数 $\Phi^{(3)}(k)$ 中，$n_z(k+t|k)-q_z(k+t|k)$ 表示在时间区间 $[(k+t)T_u,(k+t+1)T_u]$ 内，处于链路 $z\in\mathcal{L}_g$ 上的无效车辆数量，即未能有效流动的车辆数量。

综上所述，针对一般路段的整体目标函数可表示如下：

$$\Phi(k) = \sum_{z\in\mathcal{L}_g}\sum_{t=0}^{p^{\text{lower}-1}}\Big(\alpha_{z,p}\left(n_z(k+t+1|k)\right)^2+\beta_{z,p}n_z(k+t+1|k)-\gamma_{z,p}q_z(k+t|k)\Big) \tag{4.11}$$

至此，针对子系统内各路段的具体任务，分别构建了相应的目标函数。在此基础上，子系统中每个智能体所需求解的分布式模型预测控制优化问题定义如下：

中国知网 https://www.cnki.net

问题 4.2.

$$\min_{\mathbf{g_z(k)}} \quad J_{\text{lower}} = \Psi(k) + \Phi(k) \tag{4.12a}$$

$$\text{s.t.} \quad \text{for} \quad z \in \mathcal{L}_g \cup \mathcal{L}_c, \quad t = 0, 1, 2, \ldots, p^{\text{lower}} - 1$$

$$n_z(k+t+1|k) = n_z(k) + \sum_{t=0}^{p} \sum_{w \in \mathcal{N}_z^+} [r_{wz}(k+t|k) \cdot q_w(k+t|k) - q_z(k+t|k)] \tag{4.12b}$$

$$q_z(k) = S_z \cdot g_z(k) \tag{4.12c}$$

$$g_z(k) = \sum_{p \in \mathcal{P}_z} g_p(k) \tag{4.12d}$$

$$q_z(k) \leq n_z(k) \tag{4.12e}$$

$$\sum_{w \in \mathcal{N}_z^+} r_{wz}(k) q_w(k) \leq \bar{n}_z - n_z(k) \tag{4.12f}$$

$$0 \leq g_p(k) \leq \bar{g}_p \leq T_u \tag{4.12g}$$

其中 $\mathbf{g_z(k)}$ 表示由求解得到该子系统中各路段绿灯时长的集合。

在建立了分布式模型预测控制控制器的优化问题 4.2 之后，由于路段间交通流存在相互依赖，直接求解各子系统的分布式优化问题难以获得全局最优解。为此，通过交替方向乘子法将全局问题分解为若干子问题，并通过局部变量与全局变量的交替更新，逐步实现全局一致性。

交替方向乘子法可用于求解如下形式的优化问题：

$$\begin{aligned} \min \quad & f(x) + g(y) \\ \text{s.t.} \quad & Ax + By = c \end{aligned}$$

其中 $x \in \mathbb{R}^m$、$y \in \mathbb{R}^n$ 为待优化的控制变量，$f : \mathbb{R}^m \to \mathbb{R}$ 和 $g : \mathbb{R}^n \to \mathbb{R}$ 为凸函数，$A \in \mathbb{R}^{p \times m}$、$B \in \mathbb{R}^{p \times n}$、$c \in \mathbb{R}^p$ 分别表示约束条件中的矩阵与向量。

该问题的拉格朗日函数（Lagrangian）定义如下：

$$\mathcal{L}_\rho(x, y, \lambda) = f(x) + g(y) + \lambda^\top (Ax + By - c) + \frac{\rho}{2} \|Ax + By - c\|_2^2$$

其中 λ 为拉格朗日乘子，$\rho > 0$ 是增强算法收敛速度的惩罚参数。

在交替方向乘子法的迭代过程中，通过交替最小化上述拉格朗日函数并更新拉格

中国知网 https://www.cnki.net

朗日乘子，实现变量的逐步优化。具体更新规则如下：

$$
\begin{aligned}
x^{k+1} &= \arg\min_{x} \mathcal{L}_{\rho}(x, y^k, \lambda^k) \\
y^{k+1} &= \arg\min_{y} \mathcal{L}_{\rho}(x^{k+1}, y, \lambda^k) \\
\lambda^{k+1} &= \lambda^k + \rho(Ax^{k+1} + By^{k+1} - c)
\end{aligned}
$$

该迭代方式通过将复杂的全局优化问题划分为多个可并行求解的小子问题，尤其适用于交通网络中多个子系统之间的分布式协调控制。

为保证交替方向乘子法朝向最优解收敛，需监测迭代过程中变量的变化情况。其收敛判据定义如下：

$$
\|x^{k+1} - x^k\| \to 0 \quad \text{as} \quad k \to \infty
$$

当变量的变化幅度逐步减小并趋于稳定时，即可判定算法已收敛至最优解，从而终止迭代过程。

本研究以此基本构型构建算法 2所示的本研究中采用的交替方向乘子法。为使其更适用于交通流优化问题，对其流程进行了改进：

（1）将每条路段的绿灯时间作为独立变量，通过求解相应目标函数得到局部解 g_z；

（2）引入区域内绿灯时间的平均值 g 作为全局变量，实现信号配时协调；

（3）通过更新拉格朗日乘子修正局部解与全局均值的偏差，确保网络协调运行。

算法 2 用于在区域内部协调由各子系统独立生成的绿灯时间。对于连接不同子系统的边界路段，其绿灯时间取自相邻子系统的平均值，以实现交通流的均衡分配。该方法在优化过程中通过全局变量统一信号策略，克服了局部独立优化导致的潜在冲突。

最终，在每个区域内利用交替方向乘子法求解分布式模型预测控制问题，获取各路段的绿灯时间 g_z，并由对应路段下游交叉口的信号灯控制。考虑到本研究的道路网络由多个基本子网组成（见图 4.1），基于表 4.1 与表 4.2 所示的信号相位结构，制定各方向通行顺序。具体而言，在一个信号周期 T_u 内，系统依次按照相位顺序为各方向分配绿灯时间 g_z，相位结束后切换为红灯，完成全部相位后开始新一周期。为简化控制实施，本研究采用人工配置方式将信号配时方案输入至各交通信号灯。

中国知网 https://www.cnki.net

算法 2: 基于交替方向乘子法的交通信号灯时间优化算法

Input: 初始交通信号灯时间 $g(0)$，拉格朗日乘子 $\lambda(0)$，惩罚参数 ρ，迭代计数器 $k_d = 0$，停止阈值 ϵ_{prim}

Output: 优化后的交通信号灯时间 $g(k_d + 1)$

while 未收敛 **do**

  局部优化:

  for 区域内每个路段 z **do**

    更新局部绿灯时长 $g_z(k+1)$，通过求解以下优化问题:

$$g_z(k+1) = \arg\min_{g_z} \left(f_i(g_z) + \lambda_z(k) g_z + \frac{\rho}{2} \|g_z - g(k)\|^2 \right)$$

    其中 $f_i(g_z)$ 是从 (4.12)中得到的路段 z 的代价函数;

  end

  全局协调:

  计算区域内平均绿灯时长:

$$\bar{g}(k+1) = \frac{1}{N} \sum_{z=1}^{N} g_z(k+1)$$

  更新全局交通信号灯时间:

$$g(k+1) = \bar{g}(k+1)$$

  变量更新:

  更新拉格朗日乘子:

$$\lambda(k+1) = \lambda(k) + \rho(g(k+1) - g(k))$$

  收敛检查:

  计算原始残差:

$$r(k+1) = \|g(k+1) - g(k)\|$$

  if $r(k+1) \leq \epsilon_{prim}$ **then**

    跳出循环

  end

  else

    迭代计数器增加: $k \leftarrow k + 1$

  end

end

return 优化后的绿灯时间 $g(k+1)$

中国知网 https://www.cnki.net

4.4 案例研究

在4.3节设计了具有上层交通需求平衡控制器以及下层交通信号优化控制器的分层分布式模型预测控制方案后，本节通过路网交通流仿真验证其可行性与可靠性。

4.4.1 仿真设置

仿真使用的是 3.0GHz Intel® Core™ i5 -12500 的 CPU，运行内存 16GB，64 位 Windows10 操作系统，采用 MATLAB-VISSIM 的联合仿真，其中 MATLAB 版本为 R2021b，VISSIM 版本为 4.30。具体联合仿真方式为先使用 VISSIM 搭建如图4.4所示交通系统，并进行子区域以及子系统划分。通过如图所示仿真流程，状态变量（交通状态、流量）在 VISSIM 中收集，然后传输到 MATLAB。一旦 MATLAB 通过 fmincon 函数处理这些输入并计算出交通信号的绿灯时间长度，数值就会从 MATLAB 传输回 V

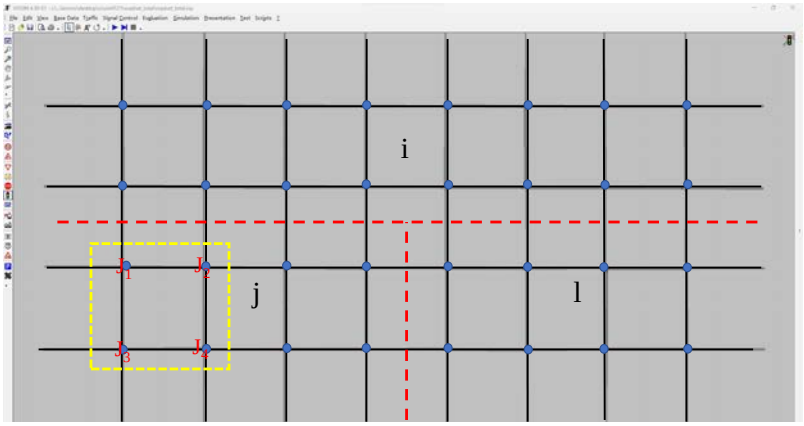

图 4.4　在 VISSIM 中建立道路网络以及区域划分

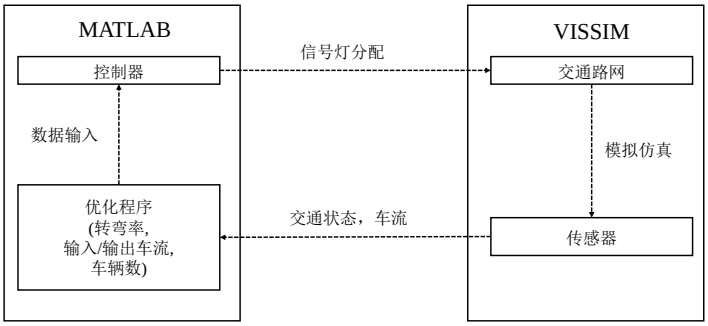

图 4.5　本章仿真流程示意图

中国知网　https://www.cnki.net

为了支撑大规模城市道路网络的仿真研究，本研究扩展了图4.1所示的道路网络结构至 32 个交叉口，分布在 $16+8+8=32$ 的子区域设置中。在图4.5中，蓝色点表示交叉口，黑色实线表示主要道路链接，红色虚线表示区域划分，黄色虚线所围成的区域突出显示了基于图4.1所示结构的子系统。该网络被划分为三个区域：i、j 和 l。图4.1所示的结构代表了图4.5中整个网络的一部分，其他部分遵循相同的结构，以简化交通信号计划的配置。每个交叉口的信号相位基于表4.1和表4.2进行设置。

仿真首先基于三个区域进行正常车辆通行下的检测，通过离散数据获得各区域宏观基本图拟合曲线如图4.6所示。为了拟合每个区域的车辆数与加权交通流的宏观基

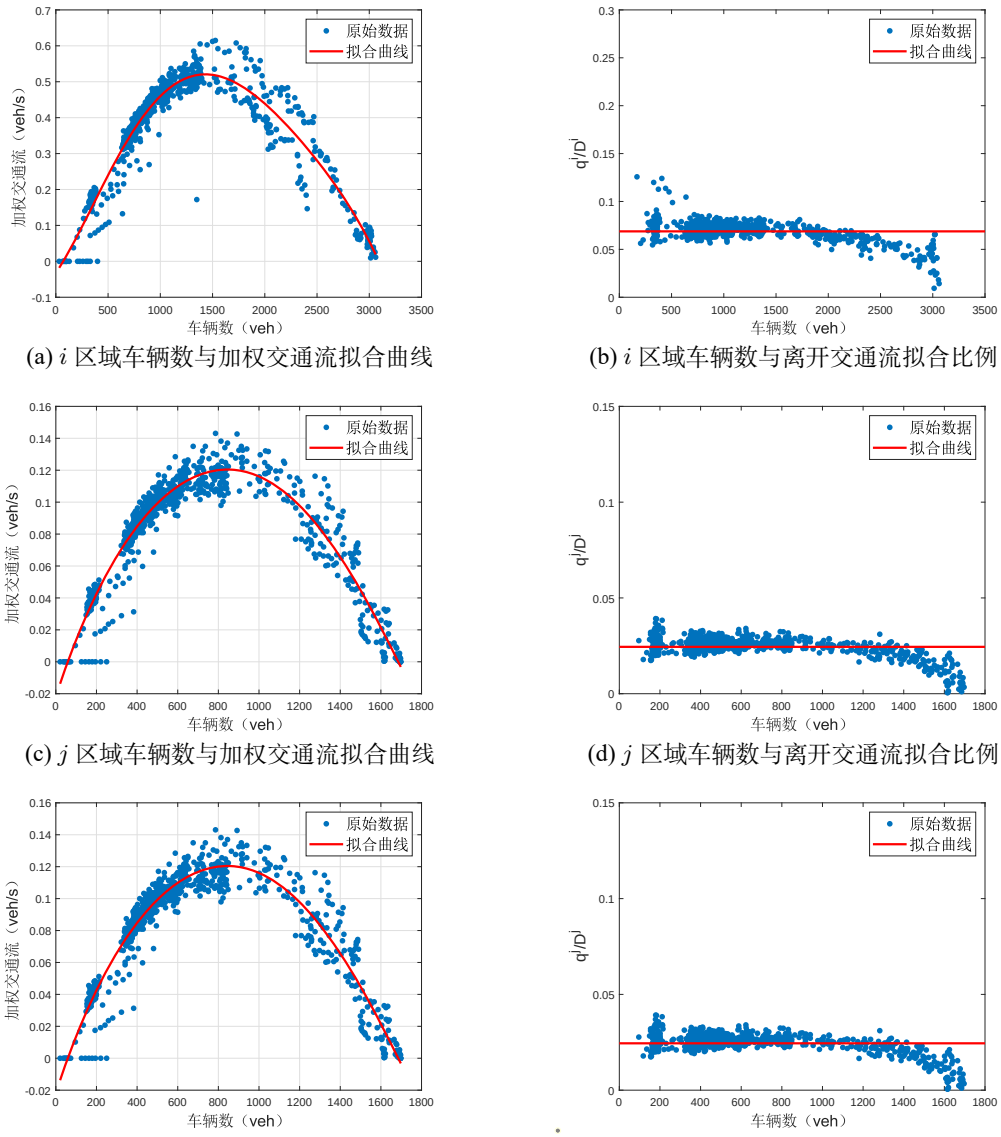

(a) i 区域车辆数与加权交通流拟合曲线　(b) i 区域车辆数与离开交通流拟合比例

(c) j 区域车辆数与加权交通流拟合曲线　(d) j 区域车辆数与离开交通流拟合比例

(e) l 区域车辆数与加权交通流拟合曲线　(f) l 区域车辆数与离开交通流拟合比例

图 4.6　三个子区域的宏观基本图拟合曲线

中国知网　https://www.cnki.net

本图曲线，使用一个基于车辆数量的五阶多项式函数

$$q^w(k) = a \cdot N^5(k) + b \cdot N^4(k) + c \cdot N^3(k) + d \cdot N^2(k) + e \cdot N(k) + f$$

，对式 (2.19) 所述函数关系进行描述。相关数据以及其他定值变量如表4.3所示。

设置总模拟时间设置为 3600 秒，并在模拟开始时设置预热期，以允许车辆遍布整个城市路网。在网络达到过饱和状态后，采用不同的控制方案进行比较。在每个交叉口，假设来自每个链路的所有可行方向的转弯率相等。在本例中，车辆在各个路口随机选择行驶方向，基于当前路段以等概率选择一个允许行驶的方向。这种设置也可以调整，以反映从真实路网中的历史数据推导出的特定概率。因此，在该场景中，将转弯率视为已知变量，而将车辆路径视为随机变量。设置如下三个方案进行仿真结果的对比分析：

（1）定时控制（Fixed-time）方案：即该方案采用固定的交通信号配时方案，即每个交叉口的信号相位及绿灯时间在整个仿真过程中均为预先设定并保持不变。此方案不考虑交通状况的动态变化，例如网络中某些区域出现的过饱和现象。具体而言，绿灯时间在各相位间平均分配，每个交叉口的信号周期为 120 秒，划分为四个相位，每个相位的绿灯时间为 30 秒。

（2）仅使用分布式模型预测控制（DMPC-only）方案：该方法仅依赖第4.3.2节所描述的分布式模型预测控制算法进行交通信号管理，未采用分层控制结构或宏观基本图特性。道路网络被划分为若干子系统，每个子系统由一个分布式模型预测控制控制器独立控制，并求解优化问题 4.2。这些控制器协同工作，通过交替方向乘子法处理子系统之间的交互问题，从而优化交叉口的绿灯时间分配。

（3）分层分布式模型预测控制（HDMPC）方案：该方法是本文提出的分层控制方案，结合了第4.3.1节所述的上层交通需求均衡控制器与第4.3.2节所述的下层信号优化控制器，形成协同优化的整体控制方案。

中国知网 https://www.cnki.net

表 4.3　本章仿真中对系统定值变量的数值设定

符号	物理意义	数值设定	单位
a_i	i 区域五次项系数	$-2.404914 \times 10^{-17}$	–
b_i	i 区域四次项系数	2.070999×10^{-13}	–
c_i	i 区域三次项系数	$-6.163690 \times 10^{-10}$	–
d_i	i 区域二次项系数	5.037646×10^{-7}	–
e_i	i 区域一次项系数	4.214855×10^{-4}	–
f_i	i 区域常数项系数	-3.211271×10^{-2}	–
a_j,a_l	j 和 l 区域五次项系数	2.784146×10^{-17}	–
b_j,b_l	j 和 l 区域四次项系数	$-1.276308 \times 10^{-13}$	–
c_j,c_l	j 和 l 区域三次项系数	2.304215×10^{-10}	–
d_j,d_l	j 和 l 区域二次项系数	-3.8293×10^{-7}	–
e_j,e_l	j 和 l 区域一次项系数	3.901908×10^{-4}	–
f_j,f_l	j 和 l 区域常数项系数	-2.17694×10^{-2}	–
$N_{i,\text{critical}}$	i 区域临界状态对应车辆数	1431	veh
$N_{j,\text{critical}}$,$N_{l,\text{critical}}$	j 和 l 区域临界状态对应车辆数	843	辆
$m_{ij}, m_{il}, m_{ji}, m_{li}, m_{jl}$	区域间连接路段数	4	–
m_{lj}	区域间连接路段数	2	–
$m_{i,\text{out}}$	区域与外界连接路段数	14	–
$m_{j,\text{out}}$	区域与外界连接路段数	6	–
$m_{l,\text{out}}$	区域与外界连接路段数	8	–
$1/\kappa_i$	i 区域比例系数	0.068768	–
$1/\kappa_j, 1/\kappa_l$	j 和 l 区域比例系数	0.024461	–
$Q_{i,\text{in}}, Q_{j,\text{in}}, Q_{l,\text{in}}$	各区域流入车流量	800	辆/秒
T_u	信号灯周期时间与采样时间间隔	120	秒
g_{min}	最短绿灯时间	0	秒
g_{max}	最长绿灯时间	60	秒
p^{upper},p^{lower}	上下层预测时域	10	–
α	上层目标函数惩罚项系数	0.25	–
$\alpha_{z,p}$	下层目标函数系数	1	–
$\beta_{z,p}$	下层目标函数系数	0.5	–
$\gamma_{z,p}$	下层目标函数系数	0.3	–

中国知网　https://www.cnki.net

4.4.2 仿真结果

本节通过多个指标对控制方案在优化交通流方面的效果进行了评价。图4.7展示了在不同控制方案下，各区域内车辆数量随时间的变化情况。结果表明，Fixed-time 和 HDMPC 方案均能使车辆数量趋于稳定，但 HDMPC 方案控制下的车辆总量明显低于 Fixed-time 方案，并接近临界车辆数 N_{critical}；相比之下，DMPC-only 方案则持续减少区域内的车辆数量。表 4.4 给出了三种方案下道路网络的平均车辆占用率，反映出 HDMPC 方案和 DMPC-only 方案在缓解拥堵方面优于固定信号灯时间的 Fixed-time 方案。

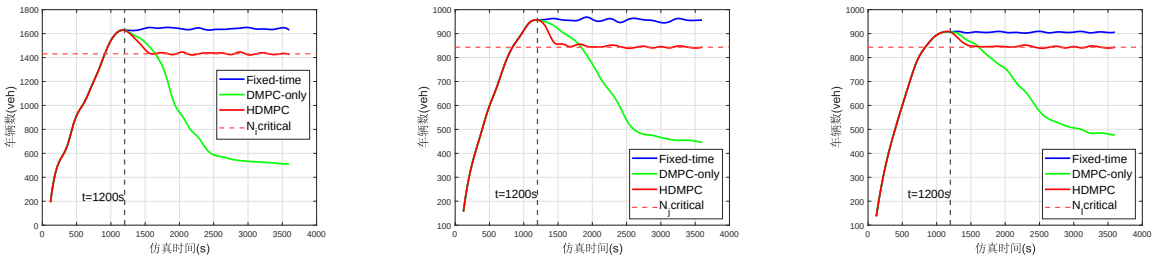

(a) i 区域车辆数变化　(b) j 区域车辆数变化　(c) l 区域车辆数变化

图 4.7　本章仿真中不同控制方案下各区域的车辆数变化趋势

表 4.4　本章仿真中不同方案下平均车辆占用率

Fixed-time	DMPC-only	HDMPC
57.28%	36.42%	42.6%

三个区域中每个车辆的 TTS 数据，可通过累加每辆车辆完全通过该区域所需的时间来计算。结果如图4.8所示，可以观察到 Fixed-time 方案的 TTS 比 HDMPC 方案和 DMPC-only 方案的 TTS 都高，且 DMPC-only 方案的 TTS 最低。由于平均车辆占用率和 TTS 都与区域内的车辆数量直接相关，这些指标为车辆数量的变化提供了支持证据。

图 4.9 展示了各区域加权交通流量的时变趋势。在进入过饱和状态前，加权流量达峰值。HDMPC 方案可将其维持在最大水平，而 Fixed-time 方案则使其稳定在过饱和状态下，DMPC-only 方案下则出现持续下降。这说明固定信号灯时间难以缓解过饱和现象，其信号方案在前 1200 秒内保持不变，无法响应交通动态变化；一旦网络过饱和，由于绿灯时长固定，车辆数难以进一步增加，系统陷入饱和稳定状态。DMPC-only 方案未利用宏观基本图特性，而是将网络划分为多个子系统，分别求解其优化问题。

中国知网 https://www.cnki.net

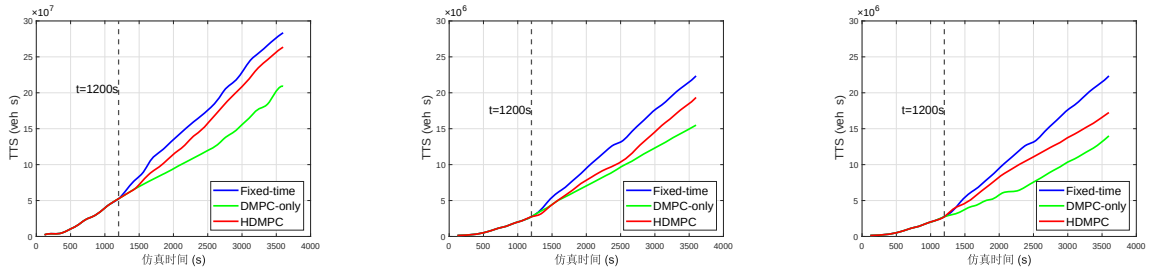

(a) i 区域车辆 TTS 变化　(b) j 区域车辆 TTS 变化　(c) l 区域车辆 TTS 变化

图 4.8　本章仿真中不同控制方案下各区域的车辆 TTS 变化趋势

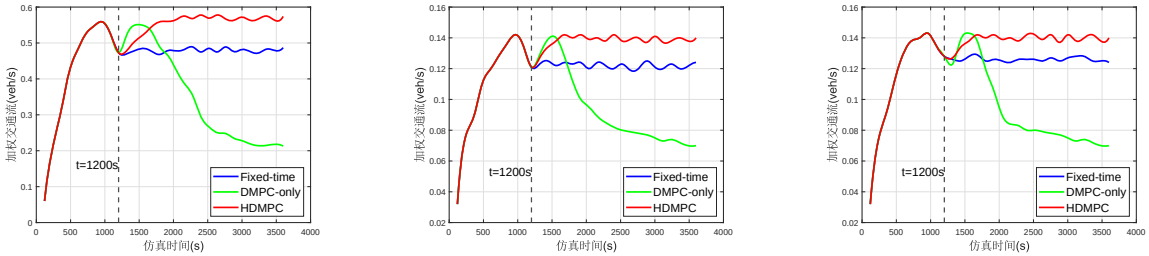

(a) i 区域加权交通流变化　(b) j 区域加权交通流变化　(c) l 区域加权交通流变化

图 4.9　本章仿真中不同控制方案下各区域的加权交通流变化趋势

该方法并不设定区域目标车辆数，而侧重于优化车道占用率、旅行时间及非活跃车辆数，从而动态调整绿灯时长以缓解拥堵。相比之下，HDMPC 方案在初期降低车辆数量，并最终稳定于宏观基本图导出的临界值 $N_{i,\text{critical}}, N_{j,\text{critical}}, N_{l,\text{critical}}$。这得益于下层控制器对区域间连接道路的协调调节，有效实现了交通负载的平衡分配。

从区域交通流的通行看，HDMPC 方案相较于固定时控显著减少了网络中车辆数量；尽管 DMPC-only 在车辆削减方面更具直接效果，但 HDMPC 方案在加权流量方面体现了更优的网络资源利用效率。因此，单纯对比车辆数量和加权流量仍不足以全面评价 HDMPC 方案的优势，需从更多维度展开深入分析以验证其整体效果，故选择区域内车辆通行的排队情况作为另外的评价指标。如图4.10所示为不同控制方案下各区域的车辆平均等待时间变化趋势，图4.11所示为不同控制方案下各区域的车辆平均排队长度变化趋势。

该指标统计的具体方法为：统计各路段上车辆的排队信息，并在区域内取平均值。当网络由过饱和逐步恢复至欠饱和状态后，拥堵缓解更多依赖于信号调控而非车辆总量。图4.10表明在自由流条件下，平均等待时间主要受信号控制影响，从一个固定的非零基准线开始变化；图4.11表明在自由流阶段，排队长度接近于零，随着信号灯变化引发停车而逐步上升，最终反映出网络拥堵程度加剧。

在控制方案实施前，随着流量增长，平均等待时间和排队长度持续上升，加剧拥

中国知网 https://www.cnki.net

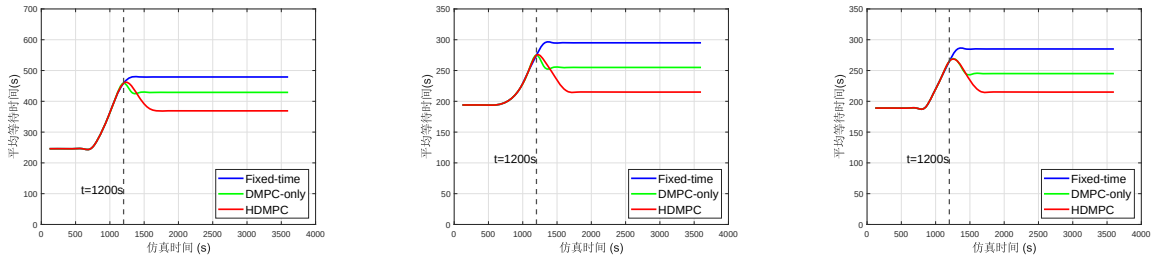

(a) i 区域车辆平均等待时间变化　(b) j 区域车辆平均等待时间变化　(c) l 区域车辆平均等待时间变化

图 4.10　本章仿真中不同控制方案下各区域的车辆平均等待时间变化趋势

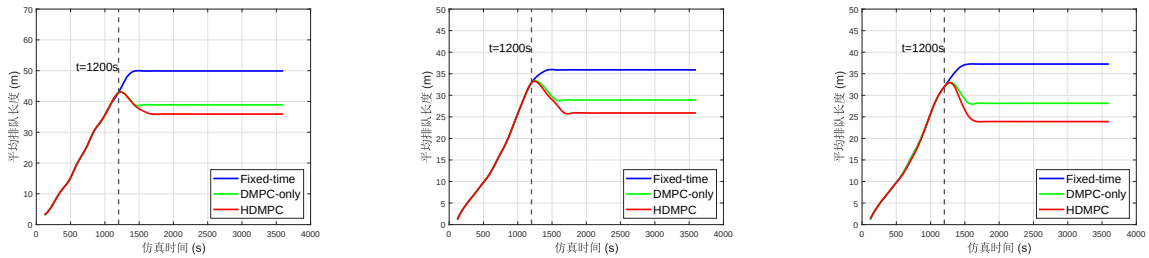

(a) i 区域车辆平均排队长度变化　(b) j 区域车辆平均排队长度变化　(c) l 区域车辆平均排队长度变化

图 4.11　本章仿真中不同控制方案下各区域的车辆平均排队长度变化趋势

堵与额外延误。而在采用不同控制方案后，Fixed-time 方案因无法适应流量变化，排队长度持续增长，最终达到饱和上限；相比之下，HDMPC 与 DMPC-only 方案均能有效缓解过饱和，显著降低车辆等待时间与排队长度。尽管 DMPC-only 方案在局部范围内优化了交通流，HDMPC 方案通过上下层协同实现全局协调，不仅提高了局部通行效率，还优化了系统整体运行状态。HDMPC 方案在车辆调度与信号配时之间建立有效联动，能更全面地降低路网排队与延误，整体优于 DMPC-only 方案。

综上所述，结合图 4.7–4.11 与表 4.4 的结果，HDMPC 方案在过饱和城市道路网络中表现出优异的拥堵缓解能力。其优势主要源于下层信号优化目标函数的精细设计及上层交通需求平衡控制器的引入。通过融合宏观基本图特性，分层分布式模型预测控制实现了通行效率与网络容量利用率的协调优化，在缓解拥堵的同时提升加权交通流，达成城市路网运行效率的最优状态。

表 4.5　本章仿真中不同方案下 CPU 计算时间

控制方案	平均 CPU 计算时间（s）	最大 CPU 计算时间（s）
DMPC-only	39.72	45.36
HDMPC	32.42	40.67

此外计算 CPU 计算时间如表4.5所示，假设上下层之间控制器以及低层的代理之

中国知网　https://www.cnki.net

间没有通信延迟。与 DMPC-only 方案相比，HDMPC 方案降低了所需的全局信号协调范围，从而降低了计算复杂度并缩短了达到最优解所需的 CPU 时间。结果如数据所示，分层分布式模型预测控制方法显著减轻了计算负担。需要指出的是，此处的平均和最大 CPU 时间分别代表每个控制时间步长解决在线优化问题所需的平均和最大计算时间。

4.5 本章小结

本章设计了一种结合了分层策略与分布式模型预测控制的分层分布式模型预测控制方案，并结合存储转发模型与宏观基本图进行交通流建模。该方案包含一个上层交通需求平衡控制器和一个下层信号优化控制器，以管理广泛的城市路网。每个层次处理不同的流量模型和目标，控制器通过通信进行协调，以优化流量和网络性能。为了提高计算效率，在底层实现并行分布式模型预测控制，改进交替方向乘子法使子区域控制器同步并达成控制决策的一致性。分层分布式模型预测控制方法嵌入了实时模型预测控制框架，在 MATLAB-VISSIM 平台上进行了联合仿真验证。结果表明，分层分布式模型预测控制通过将车辆数量与宏观基本图临界点相匹配，有效地减少了过饱和网络中的拥塞，提高了加权平均交通流量。案例研究表明，所设计的分层分布式模型预测控制方案在城市路网管理中优于固定信号灯时间的控制方案和仅采用分布式模型预测控制的方案。

中国知网 https://www.cnki.net

第 5 章 城市路网交通流的云边协同分布式模型预测控制

5.1 引言

在前两章的研究中，通过对路网交通流的数学模型建立以及模型预测控制方案的设计，成功实现了针对不同车辆类型与大规模路网交通流的模型预测控制。但是不难看出的是，前文研究中所构建的路网模型依旧规模有限，如果构建和城市路网完全一致的交通模型，即扩展至复杂拓扑结构时（包含数千个交叉路口和数万条路段），现有方法在计算效能和系统可扩展性方面面临双重挑战：（1）集中式优化维度随路网规模提高呈指数爆炸式增长，即使采用分布式架构，本地计算节点仍需承担高维状态空间建模与多时段滚动优化任务；（2）传统分层控制架构在应对突发交通事件时存在响应延迟，边缘节点的有限算力难以支撑分钟级信号配时方案的实时重优化。文献 [56] 中提出云控制系统概念，将原有本地计算的控制问题在云端部署，使其可以提供强大且可扩展的计算资源来处理计算密集型的分布式模型预测控制算法，并管理路段检测器产生的大量数据，为突破现有挑战提供了一个可供选择的思路。

云控制系统在智能交通系统中的应用如文献 [90] 采用云计算进行数据分析，集成了基于机器学习的交通流预测模型；文献 [91] 集成了基于深度强化学习的边云协同资源分配算法，将深度强化学习与扩展卡尔曼滤波相结合组成交通信号配时方法；文献 [92] 提出了一种具有延迟补偿的云边协同分布式模型预测控制方法，利用云端广泛的计算能力和可扩展性，旨在增强对复杂车辆编队系统的控制。这些研究针对不同交通系统优化问题进行基于云端的分析，并对其控制算法的云端部署进行了广泛研究，但现有研究并未深入探索交通流的模型预测控制在云端部署以及验证其可行性。

因此，本章提出一种城市路网交通流的云边协同分布式模型预测控制（Cloud-edge Cooperative Distributed Model Predictive Control, CEC-DMPC）方案，主要研究内容及创新点为：

1. 设计一种云边协同的交通流分布式模型预测控制架构。通过云控制层实现全网态势预测与全局策略生成，边缘控制层执行区域级实时感知与动态优化，构建“云决策-边执行-动态调整”的控制策略，以平衡计算负荷与响应速度。这种协同方法结合了云控制器和边缘控制器的优势，在路段信号灯绿灯时间优化场景中提供稳定性的同时优化了系统性能。

中国知网 https://www.cnki.net

2. 针对云控制器与边缘控制器的融合，设计了一种基于成本的事件触发机制和切换策略。事件触发机制可以根据实时需求动态调整云控制器的执行频率，减少不必要的数据包传输，从而在控制性能和云资源消耗之间保持平衡。

3. 利用 Docker 容器化技术，以便于分布式模型预测控制算法在真实云环境中的部署和操作隔离。通过使用容器化技术，确保了分布式模型预测控制算法的精简和高效的部署过程。

4. 使用 Python-SUMO 平台联合仿真，通过对所构建路网使用不同控制方案，对比所提出云边协同分布式模型预测控制方案与固定信号灯时间的方案和仅有边缘控制的分布式模型预测控制方案，通过不同性能指标变化趋势评估路网通行情况，验证所提方案有效性。

5.2 问题构建

构建一个由 N 条有向路段组成的城市交通路网模型，假设其中部分路段表示为如图5.1所示，以 z 表示单条路段，并对其标号为 $z = 1, 2, \cdots, N$。这些路段彼此间通过交叉口进行连接，并有车辆在其中通行形成交通流。

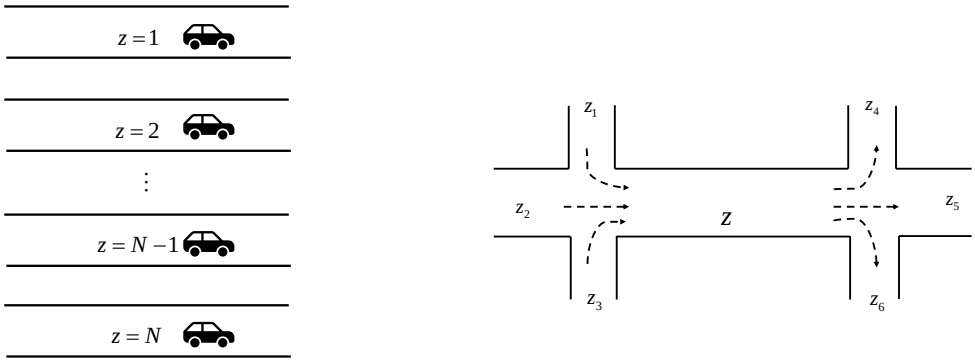

(a) 集合内共包含 N 条路段　　(b) 单条路段 z 结构示意图

图 5.1　本章所构建路段集合示意图

对任意单条路段 z 按照2.1.3节所述存储转发模型进行预测模型建立，在控制时刻 k 处的路段车辆数记作 $n_z(k)$，则：

$$n_z(k+1) = n_z(k) + T_u\big(r_{wz}(k) \cdot q_w(k) - q_z(k)\big) \tag{5.1}$$

其中 T_u 为采样周期，与路段 z 相邻的上游路段 w 驶出车流量 $q_w(k)$ 与对应行驶方向

中国知网 https://www.cnki.net

转弯率 $r_{wz}(k)$ 的乘积为来自上游路段的汇入车流量；$q_z(k)$ 为路段 z 驶出车流量，其由下式计算得出：

$$q_z(k) = S_z \cdot g_z(k) \tag{5.2}$$

其中 S_z 为当前路段 z 饱和车流量，$g_z(k)$ 为路段对应周期绿灯时长（即控制决策量）。预测模型同时满足以下约束表达：

$$q_z(k) \leq n_z(k) \tag{5.3}$$

$$r_{wz}(k)q_w(k) \leq \bar{n}_z - n_z(k) \tag{5.4}$$

其中 $\bar{n}_z$ 表示所定义的路段最大承载车辆数，对该两项不等式约束的解释已经在2.1.3节说明，此处不再赘述。同时对信号灯绿灯时间有如下约束定义：

$$0 \leq g_z(k) \leq g_z^{\max} \tag{5.5}$$

$$\sum_{m_z} g_z(k) \leq T_u \tag{5.6}$$

其中 $g_z^{\max}$ 表示路段绿灯时间的单次最大可设定值，m_z 为该路段在一个周期内的信号相位数。而一个周期所有相位下的绿灯总时长须不超过固定信号周期，即式(5.6)所示。与前文研究内容相似，本章认为控制步长对应采样周期等于信号周期。

以单条路段 z 为例，设计其在时刻 k 所求解的有限时域最优控制问题。定义决策变量

$$G_z(k) = \left[g_z(k|k),\, g_z(k+1|k),\, \ldots,\, g_z(k+p-1|k)\right]^\top$$

其中 $g_z(k+t|k)$ 为第 t 步的绿灯时长，p 为预测时域。$G_z(k) \in \mathbb{R}^{m_z p}$ 为一个 $m_z p$ 维向量。同时定义第 $k+t$ 步状态变量为

$$X_z(k+t|k) \;=\; \left[n_z(k+t|k),\, n_{z_1}(k+t|k), \ldots, n_{z_{l_z}}(k+t|k)\right]^\top$$

其包括本路段及与之相连（上下游）的 l_z 条路段的车辆数。$X_z(k+t|k) \in \mathbb{R}^{(l_z+1)}$ 构成一个 l_z+1 维向量。

由此，基于存储转发模型表达的路段车流预测模型可以写成如下向量形式：

$$X_z(k+1) = A_z X_z(k) + B_z G_z(k) \tag{5.7}$$

其中 $A_z \in \mathbb{R}^{(l_z+1)\times(l_z+1)}$，由式(5.8)定义。其中对角线元素负责储存未离开路段车辆

中国知网 https://www.cnki.net

数；同时定义上游转弯率 β，$\beta_{z_{l_z},z}$ 表示上游路段 z_{l_z} 车流向路段 z 方向行驶的转弯率。$T_u\beta_{z_{l_z},z}$ 表示路段在一个采样周期 T_u 内接受从上游第 l_z 条路段汇入的车辆增量。

$$A_z = \begin{bmatrix} 1 & T_u\,\beta_{z_1,z} & \dots & T_u\,\beta_{z_{l_z},z} \\ 0 & 1 & \dots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}, \tag{5.8}$$

而 $B_z \in \mathbb{R}^{(l_z+1)\times m_z p}$ 则将相位绿灯时间映射到本路段流出车辆数，由式(5.9)定义。

$$B_z = \begin{bmatrix} T_u\,S_z\,\mathbf{1}_{\{p_z\in\mathcal{P}_z\}} \\ \mathbf{0}_{l_z\times m_z p} \end{bmatrix} \tag{5.9}$$

其中 $p_z \in \mathcal{P}_z$ 表示该位置对应元素是服务于本路段的相位，$\mathcal{P}_z$ 是服务路段 z 的相位索引集合。我们由此设计一个目标函数如式(5.10)所示：

$$J_z = \sum_{t=0}^{p-1}\Big[\|X_z(k+t)\|_{Q_z}^2 + \|G_z(k+t)\|_{R_z}^2 + \|G_z(k+t) - G_z(k+t-1\|_{W_z}^2\Big] \tag{5.10}$$

其中拥堵惩罚项 $\|X_z(k+t)\|_{Q_z}^2$ 用于抑制路段及邻接路段的高队列，Q_z 为对应权重矩阵。配时惩罚项 $\|G_z(k+t)\|_{R_z}^2$ 用于合理分配信号时长避免信号灯过度给绿，R_z 为对应权重矩阵；平顺性惩罚项 $\|G_z(k+t) - G_z(k+t-1\|_{W_z}^2$ 用于限制相位时长突变，确保配时方案合理过渡，W_z 为对应权重矩阵。

5.3 交通流云边协同分布式模型预测控制方案设计

5.3.1 具有触发通信的云边协同分布式模型预测控制架构

本节提出的 CEC-DMPC 方案架构如图5.2所示，该方案采用三层架构设计，自上而下分别为云控制层、边缘控制层和受控路段对应的道路信号灯执行层，各层级间通过信息交互与协同决策形成闭环控制体系。该架构以5.2节所重构的存储转发模型为基础构建交通流预测动态模型，通过事件触发机制与云边控制动态切换策略的协同作用，在维持全局交通协调性的同时提升局部响应效率。其中，云控制层利用全局交通状态数据进行分布式模型预测控制优化计算，生成信号配时方案及未来时域预测状态；边缘控制层则基于简化模型执行本地化分布式模型预测控制，通过滚动时域与邻

中国知网 https://www.cnki.net

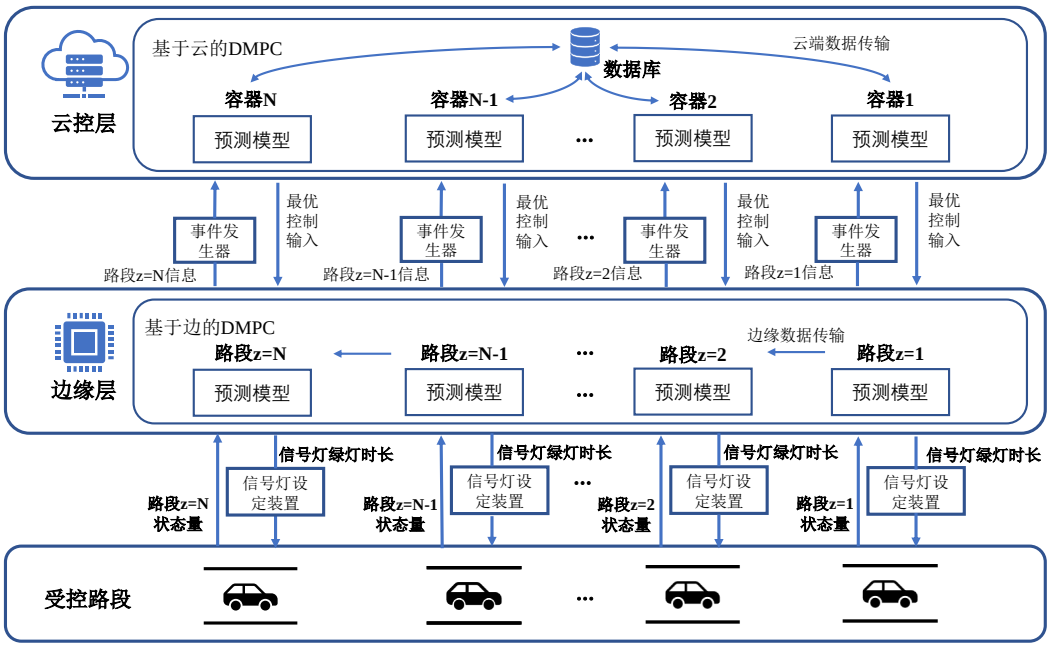

图 5.2　交通流云边协同分布式模型预测控制方案示意图

接耦合范围实现快速求解。两层级间通过事件触发机制协调计算资源分配：当路段交通状态偏离云端预测阈值或出现突发拥堵时，事件生成器激活云端重优化流程，同步上传最新状态信息以更新控制策略。控制指令最终经输入选择器动态择优执行，该模块通过评估通信延迟、控制成本及策略一致性指标，选择云端全局策略或边缘本地策略输出至信号灯执行层，确保控制输入的时空最优性。

如图中最高层所示的云控制层作为全局决策中枢，依托云端强大的计算能力处理城市路网级交通状态预测与优化任务。该层基于多源交通数据（包括实时路段排队长度、车流量、历史趋势数据等）构建全局交通状态估计模型，采用分布式模型预测控制算法进行优化求解。同时通过将存储转发模型嵌入预测控制框架，可实现各路段绿灯时间控制策略的并行化求解。为提升系统扩展性与部署灵活性，本研究采用 Docker 容器技术对控制子任务进行模块化封装，在云环境中利用容器化技术并行解决分布式控制问题。每条路段信息将对应于一个独立的容器，数据库用于容器间的数据交换。云层利用云计算资源解决基于高精度非线性模型的非凸优化问题，以提高控制性能。云端输出的控制量不仅包含当前最优信号配时方案，还生成未来滚动时域内的交通状态预测值，为边缘节点提供动态参考基准。

在云控制层未被触发的情况下，系统控制器将切换到边缘层，并部署分布式模型预测控制算法。与云控制层相对应，边缘控制层部署于各路段对应路口处的本地控制

中国知网　https://www.cnki.net

器，聚焦于局部路段的实时优化控制。受限于边缘设备的计算资源，该层采用线性化存储转发模型构建的简化版分布式模型预测控制控制器，通过缩短滚动时域窗口和限定邻接耦合范围确保优化问题的实时可解性。在常规运行状态下，边缘控制器基于本地检测器感知的路段内车辆数变化和相邻路段状态信息进行绿灯配时动态调整，同时接收云端下发的参考策略进行协同优化。这种设计使得边缘层既保持对突发交通事件的快速响应能力，又能与云端全局优化目标保持动态一致。

为协调云边两层的控制决策，系统引入事件触发机制作为协同控制的枢纽模块。该机制通过持续监测本地交通状态参数（包括实际状态与云端预测值的偏差度、路段内车辆拥堵变化、信号灯配时响应等关键指标），动态判断是否需要进行全局优化重计算。将基于云的分布式模型预测控制得到的最优控制序列存储在边缘层。如果该序列的性能令人满意，则可以继续使用其中的元素，而不会产生触发事件；当检测到预测偏差超过预设阈值或局部拥堵态势急剧恶化时，边缘节点立即触发事件请求，将最新状态信息同步至云端并启动区域级全局优化。

本架构通过云端的全局预测优化与边缘的局部实时控制相结合，构建了多层次、自适应的城市交通信号协同控制体系。云控制层提供宏观层面的战略决策支持，边缘控制层保障微观层面的战术执行能力，配合事件触发机制与输入选择器的动态调节，形成“云决策-边执行-动态调整”的闭环控制架构。

5.3.2 基于云的分布式模型预测控制器设计

在本研究所提出的云边协同控制方案中，云端作为系统的全局优化中心，承载对整个交通路网的状态信息采集与预测任务，负责高维非线性优化问题的求解，并通过控制策略下发引导边缘控制器的本地优化行为。云控制层的核心由一组基于容器技术的并行分布式模型预测控制组成，每个控制容器对应一条具体的交通路段，构成云端容器集群。在本节中将围绕云控制层设计基于云的分布式模型预测控制（Cloud-based Distributed Model Predictive Control, C-DMPC）器。

图5.2中云控层共 N 个容器，与边缘对应，且每个容器负责处理从对应边缘上报的末态数据。云控制层汇总所有边缘上报的 $\{X_z^{\text{pred}}(k+p)\}_{z=1}^{N}$，在更长时域 $M > p$

中国知网 https://www.cnki.net

求解云端优化问题，给出对各节点的策略修正。由式(5.10)转化得到目标函数：

$$J_c = \sum_{z=1}^{N}\sum_{t=0}^{M-1}\left[\widetilde{w}_x \cdot \|X_z(k+t)\|^2 + \widetilde{w}_g \cdot \|G_z(k+t) - G_z(k+t-1)\|^2\right] + \sum_{i\in\mathcal{N}_z}\gamma_{iz}\cdot\|X_i(k+p) - X_z(k+p)\|^2 \tag{5.11}$$

其中 $\widetilde{w}_x$ 和 $\widetilde{w}_g$ 分别为车辆数与信号灯时间变化量的权重系数，$\mathcal{N}_z$ 表示路段 z 相邻路段集合，γ_{iz} 是相邻路段之间的一致性权重，控制这对路段一致性的优化强度。由此构建云控层求解的分布式模型预测控制优化问题，其中 $\mathbf{1}$ 为 $m_z p$ 维单位列向量。

问题 5.1.

$$\min_{G_z(k+t)} \quad J_c \tag{5.12a}$$

$$\text{s.t.} \quad \text{for} \quad t = 0, 1, 2, \ldots, M-1$$

$$X_z(k+t+1) = A_z X_z(k+t) + B_z G_z(k+t) \tag{5.12b}$$

$$G_z^{\min} \leq G_z(k+t) \leq G_z^{\max} \tag{5.12c}$$

$$\mathbf{1}^\top G_z(k+t) \leq T_u \tag{5.12d}$$

云控制层在预测时域 M 上并行构建多个子区域的优化问题，总体优化目标包括：控制车辆数防止拥堵，平衡信号平稳性，并在不同子区域之间引入一致性耦合项，以保证相邻路段的配时策略协同衔接。通过交替方向乘子法将大规模非凸优化任务拆分成容器可并行求解的小规模子问题，最终在云端协调节点内汇总和更新各容器的策略修正项，设计求解算法如算法3所示。

解得各路段最优序列后，计算修正项 $\delta_z = \widehat{X}_z(k+p) - X_z^{\text{pred}}(k+p)$，并写入数据库，通过消息队列下发至边缘层。其通信机制遵照守以下准则：（1）上行：仅在边缘触发条件时接收预测末态；（2）下行：周期性或触发驱动向所有容器下发 δ_z。

为满足线上实时性与高可用性需求，云端所有分布式模型预测控制优化问题均采用 Docker 容器化部署。每个容器内部封装对应路段的模型更新、预测计算与最优控制求解器模块，并通过统一的数据库或消息队列接口与其他容器及协调模块通信。云控制层周期性或在接收到事件触发请求时，向容器化的分区任务下发最新的边缘预测末态与耦合拉格朗日乘子；各子任务并行求解分布式模型预测控制问题后，将本次策略修正项和末端队列预测值写回至中央数据库。协调模块读取所有子区域的结果，汇总生成对全网一致性的全局更新方案，并下发给相应的边缘节点。如此形成的“云-数据库-边”的闭环，既保证了全局一致性调度，又兼顾了边缘层的实时响应性。

中国知网 https://www.cnki.net

算法 3: 基于云的分布式模型预测控制与交替方向乘子法协同优化算法

Input: 初始状态 $X_z^{(0)}$, 控制量 $G_z^{(0)}$, 全局一致变量 $Z_z^{(0)}$, 拉格朗日乘子 $\lambda_z^{(0)}$
最大迭代次数 $K_{\max}$，容差阈值 $\varepsilon_{\text{pri}}, \varepsilon_{\text{dual}}$，惩罚参数 ρ
Output: X_z^*, G_z^*

for $l = 1$ **to** $K_{\max}$ **do**
  foreach 路段 $z = 1, 2, \ldots, N$ **并行 do**

$$(X_z^{(l)}, G_z^{(l)}) := \arg\min J_c(X_i, g_i) + \frac{\rho}{2}\left\|X_z - Z_z^{(l-1)} + \lambda_z^{(l-1)}\right\|^2$$

  end
  更新全局一致变量:

$$Z_z^{(l)} = \frac{1}{|\mathcal{N}_z|}\sum_{i\in\mathcal{N}_z}\left(X_i^{(l)} + \lambda_i^{(l-1)}\right)$$

  更新乘子变量:

$$\lambda_z^{(l)} = \lambda_z^{(l-1)} + X_z^{(l)} - Z_z^{(l)}$$

  计算残差:

$$r_z^{(l)} = X_z^{(l)} - Z_z^{(l)}, \quad s_z^{(l)} = \rho(Z_z^{(l)} - Z_z^{(l-1)})$$

  if $\|r_z^{(l)}\|_2 \le \varepsilon_{pri}$ ***and*** $\|s_z^{(l)}\|_2 \le \varepsilon_{dual}$ **then**
    break;
  end
end
return $X_z^l = \widehat{X}_z, G_z^l$ for all z

5.3.3 基于边的分布式模型预测控制器设计

在云端部署基于云的分布式模型预测控制后，与之对应的是边缘层的分布式模型预测控制问题以及时间触发机制，因此在本节中将围绕边缘层设计基于边的分布式模型预测控制（Edge-based Distributed Model Predictive Control, E-DMPC）器。E-DMPC 不仅要在本地快速响应路段级交通波动，还要在整体架构中与云端协同发挥作用，因此其设计既要考虑算法的实时性与计算效率，也要兼顾与云端全局优化结果的一致性。

基于5.2节所述的存储转发模型，进一步增加与云端参考末态的一致性偏差作为成本函数，并设计软约束机制将云端给出的预测末态作为目标引导项，以确保局部策略不会背离全局最优解。由式(5.10)转化得到目标函数:

中国知网 https://www.cnki.net

$$\min_{G_z(k+t)} \quad J_z = \sum_{t=0}^{p-1} \Big[\|X_z(k+t)\|_{Q_z}^2 + \|G_z(k+t)\|_{R_z}^2 + \|G_z(k+t) - G_z(k+t-1)\|_{W_z}^2 \Big] + \|X_z(k+p) - \widehat{X}_z(k+p)\|_{P_z}^2 \tag{5.13}$$

其中 $\widehat{X}_z(k+p)$ 表示云端给定的参考末态，是基于全局优化考虑得出的各路段车辆数分布，P_z 为其对应的权重矩阵。将该末态信息引入边缘层，可以引导本地优化结果更好地贴近全局最优分配，从而避免出现“本地最优—全局不佳”的情形。该项在目标函数中的权重体现了云边协同的分配侧重：高权重时，边缘紧密地服从云端决策；权重较低时，如路段突发紧急交通管制等情况，边缘更倾向于依赖自身局部观测进行优化。

由此构造边缘控制器求解问题如下：

问题 5.2.

$$\min_{G_z(k+t)} \quad J_z \tag{5.14a}$$

$$\text{s.t.} \quad \text{for} \quad t = 0, 1, 2, \ldots, p-1$$

$$X_z(k+t+1) = A_z X_z(k+t) + B_z G_z(k+t) \tag{5.14b}$$

$$G_z^{\min} \leq G_z(k+t) \leq G_z^{\max} \tag{5.14c}$$

$$\mathbf{1}^\top G_z(k+t) \leq T_u \tag{5.14d}$$

E-DMPC 除遵守存储转发模型所构造动态方程对应约束(5.14b) - (5.14d)外，利用软约束机制将云端给出的预测末态作为目标引导项，以确保局部策略不会背离全局最优解。控制器在每个调度周期启动二次规划（Quadratic Programming, QP）求解过程，并仅取第一步结果下发至信号机，其余控制序列留作滚动时域的初始猜测，以实现连续决策。

求解所述 E-DMPC 问题时，针对边缘计算资源有限的问题，本研究选用 QP 求解器，以历史最优解初始化当前求解，加速优化收敛。求解过程中的所有中间数据和性能指标均保存在本地缓存，一旦出现网络故障或延迟，边缘控制器即可在毫秒级内完成新一轮优化，而无需与云端通信。

与此同时，E-DMPC 与云端的交互通过事件触发机制进行：当本地预测偏差或拥堵指标超限时，边缘控制器会主动上传最新状态至云端，触发全局分布式模型预测控制重计算；在触发条件未满足时，边缘控制器则继续基于云端上一次下发的参考策略

中国知网 https://www.cnki.net

自循环优化，以最大限度地减少通信开销。具体设计如下：

边缘节点 z 在完成时刻 k 的 E-DMPC 求解后，触发判断依据以下准则：

（1）末态预测偏差检测：定义预测时域末端状态偏差度量：

$$\Delta X_z(k) = \|X_z(k+N|k) - \widehat{X}_z(k+p|k)\|_2$$

当 $\Delta X_z(k) > \epsilon_z$ 时触发云端通信，其中 ϵ_z 为通过历史数据所得的阈值参数。

（2）局部拥堵态势预警：若在预测时域内存在：

$$n_z(k+t|k) \geq X_z^{\text{crit}}$$

则立即触发报警，式中 X_i^{crit} 表征路段饱和流率对应的临界排队长度。

当任一触发条件满足时，边缘节点通过容器化接口执行以下操作：

（1）构建事件报文：包含三元组 $\langle X_z(k+p|k), \Gamma_z(k), \tau_z \rangle$，其中 $\Gamma_i(k) \in \{\text{deviation}, \text{congestion}\}$ 为事件类型标识符，τ_z 为时间戳-节点 ID 复合编码。

（2）选择传输模式：实时模式，通过消息队列实现事件优先级推送；缓存模式，写入数据库供云端周期轮询，该模式适用于非紧急状态。

云端控制器接收触发事件后启动协同优化流程：

（1）数据聚合：云端识别所有发生事件的路段及其邻接关联路段，记为区域集合 $\mathcal{R}$。基于边缘节点上报的预测末态信息，构造区域状态矩阵：

$$\mathbf{X}(k+p|k) = \begin{bmatrix} X_{z_1}(k+p|k)^\top \\ X_{z_2}(k+p|k)^\top \\ \vdots \\ X_{z_r}(k+p|k)^\top \end{bmatrix}, \quad z_r \in \mathcal{R}$$

（2）全局优化：更新 C-DMPC：

$$\min_{\{G_z, X_z\}} \sum_{z\in\mathcal{R}} \left(\sum_{t=0}^{M-1} \left(\widetilde{w}_x \|X_z(k+t)\|^2 + \widetilde{w}_g \|G_z(k+t) - G_z(k+t-1)\|^2 \right) \right) + \sum_{i\in\mathcal{N}_z} \gamma_{iz} \cdot \|X_i(k+p) - X_z(k+p)\|^2$$

并采用算法3进行求解。

（3）策略下发：当优化问题求解结束，系统将提取各路段的最优预测末态 $\widehat{X}_z$ 及其相较旧参考的偏差修正项 $\delta_z = \widehat{X}_z - X_z^{\text{pred}}(k+p)$，并通过消息队列或数据库通道将

中国知网 https://www.cnki.net

结果统一下发至边缘控制器。边缘节点在接收到新的修正后，将其作为更新的目标参考，重新构造目标函数并进入下一轮自循环优化，实现云边协同的动态闭环控制。

当双触发条件均未激活时，系统进入本地自治模式，即边缘控制器持续执行基于最近参考轨迹的滚动优化

将本节所述 E-DMPC 与触发机制整理为算法4，该协同机制通过条件触发、分层通信与自主控制的多模态融合，使系统通信负载降低。

算法 4: E-DMPC 求解与事件触发算法

Input: 当前时刻 k 的队列状态 $X_z(k)$；
云端下发的参考末态 $\widehat{X}_z(k+p)$；
上次优化得到的控制序列 G_z^{prev}；
系统矩阵 A_z, B_z；权重矩阵 Q_z, R_z, W_z, P_z；
预测时域长度 p；触发阈值 $\epsilon_z, X_z^{\text{crit}}$；
最小重触发间隔 $\tau_z^{\min}$，以及上次触发时间 t_{last}
Output: 本周期执行绿灯时长 $g_z(k)$；触发标志 $\text{flag}_z(k)$

构建优化问题：
  目标函数 J_z 及约束：
    状态更新 $X_z(k+t+1) = A_z X_z(k+t) + B_z G_z(k+t)$；
    绿灯时长上下限及总周期时长约束；
    软末态一致性 $\|X_z(k+p) - \widehat{X}_z(k+p)\|_{P_z}^2$；
Warm start： 将 G_z^{prev} 作为 QP 初始解;
QP 求解： 调用嵌入式求解器，得到最优序列 $G_z^\star = \{g_z^\star(k), \ldots, g_z^\star(k+p-1)\}$;
$g_z(k) \leftarrow g_z^\star(k)$; // 下发本时刻绿灯时长
$G_z^{\text{prev}} \leftarrow G_z^\star$; // 缓存优化序列
计算并缓存预测末态 $X_z^{\text{pred}}(k+p)$;
if $k - t_{\text{last}} \geq \tau_z^{\min}$ ***and*** $\left(\|X_z^{pred}(k+p) - \widehat{X}_z(k+p)\| > \epsilon_z\right.$ ***or*** $\left.\max_{t=0,\ldots,p-1} n_z(k+t) > X_z^{\text{crit}}\right)$ **then**
  $\text{flag}_z(k) \leftarrow 1$; // 触发云端重优化
  上报 $X_z^{\text{pred}}(k+p)$ 至云端数据库;
  $t_{\text{last}} \leftarrow k$; // 更新触发时间
end
else
  $\text{flag}_z(k) \leftarrow 0$; // 继续本地循环优化
end
return $g_z(k)$, $\text{flag}_z(k)$;

中国知网 https://www.cnki.net

5.3.4 云边协同分布式模型预测控制器设计

基于前两节所构建的基于云的分布式模型预测控制器与基于边的模型预测控制器，本节将对其进行整体设计，构建云边协同分布式模型预测控制器。如算法5所示：

算法 5: 云边协同分布式模型预测控制算法

Input: 初始状态 $\{x_z(0)\}$，预测时域 p，容器数 N，
云端权重 $\widetilde{w}_x, \widetilde{w}_g, \gamma_{iz}$，边缘权重 Q_z, R_z, W_z, P_z
Output: 每时刻路段信号控制输入 $g_z(k)$

```
初始化阶段（k = 0）:
for z = 1 to N 并行 do
    云端容器读取 x_z(0)，执行 C-DMPC，得到 X̂_z(0 + p) 与修正量 δ_z；
    将 δ_z 下发至边缘容器 z；
end
在线迭代阶段（k = 1, 2, ..., p）:
for i = 1 to N 并行 do
    边缘预测与执行：
    读取本地状态 x_z(k) 与邻居状态；
    执行 E-DMPC，求解 g_z(k:k+N−1)；
    应用当前控制量 g_z(k)；
    事件触发上报：
    if 预测误差或拥堵指标触发 then
        上传 X̂_z^pred(k + p) 至云端；
    end
    自循环模式：
    if 未触发通信 then
        使用最近的 δ_z 更新目标函数，继续优化；
    end
end
云端协调：
if 收到任意上报 then
    执行 C-DMPC，更新 {X̂_z(k + p), δ_z}；
    将 δ_z 下发至对应边缘容器；
end
```

该方案充分结合了云端的全局优化能力与边缘的快速响应特性，在保障控制精度的同时显著提升了系统的可扩展性与鲁棒性。通过事件触发机制实现的信息交互与控制切换机制，有效缓解了频繁通信带来的网络负载，确保了在复杂城市交通环境下的实时性与稳定性。该方案为城市路网交通流提供了一种兼顾全局协调与局部自主的交通信号控制高效解决方案。

中国知网 https://www.cnki.net

5.4 案例研究

5.3节完成了对云边协同分布式模型预测控制方案的设计，其中包含云控制层的 C-DMPC，边缘层的 E-DMPC 以及触发云边协同控制的机制，本节将通过路网交通流仿真验证其可行性与可靠性。

5.4.1 仿真设置

仿真使用的云服务器配置为阿里云的高频计算类型，采用 3.3GHz Intel® Xeon（SPR）™ 处理器，配置 32 vCPUs，运行内存 64GB。云服务器的操作系统是 Ubuntu 22.04，模拟环境是 Python 3.7 和 SciPy。边缘客户端使用一台配置 3.0GHz Intel® Core™ i5-12500 的 CPU，运行内存 16GB 的个人电脑。采用 Python+SUMO 的联合仿真，其中 Python 版本为 3.7，SUMO 版本为 1.16.0。Python 与 SUMO 的联合仿真方式已在3.4.1节表述，故在此不再赘述。云服务器的 Docker 容器由三个模块组成：（1）Docker Image：一个自成一体的可执行软件包，包括运行 Python 应用程序所需的所有依赖项和环境；（2）Dockerfile：一个文本文件，提供构建 Docker 镜像的说明，定义其组成和配置；（3）Python 脚本：应用程序的核心代码，运行在 Docker 容器中。

仿真在 SUMO 中搭建使用如图5.3所示路网，该部分 4 个交叉口按 2×2 的标准进行排列，并使用有向路段连接，每方向两条路段标定车辆通行的下游路段，路网内合计 16 条路段。对应控制方案 $N = 16$，单个路段 z 结构如图5.1(b)所示。路网交通流通行遵循图5.3(b)所示相位，其余仿真参数设定由表5.1给出。

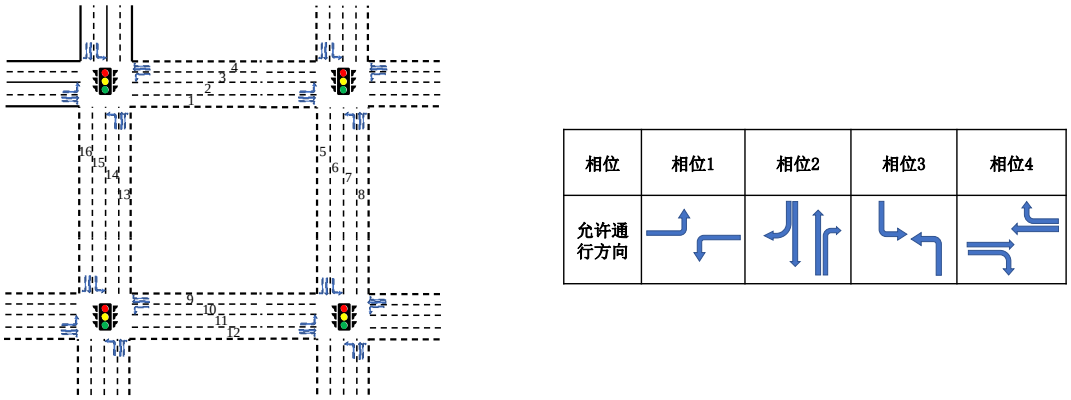

(a) 本章仿真所构建路网模型　　(b) 本章仿真所构建路网模型内路口信号灯相位图

图 5.3　本章所构建路网示意图

仿真设置总模拟时间 1800 秒，并在仿真前 600 秒设置预热期使得车流进入路网

中国知网 https://www.cnki.net

表 5.1　本章仿真中对系统定值变量的数值设定

符号	物理意义	数值设定	单位
–	单条路段长度	500	米
–	车辆在自由流状态下平均速度	20	米/秒
–	路网内车辆平均长度	5	米
T_u	信号灯周期时间与采样时间间隔	60	秒
$g_{\min}$	最短绿灯时间	5	秒
$g_{\max}$	最长绿灯时间	45	秒
S_z	路段饱和车流量	3.5	辆/秒
–	各路口流入车流量	2	辆/秒
p	边缘层预测时域	10	–
M	云控层预测时域	20	–
Q_z	拥堵惩罚项权重矩阵	$1 \cdot I_n$	–
R_z	配时惩罚项权重矩阵	$0.1 \cdot I_n$	–
W_z	时长突变惩罚项权重矩阵	$0.1 \cdot I_n$	–
P_z	一致性偏差惩罚项权重矩阵	$10 \cdot I_n$	–
$\widetilde{w}_x$	状态权重	1	–
$\widetilde{w}_g$	控制变化权重	0.1	–
γ_{iz}	区域协调权重	5	–
ϵ_z	预测偏差触发阈值	5	–
X_z^{crit}	拥堵触发阈值	180	–
$\tau_z^{\min}$	最小重触发间隔	180	秒
$K_{\max}$	最大迭代次数	200	–
ε_{pri}	容差阈值	0.1	–
$\varepsilon_{\text{dual}}$	容差阈值	0.1	–
ρ	惩罚参数	0.5	–

系统。本仿真案例中车辆在各个路口行驶方向依旧随机选择，各方向转弯率相同。设置如下三个方案进行仿真结果的对比分析：

（1）固定信号灯时间（Fixed-time）方案：采用固定不变的交通信号配时方案，与4.4.1节所述该方案类似，本例中将信号周期改为 60 秒，依旧设置四个相位平均分配。

中国知网 https://www.cnki.net

（2）仅基于边的分布式模型预测控制（E-DMPC）方案：不使用云控制层，即所有控制均在本地完成，无需与云通信。路网各路段的边缘节点仅获取本路段和邻接路段状态；并不参与中央协调，其目标函数中不包含 $\|X_z(k+p)-\widehat{X}_z(k+p)\|_{P_z}^2$ 项，仅考虑本地路段状态与相邻路段状态间的耦合约束。

（3）所设计的云边协同模型预测控制（CEC-DMPC）方案：本章所提出的云边协同控制方案，基于5.3节所述，包含基于云的分布式模型预测控制优化、基于边的分布式模型预测控制优化以及触发机制。

5.4.2 仿真结果

本节通过不同指标下路段相关状态量的变化趋势，对控制方案优化交通流通行的效果进行评价。通过 SUMO 仿真平台获取的数据，取图5.3(a)中路段 1、6、11、16 的数据进行分析。

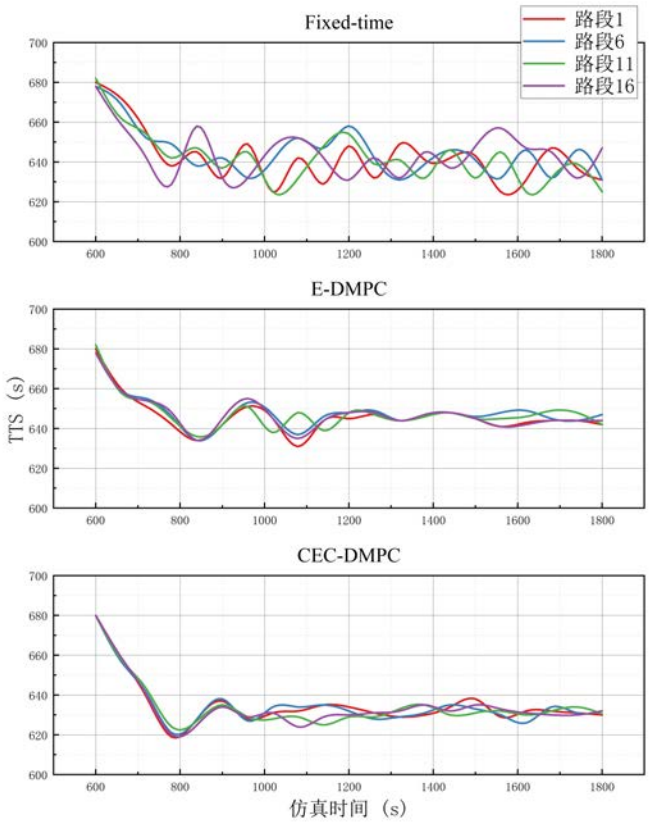

图 5.4　本章仿真中不同控制方案下路段 TTS 变化趋势

如图5.4所示为三种方案下各路段 TTS 变化的趋势，本例中 TTS 通过采样时间间隔内路段车辆的通行时间叠加计算得到。不难看出固定信号灯时间的情况对提高车辆

中国知网　https://www.cnki.net

通行效率并未产生实质性的效果，在预热时间结束后采用的信号灯方案因无法根据交通流状态更新优化策略，使得车辆通行时间无法有效降低。在引入 E-DMPC 后，边缘计算通过存储转发模型在本地配置的优化问题，其目标函数包含对拥堵情况的惩罚项，同时对信号灯时间进行了优化调整，使得车辆通行时间产生降低的同时，路段内车辆数趋于稳定状态，故随着时间的推进路段 TTS 的值不再剧烈变化，路段通行趋于平稳。而 CEC-DMPC 方案通过在 E-DMPC 方案中增加云控制层进行全局优化，进一步提升了系统的协调性和响应能力。如图所示，CEC-DMPC 方案在全局调控下车辆通行时间进一步缩短，使 TTS 指标在多数路段上低于 E-DMPC 与 Fixed-time 方案，表现出更高的效率与稳定性。

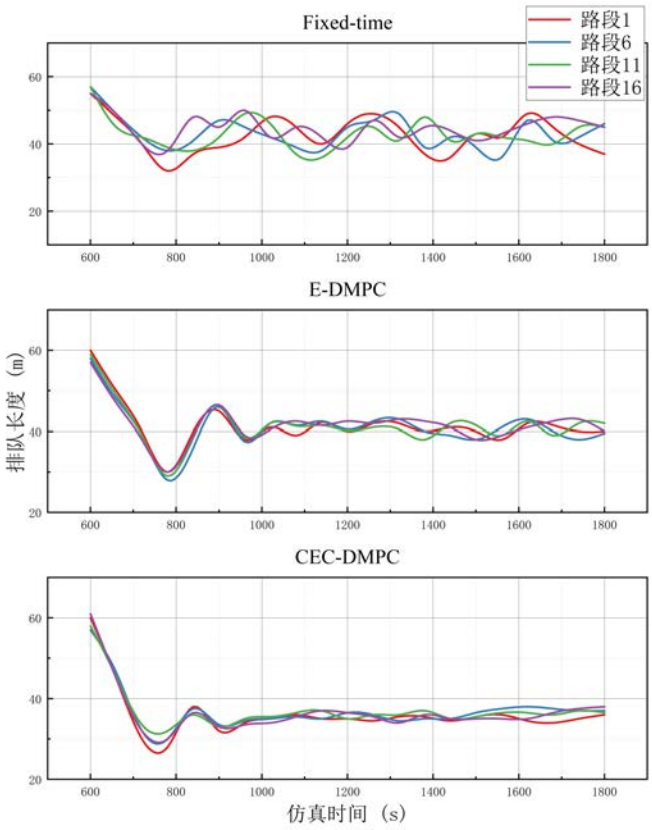

图 5.5　本章仿真中不同控制方案下路段排队长度变化趋势

除 TTS 外，图5.5所示以排队长度的维度对通行情况进行分析，本例排队长度通过路段在采样时间间隔在路口排队通行的长度计算。Fixed-time 方案下因信号灯未做响应，排队长度始终处于一定范围内的波动，未产生实质性的降低。E-DMPC 方案对路段状态量的优化使得排队长度在方案实施后开始降低，边缘计算的效果得到明显呈现。而 CEC-DMPC 方案的引入则进一步提高了该项的响应速度与优化效果。具

中国知网　https://www.cnki.net

体而言，云端基于边缘节点上报的预测末态信息，聚合构建区域状态矩阵，并通过 C-DMPC 模块对全局交通状态进行统一优化，以此生成反馈修正项 δ_z，用于调整边缘节点的控制策略。该机制有效弥补了边缘控制在面对全局耦合关系时的局限性，尤其在多路段交互影响较强的情形下，能够更好地协调相邻路段之间的信号配时。此外，在整个仿真周期内，CEC-DMPC 方案展现出更快的收敛趋势和更小的波动幅度，说明其在动态交通环境中具有更强的适应能力。

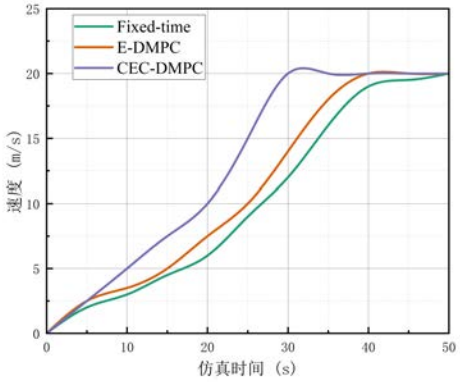

图 5.6　本章仿真中不同控制方案下车辆通行速度变化趋势

在对路段内交通流通行分析后，测量为三种控制方案下车辆在行驶路段上的平均速度变化趋势。如图5.6所示，可以观察到，车辆在起步进入路网系统后：CEC-DMPC 方案下相比另外两个方案车辆可以更快的到达自由流速度，这得益于路网交通流的有效疏导，也表明车辆在该方案下损耗时间以及能源等将更低。Fixed-time 方案下车辆受限于道路拥堵无法加速，E-DMPC 方案效果则介于两者中间。

由以上仿真结果可以得出结论，CEC-DMPC 在保障交通系统全局协调性与响应实时性的同时，实现了更优的车辆通行速度表现，验证了所提云边协同控制策略的有效性与先进性。

表 5.2　本章仿真中不同方案下 CPU 计算时间

控制方案	平均 CPU 计算时间（s）	最大 CPU 计算时间（s）
E-DMPC	23.45	25.12
CEC-DMPC	15.24	18.09

此外计算 E-DMPC 方案与 CEC-DMPC 方案的 CPU 计算时间如表5.2所示，边缘层内存占用量如表5.3所示。与 E-DMPC 方案相比，CEC-DMPC 方案通过云控层与边

中国知网　https://www.cnki.net

表 5.3　本章仿真中不同方案下边缘层内存占用量

控制方案	平均内存占用（GB）	峰值内存占用（GB）
E-DMPC	2.25	2.31
CEC-DMPC	1.45	1.53

缘层的协同控制，将高维非线性优化问题部署在云端并仅在边缘层部署简易的分布式优化问题，从而降低了计算复杂度并缩短了达到最优解所需的 CPU 时间。与此同时，由云端存储并求解，边缘层修正的策略使得边缘层对于运行内存的占用显著降低，有效缓解了计算负荷。如数据所示，云边协同分布式模型预测控制方法显著提高了计算效率并减轻了计算负荷。

综上所述，仿真结果验证了本章所设计的城市路网交通流云边协同分布式模型预测控制方案的可行性与对计算负荷有效处理。

5.5 本章小结

本章设计了一种城市路网交通流的云边协同分布式模型预测控制方案，该方案包含云控层、边缘层与受控对象。在云控层求解基于云的分布式模型预测控制问题，实现全网态势预测与全局策略生成，同时云端利用 Docker 容器化技术部署分布式模型预测控制。在边缘层求解基于边的分布式模型预测控制问题，求解简易分布式模型预测控制问题，执行区域级与动态优化。该方案构建“云决策-边执行-动态调整”的控制策略，用以平衡计算负荷与响应速度。同时设计了一种基于成本的事件触发机制和切换策略，根据实时需求动态调整云控制器的执行频率。在 Python-SUMO 平台上进行联合仿真验证，通过与固定信号灯时间方案和仅基于边的分布式模型预测控制方案的对比，以不同性能指标变化趋势评估路网通行情况，验证了所提方案有效性。

中国知网　https://www.cnki.net

结论

本文针对城市路网交通流的模型预测控制问题，提出了三种基于模型预测控制的交通流控制方案，由路口交通信号控制作为控制输入，实现对路网交通流的优化。同时通过仿真实例研究对比，验证了所提出控制方案的有效性和可行性。本文的主要研究工作可以总结为以下几个方面：

（1）针对特定交通状况下的交通流控制，对基础的交通流 S 模型进行改进，增加公交车、公交车站与公交专用道元素，并扩展为前后连接的三路口系统进行集中式模型预测控制方案设计。通过对公交车元素行驶特性的约束改进，将原有针对普通车辆通行的 S 模型改进为预测公交车流的 S 模型，并与普通车行驶状态进行集成，在一个三路口系统中平衡普通车辆通行拥堵与公交车辆进站排队问题。最后，通过城市交通流模拟平台进行仿真，验证所设计方案的有效性。

（2）基于上述研究在因模型与约束复杂性难以在大规模路网中实现的问题，提出一种大规模城市路网交通流分层分布式模型预测控制方案。该方案构建双层优化框架：在上层采用集中式模型预测控制，以区域宏观基本图性质进行全局流量优化；在下层采用分布式模型预测控制，以简化的交通流存储转发模型进行路段信号协同优化。通过分层与分布式设计，将大规模路网交通流优化问题降维以实现计算复杂度的减小。最后，通过交通流模拟平台进行仿真，验证所设计方案的有效性。

（3）基于上述研究在处理路网交通流优化问题中面临的计算效能与系统可扩展性问题，提出一种交通流的云边协同分布式模型预测控制方案。该方案应用云控制系统构建模型预测控制问题，在云控层实现全网态势预测与策略生成，在边缘层执行区域实时感知与动态优化。同时设计事件触发机制根据需求调整云控制器执行频率。通过云边协同方案设计，将分布式模型预测控制问题分别部署在云端和本地，构建“云决策-边执行-动态调整”的控制策略。最后，通过交通流模拟平台进行仿真，验证所设计方案的有效性。

尽管本文对基于模型预测控制的城市路网交通流控制优化做了一些研究，但是仍有很多不足与未来可以继续研究的工作：

（1）本文所使用的交通流预测模型对实际通行情况的建模尚不完善，后续可进一步在交通流理论层面改善相关模型，将实际交通中的通行情况与驾驶行为建模加入预

中国知网 https://www.cnki.net

测模型中，提高模型预测的准确性。

（2）本文所构造的模型预测控制方案中，部分变量使用历史经验数据作为定值进行代入，导致模型失配与控制性能下降。基于此，可以进一步研究数据驱动的模型预测控制，或者将这一部分变量作为随机变量设计随机模型预测控制算法。上述方案可以进一步提高模型预测控制在实际系统中的控制效果。

（3）本文所列举的仿真结果均通过 SUMO/VISSIM 城市交通流仿真平台获得，未来可以通过与交通出行服务供应商合作，搭建真实交通通行平台进行实物验证。

中国知网 https://www.cnki.net

参考文献

[1] 中华人民共和国国家统计局. 中国统计年鉴 (2024)[M]. 北京: 中国统计出版社, 2024.

[2] 中华人民共和国公安部. 全国机动车保有量达 4.53 亿辆驾驶人达 5.42 亿人[EB/OL]. (2025-01-18) [2025-04-03]. https://www.gov.cn/lianbo/bumen/202501/content_6999762.htm.

[3] 2023 年交通运输行业发展统计公报[R]. 中国交通报, 2024.

[4] Federal Highway Administration. Highway Statistics 2023[EB/OL]. (2024-02-03) [2025-04-03]. https://www.fhwa.dot.gov/policyinformation/statistics/2023/.

[5] 百度地图. 2024 年度中国城市交通报告[EB/OL]. (2025-03-31) [2025-04-03]. https://huiyan.baidu.com/reports/landing?id=179&role=traffic.

[6] Bureau of Transportation Statistics. Annual Person-Hours of Highway Traffic Delay Per Auto Commuter[EB/OL]. (2023-04-23) [2025-04-03]. https://www.bts.gov/content/annual-person-hours-highway-traffic-delay-person..

[7] Ouallane A A, Bakali A, Bahnasse A, et al. Fusion of engineering insights and emerging trends: Intelligent urban traffic management system[J]. Information Fusion, 2022, 88: 218-248.

[8] Wang A, Wang J, Zhang R, et al. Mitigating urban heat and air pollution considering green and transportation infrastructure[J]. Transportation Research Part A: Policy and Practice, 2024, 184: 104079.

[9] Joshi V D, Agarwal P, Kumar A. Fuzzy transportation planning: a goal programming tactic for navigating uncertainty and multi-objective decision making[J]. International Journal on Interactive Design and Manufacturing (IJIDeM), 2023: 1-29.

[10] Wu N, Li D, Xi Y. Distributed integrated control of a mixed traffic network with urban and freeway networks[J]. IEEE Transactions on Control Systems Technology, 2021, 30(1): 57-70.

[11] Li D, Zhu F, Wu J, et al. Managing mixed traffic at signalized intersections: An adaptive signal control and CAV coordination system based on deep reinforcement learning[J]. Expert Systems with Applications, 2024, 238: 121959.

[12] Zhou B, Zhou Q, Hu S, et al. Cooperative traffic signal control using a distributed agent-based deep reinforcement learning with incentive communication[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(8): 10147-10160.

[13] 王坤. 基于深度强化学习的智能交通信号控制方法研究[D]. 哈尔滨理工大学, 2023.

[14] Sarwatt D S, Lin Y, Ding J, et al. Metaverse for intelligent transportation systems (ITS): A comprehensive review of technologies, applications, implications, challenges and future directions[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(7): 6290-6308.

中国知网 https://www.cnki.net

[15] Feng S, Song Z, Li Z, et al. Robust platoon control in mixed traffic flow based on tube model predictive control[J]. IEEE Transactions on Intelligent Vehicles, 2021, 6(4): 711-722.

[16] Liu C, Ke L. Cloud assisted Internet of things intelligent transportation system and the traffic control system in the smart city[J]. Journal of Control and Decision, 2023, 10(2): 174-187.

[17] Sen S, Head K L. Controlled optimization of phases at an intersection[J]. Transportation science, 1997, 31(1): 5-17.

[18] De Oliveira L B, Camponogara E. Predictive control for urban traffic networks: initial evaluation[J]. IFAC Proceedings Volumes, 2007, 40(20): 424-429.

[19] Sims A G. The Sydney coordinated adaptive traffic system[C]. Engineering Foundation Conference on Research Directions in Computer Control of Urban Traffic Systems, 1979, Pacific Grove, California, USA. 1979: 12-27.

[20] Gartner N H, Tarnoff P J, Andrews C M. Evaluation of optimized policies for adaptive control strategy[J]. Transportation Research Record, 1991(1324).

[21] Gao J, Shen Y, Liu J, et al. Adaptive traffic signal control: deep reinforcement learning algorithm with experience replay and target network[EB/OL]. (2017-05-08) [2025-04-08]. https://arxiv.org/abs/1705.02755.

[22] Qin H, Zhang W. Short-Term Traffic Flow Prediction and Signal Timing Optimization Based on Deep Learning[J/OL]. Wireless Communications and Mobile Computing, 2022. https://onlinelibrary.wiley.com/doi/abs/10.1155/2022/8926445.

[23] Ding C, Zhu L, Shen L, et al. The intelligent traffic flow control system based on 6G and optimized genetic algorithm[J]. IEEE Transactions on Intelligent Transportation Systems, 2024. DOI: 10.1109/TITS.2024.3467269.

[24] Lin S, Xi Y. An efficient model for urban traffic network control[J]. IFAC Proceedings Volumes, 2008, 41(2): 14066-14071.

[25] Pedroso L, Batista P. Decentralized store-and-forward based strategies for the signal control problem in large-scale congested urban road networks[J]. Transportation Research Part C: Emerging Technologies, 2021, 132: 103412.

[26] Fu Q, Tian Y, Sun J. Modeling and simulation of dynamic lane reversal using a cell transmission model[J]. Journal of Intelligent Transportation Systems, 2022, 26(6): 717-729.

[27] Sun D, Jamshidnejad A, De Schutter B. A novel framework combining MPC and deep reinforcement learning with application to freeway traffic control[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(7): 6756-6769.

[28] 肖建力, 邱雪, 张扬, 等. 交通大模型综述[J]. 交通运输工程学报, 2025, 25(01): 8-28.

[29] 张奇. 多模式交通网络自动生成及交通流宏微观一体化仿真方法[D]. 东南大学, 2023.

中国知网 https://www.cnki.net

[30] Zhang T T, Jin P J, McQuade S T, et al. Car-following models: A multidisciplinary review[J]. IEEE Transactions on Intelligent Vehicles, 2024. DOI: 10.1109/TIV.2024.3409468.

[31] 邓建华, 冯焕焕, 葛婷. 智能跟驰交通元胞自动机模型[J/OL]. 复杂系统与复杂性科学, 2024. https://link.cnki.net/urlid/37.1402.N.20241104.0954.002.

[32] Ahmad F, Al-Fagih L. Game theory applications in micro and macroscopic simulations in transportation networks: a comprehensive review[J]. IEEE Access, 2023, 11: 93635-93663.

[33] Thonhofer E, Palau T, Kuhn A, et al. Macroscopic traffic model for large scale urban traffic network design[J]. Simulation Modelling Practice and Theory, 2018, 80: 32-49.

[34] Richalet J, Rault A, Testud J, et al. Model predictive heuristic control[J]. Automatica, 1978, 14(5): 413-428.

[35] Cutler C R. Dynamic matrix control: An optimal multivariable control algorithm with constraints[D]. University of Houston, 1983.

[36] Clarke D W, Mohtadi C, Tuffs P S. Generalized predictive control—Part I. The basic algorithm[J]. Automatica, 1987, 23(2): 137-148.

[37] Garcia C E, Prett D M, Morari M. Model predictive control: Theory and practice—A survey[J]. Automatica, 1989, 25(3): 335-348.

[38] Mayne D Q, Rawlings J B, Rao C V, et al. Constrained model predictive control: Stability and optimality[J]. Automatica, 2000, 36(6): 789-814.

[39] Richards A, How J P. Robust distributed model predictive control[J]. International Journal of control, 2007, 80(9): 1517-1531.

[40] Stewart B T, Venkat A N, Rawlings J B, et al. Cooperative distributed model predictive control[J]. Systems & Control Letters, 2010, 59(8): 460-469.

[41] Ellis M, Durand H, Christofides P D. A tutorial review of economic model predictive control methods[J]. Journal of Process Control, 2014, 24(8): 1156-1178.

[42] Mesbah A. Stochastic model predictive control: An overview and perspectives for future research[J]. IEEE Control Systems Magazine, 2016, 36(6): 30-44.

[43] Jamal A, Al-Ahmadi H M, Butt F M, et al. Metaheuristics for traffic control and optimization: Current challenges and prospects[M]. IntechOpen, 2021.

[44] Aboudolas K, Papageorgiou M, Kouvelas A, et al. A rolling-horizon quadratic-programming approach to the signal control problem in large-scale congested urban road networks[J]. Transportation Research Part C: Emerging Technologies, 2010, 18(5): 680-694.

[45] Lu K, Du P, Cao J, et al. A novel traffic signal split approach based on explicit model predictive control[J]. Mathematics and Computers in Simulation, 2019, 155: 105-114.

中国知网 https://www.cnki.net

[46] Han L, Zheng K, Zhao L, et al. Short-term traffic prediction based on deepcluster in large-scale road networks[J]. IEEE Transactions on Vehicular Technology, 2019, 68(12): 12301-12313.

[47] Chen J, Wang W, Yu K, et al. Node connection strength matrix-based graph convolution network for traffic flow prediction[J]. IEEE Transactions on Vehicular Technology, 2023, 72(9): 12063-12074.

[48] Todorović U, Frejo J R D, De Schutter B. Distributed MPC for large freeway networks using alternating optimization[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23(3): 1875-1884.

[49] Liu S, Sadowska A, De Schutter B. A scenario-based distributed model predictive control approach for freeway networks[J]. Transportation Research Part C: Emerging Technologies, 2022, 136: 103261.

[50] Yu H, Hou Z. Two-level hierarchical optimal control for urban traffic networks[J]. Transportmetrica A: transport science, 2022, 18(1): 144-165.

[51] Pham V H, Ahn H S. Distributed stochastic mpc traffic signal control for urban networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(8): 8079-8096.

[52] Haddad J, Ramezani M, Geroliminis N. Model predictive perimeter control for urban areas with macroscopic fundamental diagrams[C]. 2012 American Control Conference (ACC). 2012: 5757-5762.

[53] Zárate Flórez J, Martinez J, Besançon G, et al. Decentralized-coordinated model predictive control for a hydro-power valley[J]. Mathematics and Computers in Simulation, 2013, 91: 108-118.

[54] Portilla C, Valencia F, Espinosa J, et al. Model-based predictive control for bicycling in urban intersections[J]. Transportation research part C: emerging technologies, 2016, 70: 27-41.

[55] Hosseinzadeh M, Sinopoli B, Kolmanovsky I, et al. MPC-based emergency vehicle-centered multi-intersection traffic control[J]. IEEE Transactions on Control Systems Technology, 2022, 31(1): 166-178.

[56] Xia Y. From networked control systems to cloud control systems[C]. Proceedings of the 31st Chinese control conference. 2012: 5878-5883.

[57] Xia Y. Cloud control systems[J]. IEEE/CAA Journal of Automatica Sinica, 2015, 2(2): 134-142.

[58] Xia Y, Zhang Y, Dai L, et al. A brief survey on recent advances in cloud control systems[J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 2022, 69(7): 3108-3114.

[59] Skarin P, Eker J, Årzén K E. Cloud-based model predictive control with variable horizon[J]. IFAC-PapersOnLine, 2020, 53(2): 6993-7000.

[60] Kehoe B, Patil S, Abbeel P, et al. A survey of research on cloud robotics and automation[J]. IEEE Transactions on automation science and engineering, 2015, 12(2): 398-409.

[61] NASA Ames Research Center. What is Unmanned Aircraft Systems Traffic Management?[EB/OL]. (2021-05-27) [2025-04-06]. https://www.nasa.gov/centers-and-facilities/ames/what-is-unmanned-aircraft-systems-traffic-management/.

中国知网 https://www.cnki.net

[62] 夏元清. 云控制系统及其面临的挑战[J]. 自动化学报, 2016, 42(1): 1-12.

[63] Xia Y, Qin Y, Zhai D H, et al. Further results on cloud control systems[J]. Science China Information Sciences, 2016, 59: 1-5.

[64] Liu G P. Coordinated control of networked multiagent systems via distributed cloud computing using multistep state predictors[J]. IEEE Transactions on Cybernetics, 2020, 52(2): 810-820.

[65] Liu G P. Coordinated control of networked nonlinear multiagent systems using variable horizon learning predictors via cloud edge computing[J]. IEEE Transactions on Control of Network Systems, 2022, 9(4): 1975-1986.

[66] 谭浩然, 黄志武, 吴敏. 基于云控制系统的监控系统设计与实现[J]. 控制与决策, 2019, 34(8): 1688-1694.

[67] 李克强, 常雪阳, 李家文, 等. 智能网联汽车云控系统及其实现[J]. 汽车工程, 2021, 42(12): 1595-1605.

[68] 夏元清, 王晁, 高润泽, 等. 云网边端协同云控制研究进展及挑战[J]. 信息与控制, 2024, 53(3): 273-286.

[69] Jiang T, Zhang Y, Park J H, et al. Finite-time boundedness of networked control systems via hybrid predictive control based on cloud storage method[J]. Information Sciences, 2023, 622: 1092-1108.

[70] Dai L, Ma Y, Gao R, et al. Cloud-based computational model predictive control using a parallel multiblock ADMM approach[J]. IEEE Internet of Things Journal, 2023, 10(12): 10326-10343.

[71] Li P, Zhao Y B, Kang Y. Integrated channel-aware scheduling and packet-based predictive control for wireless cloud control systems[J]. IEEE Transactions on Cybernetics, 2020, 52(5): 2735-2749.

[72] 王殿海. 交通流理论[M]. 北京: 人民交通出版社, 2007.

[73] 凌太宇. 城市交通路网拥堵控制的递阶结构与仿真[D]. 上海交通大学, 2014.

[74] Lin S, De Schutter B, Xi Y, et al. Fast model predictive control for urban road networks via MILP[J]. IEEE Transactions on Intelligent Transportation Systems, 2011, 12(3): 846-856.

[75] Stoilova K, Stoilov T. Extensions to traffic control modeling store-and-forward[J]. Expert Systems with Applications, 2023, 233: 120950.

[76] 赵雪娟. 基于 MFD 和 MPC 的城市交通路网区域协调控制算法研究[D]. 北京交通大学, 2019.

[77] Geroliminis N, Daganzo C F. Existence of urban-scale macroscopic fundamental diagrams: Some experimental findings[J]. Transportation Research Part B: Methodological, 2008, 42(9): 759-770.

[78] Geroliminis N, Sun J. Properties of a well-defined macroscopic fundamental diagram for urban traffic[J]. Transportation Research Part B: Methodological, 2011, 45(3): 605-617.

[79] 席裕庚, 李德伟, 林姝. 模型预测控制——现状与挑战[J]. 自动化学报, 2013, 39(3): 222-236.

[80] 陈虹. 模型预测控制[M]. 北京: 科学出版社, 2013.

中国知网 https://www.cnki.net

[81] Gu W, Mei Y, Chen H, et al. An integrated intersection design for promoting bus and car traffic[J]. Transportation Research Part C: Emerging Technologies, 2021, 128: 103211.

[82] Wan J, Wang C, Bie Y. Optimal Traffic Control for a Tandem Intersection With Improved Lane Assignments at Presignals[J]. IEEE Intelligent Transportation Systems Magazine, 2023, 16(3): 53-69.

[83] Fu F, Xie J, Cai M, et al. A Bus-Service-Based Zone Division Approach for the Spatial Analysis of Public Bus: A Case Study in South China[J]. Journal of Advanced Transportation, 2024, 2024(1): 8681100.

[84] Wirasinghe S, Kattan L, Rahman M, et al. Bus rapid transit–a review[J]. International Journal of Urban Sciences, 2013, 17(1): 1-31.

[85] Xu T, Barman S, Levin M W, et al. Integrating public transit signal priority into max-pressure signal control: Methodology and simulation study on a downtown network[J]. Transportation Research Part C: Emerging Technologies, 2022, 138: 103614.

[86] 殷梦洁. 有无专用道的公交车停靠站时间预测研究[D]. 长安大学, 2020.

[87] Geroliminis N, Haddad J, Ramezani M. Optimal perimeter control for two urban regions with macroscopic fundamental diagrams: A model predictive approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2012, 14(1): 348-359.

[88] Zhou Z, De Schutter B, Lin S, et al. Two-level hierarchical model-based predictive control for large-scale urban traffic networks[J]. IEEE Transactions on Control Systems Technology, 2016, 25(2): 496-508.

[89] Gao S, Li D, Zheng N, et al. Resilient perimeter control for hyper-congested two-region networks with MFD dynamics[J]. Transportation Research Part B: Methodological, 2022, 156: 50-75.

[90] Jalil K, Chen Q, Zahid M N, et al. Machine Learning-Driven Traffic Flow Prediction Using Cloud Control Big Data Analysis[C]. 2024 10th International Conference on Virtual Reality (ICVR). 2024: 396-401.

[91] Zhang L, Zhou Z, Yi B, et al. Edge-Cloud Framework for Vehicle-Road Cooperative Traffic Signal Control in Augmented Internet of Things[J]. IEEE Internet of Things Journal, 2025, 12(5): 5488-5499.

[92] Zhao J, Ma Y, Dai L, et al. Cloud-Edge Cooperative Distributed MPC With Event-Triggered Switching Strategy for Heterogeneous Vehicle Platoon[J]. IEEE Transactions on Vehicular Technology, 2024, 73(10): 14425-14437.

中国知网 https://www.cnki.net