面向高速端到端视觉避障的 ViT+Mamba 时序建模与流式部署一致性分析

戴英特，沈俊楠，甘明刚*
北京理工大学，北京，100081
E-mail: daiyingte@gmail.com

摘要： 高速四旋翼在密集障碍环境中的自主飞行对感知与控制提出了极高要求：随着速度增加，观测噪声、执行延迟与建模误差会被放大，传统模块化“感知–规划–控制”流水线易在极限工况下失效。端到端视觉控制为该问题提供了新的途径，但其性能高度依赖时序信息的建模能力以及流式部署时的状态一致性。本文面向高速端到端避障控制任务，提出一种 ViT+Mamba 策略网络：利用视觉 Transformer 提取空间表征，并以选择性状态空间序列模型 Mamba 进行时序聚合，从单目深度观测与轻量状态直接输出世界坐标系下的速度指令。我们在 Spheres（同分布）与 Trees（异分布）两类环境中，针对 3/5/7/9/12 m/s 五档速度、每档 10 次试验进行系统评测，结果表明 ViT+Mamba 相比 ViT+LSTM 基线在高速段显著降低碰撞率与碰撞事件次数，且在异分布环境中仍保持优势。进一步地，我们分析发现流式推理中的错误状态重置会使序列模型退化为“无记忆”策略并引发系统性漂移，从而污染评测与部署；为此本文实现了回合边界级的状态管理与硬防护机制，确保实验可复现与结果可信。最后，针对 ViT+Mamba 更敏捷响应带来的指令抖动（Command Jerk）代价，我们引入部署端风险自适应指令变化约束（RACS）作为补充，在尽量保持安全性优势的同时有效降低 jerk。
关键词： 四旋翼；端到端控制；视觉避障；Transformer；Mamba；流式推理；指令抖动

ViT+Mamba for High-Speed End-to-End Vision-Based Quadrotor Obstacle Avoidance: Temporal Modeling and Streaming Deployment Consistency

Dai Yingte, Shen Junnan, Gan Minggang*
Beijing Institute of Technology, Beijing 100081, China
*Corresponding author: Gan Minggang, E-mail: agan@bit.edu.cn

Abstract: High-speed quadrotor obstacle avoidance in cluttered environments is challenging due to amplified sensing noise, execution latency, and modeling errors, which often degrade modular perception–planning–control pipelines. End-to-end vision-based control is a promising alternative, yet its performance critically depends on temporal modeling and streaming deployment consistency. This paper presents a ViT+Mamba policy that combines a vision transformer encoder with a selective state-space sequence model to map monocular depth observations and lightweight state inputs to world-frame velocity commands. We evaluate the proposed approach on Spheres (in-distribution) and Trees (out-of-distribution) across five forward speeds (3/5/7/9/12 m/s) with 10 trials per speed. Results show that ViT+Mamba substantially reduces collision frequency and collision-event counts compared with a ViT+LSTM baseline, especially in the high-speed regime, while maintaining robustness under distribution shift. We further identify that incorrect step-wise state resets during streaming inference can degenerate sequence models into memoryless policies, causing systematic drift and misleading evaluation; we therefore enforce episode-level state management with hard safeguards to ensure reliable deployment and reproducible benchmarking. Finally, to mitigate the increased command jerk induced by more responsive temporal modeling, we incorporate a lightweight deployment-time risk-adaptive command shaping module (RACS), which reduces jerk while largely preserving safety gains.
Key Words: quadrotor; end-to-end control; obstacle avoidance; vision transformer; Mamba; streaming inference; command jerk

1 引言

高速四旋翼在密集障碍环境中的自主飞行对感知与控制的实时性提出了严峻挑战。随着飞行速度增加，空气动力学效应、观测噪声与系统延迟在闭环中被显著放大，导致传统“感知–规划–控制”模块化管线在极限工况下的鲁棒性急剧下降。端到端视觉控制 [1] 通过将高维视觉观测直接映射为控制指令，规避了显式建图与规划的延迟瓶颈，已成为高速避障的重要研究方向。

然而，现有端到端方法主要依赖 LSTM [2] 处理时序信息，存在两方面局限：一是 LSTM 在处理长序列时存在梯度消失风险，且在流式推理（Streaming Inference）中，训练时的全序列模式与部署时的逐步更新模式存在状态管理差异，易导致“无记忆”退化与控制漂移；二是高响应的端到端模型往往输出高频

抖动的速度指令（Command Jerk），影响电机寿命与飞行平滑性。

为此，本文提出 ViT+Mamba 端到端策略，利用 Mamba [3] 的选择性状态空间（Selective Scan）特性替代 LSTM，在保持线性计算复杂度的同时提升时序建模能力。本文的主要贡献如下：

1. 提出 ViT+Mamba 高速避障策略，在 3–12 m/s 的多档速度评测中，相比 ViT+LSTM 基线显著降低了碰撞率与碰撞事件次数；
2. 系统分析了序列模型在流式部署中的状态一致性问题，揭示了错误状态重置导致的系统性漂移，并实现了严格的回合级状态管理；
3. 针对高敏捷性带来的指令抖动，引入部署端风险自适应指令约束（RACS），以微小的计算代价在保持安全性的前提下有效提升了控制平滑性。

2 相关工作

2.1 端到端视觉飞行控制

端到端学习通过将原始感知数据直接映射到控制指令，简化了复杂的模块化管线，在高速无人机控制中展现出显著潜力。Loquercio 等人 [1] 早期展示了通过域随机化技术实现从仿真到现实（Sim-to-Real）的无人机竞速迁移。随着深度强化学习的发展，Kaufmann 等人 [4] 近期实现了能够击败人类冠军的端到端无人机竞速系统，标志着该领域的重大突破。然而，相比于竞速场景，在非结构化密集障碍环境中的高可靠性避障仍是一个挑战，特别是如何有效处理感知不确定性与动态障碍 [5,6]。

2.2 视觉 Transformer 与时序建模

视觉 Transformer (ViT) [7] 凭借其强大的全局特征提取能力，已在计算机视觉领域逐渐取代传统 CNN。在机器人控制中，ViT 也被用于提取更鲁棒的环境表征。Bhattacharya 等人 [2] 首次系统地将 ViT 引入四旋翼端到端避障，提出了 ViT+LSTM 架构，证明了其在高速场景下优于 ResNet 等卷积架构。然而，其时序部分仍依赖 LSTM，存在长序列计算瓶颈与梯度消失风险。

另一方面，结构化状态空间模型（SSMs）如 S4 [8] 和 Mamba [3] 近期引起了广泛关注。Mamba 引入选择性扫描机制（Selective Scan），在保持线性计算复杂度的同时实现了媲美 Transformer 的时序建模能力 [9,10]。本文旨在探究 Mamba 在高频闭环控制中的特性，特别是其替代 LSTM 处理流式观测序列的优势。

2.3 控制安全性与部署一致性

在学习型控制的实际部署中，安全性是一个核心考量。安全强化学习 [11] 和基于控制障碍函数（CBF）的方法 [12] 试图在训练中施加约束。另一类方法是采用预测安全滤波器 [13]，在策略输出后进行修正。本文提出的 RACS 属于后处理平滑策略，旨在解决高响应模型带来的指令抖动问题。此外，序列模型在训练（Batch）与推理（Streaming）模式下的状态管理差异常导致性能退化，这一点在自然语言处理中已有讨论，但在机器人端到端控制中鲜有系统分析。

3 问题定义

3.1 任务与回合终止条件

本文研究四旋翼在三维密集障碍环境中的高速视觉避障任务。评测环境包含两类障碍分布：Spheres（随机球体障碍，同分布环境）与 Trees（树状结构障碍，异分布环境）。每个回合（Trial）的终止目标设定为无人机沿 X 轴飞行距离超过 58–60 米（到达终点线）。此外，系统设置 40 秒的硬性时间上限（Timeout），若在此时间内未到达终点，或因碰撞导致严重停滞而无法继续有效前进，则回合因超时而终止。

需要强调的是：碰撞不会立即终止回合，碰撞标志在整个回合持续记录，用于统计全程尺度的碰撞频率与碰撞事件次数。

3.2 观测、轻量状态与控制输出

在时间步 t，策略输入由深度图像与轻量状态组成。深度观测为单目深度图像 D_t（单位：米）。轻量状态为 $s_t = [q_t, \tilde{v}^{target}]$，其中 q_t 为单位四元数，采用 $[w, x, y, z]$ 排列顺序，表示无人机在世界坐标系下的实时姿态；$\tilde{v}^{target}$ 为目标前向速度的归一化输入，采用线性缩放 $\tilde{v}^{target} = v^{target}/10$。模型不直接输入无人机实时速度，而是以目标速度作为条件输入，结合视觉观测与姿态信息学习在障碍环境中维持目标速度并完成避障。

策略在每个控制周期输出世界坐标系下的三维线速度指令 $\mathbf{v}_t = [v_t^x, v_t^y, v_t^z]$。采用 world frame 输出与控制基线保持一致，从而保证 ViT+Mamba 与 ViT+LSTM 在同一控制语义下公平比较。

3.3 评价指标

(1) Collision Rate（全程碰撞率）：定义为回合内碰撞帧数占回合总帧数的比例，用于度量碰撞接触在整个飞行过程中的频繁程度/持续时间。(2) Collision Count（碰撞事件次数）：将连续碰撞帧视为同一次事件，统计碰撞标志从 0 变为 1 的上升沿次数，用于刻画碰撞事件的发生次数。(3) Command Jerk：用于衡量指令平滑性，定义为相邻两步发布速度指令之差的范数，并报告回合内平均值及跨回合统计量。此外，我们记录推理时间与控制周期分布用于排除系统负载差异造成的混淆因素。

4 方法

4.1 总体框架与控制回路

本文采用端到端视觉控制框架：在每个控制周期，策略接收单目深度图像与轻量状态输入，输出世界坐标系下的三维速度指令，由仿真器/低层控制器执行并更新无人机状态。系统以流式方式运行，每一步使用当前观测推理，并在内部维护时序状态以利用短时历史信息。整体系统流程如图 1 所示。

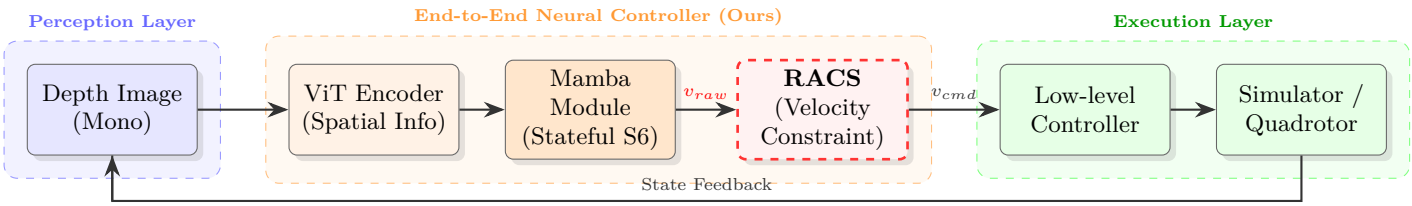

图 1 端到端导航管线概览。深度图经由 ViT 编码器和 Mamba 时序模块处理生成原始速度指令；RACS 模块作为部署端约束，在执行前对指令进行平滑与限幅。

4.2 学习框架：行为克隆

本文采用行为克隆（Behavioral Cloning）训练策略网络。示范数据由带特权信息的专家策略生成：专家在每个时间步可访问无人机状态以及一定局部范围内的障碍物几何信息，并在无人机前方固定视距处的横向–竖向平面（y–z 平面）离散采样候选航点；对每个候选航点执行从当前位置到该航点的直线碰撞检测，选择最接近网格中心的无碰撞航点，并对相对位移施加比例增益生成世界坐标系下的三维线速度指令作为监督信号。训练数据集包含约 585 条专家轨迹。学生策略以 (D_t, s_t) 为输入回归专家速度指令。为验证泛化能力，所有策略网络仅在 Spheres 环境生成的专家数据上训练，并在 Trees 环境中进行零样本（Zero-shot）测试。

4.3 策略网络结构：ViT+Mamba

本文策略采用“空间编码 + 时序聚合 + 控制头”的结构。视觉编码器采用 2-stage ViT 架构：第一阶段 Patch Size 为 7×7（Stride 4），第二阶段为 3×3（Stride 2），特征通道由 32 升至 64，最终映射为 512 维视觉特征向量。该轻量化设计将输入深度图（60×90）高效压缩，适应高速飞行的实时性要求。

时序模块包含 4 层 Mamba（选择性状态空间序列模型），配置为模型维度 $d_{model} = 192$，状态维度 $d_{state} = 64$，卷积核大小 $d_{conv} = 4$ 及扩展因子 4。Mamba 融合了视觉特征与四元数姿态、归一化目标速度，通过状态传播形式维护内部时序状态。相比 LSTM，该配置在保持线性计算复杂度的同时，更深层地捕获了高速飞行中的动态关联。ViT+Mamba 模型的总参数量约为 3.50M。

4.4 流式部署一致性：状态管理与安全防护

训练阶段常以定长序列进行前向计算，而部署阶段以逐步推理方式运行。若在工程实现中错误地在每个控制步重置序列模型状态，时序模型将退化为近似无记忆策略，导致控制漂移与安全性能显著下降。为保证流式推理与训练语义一致，本文显式实现并强制执行序列模型状态的生命周期管理：(1) 回合级重置：仅在回合边界（仿真器 reset 信号触发）重置 Mamba/LSTM 状态；(2) 回合内状态连续传播：同一回合内状态跨步传播以保留短时记忆；(3) 硬故障拦截：对每步重置等非安全模式在未开启调试开关时直接报错终止；(4) 配置可追溯：将请求配置与实际生效配置写入评测日志，确保实验可审计与可复现。本文所有主结果均在状态一致的流式推理下获得，从而将性能差异归因于模型能力而非实现细节。

4.5 部署端指令平滑补充：RACS

我们观察到 ViT+Mamba 在高速段显著降低碰撞，但由于更敏捷的时序响应，速度指令变化幅度（Command Jerk）可能高于基线。本文引入部署端轻量指令平滑模块 RACS（Risk-Adaptive Command Shaping）。在本文的工程实现中，该模块被设计为一个严格的动态速率限制器（Strict Dynamic Rate Limiter）。与传统静态限幅不同，它根据实时飞行状态动态调整允许的速度变化率边界 δ_t，通过硬约束 $\|\mathbf{v}_{cmd} - \mathbf{v}_{prev}\|_2 \leq \delta_t$ 在不牺牲敏捷性的前提下有效抑制 Mamba 输出的高频抖动。这一实现以极低的计算开销（<0.1ms）换取了控制平滑性的显著提升。

5 实验设置

5.1 仿真平台与环境

本文所有实验在 Flightmare [14] 高保真仿真平台中完成。我们采用两类标准障碍环境进行评测：(1) **Spheres**：随机分布的球体障碍，作为同分布测试环境；(2) **Trees**：树状结构障碍，作为异分布测试环境，用于检验方法的泛化能力。

5.2 评测协议（速度档位、试验次数与终止规则）

我们在五个目标前向速度档位上系统评测：3、5、7、9、12 m/s。对于每个环境、每个速度档位，执行 10 次独立试验（trials）。每个回合（Trial）以“到达终点线”为主要终止条件：无人机沿 X 轴前向飞行距离超过 58–60 m 即判定到达终点并终止回合。此外，系统设置 **40 s** 的时间上限（Timeout），若在该时间内未到达终点，则回合因超时而终止。

5.3 实施细节与训练配置

所有模型均在单张 NVIDIA RTX 4060 GPU 上训练。网络输入处理包括：将深度图调整为 60×90 分辨率并进行归一化（scale factor 0.09），同时引入高斯噪声（$\sigma = 0.02$）与随机亮度（±10%）增强以提升鲁棒性。

训练采用 AdamW 优化器，基础学习率设为 1×10^{-4}，权重衰减为 1×10^{-4}，并配合 15 epochs 的线性预热（Warmup）。训练序列长度截断为 150 步，前 20 步作为 Burn-in 阶段不计算梯度。为了平衡模仿精度与控制平滑性，我们采用了三阶段课程学习策略来调节辅助损失（Jerk Loss）的权重：前 30 epochs 仅优化速度跟踪误差（MSE），30–70 epochs 线性增

加 Jerk 惩罚权重，70–100 epochs 保持权重恒定。详细超参数配置如表 1 所示。

表 1 策略网络训练超参数配置

参数 (Parameter)	数值 (Value)
Training Setup	
Optimizer	AdamW
Learning Rate	1×10^{-4} (Linear Warmup)
Weight Decay	1×10^{-4}
Batch Size	1 (Trajectory-level)
Total Epochs	100
Gradient Clip	1.0
Sequence Modeling	
Training Seq. Length	150 steps
Burn-in Steps	20 steps
Input Resolution	60×90
Data Augmentation	Noise ($\sigma = 0.02$), Brightness ($\pm 10\%$)

5.4 输入输出与坐标系约定

策略输入由单目深度图像与轻量状态组成。轻量状态定义为 $s_t = [q_t, \tilde{v}^{target}]$，其中 q_t 为单位四元数。策略输出为三维线速度命令 $\mathbf{v}_t = [v_t^x, v_t^y, v_t^z]$，并在世界坐标系（world frame）下表达。

5.5 对比方法（Baselines）

(1) **ViT+LSTM（Baseline）**：视觉编码采用 ViT，时序模块为 3 层 LSTM；(2) **ViT+Mamba（Ours）**：将时序模块替换为 4 层 Mamba；(3) **ViT+Mamba + RACS**：在 ViT+Mamba 基础上加入部署端速度变化约束。

5.6 评价指标（Metrics）

本文采用如下指标衡量安全性与平滑性：

- **Collision Rate（全程碰撞率）**：定义为碰撞帧数占全部帧数的比例。
- **Collision Count（碰撞事件次数）**：统计碰撞标志从 0 变为 1 的上升沿次数。
- **Command Jerk（指令抖动）**：定义为相邻两帧发布速度指令的一阶差分范数 $\|\mathbf{v}_t - \mathbf{v}_{t-1}\|_2$。若启用 RACS，则以最终发布并执行的速度指令计算 jerk，以反映真实控制平滑性。
- **Inference Time（推理时间）**：记录单步模型前向推理耗时。

5.7 统计与报告方式

对每个速度档位与环境下的 10 次试验，我们报告各指标的均值。

6 结果与分析

6.1 ViT+Mamba 相对 ViT+LSTM 的高速安全性提升（主结果）

我们首先在 Spheres（同分布）与 Trees（异分布）两类环境中进行评测。图 2 汇总了不同速度下的全程碰撞率与碰撞事件次数。总体来看，ViT+Mamba 在两类环境、尤其是高速档位（9–12 m/s）下呈现更优的安全性：全程碰撞率与碰撞事件次数均明显低于 ViT+LSTM 基线，且在 Trees 环境中仍保持优势，表明该改进并非仅对同分布场景有效。

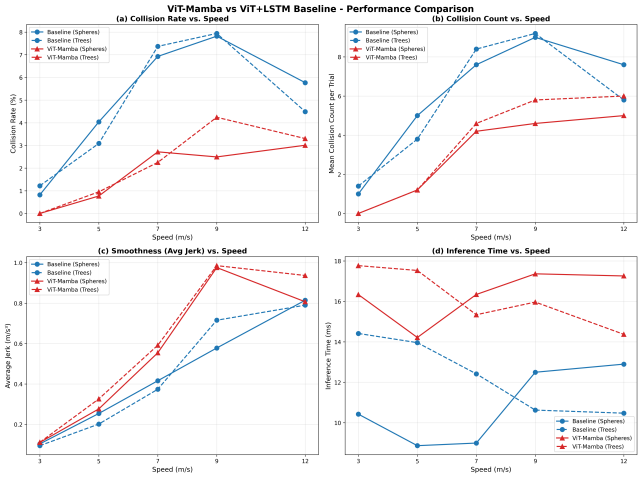

图 2 ViT+Mamba 与 ViT+LSTM 基线在 Spheres/Trees 环境下的性能对比。(a) 全程碰撞率（碰撞帧占比）随速度变化；(b) 碰撞事件次数随速度变化；(c) Command Jerk 随速度变化；(d) 单步推理时间随速度变化。

6.2 平滑性代价：更敏捷的时序响应带来更高的 Command Jerk

尽管 ViT+Mamba 在安全性指标上取得显著收益，我们观察到其 Command Jerk 在中高速段整体高于 LSTM 基线（见图 2(c)）。这表明更强的时序响应能力可能伴随更激进的指令变化。

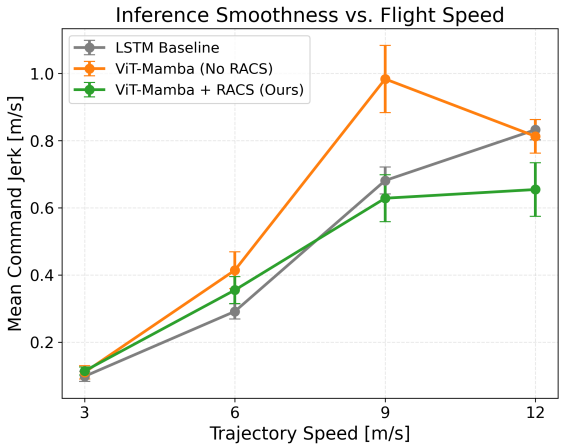

图 3 不同方法的 Command Jerk 随速度变化趋势（误差条表示跨试验离散程度）。该图用于更清晰地展示平滑性代价与补救效果。

6.3 RACS：部署端风险自适应指令变化约束对 jerk 的改善

为缓解 ViT+Mamba 在高速下的指令抖动代价，我们引入 RACS 模块。实验结果（图 4）显示，RACS 在多数速度档位能够显著降低 Command Jerk，相比不使用平滑的 Mamba（No RACS）具有稳定改善；同时，其安全性指标整体仍保持在较低水平。

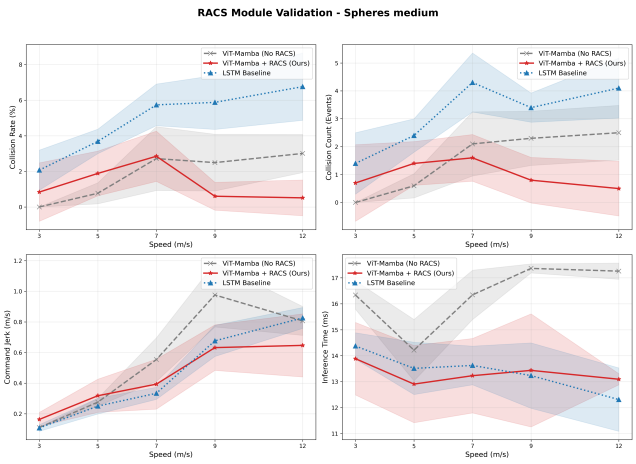

图 4 RACS 在 Spheres_medium 场景下的验证结果。图中对比了 Mamba No RACS、Mamba + RACS（Ours）以及基线方法在不同速度下的安全性与平滑性。

6.4 流式状态一致性分析：错误重置会导致无记忆退化与系统性漂移

图 5 给出了 KeepState（回合内连续传播）与 ResetState（每步重置）下的横向漂移可视化对比。ResetState 会引发显著的横向漂移趋势。

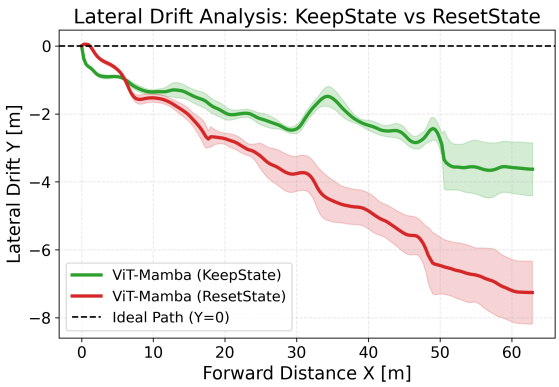

图 5 流式推理中 KeepState 与 ResetState 的漂移对比可视化。ResetState（每步重置）会导致显著的横向漂移趋势，反映出时序模型在无记忆退化下的闭环不稳定行为。

为量化该现象，我们在表 2 中给出消融结果。每步重置会显著提高碰撞发生概率（全程碰撞率从 0% 上升至 90%），并产生系统性漂移（平均横向漂移达到 0.77 m）。本文将横向漂移定义为回合内横向位置绝对值的时间平均：

$$\text{Mean Y Drift} = \frac{1}{T}\sum_{t=1}^{T}|y_t|$$

该指标用于刻画回合内持续性的横向偏离程度。注意，Mean Y Drift 以米（m）为单位统计，0.77 m 的平均横向偏移已足以显著增加擦碰/碰撞风险。

表 2 流式状态管理消融（KeepState vs ResetState）。表中给出全程碰撞率、平均 jerk 与横向漂移统计。

模式	Collision Rate (%)	Mean Jerk (m/s)	Mean Y Drift (m)
Mamba (KeepState)	0.0	0.198	0.022
Mamba (ResetState)	90.0	0.376	0.770

6.5 系统时序一致性：控制周期抖动的统计与对齐

为排除系统负载差异造成的混淆因素，我们记录控制循环周期 Δt 的统计分布，见图 6。

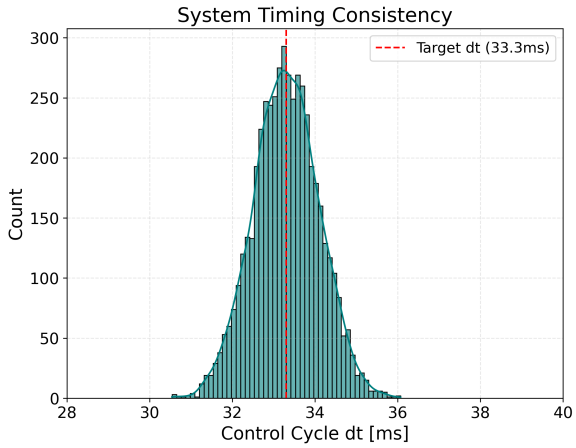

图 6 控制循环周期 Δt 的分布统计，用于检验不同方法的系统时序一致性并排除负载差异造成的混淆因素。

7 讨论

本文结果表明，在高速端到端避障控制中，时序建模能力与流式部署一致性是决定闭环安全性的关键因素。同时，本文也揭示了流式部署中的一个关键风险：若在工程实现中错误地在每个控制步重置序列模型状态，时序模型会退化为近似无记忆策略，并在闭环中产生系统性漂移。

关于平滑性方面，ViT+Mamba 更敏捷的时序响应可能引入更高的指令抖动（Command Jerk）。本文引入 RACS 作为部署端补充模块，通过轻量的指令变化约束在不修改训练过程的前提下降低 jerk，并在一定程度上维持 Mamba 的安全性优势。

8 结论

本文面向高速端到端视觉避障控制任务，提出 ViT+Mamba 策略框架，系统评测表明，相比 ViT+LSTM 基线，ViT+Mamba 在 Spheres 与 Trees 环境中，尤其在高速档位显著降低全程碰撞率与碰撞事件次数。进一步地，本文通过消融分析证明：流式推理中的状态一致性对序列模型闭环稳定性至关重要，错误的逐步重置会导致无记忆退化与系统性漂移。最后，针对 Mamba 更敏捷响应带来的 jerk 代价，本文引入部署端 RACS 约束作为补充，有效改善指令平滑性。

参考文献

[1] LOQUERCIO A, KAUFMANN E, RANFTL R, et al. Deep drone racing: From simulation to reality with domain randomization[J]. IEEE Transactions on Robotics, 2019, 36(1): 1–14.

[2] BHATTACHARYA A, RAO N, PARIKH D, et al. Vision transformers for end-to-end vision-based quadrotor obstacle avoidance[C] //2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 1–8.

[3] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.

[4] KAUFMANN E, BAUERSFELD L, LOQUERCIO A, et al. Champion-level drone racing using deep reinforcement learning[J]. Nature, 2023, 620(7976) : 982 – 987.

[5] XIAO X, LIU B, WARNELL G, et al. Motion planning with hybrid topology for autonomous navigation in dynamic environments[C] // 2020 IEEE International Conference on Robotics and Automation (ICRA). 2020 : 3607 – 3613.

[6] ZHOU B, PAN J, GAO F, et al. Raptor: Robust and perception-aware trajectory replanning for quadrotor fast flight[J]. IEEE Transactions on Robotics, 2021, 37(6) : 1992 – 2009.

[7] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C] // International Conference on Learning Representations (ICLR). 2021.

[8] GU A, GOEL K, RÉ C. Efficiently modeling long sequences with structured state spaces[C] // International Conference on Learning Representations (ICLR). 2022.

[9] SMITH J T, WARRINGTON A, LINDERMAN S W. Simplified state space layers for sequence modeling[J]. arXiv preprint arXiv:2303.03982, 2023.

[10] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[11] BRUNKE L, GREEFF M, HALL A W, et al. Safe learning in robotics: From learning-based control to safe reinforcement learning[J]. Annual Review of Control, Robotics, and Autonomous Systems, 2022, 5 : 411 – 444.

[12] CHENG R, OROSZ G, MURRAY R M, et al. End-to-end safe reinforcement learning through barrier functions for safety-critical continuous control tasks[C] // Proceedings of the AAAI Conference on Artificial Intelligence : Vol 33. 2019 : 3387 – 3395.

[13] WABERSICH K P, ZEILINGER M N. Linear model predictive safety certification for learning-based control[C] // 2019 IEEE 58th Conference on Decision and Control (CDC). 2019 : 7130 – 7135.

[14] SONG Y, NAJI S, KAUFMANN E, et al. Flightmare: A flexible quadrotor simulator[C] // Conference on Robot Learning (CoRL). 2021 : 1147 – 1157.